ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO BÀI TẬP

Môn: Cách tiếp cận hiện đại trong xử lý ngôn ngữ tự nhiên

Phân loại chủ đề tin tức tiếng Việt với SVM, Logistic Regression, LSTM và PhoBERT

Dữ liệu – Mô hình – Ứng dụng

CO5087 – Học kỳ 261 (2026–2027)

Giảng viên: Lê Thành Sách, Nguyễn Quốc Minh

Thực hiện

Đặng Nguyễn Tấn Tài 2570357

Lớp: CH01

Thành phố Hồ Chí Minh, 10/2026

Tóm tắt

Báo cáo nghiên cứu bài toán phân loại tin tức tiếng Việt vào một trong 20 chuyên mục của VietNamNet dựa trên tiêu đề và nội dung bài báo. Nhãn tham chiếu được xác định từ chuyên mục xuất bản; mỗi bài có một nhãn chính dù nội dung có thể đề cập nhiều lĩnh vực. Quy trình gồm thu thập và làm sạch dữ liệu, tiền xử lý tiếng Việt, xây dựng mô hình và đánh giá trên tập kiểm tra độc lập.

Bốn phương pháp được khảo sát là SVM, Logistic Regression (LR), LSTM hai chiều (BiLSTM) và PhoBERT. Chúng đại diện cho ba hướng: đặc trưng từ vựng TF–IDF, học biểu diễn theo chuỗi và sử dụng mô hình ngôn ngữ tiền huấn luyện. Các phương pháp được đánh giá trên cùng tập kiểm tra; việc chọn cấu hình, bản lưu mô hình và tham số hiệu chỉnh chỉ sử dụng tập xác thực. Macro-F1 của PhoBERT, SVM, LR và BiLSTM lần lượt đạt 87.22%, 85.33%, 84.98% và 84.60%. Phân tích theo chuyên mục cho thấy phương pháp đứng đầu tổng thể không nhất thiết tốt nhất ở mọi lớp.

Ngoài chất lượng phân loại, báo cáo xem xét các bài dự đoán sai, độ tin cậy của xác suất và chi phí tính toán. Kết quả cho thấy SVM là đối chứng mạnh với thời gian huấn luyện ngắn trên CPU, còn PhoBERT đạt chất lượng tổng thể cao hơn trong điều kiện thực nghiệm. Kết luận được giới hạn ở nguồn dữ liệu và các cấu hình đã khảo sát, chưa khẳng định thứ hạng trên mọi nguồn tin hoặc mọi lần huấn luyện. Ứng dụng hỗ trợ biên tập dùng PhoBERT để đề xuất nhãn, cho phép rà soát và lưu phản hồi, được trình bày ở phụ lục.

Danh mục thuật ngữ

Thuật ngữ	Ý nghĩa trong báo cáo
Tập dữ liệu (corpus)	Tập bài báo cùng nhãn chuyên mục và thông tin nguồn, dùng để huấn luyện hoặc đánh giá.
Hệ thống chuyên mục (taxonomy)	Danh sách nhãn và quan hệ mục cha–con theo cách tổ chức của tòa soạn.
Loại bỏ bài trùng lặp	Chỉ giữ một đại diện khi nhiều bản ghi có cùng văn bản; loại cả nhóm nếu văn bản giống nhau nhưng nhãn mâu thuẫn.
Rò rỉ dữ liệu	Thông tin của tập đánh giá tham gia vào quá trình học hoặc lựa chọn mô hình, khiến kết quả đánh giá có thể cao hơn thực tế.
Train / validation / test	Tập huấn luyện / tập xác thực để chọn cấu hình / tập kiểm tra cuối.
Phân tầng	Chia dữ liệu sao cho tỷ lệ các chuyên mục trong mỗi tập gần tỷ lệ của toàn bộ dữ liệu.
Seed	Giá trị khởi tạo bộ sinh số ngẫu nhiên, dùng để tái tạo phép chia hoặc lấy mẫu.
Phân đoạn từ	Xác định từ tiếng Việt gồm một hoặc nhiều âm tiết; ví dụ trẻ_em.
Token / subword	Đơn vị đầu vào của mô hình; subword là đơn vị nhỏ hơn từ hoặc bằng từ, tùy cách mã hóa.
Từ dừng (stopword)	Các từ thường gặp được loại khi tạo đặc trưng cho SVM/LR, theo danh sách cố định.
TF–IDF	Biểu diễn văn bản bằng tần suất từ, giảm trọng số của từ xuất hiện trong nhiều tài liệu.
SVM	Máy vector hỗ trợ; trong báo cáo dùng bộ phân loại tuyến tính học ranh giới giữa các lớp.
Logistic Regression	Hồi quy logistic, viết tắt LR; bộ phân loại tuyến tính tối ưu mất mát logarit.
LSTM / BiLSTM	Mạng hồi tiếp có bộ nhớ / biến thể xử lý chuỗi theo cả chiều xuôi và chiều ngược.
Embedding	Vector số biểu diễn một từ hoặc một token; có thể được học từ dữ liệu huấn luyện.
BPE	Cách mã hóa chuỗi thành các đơn vị subword dùng trong tokenizer PhoBERT.
Head–Tail	Giữ phần đầu và phần cuối khi chuỗi vượt giới hạn đầu vào của mô hình.
Fine-tuning	Huấn luyện điều chỉnh mô hình tiền huấn luyện cho bài toán phân loại chuyên mục.
Bản lưu mô hình	Bản lưu trọng số mô hình tại một thời điểm huấn luyện, dùng để lựa chọn hoặc nạp lại.
Logits	Các điểm số chưa chuẩn hóa do mô hình tạo ra, chưa phải xác suất.

Thuật ngữ	Ý nghĩa trong báo cáo (tiếp theo)
Argmax	Chọn lớp có điểm số lớn nhất trong các lớp được xét.
Softmax	Biến đổi các điểm số thành các xác suất lớp có tổng bằng 1.
Precision / recall	Độ chính xác của các bài được dự đoán vào một lớp / tỷ lệ bài thuộc lớp đó được nhận ra.
Support	Số bài có nhãn tham chiếu thuộc một lớp trong tập đánh giá.
Macro-F1 / Weighted-F1	Trung bình F1 với các lớp có trọng số bằng nhau / trọng số theo số bài của từng lớp.
NLL	Mất mát logarit âm của xác suất nhãn tham chiếu, không dùng trọng số lớp trong bước hiệu chỉnh.
ECE	Sai lệch giữa độ tin cậy trung bình và tỷ lệ dự đoán đúng trong các khoảng xác suất.
Temperature scaling	Hiệu chỉnh xác suất bằng một tham số dương T chia logits trước soft-max.
Hệ số điều chỉnh lớp	τ_c dùng trong điểm quyết định $p_c(T)/\tau_c$; khác trọng số lớp khi huấn luyện.
Độ tin cậy (confi-dence)	Xác suất của nhãn được chọn theo quy tắc quyết định đã công bố.
Bootstrap ghép cặp	Lấy mẫu có hoàn lại cùng các bài cho các mô hình, nhằm ước lượng mức dao động của chênh lệch chỉ số.
Ablation	Thí nghiệm thay đổi hoặc bỏ một thành phần, giữ các điều kiện khác để xét ảnh hưởng riêng của thành phần đó.

Mục lục

Tóm tắt **i**

Danh mục thuật ngữ **ii**

1 Bài toán và thiết kế đánh giá **1**

1.1 Bối cảnh và phát biểu bài toán 1

1.2 Mục tiêu nghiên cứu và phạm vi 1

1.3 Nguyên tắc tổ chức dữ liệu và đánh giá 2

2 Tổng quan nghiên cứu và lựa chọn phương pháp **3**

2.1 Các hướng biểu diễn trong phân loại văn bản 3

2.2 Phương pháp tuyến tính trên đặc trưng từ vựng 3

2.3 Mạng hồi tiếp và vector biểu diễn từ 4

2.4 PhoBERT và mô hình tiền huấn luyện 4

2.5 Tổng hợp các công trình và cơ sở so sánh bốn phương pháp 5

2.5.1 Lựa chọn ba họ biểu diễn 6

2.5.2 Giới hạn của nghiên cứu liên quan và nguyên tắc đối chứng 6

3 Tập dữ liệu VietNamNet và tiền xử lý tiếng Việt **8**

3.1 Thu thập, xác minh chuyên mục và tạo tập dữ liệu 8

3.1.1 Thuật toán xác định chuyên mục cấp bài 9

3.1.2 Đơn vị quan sát và chất lượng nhãn 10

3.2 Phân bố nhãn, mất cân bằng và chia tập 11

3.3 Ghép văn bản, chuẩn hóa và phân đoạn từ 13

3.4 Độ dài đầu vào và tác động của giới hạn token 15

3.5 Loại bỏ bài trùng lặp, phòng ngừa rò rỉ dữ liệu và giới hạn dữ liệu 16

4 Biểu diễn và kiến trúc bốn phương pháp **17**

4.1 TF–IDF và hai bộ phân loại tuyến tính 17

4.1.1 Từ tần suất đến vector thưa 17

4.1.2 SVM tuyến tính và Logistic Regression 18

4.1.3 Đặc trưng học được và giới hạn diễn giải 18

4.2 Biểu diễn chuỗi và kiến trúc BiLSTM 19

4.2.1 Từ vựng, từ ngoài từ vựng và Head–Tail . . . 20
4.2.2 Cơ chế cổng và trạng thái chuỗi . . . 20
4.2.3 Trạng thái hai chiều và đầu phân loại . . . 21
4.3 PhoBERT, BPE và Head–Tail . . . 21
4.3.1 Phân đoạn từ và mã hóa BPE . . . 22
4.3.2 Lựa chọn Head–Tail cho bài báo dài . . . 22
4.3.3 Chi phí và các phương án so sánh . . . 23
4.3.4 Cấu hình kiến trúc thực tế . . . 23
4.4 Cơ chế self-attention, encoder và đầu phân loại . . . 25
4.4.1 Vector biểu diễn từ và thông tin vị trí . . . 25
4.4.2 Self-attention và xử lý theo ngữ cảnh . . . 25
4.4.3 Residual, LayerNorm và feed-forward . . . 25
4.4.4 Đầu phân loại và logits . . . 26
4.4.5 Quy mô tham số và ý nghĩa của fine-tuning . . . 26
4.4.6 Đọc một đầu attention và giới hạn giải thích . . . 27
4.5 Đối chiếu thông tin đầu vào và giới hạn diễn giải . . . 27

5 Huấn luyện, lựa chọn cấu hình và hiệu chỉnh 28
5.1 Giao thức lựa chọn và thông số thực nghiệm . . . 28
5.2 Huấn luyện SVM/LR và BiLSTM . . . 28
5.3 Fine-tuning PhoBERT và diễn biến validation . . . 30
5.3.1 Chọn bản lưu mô hình theo mục tiêu đánh giá . . . 31
5.3.2 Tính toán mini-batch và precision . . . 32
5.3.3 Validation dùng lại và nguy cơ phụ thuộc lựa chọn . . . 33
5.4 Temperature scaling và quyết định theo lớp . . . 33

6 Kết quả thực nghiệm, so sánh và phân tích lỗi 35
6.1 Điều kiện đánh giá chung . . . 35
6.2 Kết quả tổng thể bốn phương pháp . . . 35
6.3 Kết quả theo 20 chuyên mục . . . 37
6.3.1 Nông thôn mới: đánh đổi độ chính xác và khả năng nhận ra bài thuộc lớp 37
6.3.2 Lợi thế không phân bố đều giữa các chuyên mục . . . 38
6.3.3 Số mẫu và ranh giới nhãn . . . 39
6.4 Ma trận nhầm lẫn và phân tích lỗi bài thật . . . 39
6.4.1 Diễn giải các ví dụ có thể truy vết . . . 41
6.4.2 Sai số do mục tiêu đơn nhãn và quan sát đầu vào . . . 42

6.4.3 Từ lỗi chung tới kiểm toán dữ liệu 42
6.5 Đánh giá ghép cặp và bất định thống kê 42
6.6 Hiệu chỉnh xác suất và độ tin cậy 44
6.7 Chi phí tính toán và trả lời RQ1–RQ3 45
6.7.1 Chi phí của biểu diễn và cập nhật tham số 46
6.7.2 Phạm vi đo và ý nghĩa đối với lựa chọn mô hình 46
6.7.3 Diễn giải theo câu hỏi nghiên cứu 47

7 Kết luận và giới hạn nghiên cứu 48
7.1 Kết luận từ bằng chứng thực nghiệm 48
7.2 Giới hạn và hướng kiểm chứng tiếp theo 48

Tài liệu tham khảo 50

A Bằng chứng, thực thi và tái hiện A-1
A.1 Nguồn bằng chứng và môi trường A-1
A.2 Tái hiện và kiểm tra tính toàn vẹn A-1
A.3 Ma trận chuẩn hóa các đối chứng A-2

B Ứng dụng hỗ trợ biên tập B-1
B.1 Kiến trúc dịch vụ và yêu cầu nhất quán khi suy luận B-1
B.2 Quy trình dự đoán, đọc bài và sửa nhãn B-2
B.3 Phân luồng và vận hành B-4
B.4 Monitoring và Dataset Lab B-6
B.5 Kiểm chứng và giới hạn B-7

Danh sách hình vẽ

2.1 Ba họ biểu diễn và bốn quy trình phân loại. Phần văn bản quan sát, tiền huấn luyện và ngân sách tối ưu khác nhau. 7

3.1 Xác minh chuyên mục và tạo tập dữ liệu; nhánh loại/gộp không đi vào dữ liệu huấn luyện. 9
3.2 Ba tập dữ liệu có vai trò tách biệt; tập test nằm ngoài cập nhật, chọn bản lưu mô hình và hiệu chỉnh. 12
3.3 Phân bố 20 lớp của tập dữ liệu cuối 199,965 bài, sau khi bỏ bài trùng lặp nội dung. 12
3.4 Chuẩn hóa chung trước loại bỏ bài trùng lặp; biến đổi riêng của từng mô hình diễn ra sau khi chốt tập dữ liệu. 14
3.5 Khảo sát 1,000 bài: giới hạn 256 vị trí làm mất một phần đáng kể chuỗi đầu vào. 15

4.1 Đặc trưng có hệ số dương lớn ở Nông thôn mới; thang hệ số không trực tiếp tương đương giữa hai mô hình. 19
4.2 BiLSTM thực thi trong notebook: vector biểu diễn từ học từ đầu, packed sequence, ghép hidden cuối hai hướng và đầu phân loại 20 lớp. Dropout vector biểu diễn từ được lược trong khối để giữ sơ đồ gọn. 21
4.3 Cách ghép Head–Tail; dấu token được minh họa theo ký hiệu của tokenizer PhoBERT. 23
4.4 PhoBERT và đầu phân loại trong RobertaForSequenceClassification. 24
4.5 Tính toán bên trong một lớp encoder; mask loại vị trí padding khỏi attention. . 26

5.1 Validation của cấu hình BiLSTM được chọn; cực tiểu loss và bản lưu mô hình tốt nhất thuộc các epoch khác nhau. 29
5.2 PhoBERT qua bảy epoch; lựa chọn bản lưu mô hình theo Macro-F1 không trùng cực tiểu loss. 31
5.3 Huấn luyện có tích lũy gradient và chọn bản lưu mô hình theo Macro-F1. . . . 33
5.4 Hiệu chỉnh xác suất, chọn nhãn và định tuyến biên tập là các bước riêng. 34

6.1 PhoBERT chuẩn hóa theo hàng, argmax trước hệ số lớp; thang tỷ lệ 0–1. 40
6.2 Biểu đồ độ tin cậy của PhoBERT trên cùng test, cùng thang trục và 15 khoảng xác suất; độ tin cậy cực đại trước hệ số quyết định theo lớp. 44

A.1 Linear SVM, argmax trên 29,995 bài test; chuẩn hóa theo hàng (%). A-2
A.2 Logistic Regression, cùng test và hệ thống chuyên mục; chuẩn hóa theo hàng (%).A-3
A.3 BiLSTM, cùng test và hệ thống chuyên mục; chuẩn hóa theo hàng (%). A-4

B.1 Sáu dịch vụ của ứng dụng và gói mô hình dùng cho suy luận. B-1
B.2 Nội dung bài và URL nguồn trong màn hình rà soát. B-2
B.3 Nhãn gợi ý, độ tin cậy, các ứng viên và thao tác biên tập. B-3
B.4 Vòng phản hồi có truy vết phiên bản mô hình và lần dự đoán. B-3
B.5 Admin xem preview và điều chỉnh hai ngưỡng phân luồng của dữ liệu vận hành. B-4
B.6 Tỷ lệ bài được giữ và Accuracy có điều kiện của nhóm đạt ngưỡng trên test; đây là mô phỏng offline. B-5
B.7 Danh mục phiên bản PhoBERT: phiên bản, hiệu chỉnh xác suất và kết quả offline từ tệp kết quả. B-5
B.8 Monitoring theo phản hồi gắn với đúng prediction. B-6
B.9 Dataset Lab: phân bố và ứng viên rà soát trong dữ liệu vận hành. B-7

Danh sách bảng

2.1 Nghiên cứu phân loại tin tức tiếng Việt và điều kiện diễn giải; số liệu thuộc từng nguồn, không phải benchmark chung. 5

3.1 Lượt URL, URL duy nhất và dòng văn bản là các đơn vị đếm khác nhau. 8
3.2 Hệ thống chuyên mục và số bài ở từng giai đoạn; ID thống nhất trong notebook và app. 11
3.3 Trích đoạn UNIQLO từ output thật; ba trạng thái thể hiện thay đổi chữ số, dấu câu và đơn vị từ. 13
3.4 Chiều dài ở các mức biểu diễn và bản dữ liệu. Dấu – là thống kê không dùng tại đây. 15

4.1 Hai cấu hình tuyến tính được chọn bằng validation. 18
4.2 Thông số đọc từ config.json của bản lưu mô hình. 24

5.1 Thiết lập lựa chọn và thiết bị; cấu hình biểu diễn chi tiết ở chương 4. 28
5.2 Cấu hình fine-tuning PhoBERT trên một RTX A3000 Laptop 12 GB. 30
5.3 Đánh giá cuối epoch trên validation PhoBERT. 31

6.1 Chất lượng bốn mô hình với quyết định argmax điểm số; chưa dùng hệ số điều chỉnh lớp của PhoBERT. Chỉ số phần trăm, làm tròn bốn chữ số trên cùng 29,995 bài test. 36
6.2 PhoBERT trước/sau điều chỉnh theo lớp trên cùng test; chỉ số ở thang 0–1, chênh lệch là sau trừ trước. 36
6.3 F1 (%) theo 20 chuyên mục với argmax, cùng số mẫu test; DTTS là Dân tộc thiểu số. Giá trị làm tròn có thể che chênh lệch rất nhỏ. 37
6.4 Nông thôn mới: precision, recall và F1 của bốn mô hình trước điều chỉnh nhãn; số mẫu là 146 bài. 38
6.5 Các hướng nhầm nổi bật của PhoBERT argmax; tỷ lệ lấy số mẫu nhãn tham chiếu làm mẫu số. 40
6.6 Số mô hình dự đoán đúng từng bài trong bốn quyết định argmax; tổng bằng 29,995. 41
6.7 Chênh lệch Macro-F1 ghép cặp với argmax; khoảng tin cậy là từng cặp cho mô hình cố định, không phải khoảng đồng thời của toàn bộ so sánh. 43
6.8 NLL và ECE với 15 khoảng xác suất trước/sau temperature; độ tin cậy là xác suất cực đại trước hệ số quyết định lớp. 44
6.9 Thời gian thực nghiệm của bốn phương pháp; các phạm vi đo được giải thích trong nội dung. 45

1. Bài toán và thiết kế đánh giá

1.1 Bối cảnh và phát biểu bài toán

Tin tức trực tuyến được xuất bản liên tục và bao phủ nhiều lĩnh vực. Việc xác định chuyên mục giúp tổ chức nội dung, tìm kiếm và hỗ trợ biên tập. Với văn bản tiếng Việt, bài toán không chỉ là tìm một vài từ khóa: khoảng trắng thường phân cách âm tiết, bài báo có độ dài khác nhau và một nội dung có thể liên quan đồng thời đến nhiều chủ đề.

Báo cáo xét việc dự đoán chuyên mục chính của một bài VietNamNet từ tiêu đề và nội dung. Nhãn tham chiếu là chuyên mục xuất bản theo cách tổ chức của tòa soạn. Đây là bài toán đa lớp đơn nhãn: mỗi bài được gán một trong các chuyên mục đã xác định. Chẳng hạn, một bài về sinh kế ở địa phương có thể nhắc tới chính sách, văn hóa và du lịch, nhưng nhãn dùng để đánh giá vẫn là một chuyên mục chính.

Ký hiệu $x_i = (t_i, b_i)$ là tiêu đề và nội dung của bài i, $y_i \in \mathcal{C}$ là nhãn tham chiếu, với $\mathcal{C}$ gồm 20 chuyên mục. Tập dữ liệu có giám sát được viết dưới dạng

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{N}, \tag{1.1}$$

trong đó N là số bài đủ điều kiện sử dụng. Với phương pháp m, ϕ_m chuyển văn bản thành biểu diễn số, f_{θ_m} tạo điểm cho các lớp và quy tắc argmax chọn lớp có điểm cao nhất:

$$z_i^{(m)} = f_{\theta_m}(\phi_m(x_i)), \qquad \hat{y}_i^{(m)} = \arg\max_{c \in \mathcal{C}} z_{i,c}^{(m)}. \tag{1.2}$$

URL và thông tin chuyên mục trên trang bài được dùng để kiểm tra nguồn nhãn, không làm đặc trưng đầu vào cho bộ phân loại. Danh sách top-k gồm các nhãn có điểm cao để người dùng xem xét, không có nghĩa một bài được coi là thuộc đồng thời tất cả các nhãn đó.

Sai số trong báo cáo được hiểu là dự đoán không khớp chuyên mục tham chiếu. Với những bài giao thoa nội dung, điều này chưa đủ để kết luận mô hình hiểu sai toàn bộ ý nghĩa bài báo. Hệ thống cũng không kiểm chứng tính xác thực của tin và chưa có cơ chế đã được đánh giá để nhận diện chắc chắn mọi bài nằm ngoài các chuyên mục được hỗ trợ.

1.2 Mục tiêu nghiên cứu và phạm vi

Báo cáo lựa chọn SVM, Logistic Regression, BiLSTM và PhoBERT để khảo sát ba hướng biểu diễn văn bản: đặc trưng từ vựng, vector từ kết hợp xử lý chuỗi và biểu diễn ngữ cảnh từ mô hình tiền huấn luyện. Ba câu hỏi nghiên cứu là:

RQ1: Trên cùng dữ liệu và hệ thống chuyên mục, chất lượng phân loại của bốn phương pháp khác nhau như thế nào?

RQ2: Khác biệt chất lượng có tương xứng với thời gian huấn luyện, bộ nhớ và chi phí suy luận của từng hướng tiếp cận không?

RQ3: Các phương pháp khác nhau thế nào ở chuyên mục ít mẫu hoặc có nội dung giao thoa?

Quy trình nghiên cứu gồm chuẩn bị dữ liệu, xây dựng biểu diễn phù hợp từng phương pháp, huấn luyện và đánh giá. LSTM được triển khai bằng biến thể hai chiều BiLSTM, với các vector từ học từ dữ liệu của bài toán. PhoBERT sử dụng tham số ngôn ngữ đã được tiền huấn luyện rồi điều chỉnh cho nhiệm vụ phân loại. So sánh vì vậy phản ánh hiệu quả của các quy trình phân loại cụ thể, chưa tách riêng tác động của từng lựa chọn kiến trúc hay tiền xử lý.

Phạm vi ứng dụng là hỗ trợ biên tập: đề xuất chuyên mục, hiển thị các nhãn ứng viên và lưu quyết định của người rà soát. Người dùng giữ vai trò xử lý những trường hợp khó; phản hồi không tự động làm thay đổi trọng số mô hình. Phần ứng dụng minh họa cách sử dụng kết quả NLP, còn chất lượng mô hình được xác định bằng đánh giá độc lập.

1.3 Nguyên tắc tổ chức dữ liệu và đánh giá

Dữ liệu được làm sạch trước khi chia thành tập huấn luyện (train), tập xác thực (validation) và tập kiểm tra (test). Tập huấn luyện dùng để học trọng số, từ vựng và các thống kê tạo đặc trưng. Tập xác thực dùng để lựa chọn cấu hình, bản lưu mô hình và tham số hiệu chỉnh. Tập kiểm tra chỉ dùng để đánh giá cuối sau khi các lựa chọn đã cố định. Bốn phương pháp sử dụng cùng các bài và nhãn trong từng tập để kết quả có thể đối chiếu trực tiếp.

Macro-F1 được chọn làm tiêu chí chính vì mỗi chuyên mục đóng góp ngang nhau, giúp phản ánh chất lượng ở các lớp ít bài. Accuracy là tỷ lệ bài được dự đoán đúng trên toàn tập; Weighted-F1 tính trung bình F1 theo số bài của từng lớp. Kết quả theo lớp và ma trận nhầm lẫn giúp nhận ra các cặp chuyên mục khó phân biệt. Độ tin cậy của xác suất và thời gian tính toán được xem xét riêng, vì một phương pháp có F1 cao chưa nhất thiết có xác suất đáng tin cậy nhất hoặc chi phí thấp nhất.

Để hạn chế rò rỉ dữ liệu, các bài trùng lặp được xử lý trước khi chia tập và các biến đổi cần học từ dữ liệu chỉ được xây dựng trên tập huấn luyện. Dùng lại tập xác thực cho nhiều quyết định có thể tạo phụ thuộc vào tập này; phép chia ngẫu nhiên cùng nguồn cũng chưa phản ánh đầy đủ tin đến sau hoặc nguồn báo khác. Những giới hạn đó được giữ khi diễn giải kết quả.

Chương tiếp theo trình bày nghiên cứu liên quan và cơ sở lựa chọn các phương pháp. Quy tắc thu thập, làm sạch và tổ chức dữ liệu được trình bày ở chương dữ liệu; các chương sau mô tả kiến trúc, huấn luyện và kết quả thực nghiệm.

2. Tổng quan nghiên cứu và lựa chọn phương pháp

2.1 Các hướng biểu diễn trong phân loại văn bản

Một hệ thống phân loại văn bản kết hợp tiền xử lý, biểu diễn đầu vào, bộ phân loại và giao thức đánh giá. Khảo sát của Kowsari và cộng sự tổ chức các phương pháp theo những thành phần này [8]. Cách nhìn đó giúp phân biệt ba hướng: đặc trưng từ vựng như BoW/TF–IDF; vector biểu diễn từ kết hợp mạng xử lý chuỗi; biểu diễn theo ngữ cảnh từ mô hình ngôn ngữ tiền huấn luyện. Khác biệt giữa các hướng nằm cả ở thông tin được giữ trong đầu vào lẫn tri thức học được, không chỉ ở tên thuật toán.

Phân loại tin tức tiếng Việt có nền tảng thực nghiệm trước thời kỳ Transformer. Hoang và cộng sự khảo sát BoW, lựa chọn đặc trưng và mô hình ngôn ngữ n-gram trên tập dữ liệu tin tức hai cấp nhãn [7]. Công trình tại FAIR'9 sử dụng từ lõi và xác suất có điều kiện với Naive Bayes trên 220 văn bản, sáu chủ đề [1]. Đây là ví dụ về lựa chọn tín hiệu đại diện cho chuyên mục; mô hình từ lõi không đồng nhất với LDA, và quy mô thử nghiệm nhỏ chưa đại diện bài toán hiện tại.

Khoảng trắng tiếng Việt thường phân cách âm tiết, nên đơn vị đếm không mặc nhiên là từ. Khảo sát của Nguyễn Chí Hiếu nhấn mạnh vai trò biểu diễn và phân đoạn từ trong phân loại tiếng Việt [13]. VnCoreNLP là một công trình tiêu biểu về công cụ phân đoạn và phân tích ngôn ngữ [20]. Nghiên cứu này dùng PyVi để phân đoạn từ; VnCoreNLP được nêu như một công trình liên quan để làm rõ bối cảnh lựa chọn công cụ. Các khảo sát giúp tổ chức phương pháp nhưng không cung cấp một phép so sánh trực tiếp bốn mô hình trên tập dữ liệu VietNamNet này.

2.2 Phương pháp tuyến tính trên đặc trưng từ vựng

TF–IDF tạo vector thưa, có số chiều phụ thuộc từ vựng và n-gram. SVM tuyến tính học ranh giới có biên giữa các lớp trong không gian đó; Logistic Regression (LR) học điểm tuyến tính bằng mục tiêu mất mát logarit. Cả hai khai thác đồng thời nhiều đặc trưng và điều chuẩn, không cần huấn luyện encoder ngôn ngữ lớn. TF–IDF không mô hình hóa đầy đủ thứ tự dài, nhưng n-gram vẫn giữ được một phần ngữ cảnh cục bộ [8].

Trần Cao Đệ và Phạm Nguyên Khang dùng 7,842 bài thuộc 10 chủ đề từ báo điện tử, gồm VietNamNet, với 5,000 bài train và 2,842 bài test. TF–IDF kết hợp SVD và SVM đạt F1 trung bình được báo cáo là 91.0%, so với 84.1% của cây quyết định [16]. Kết quả cho thấy biểu diễn và giảm chiều có thể ảnh hưởng chất lượng. Tuy nhiên, SVD được mô tả trên ma trận toàn tập dữ liệu trước huấn luyện bộ phân loại; giao thức đó chưa bảo đảm một đánh giá quy nạp chỉ học biến đổi từ train. Không suy ra SVD bắt buộc cho SVM, và không sao chép cách học tham số này vào đối chứng mới.

Trên VNNews-01 gồm 37,500 bài, 25 lớp từ hơn 30 website, Duong và Truong Hoang đánh giá bằng trung bình F-measure qua kiểm định chéo năm phần dữ liệu. SVM kernel RBF

đạt 0.749; LR multinomial đạt 0.734 [5]. Giá trị 0.749 thuộc RBF, không phải LinearSVC; nguồn cũng chưa xác định rõ cách tổng hợp F-measure theo lớp. Đây là bằng chứng cho tính khả thi của cả SVM và LR, không phải một mức Macro-F1 có thể đối chiếu với bài tập lớn.

LR có lý do lựa chọn riêng, không chỉ là phương án thay thế khi không dùng SVM. Trong nghiên cứu của Nguyen Thi Hien và cộng sự, LR với TF–IDF đạt Accuracy 92.77% ở Level 1 [12]; trên BN-VN3S, LR đạt Macro-F1 91.36%, còn LinearSVC đạt 92.33% [3]. Hai bộ phân loại cùng biểu diễn nhưng khác mục tiêu tối ưu tạo đối chứng để kiểm tra liệu tín hiệu từ vựng đã giải thích phần lớn nhãn hay chưa. Lựa chọn tuyến tính cũng phù hợp khảo sát tập dữ liệu lớn, song chi phí thực tế vẫn phải đo trên cùng phần cứng.

2.3 Mạng hồi tiếp và vector biểu diễn từ

Vector biểu diễn từ biểu diễn token bằng vector đặc, còn LSTM tích lũy trạng thái theo thứ tự chuỗi. Hướng này có thể học quan hệ vượt một n-gram cố định mà không dùng encoder Transformer tiền huấn luyện [8]. Vector biểu diễn từ tĩnh không tự trở thành biểu diễn theo ngữ cảnh; ngữ cảnh được hình thành qua mạng xử lý chuỗi. Trạng thái phụ thuộc bước trước làm hạn chế song song hóa theo chiều thời gian khi chuỗi dài. Chiều dài đầu vào, chất lượng phân đoạn, nguồn vector biểu diễn từ và khả năng học từ ít gặp đều ảnh hưởng kết quả.

Nguyen Thi Hien và cộng sự khảo sát LR, cây quyết định, SVM, LSTM và CNN trên hai cấp nhãn 10/27 của tập dữ liệu tin tức. Ở Level 1, LSTM với BoW đạt Accuracy 94.52%; với TF–IDF, LSTM đạt 93.75% và SVM đạt 93.60% [12]. Các giá trị hỗ trợ nghiên cứu LSTM trên tiếng Việt nhưng chưa tách tác động kiến trúc khỏi biểu diễn. Nguồn chưa giải thích đủ việc chuyển đặc trưng BoW/TF–IDF và SVD thành trục tuần tự của LSTM. Vì vậy, thiết kế khảo sát ở đây dùng chuỗi token có thứ tự và vector biểu diễn từ, không coi các chiều TF–IDF là vị trí từ.

UIT-ViON đối chiếu LSTM với nhiều vector biểu diễn từ cùng LR, TextCNN và PhoBERT trên tiêu đề tin [14]. Kết quả này bổ sung bằng chứng ở đầu vào ngắn; không chứng minh cùng cấu hình phù hợp bài dài. Một hướng LSTM–CNN cũng được thực nghiệm trên cảm xúc tiếng Việt [19], nhưng tác vụ cảm xúc và kiến trúc lai không phải benchmark cho LSTM phân loại chuyên mục. Tương tự, BiGRU trong BN-VN3S là bằng chứng về họ mạng hồi tiếp, không phải kết quả của LSTM [3].

2.4 PhoBERT và mô hình tiền huấn luyện

PhoBERT phát triển mô hình ngôn ngữ tiền huấn luyện riêng cho tiếng Việt theo hướng RoBERTa, kết hợp phân đoạn từ và BPE trước học biểu diễn ngữ cảnh [11]. Fine-tuning tận dụng tham số đã học trên tập dữ liệu lớn cho tác vụ có giám sát, đi kèm yêu cầu bộ nhớ và giới hạn chiều dài đầu vào. Bài PhoBERT gốc đánh giá POS, parsing, NER và NLI, không trực tiếp cung cấp kết quả phân loại chuyên mục của bài tập lớn. Bản lưu mô hình phobert-base-v2 có thông tin riêng từ tài liệu mô hình và config; chương 4 trình bày cấu hình thực thi.

UIT-ViON gồm 260,000 tiêu đề, 13 chủ đề từ sáu nguồn, chia train/validation/test theo

80/10/10. PhoBERT đạt F1-score 80.62%, cao nhất trong bảng kết quả của nguồn [14]. Tuy nhiên, bài gọi tác vụ đa nhãn ở Abstract/Conclusion và mô tả sigmoid/BCE, trong khi các phần khác dùng cách diễn đạt đa lớp và cấu hình softmax. Mục đánh giá gọi F1 là macro-averaged. Sự không nhất quán về giao thức nhãn cần được giữ trong diễn giải; không coi đây là đối chứng đồng nhất với 20 lớp đơn nhãn. Tiêu đề cũng không chứa toàn bộ nội dung và không có vấn đề cắt bài dài như tập dữ liệu hiện tại.

BN-VN3S của Chau và cộng sự cung cấp 946,696 bài từ VietNamNet, VnExpress và Dân Trí, với 10 chủ đề. Phép chia phân tầng 80/10/10 được dùng chung, các kết quả lấy trung bình ba seed. Macro-F1 của BiGRU, LinearSVC và PhoBERT lần lượt là 92.42%, 92.33% và 87.98% [3]. Transformer được fine-tune với cơ chế cửa sổ trượt 256 token rồi tổng hợp ở cấp bài. Thứ hạng trong thiết lập này bác bỏ giả định Transformer mặc nhiên tốt nhất; nó không chứng minh SVM hay mạng hồi tiếp luôn tốt hơn PhoBERT.

BN-VN3S còn đánh giá thay đổi theo thời gian và để riêng một nguồn báo làm test. Những thiết lập đó đặt câu hỏi tổng quát hóa khác với chia ngẫu nhiên cùng phân phối [3]. Tập dữ liệu có VietNamNet không có nghĩa hệ thống chuyên mục, bản dữ liệu hay nhãn trùng bài tập lớn. Bản nghiên cứu của Kiệt và Lang cung cấp bằng chứng bổ trợ: sau lọc còn 162,580 bài dài 100–300 từ, F1 của LR/SVM/BiLSTM–CNN/PhoBERT là 0.894/0.896/0.888/0.907 [2]. Nguồn chưa xác định rõ cách tổng hợp F1 và chưa xác minh được nơi công bố. Không đổi các giá trị thành Macro-F1; mô hình lai và tập dữ liệu lọc độ dài cũng khác LSTM và Head–Tail của thiết kế hiện tại.

2.5 Tổng hợp các công trình và cơ sở so sánh bốn phương pháp

Bảng 2.1 tập trung các nghiên cứu tin tức. Các giá trị chỉ có ý nghĩa trong điều kiện từng hàng, không tạo thứ hạng liên nghiên cứu. Khác nguồn, số lớp, đơn vị đầu vào, cách lọc, phép chia và metric đều có thể thay đổi độ khó. Accuracy không thay Macro-F1; F1 chưa rõ cách tổng hợp không được tự gán thành Macro-F1 hay Weighted-F1.

Bảng 2.1: Nghiên cứu phân loại tin tức tiếng Việt và điều kiện diễn giải; số liệu thuộc từng nguồn, không phải benchmark chung.

Nghiên cứu	Dữ liệu và giao thức	Phương pháp chính	Phát hiện và giới hạn
Hoang và cộng sự (2007) [7]	Tin tức đa nguồn; hai cấp 10/27 nhãn; train/test riêng.	BoW, chọn đặc trưng, SVM và mô hình n-gram.	Biểu diễn ảnh hưởng chất lượng; hệ thống chuyên mục và giao thức lịch sử khác tập dữ liệu hiện tại.
Trần Cao Đệ, Phạm Nguyên Khang (2012) [16]	7,842 bài, 10 chủ đề; train 5,000, test 2,842.	TF–IDF, SVD, SVM; cây quyết định.	F1 trung bình báo cáo 91.0% và 84.1%; SVD trên toàn tập dữ liệu cần lưu ý khi tái hiện.
Duong, Truong Hoang (2019) [5]	VNNews-01: 37,500 bài, 25 lớp; kiểm định chéo năm phần dữ liệu.	TF–IDF; SVM, LR và các bộ phân loại khác.	F-measure: RBF SVM 0.749, LR 0.734; chưa rõ tổng hợp theo lớp.

Bảng 2.1 (tiếp theo)

Nghiên cứu	Dữ liệu và giao thức	Phương pháp chính	Phát hiện và giới hạn
Tran và cộng sự (2021) [14]	UIT-ViON: 260,000 tiêu đề, 13 chủ đề; 80/10/10.	TF–IDF + LR; vector biểu diễn từ + CNN/LSTM; PhoBERT.	PhoBERT F1 80.62%; nguồn mô tả đa nhãn nhưng giao thức chưa nhất quán; đầu vào ngắn.
Nguyen Thi Hien và cộng sự (2024) [12]	Tập dữ liệu tin tức hai cấp 10/27 nhãn; kết quả nêu ở Level 1.	BoW/TF–IDF; LR, SVM, LSTM, CNN.	Accuracy: LSTM–BoW 94.52%, SVM–TF–IDF 93.60%; đầu vào tuần tự cần làm rõ.
Kiệt, Lang (s.d.) [2]	162,580 bài, 9 lớp; lọc 100–300 từ; train/test khoảng 80/20.	TF–IDF + LR/SVM; BiLSTM–CNN; PhoBERT.	F1: 0.894/0.896/0.888/0.907; chưa rõ tổng hợp F1 và venue; bằng chứng bổ trợ.
Chau và cộng sự (2026) [3]	BN-VN3S: 946,696 bài, 10 chủ đề; 80/10/10, ba seed; thêm test nguồn/thời gian.	TF–IDF + LR/LinearSVC; BiGRU; PhoBERT và các mô hình khác.	Macro-F1: BiGRU 92.42%, LinearSVC 92.33%, PhoBERT 87.98%; phụ thuộc cấu hình và dữ liệu.

2.5.1 Lựa chọn ba họ biểu diễn

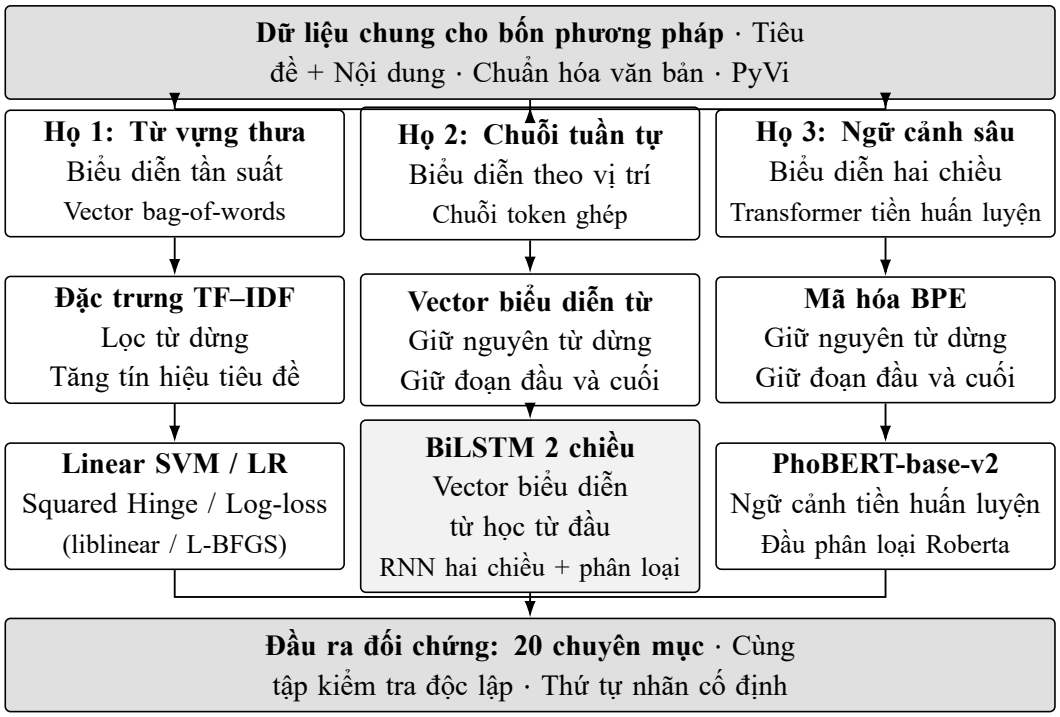
SVM và LR là hai đối chứng tuyến tính dùng TF–IDF: một hướng tối ưu biên phân lớp, một hướng tối ưu mất mát logarit. Giữ cùng cách biểu diễn giúp khảo sát ảnh hưởng mục tiêu học. LSTM khảo sát biểu diễn chuỗi và thứ tự token; PhoBERT khảo sát biểu diễn ngữ cảnh có tiền huấn luyện tiếng Việt. Bốn lựa chọn bao phủ ba họ biểu diễn có bằng chứng liên quan, với các yêu cầu tài nguyên và cách dùng thông tin khác nhau.

Để so sánh công bằng, các phương pháp cần dùng cùng tập dữ liệu sau làm sạch, hệ thống chuyên mục 20 lớp và cùng các tập huấn luyện, xác thực, kiểm tra. Từ vựng, IDF và các biến đổi học từ dữ liệu chỉ học từ tập huấn luyện; validation chọn siêu tham số, test đánh giá cuối. Macro-F1 là tiêu chí chính, cùng Accuracy, Weighted-F1 và precision/recall theo lớp. Thời gian, bộ nhớ và tốc độ suy luận cần đo với môi trường, batch và phạm vi công việc được công bố. Khác biệt về tiền huấn luyện, vector biểu diễn từ và phần văn bản được giữ phải được nêu rõ: đây là so sánh các quy trình phân loại thực tế, chưa phải ablation chỉ thay kiến trúc.

Tập dữ liệu hiện tại có 20 chuyên mục của một tòa soạn, lớp ít mẫu và ranh giới giao thoa; số bài giữa các lớp chênh lệch đáng kể. Những đặc điểm này khác hệ thống chuyên mục rộng 10/13 chủ đề, tiêu đề ngắn hoặc tập dữ liệu đã lọc độ dài trong nghiên cứu trước. Vì vậy, lựa chọn mô hình cần được kiểm chứng trên dữ liệu của bài tập lớn, đặc biệt ở nhóm Nông thôn mới, Nội dung chuyên đề và các chuyên mục dân tộc, thay vì suy ra từ một F1 tổng thể bên ngoài.

2.5.2 Giới hạn của nghiên cứu liên quan và nguyên tắc đối chứng

Nghiên cứu trước cung cấp căn cứ lựa chọn, còn các notebook SVM, LR, BiLSTM và PhoBERT tạo bằng chứng đối chứng trên tập dữ liệu hiện tại. Chương 6 đối chiếu các quy trình



Hình 2.1: Ba họ biểu diễn và bốn quy trình phân loại. Phần văn bản quan sát, tiền huấn luyện và ngân sách tối ưu khác nhau.

phân loại được lựa chọn trên cùng tập test; validation chỉ được dùng để chọn cấu hình, bản lưu mô hình và tham số hiệu chỉnh. Bằng chứng bên ngoài không xác định trước thứ hạng trên dữ liệu của bài tập lớn; một kết quả cao nhất cũng không chứng minh ưu thế trên mọi tập dữ liệu, seed hay điều kiện triển khai. Ứng dụng dùng gói PhoBERT được kiểm chứng độc lập với phạm vi đối chứng offline.

Một phép so sánh có ý nghĩa trước hết cần đầu vào và nhãn đáng tin cậy. Chương 3 xác định nguồn tin, quy tắc nhãn cha–con, chuyển chuyên mục ở cấp bài, loại bỏ bài trùng lặp và giới hạn tập dữ liệu. Đây là cơ sở chung cho các phương pháp, trước khi xét biểu diễn và tối ưu riêng của bốn quy trình phân loại.

3. Tập dữ liệu VietNamNet và tiền xử lý tiếng Việt

3.1 Thu thập, xác minh chuyên mục và tạo tập dữ liệu

Tập dữ liệu gồm bài VietNamNet trong 20 chuyên mục được chọn. Notebook thu thập trên tối đa 500 trang danh sách cho mỗi chuyên mục, rồi tải nội dung bằng 32 luồng xử lý song song; số 500 là giới hạn trang, không phải số bài. Một trang chứa nhiều URL, một URL có thể xuất hiện tại nhiều chuyên mục và chuyên mục ngắn kết thúc khi hết dữ liệu hợp lệ. Phạm vi này không bao phủ toàn bộ kho tin của website.

Trang danh sách dùng để phát hiện bài. Nhãn được kiểm tra trên chính trang bài, dựa vào đường dẫn chuyên mục và breadcrumb, tức chuỗi liên kết thể hiện vị trí của bài trong các mục cha–con. Tiêu đề, nội dung, URL chính thức (canonical) và bằng chứng chuyên mục được lấy cùng lượt tải HTML. Nếu thuộc chuyên mục nguồn, bài được giữ; nếu bằng chứng chỉ tới một lớp khác trong hệ thống chuyên mục, cả URL và nội dung chuyển về lớp đó. Bài ngoài hệ thống chuyên mục bị loại; lỗi tải, thiếu nội dung hoặc bằng chứng chưa đủ được thử tối đa ba lượt trước khi loại.

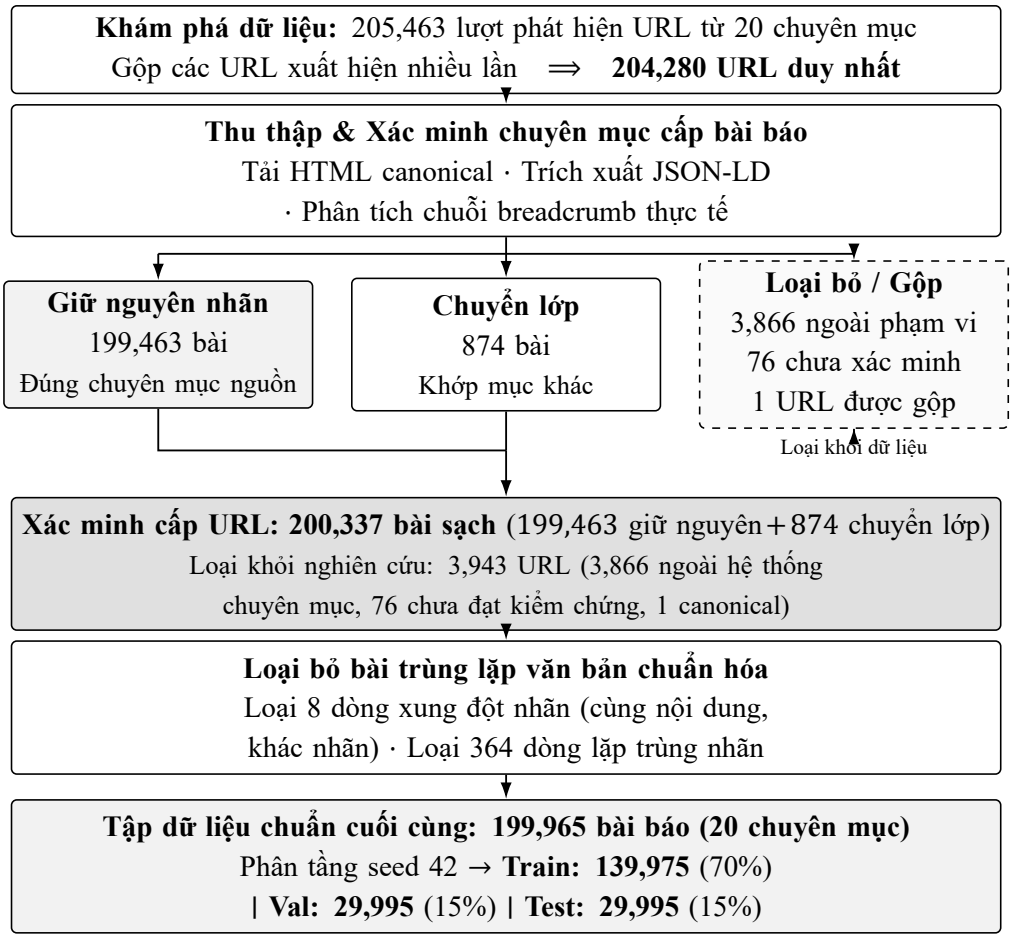
Mỗi nhãn có mã file ổn định. Đường dẫn Công nghiệp hỗ trợ là hop-tac/cong-nghiep-ho-tro, còn nhãn và tên Parquet là Công nghiệp hỗ trợ; phần đường dẫn đứng trước không tạo lớp mới. Sắc màu Việt Nam là mục con của Dân tộc – Tôn giáo và quy về lớp cha. Không dùng mô hình đang huấn luyện để tự gán nhãn cho tập dữ liệu của chính nó: nhãn được xác định từ bằng chứng xuất bản, không từ từ khóa nội dung.

Bảng 3.1: Lượt URL, URL duy nhất và dòng văn bản là các đơn vị đếm khác nhau.

Giai đoạn	Số lượng
Lượt URL ở các chuyên mục	205,463
URL đầu vào duy nhất	204,280
Giữ ở chuyên mục nguồn	199,463
Chuyển sang chuyên mục trong hệ thống chuyên mục	874
Loại ngoài hệ thống chuyên mục	3,866
Loại sau ba lượt tải/kiểm tra	76
Gộp request trùng canonical	1
Dataset sạch theo URL	200,337
Loại dòng xung đột nhãn sau xử lý	8
Loại dòng văn bản trùng cùng nhãn	364
Tập dữ liệu dùng chia tập	199,965

205,463 lượt phát hiện tạo 204,280 URL duy nhất. Số bài giữ nhãn nguồn cộng số bài chuyển bằng 200,337; các nhánh còn lại gồm 3,866 bài ngoài hệ thống chuyên mục, 76 trường hợp không đạt sau ba lượt và một yêu cầu tải chuyển về địa chỉ chính thức đã có:

$$204{,}280 = 199{,}463 + 874 + 3{,}866 + 76 + 1. \tag{3.1}$$



Hình 3.1: Xác minh chuyên mục và tạo tập dữ liệu; nhánh loại/gộp không đi vào dữ liệu huấn luyện.

874 là số bài chuyển tính theo URL duy nhất. Thông tin mô tả quan hệ nguồn–đích có thể tính một bài ở nhiều nguồn; vì vậy, tổng ô ngoài đường chéo không thay được số bài chuyển. Trong đó có 225 quan hệ Dân tộc – Tôn giáo tới Chính trị và 204 quan hệ Tuần Việt Nam tới Nội dung chuyên đề. Bản dữ liệu lưu bốn tệp JSON: raw chứa URL phát hiện, removed chứa URL bị loại hoặc gộp, meta chứa thông tin kiểm chứng, clean chứa URL theo nhãn cuối. Các tệp liên kết với nhau để truy vết một bài từ lúc phát hiện đến khi xác định nhãn cuối. Parquet giữ URL, tiêu đề, nội dung, nhãn và bằng chứng xác minh. Kiểm tra cấu trúc tệp và mã băm (hash) giúp xác nhận dữ liệu nhất quán với các quy tắc đã đặt ra. Mã băm nhận diện nội dung tệp, không chứng minh mọi nhãn đều đúng về ngữ nghĩa hoặc đã được chuyên gia gán thủ công.

3.1.1 Thuật toán xác định chuyên mục cấp bài

Chuyên mục được nhận diện theo đường dẫn (route) đã khai báo, xét đường dẫn dài trước để không chọn nhầm lớp cha khi có đường dẫn cụ thể hơn. URL được chuẩn hóa về tên miền VietNamNet hợp lệ; không lấy đường dẫn trùng tên ở một tên miền khác làm bằng chứng hệ thống chuyên mục. Canonical về cổng giảm nghèo riêng được xác định ngoài phạm vi, không ghép nhầm vào lớp chỉ vì có nội dung về vùng dân tộc.

1. Đọc dữ liệu có cấu trúc JSON-LD trong mã HTML trước khi trích xuất văn bản. Từ trường

BreadcrumbList, thu các chuỗi chuyên mục, sắp theo thuộc tính position và đối chiếu đường dẫn với danh sách chuyên mục đã khai báo.

2. Đọc liên kết trực tiếp của breadcrumb hiển thị tại bài. Không lấy nhãn từ danh sách xổ xuống chứa toàn bộ chuyên mục của website, vì danh sách này không mô tả riêng bài đang tải.

3. Với chuỗi có thông tin ngoài mục Trang chủ (Home), lấy mục cuối khớp đường dẫn. Nếu các nguồn breadcrumb đưa ra chuyên mục khác nhau, đánh dấu chưa giải quyết để thử lại; không chọn tùy ý nguồn dễ khớp nhất.

4. Chỉ khi không có breadcrumb hữu ích, dùng trường articleSection của dữ liệu có cấu trúc nếu các tên mục quy về duy nhất một nhãn trong hệ thống chuyên mục. Trường hợp thiếu hoặc mâu thuẫn bằng chứng không được gán nhãn theo tiêu đề.

Ba trạng thái kiểm chứng là accepted (chấp nhận), outside (ngoài phạm vi) và unresolved (chưa đủ căn cứ). Accepted cung cấp nhãn và đường dẫn bằng chứng; outside chỉ bài hợp lệ nhưng không có chuyên mục trong phạm vi; unresolved chỉ tình huống chưa đủ tin cậy để xác minh. Tải lại có thể giải quyết lỗi mạng hoặc bổ sung thông tin mô tả còn thiếu, nhưng không biến một mục ngoài phạm vi thành mục hợp lệ. Quy tắc này giúp nhãn có nguồn kiểm tra được mà không gọi toàn bộ quá trình là gán nhãn thủ công.

Các URL chuyển về cùng địa chỉ chính thức còn cần được đối chiếu nhãn trước khi gộp; nếu cùng địa chỉ có nhãn mâu thuẫn, quy trình không công bố tập dữ liệu như một bản dữ liệu hợp lệ. Trạng thái complete (hoàn tất) và mã băm chỉ được ghi nhận khi bộ tệp Parquet và danh sách URL clean đã được xuất đầy đủ. Notebook mô hình kiểm tra cấu trúc và tính nhất quán của đầu vào trước xử lý văn bản để tránh đọc một phần dữ liệu đang được xuất. Đây là bảo đảm nhất quán file, không một kết luận về đúng sai ngữ nghĩa.

3.1.2 Đơn vị quan sát và chất lượng nhãn

Nhãn nguồn của trang danh sách và nhãn cuối của bài là hai thuộc tính khác nhau. Giữ liên kết nguồn cho phép giải thích vì sao bài được chuyển lớp, nhưng chỉ nhãn xác minh mới là mục tiêu giám sát. Tương tự, các yêu cầu tải từ những URL khác nhau có thể chuyển hướng về cùng địa chỉ chính thức. Gộp các URL này khác với phát hiện bài có văn bản trùng nhau. Đếm URL duy nhất chưa loại được hai địa chỉ có cùng nội dung, nên còn cần bước xử lý ở tập dữ liệu văn bản.

Chính sách nhãn cha–con chỉ áp dụng cho các nhánh chuyên mục đã xác định; không suy ra mọi chuyên mục chứa từ "dân tộc" đều phải về cùng một lớp. Các mục Dân tộc – Tôn giáo và Dân tộc thiểu số và miền núi giữ hai ID riêng trong hệ thống chuyên mục. Cách tổ chức này có thể tạo bài gần về ngữ nghĩa nhưng khác nhãn tham chiếu; phần đánh giá cần phản ánh cả hai nhãn chứ không âm thầm gộp chúng để tăng điểm.

Không đạt sau các lần thử lại là nhóm không đủ điều kiện tạo bản ghi, chưa nhất thiết là một bài chắc chắn ngoài hệ thống chuyên mục. Bảng đếm giữ các lý do riêng để tránh coi lỗi mạng hoặc thiếu nội dung như một quyết định chủ đề. Việc loại nhóm này cũng có thể làm bản

dữ liệu thiên lệch theo khả năng tải và trích xuất. Những bài đã tải tốt không tạo bằng chứng về chất lượng trên toàn bộ lịch sử xuất bản.

3.2 Phân bố nhãn, mất cân bằng và chia tập

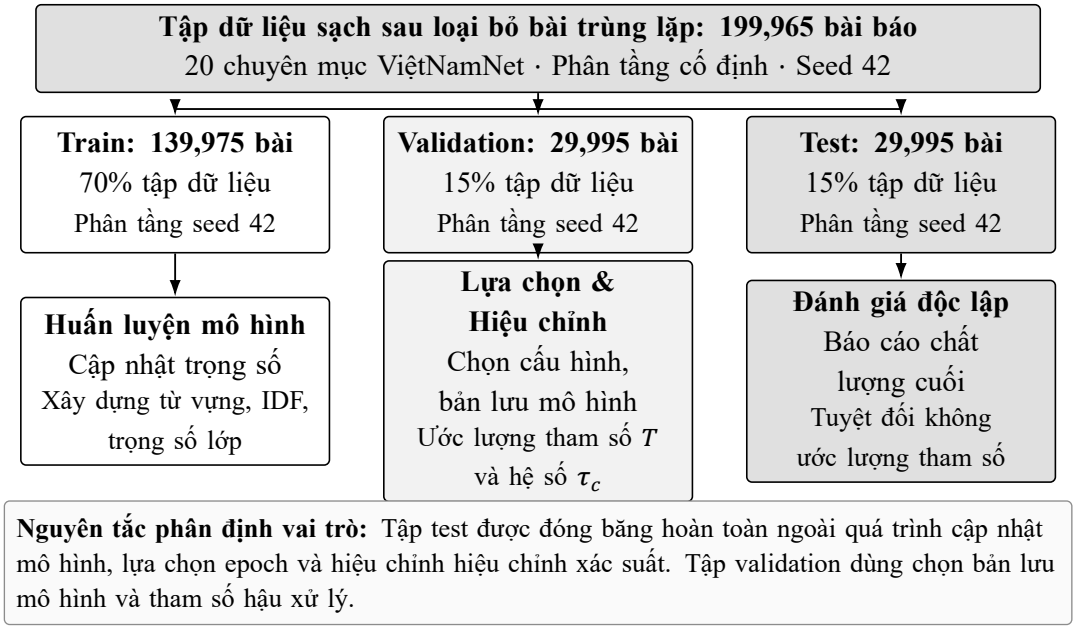
Sau khi chuẩn hóa văn bản, các bản ghi có cùng văn bản được gom thành nhóm. Tám bản ghi thuộc nhóm có nhãn mâu thuẫn bị loại; với các nhóm cùng nhãn, chỉ giữ một đại diện và bỏ 364 bản ghi lặp. Tập dữ liệu còn 199,965 bài. Bảng 3.2 đối chiếu số bài trong Parquet đầu vào với số bài còn lại sau bước này. Phép chia phân tầng dùng tỷ lệ 70/15/15 và seed 42, tạo 139,975 bài huấn luyện, 29,995 bài xác thực và 29,995 bài kiểm tra. Cách chia này giữ tỷ lệ các lớp gần phân bố tập dữ liệu; chênh một mẫu giữa validation/test là hệ quả làm tròn số lượng nguyên.

Bảng 3.2: Hệ thống chuyên mục và số bài ở từng giai đoạn; ID thống nhất trong notebook và app.

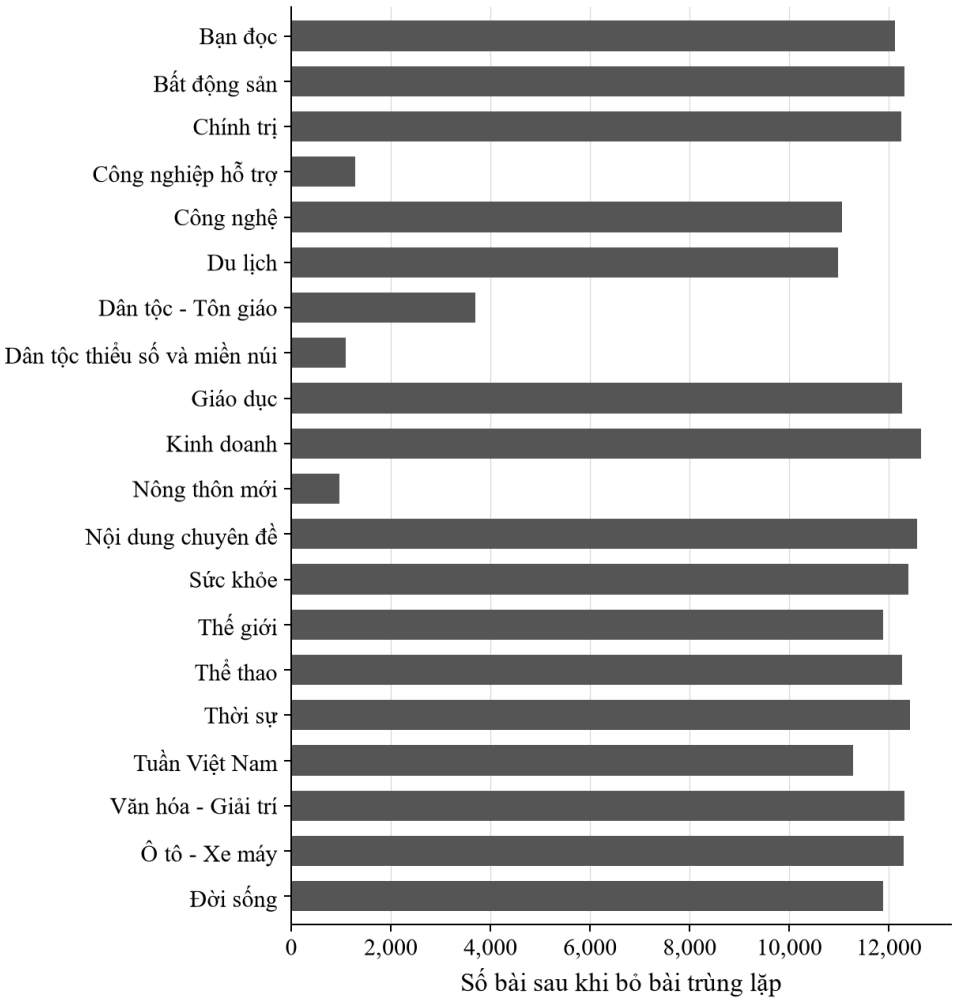
ID	Chuyên mục	Parquet	Sau loại bỏ bài trùng lặp	Train	Val	Test
0	Bạn đọc	12,310	12,119	8,483	1,818	1,818
1	Bất động sản	12,311	12,309	8,616	1,847	1,846
2	Chính trị	12,243	12,242	8,569	1,837	1,836
3	Công nghiệp hỗ trợ	1,297	1,292	905	193	194
4	Công nghệ	11,062	11,061	7,743	1,659	1,659
5	Du lịch	10,980	10,979	7,685	1,647	1,647
6	Dân tộc - Tôn giáo	3,700	3,700	2,590	555	555
7	Dân tộc thiểu số và miền núi	1,088	1,088	762	163	163
8	Giáo dục	12,261	12,259	8,581	1,839	1,839
9	Kinh doanh	12,649	12,643	8,850	1,896	1,897
10	Nông thôn mới	969	969	678	145	146
11	Nội dung chuyên đề	12,569	12,568	8,798	1,885	1,885
12	Sức khỏe	12,385	12,385	8,670	1,858	1,857
13	Thế giới	11,889	11,889	8,322	1,783	1,784
14	Thể thao	12,401	12,267	8,587	1,840	1,840
15	Thời sự	12,420	12,420	8,694	1,863	1,863
16	Tuần Việt Nam	11,280	11,276	7,893	1,692	1,691
17	Văn hóa - Giải trí	12,318	12,317	8,622	1,848	1,847
18	Ô tô - Xe máy	12,300	12,299	8,609	1,845	1,845
19	Đời sống	11,905	11,883	8,318	1,782	1,783

Kinh doanh có 12,643 bài, Nông thôn mới 969 bài; hai lớp Dân tộc thiểu số và miền núi, Công nghiệp hỗ trợ lần lượt có 1,088 và 1,292 bài. Nhiều lớp lớn có số lượng gần nhau do phạm vi phân trang, không phải do lấy mẫu ngẫu nhiên từ toàn bộ báo. Tỷ lệ lớn/nhỏ và trọng số train vì thế cần được đọc trong bản dữ liệu này: tỷ số giữa trọng số lớp lớn nhất và nhỏ nhất trong tập huấn luyện khoảng 13.05 lần.

Accuracy chịu ảnh hưởng nhiều hơn từ các lớp đông; Macro-F1 dành đóng góp ngang nhau cho mỗi lớp. Tuy nhiên, ít mẫu không phải nguyên nhân đơn độc của chất lượng thấp. Công nghiệp hỗ trợ có ít bài nhưng tín hiệu chủ đề tập trung; các lớp giao thoa có thể khó ngay



Hình 3.2: Ba tập dữ liệu có vai trò tách biệt; tập test nằm ngoài cập nhật, chọn bản lưu mô hình và hiệu chỉnh.



Hình 3.3: Phân bố 20 lớp của tập dữ liệu cuối 199,965 bài, sau khi bỏ bài trùng lặp nội dung.

cả khi số mẫu lớn. Phân tích thực nghiệm sẽ đối chiếu số lượng với precision/recall và hướng nhầm, thay vì mặc định tăng trọng số lớp giải quyết mọi lỗi.

Phân tầng giữ mỗi lớp trong ba tập; nó không làm cân bằng số mẫu giữa các lớp. Do đó, tập test vẫn thể hiện lớp Nông thôn mới nhỏ hơn nhiều lớp lĩnh vực, và tỷ lệ đúng tổng bị chi phối bởi các chuyên mục đông hơn. Đây là lý do dùng cả chỉ số tổng và theo lớp, thay vì oversample test để tạo một mức Accuracy dễ nhìn hơn.

Các nhãn bình luận và chuyên đề không chỉ khác nhau ở số lượng. Chúng có thể chứa từ vựng của lĩnh vực đang được bàn tới, khiến hai bài tương tự về chủ đề mang chuyên mục khác nhau. Trong thiết kế đầu vào không dùng URL/breadcrumb, bộ phân loại phải suy quyết định biên tập chỉ từ văn bản. Một phần độ khó vì vậy thuộc cách định nghĩa mục tiêu, không thể quy hết cho kích thước train.

3.3 Ghép văn bản, chuẩn hóa và phân đoạn từ

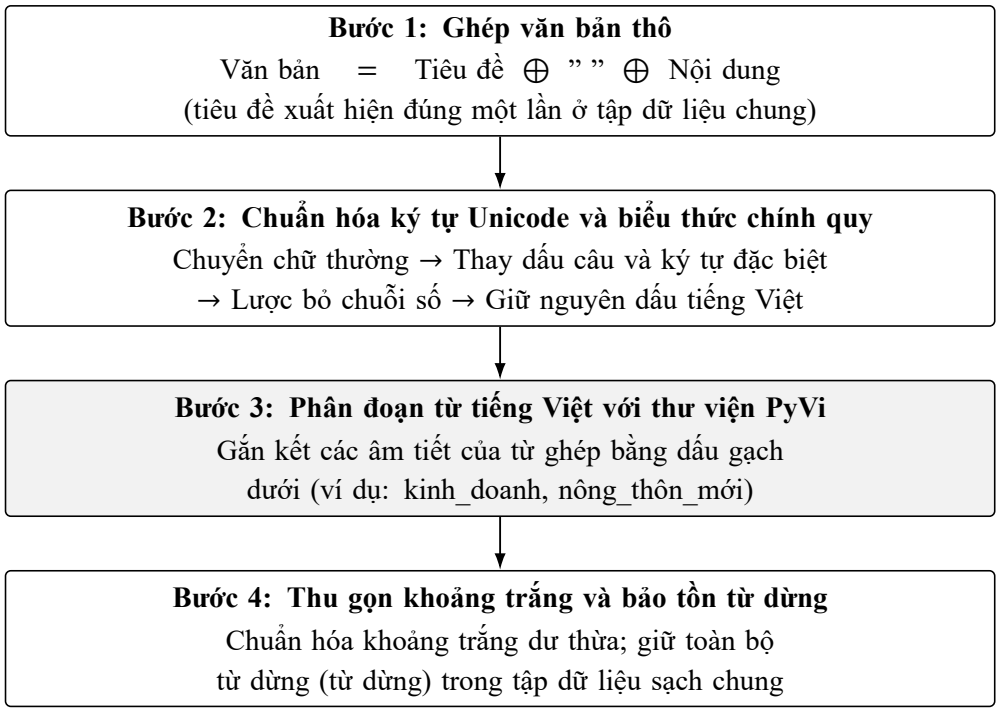
Tập dữ liệu chung ghép tiêu đề, một khoảng trắng và nội dung, với tiêu đề xuất hiện một lần. Thứ tự xử lý là chữ thường, thay ký tự ngoài \w,\s, bỏ chuỗi chữ số, PyVi và thu gọn khoảng trắng. Dấu tiếng Việt trong Unicode thông thường được giữ; dấu gạch dưới biểu diễn một từ nhiều âm tiết. Stopwords được giữ ở tập dữ liệu chung. SVM/LR loại từ dừng và lặp tiêu đề thêm hai lần sau khi chốt tập dữ liệu và chia tập. Khoảng trắng tiếng Việt có thể phân cách

Bảng 3.3: Trích đoạn UNIQLO từ output thật; ba trạng thái thể hiện thay đổi chữ số, dấu câu và đơn vị từ.

Bước	Trích đoạn thực tế
Ghép đầu vào	1 triệu trang phục UNIQLO tặng trẻ em, nạn nhân thiên tai, người tị nạn toàn cầu Đây là năm thứ 2 UNIQLO duy trì hoạt động quyên góp quần áo nằm trong khuôn khổ…
Bỏ chữ số	triệu trang phục uniqlo tặng trẻ em nạn nhân thiên tai người tị nạn toàn cầu đây là năm thứ uniqlo duy trì hoạt động quyên góp quần áo nằm trong khuôn khổ…
Phân đoạn từ	triệu trang_phục uniqlo tặng trẻ_em nạn_nhân thiên_tai người tị_nạn toàn_cầu đây là năm thứ uniqlo duy_trì hoạt_động quyên_góp quần_áo nằm trong khuôn_khổ sáng_…

âm tiết chứ chưa phải từ. PyVi nối các âm tiết thành đơn vị như trẻ_em, thiên_tai [15]. BPE là bước tiếp theo riêng của tokenizer PhoBERT: một đơn vị PyVi có thể gồm nhiều subword. Đơn vị từ, khoảng trắng và vị trí BPE không được dùng thay nhau khi đo chiều dài hay thiết kế cắt ngắn đầu vào.

Chữ thường làm mất case của tên riêng; loại chữ số làm mất năm, giá và số hiệu; thay dấu câu làm mất một phần ranh giới câu. Chưa có ablation xác nhận từng bước đều cải thiện F1. Quy trình phân loại không có bước NFC riêng, nên không cam kết bảo toàn mọi chuỗi Unicode có dấu tổ hợp. PhoBERT được tiền huấn luyện với phân đoạn của VnCoreNLP, trong khi thực nghiệm và app dùng PyVi [11, 18, 20]; sự nhất quán huấn luyện/suy luận chưa loại bỏ khác biệt



Tính nhất quán: Chuẩn hóa chung được thực hiện trước khi loại bỏ bài trùng lặp và chia tập. Biến đổi riêng (bỏ từ dừng cho SVM/LR, tokenizer BPE cho PhoBERT) chỉ diễn ra sau khi đã chốt phân chia tập train/val/test.

Hình 3.4: Chuẩn hóa chung trước loại bỏ bài trùng lặp; biến đổi riêng của từng mô hình diễn ra sau khi chốt tập dữ liệu.

với tiền huấn luyện.

3.4 Độ dài đầu vào và tác động của giới hạn token

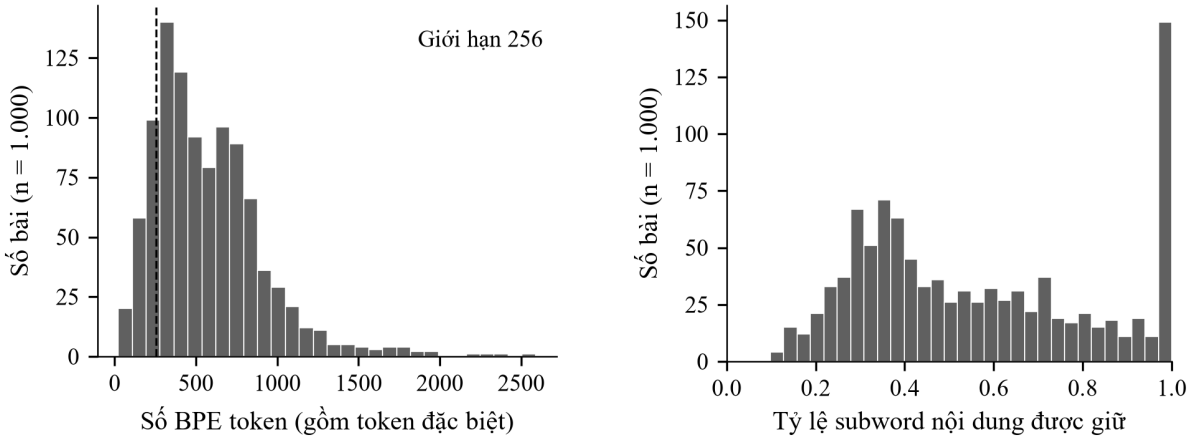
Bảng 3.4 nêu rõ giai đoạn tập dữ liệu và đơn vị đo. Trung vị là mốc chia đôi số bài theo độ dài; P95 là mốc mà 95% số bài không vượt quá. Các thống kê trước khi bỏ bài trùng lặp không được coi như số mẫu của tập dữ liệu cuối; số ký tự nội dung cũng khác số từ của chuỗi ghép tiêu đề–nội dung. P95 của các hàng sau khi bỏ bài trùng lặp được tính từ mảng độ dài đã xuất, không cần chạy lại tokenizer. Khảo sát BPE trên 1,000 bài, seed 42, tính cả token đặc biệt: trung bình

Bảng 3.4: Chiều dài ở các mức biểu diễn và bản dữ liệu. Dấu – là thống kê không dùng tại đây.

Văn bản / giai đoạn	Đơn vị	Trung bình	Trung vị	P95
Tiêu đề; trước khi bỏ bài trùng lặp	Đơn vị cách trắng	14.26	15	–
Nội dung; trước khi bỏ bài trùng lặp	Đơn vị cách trắng	693.28	617	–
Nội dung; tập dữ liệu cuối	Ký tự	3,198.85	2,840	6,645
Tiêu đề + nội dung; tập dữ liệu cuối	Từ PyVi	524.16	465	1,090
Mẫu BPE 1,000 bài	Subword + token đặc biệt	572.973	510.5	1,169.35

572.973, trung vị 510.5; 85.4% vượt 256 token. Head–Tail giữ trung bình 56.32% token nội dung trong mẫu này. Các tỷ lệ không đo phần ngữ nghĩa được bảo toàn và không phải một lần đếm toàn bộ tập dữ liệu. BiLSTM giới hạn 512 từ PyVi; trên tập dữ liệu cuối, 44.14% bài vượt độ dài này và tỷ lệ từ giữ trung bình là 87.13%. Hai kết quả không trực tiếp so với 56.32% của PhoBERT: khác đơn vị, phạm vi khảo sát và tokenizer. SVM/LR dùng toàn văn nhưng nén văn bản thành vector thưa, làm mất thứ tự xa. Mỗi hướng giữ và bỏ loại thông tin khác nhau.

Một tỷ lệ giữ cao ở mức token chưa chứng minh những đoạn quyết định nhãn đã được giữ. Chẳng hạn, thông tin chủ đề có thể lặp ở mở đầu, hoặc chỉ rõ ở phần giữa bị cắt; thống kê chiều dài không phân biệt hai trường hợp. Ngược lại, bỏ một phần lớn token không nhất thiết làm mất tương ứng từng đó tín hiệu nếu bài chứa lặp và đoạn phụ. Báo cáo dùng thống kê để xác định mức độ phổ biến của cắt ngắn đầu vào, không đổi nó thành một ước lượng mất ngữ nghĩa.



(a) Độ dài BPE, gồm token đặc biệt. **(b)** Tỷ lệ subword nội dung được giữ.

Hình 3.5: Khảo sát 1,000 bài: giới hạn 256 vị trí làm mất một phần đáng kể chuỗi đầu vào.

Nội dung dài nhất trong mảng tập dữ liệu có 131,081 ký tự, còn chuỗi chuẩn hóa dài nhất có 20,547 từ PyVi. Các cực trị cho thấy không thể giả định mọi bài nằm gần giá trị trung bình hoặc trung vị. Chúng cần được rà soát theo bài để phân biệt nội dung dài thật, đoạn liên quan và lỗi trích xuất. Báo cáo không dùng cực trị để suy một giới hạn cắt mới chưa được thử trên validation.

Giới hạn chuỗi tác động vào vị trí, còn từ vựng tác động vào kiểu token. BiLSTM có thể giữ đủ độ dài một bài nhưng vẫn thay từ lạ bằng UNK; PhoBERT có thể biểu diễn từ lạ bằng nhiều subword nhưng vì thế sớm đạt giới hạn 256 hơn. TF–IDF dùng toàn bài, song từ không thuộc từ vựng train hoặc bị bộ lọc số tài liệu chứa từ loại sẽ không có chiều riêng. Mỗi cơ chế mất thông tin khác nhau, nên "không cắt bài" không đồng nghĩa giữ toàn bộ thông tin văn bản.

Khảo sát BPE dùng mẫu cố định 1,000 bài giúp tái kiểm tra biểu đồ phân bố và tỷ lệ giữ mà không mã hóa lại tập dữ liệu. Kết quả phải đi cùng cỡ mẫu và seed, trong khi phân bố lớp/split dùng toàn tập dữ liệu cuối. Một biểu đồ mẫu có thể mô tả độ dài phổ biến nhưng chưa đại diện từng lớp ít bài với độ chính xác như toàn bộ mẫu. Khi đánh giá tác động cắt ngắn đầu vào theo nhãn, cần một phân tích có số mẫu và độ bất định riêng.

3.5 Loại bỏ bài trùng lặp, phòng ngừa rò rỉ dữ liệu và giới hạn dữ liệu

Nếu nhiều bản ghi có văn bản giống nhau sau chuẩn hóa nhưng nhãn khác nhau, cả nhóm bị loại thay vì tùy chọn một nhãn. Dòng lặp cùng nhãn được giữ một đại diện. Quy tắc này áp dụng trước khi chia tập, bỏ từ dừng và tăng trọng số tiêu đề, để bốn quy trình phân loại dựa trên cùng tập bài chứ không có bốn tập dữ liệu khác nhau do cách tạo đặc trưng.

Chín phép đối chiếu giữa ba tập theo URL, văn bản thô và văn bản chuẩn hóa không phát hiện giao nhau chính xác. Từ vựng BiLSTM và từ vựng/IDF TF–IDF chỉ học từ tập huấn luyện; validation/test dùng các biến đổi cố định. Đối chiếu mã băm trùng khớp chưa đánh giá bài viết lại, gần trùng hoặc nhiều bài về cùng sự kiện. Phép chia ngẫu nhiên cùng nguồn vì vậy không mô phỏng đầy đủ dự đoán tin tương lai.

Bộ nhớ đệm (cache) lưu kết quả xử lý để có thể dùng lại mà không tính toán từ đầu. Cache có mã nhận diện dữ liệu gắn bản dữ liệu, mapping, split và biểu diễn; số dòng bằng nhau chưa đủ để tái sử dụng cache. Mỗi notebook mô hình có cache riêng, không tham gia quá trình thực thi của app. Bản dữ liệu có thể còn quảng bá, đoạn liên quan hoặc nhiễu trích xuất, chưa được kiểm toán ngữ nghĩa toàn bộ. Dữ liệu sạch được hiểu là đạt quy tắc xác minh và kiểm tra đã công bố; đường dẫn tái hiện được tập trung tại Phụ lục A.

4. Biểu diễn và kiến trúc bốn phương pháp

Chương 2 xác định ba hướng biểu diễn được lựa chọn. Chương này mô tả đúng các cấu hình thực thi: TF–IDF với SVM/LR, LSTM hai chiều với vector biểu diễn từ học từ đầu và PhoBERT-base-v2 có tiền huấn luyện. Các khác biệt về từ dừng, tiêu đề và đơn vị cắt được công khai để diễn giải kết quả so sánh.

4.1 TF–IDF và hai bộ phân loại tuyến tính

SVM và Logistic Regression dùng cùng cách tạo đặc trưng từ tập dữ liệu chuẩn hóa. Sau khi chốt tập dữ liệu và phép chia, tiêu đề đã phân đoạn được lặp thêm hai lần trước chuỗi tiêu đề–nội dung, tạo ba lần xuất hiện của tiêu đề. Hai notebook dùng danh sách từ dừng riêng nhưng có cùng nội dung, gồm 1,959 mục sau chuẩn hóa; hash bắt đầu 8560838c. Stopword được loại ở bước biểu diễn cho mô hình, không dùng để xác định nhóm trùng của tập dữ liệu chung.

4.1.1 Từ tần suất đến vector thưa

Với từ hoặc cụm từ j và tài liệu d, biểu diễn dùng TF logarit, IDF có làm trơn và chuẩn hóa L_2:

$$\mathrm{tf}_{d,j} = 1 + \log n_{d,j} \quad (n_{d,j} > 0), \tag{4.1}$$

$$\mathrm{idf}_j = \log \frac{1 + N_{train}}{1 + \mathrm{df}_j} + 1, \tag{4.2}$$

$$v_d = \frac{\mathrm{tf}_d \odot \mathrm{idf}}{\| \mathrm{tf}_d \odot \mathrm{idf} \|_2}. \tag{4.3}$$

Từ vựng và IDF chỉ được xây dựng từ tập huấn luyện. Tập xác thực và tập kiểm tra được biến đổi bằng các tham số đã cố định. Cấu hình được chọn giữ unigram và bigram, tối đa 150,000 đặc trưng, min_df=3, max_df=0.98; số chiều thực tế là 150,000. Không có SVD trong quy trình phân loại này. Các vector được lưu và tính toán dưới dạng thưa, không tạo ma trận đặc toàn tập dữ liệu.

Việc lặp tiêu đề tăng tần suất tín hiệu đầu bài, nhưng hệ số ba không có nghĩa giá trị TF–IDF cuối tăng đúng ba lần: TF logarit và chuẩn hóa L_2 còn biến đổi tỷ lệ. Bigram được tạo trên chuỗi ghép, nên cũng có thể xuất hiện ở ranh giới các lần lặp tiêu đề. Toàn văn không bị cắt theo số vị trí như mô hình nơ-ron, song thứ tự xa và cấu trúc lập luận không được giữ trong một vector TF–IDF [8].

4.1.2 SVM tuyến tính và Logistic Regression

LinearSVC dùng điều chuẩn L_2, squared hinge loss và cơ chế một-chống-phần-còn-lại cho 20 lớp. Trong bộ phân loại lớp c, nhãn nhị phân $y_{i,c} \in \{-1, +1\}$ tạo hạng mất mát

$$\ell_{i,c} = \left[\max(0.1 - y_{i,c}(w_c^\top v_i + b_c))\right]^2. \tag{4.4}$$

Hệ số C điều khiển đánh đổi điều chuẩn và mất mát. Điểm $s_c = w_c^\top v + b_c$ là điểm biên (margin), chưa phải xác suất; nhãn được chọn bằng argmax của 20 điểm. SVM trong thực nghiệm là tuyến tính, khác kernel RBF của một số nghiên cứu ở chương 2.

Logistic Regression dùng solver L-BFGS cho phân loại multinomial với điều chuẩn L_2. Logits tuyến tính được chuẩn hóa thành xác suất lớp:

$$p_c(v) = \frac{\exp(w_c^\top v + b_c)}{\sum_{j=1}^{20} \exp(w_j^\top v + b_j)}. \tag{4.5}$$

Mục tiêu là mất mát logarit có trọng số lớp, khác squared hinge của SVM. Cả hai có cùng thông tin từ vựng, nhưng nghiệm tối ưu và thang điểm khác nhau. Xác suất do LR học vẫn cần kiểm tra hiệu chỉnh xác suất; tối ưu mất mát logarit không bảo đảm độ tin cậy đúng trên mọi nhóm bài.

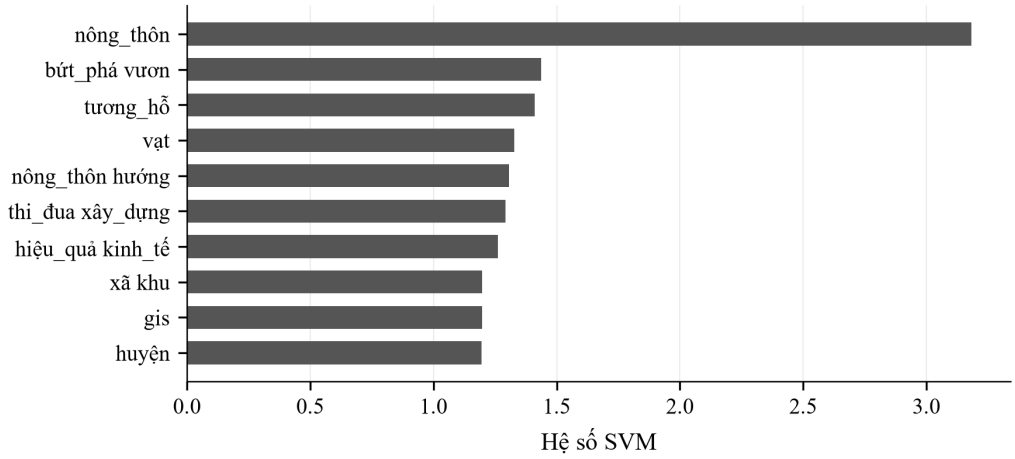
Bảng 4.1: Hai cấu hình tuyến tính được chọn bằng validation.

Thuộc tính	SVM	Logistic Regression
Đặc trưng	TF–IDF unigram/bigram, 150,000 chiều	
Trọng số lớp	balanced	balanced
C	0.5	3.0
Solver	liblinear, dual auto	L-BFGS
Ngưỡng hội tụ	10^{-4}	10^{-4}
Số vòng tối ưu	119	138
Giới hạn vòng	5,000	500
Luồng CPU	4	4

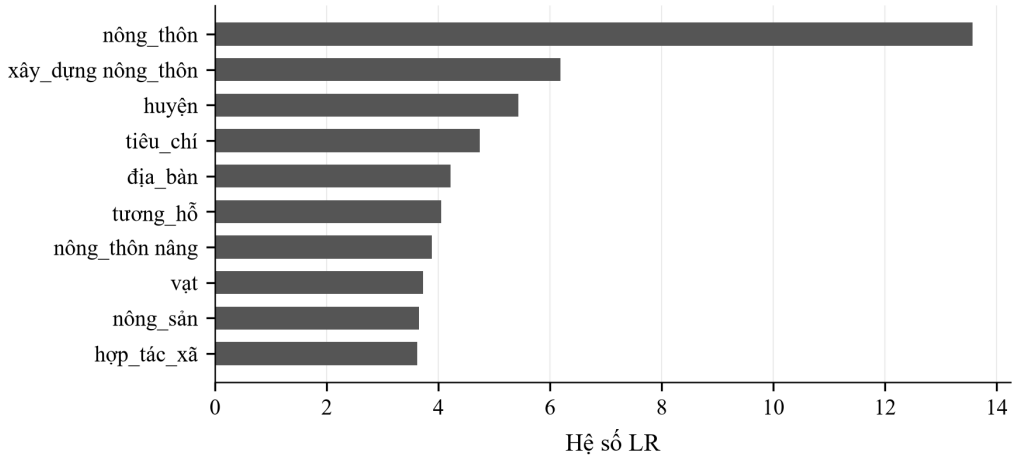
4.1.3 Đặc trưng học được và giới hạn diễn giải

Hệ số dương lớn cho biết đặc trưng tăng điểm của lớp trong mô hình đã ước lượng tham số. Với Nông thôn mới, SVM có hệ số 3.1823 cho nông_thôn; LR có hệ số 13.5690 cho cùng đặc trưng và 6.1810 cho bigram xây_dựng nông_thôn. Không so độ lớn giữa hai mô hình như một thang quan trọng chung: mục tiêu, C và thang điểm số khác nhau. Hệ số cũng không phải tác động nhân quả hoặc một lời giải thích đầy đủ cho từng bài.

Việc bỏ từ dừng giảm một phần vốn từ thường xuất hiện, nhưng cũng có thể bỏ tín hiệu diễn ngôn hoặc cách viết của tòa soạn. N-gram còn khai thác cụm cục bộ sau bước lọc, với từ nhiều âm tiết đã được nối bằng PyVi. Vì thế, một bigram là hai đơn vị phân đoạn, không nhất



(a) Linear SVM.



(b) Logistic Regression.

Hình 4.1: Đặc trưng có hệ số dương lớn ở Nông thôn mới; thang hệ số không trực tiếp tương đương giữa hai mô hình.

thiết hai âm tiết cách trắng ban đầu. Từ vựng train cố định cũng có thể bỏ thuật ngữ mới ở test; khác biệt này không đồng nhất với UNK của mô hình chuỗi.

Một hệ số lớn không có nghĩa mọi bài chứa từ đó phải nhận nhãn tương ứng. Điểm tuyến tính còn cộng các đặc trưng khác và bias, trong khi giá trị đặc trưng đã qua IDF cùng chuẩn hóa vector. Bỏ một từ khỏi một bài có thể thay chuẩn hóa và làm đổi cả vector. Phân tích hệ số cung cấp tín hiệu toàn cục của mô hình đã huấn luyện, chưa là phép giải thích cục bộ có kiểm soát cho một dự đoán cụ thể.

4.2 Biểu diễn chuỗi và kiến trúc BiLSTM

Phương pháp LSTM trong thiết kế được thực thi bằng biến thể hai chiều BiLSTM. Vector biểu diễn từ được khởi tạo và học từ train, không nạp Word2Vec, PhoW2Vec hay encoder tiền huấn luyện. Chuỗi đầu vào giữ từ dừng và chỉ ghép tiêu đề một lần với nội dung. Vì vậy, đây là một đối chứng học biểu diễn tuần tự có giám sát, khác cả TF–IDF và PhoBERT có tiền huấn

luyện.

4.2.1 Từ vựng, từ ngoài từ vựng và Head–Tail

Từ vựng đếm từ trên train, lấy từ có tần suất ít nhất hai, sắp theo tần suất giảm rồi theo từ điển khi bằng nhau. Tổng 50,000 ID gồm PAD bằng 0, UNK bằng 1 và 49,998 từ. Token ngoài từ vựng được đưa về UNK; vector biểu diễn từ PAD không được cập nhật như từ nội dung. Không học từ vựng từ validation/test để giảm tỷ lệ từ lạ một cách không hợp lệ.

Cấu hình được chọn giới hạn 512 *từ đã phân đoạn*. Bài dài giữ 256 từ đầu và 256 từ cuối, không thêm BOS/EOS. Bài ngắn được giữ đầy đủ; mỗi batch pad đến độ dài lớn nhất của các mẫu trong batch, rồi dùng chuỗi nén theo độ dài thực (packed sequence) để bỏ padding khỏi quá trình recurrent. Head–Tail vẫn bỏ phần giữa và nối hai đoạn không kề nhau, nhưng đơn vị cắt khác 254 subword nội dung của PhoBERT.

Trên tập dữ liệu 199,965 bài, 44.14% vượt 512 từ; tỷ lệ từ giữ trung bình là 87.13%. Hai giá trị được tính từ độ dài đã xuất, không phải một lần mã hóa token mới. Tỷ lệ từ ngoài từ vựng (out-of-vocabulary, OOV) trên toàn chuỗi train/validation/test lần lượt là 0.7782%, 0.8714% và 0.8696%. Kiểm tra đối chiếu OOV tính trước cắt Head–Tail; không đồng nhất với tỷ lệ UNK trong tensor cuối hoặc lượng thông tin ngữ nghĩa bị mất.

Việc đặt UNK chỉ xử lý khả năng tra ID, không bổ sung nghĩa riêng cho mỗi từ lạ. Những từ ngoài từ vựng khác nhau cùng đi vào một vector biểu diễn từ UNK; chúng vẫn có thể được phân biệt một phần bởi các từ bao quanh, nhưng thông tin từ vựng gốc đã mất. Tỷ lệ OOV thấp trên bản dữ liệu chưa dự báo tỷ lệ ở tin tương lai chứa tên riêng và thuật ngữ mới.

Packed sequence giúp trạng thái kết thúc phản ánh độ dài thật của bài, tránh recurrent tiếp tục quét nhiều PAD tới độ dài batch. Hai hướng đều quét chuỗi sau Head–Tail; hướng ngược không khôi phục phần giữa đã bị bỏ. Khi nối hai đoạn xa nhau, mô hình vẫn coi chúng là một chuỗi kề nhau, một giả định chung của cách cắt này với PhoBERT.

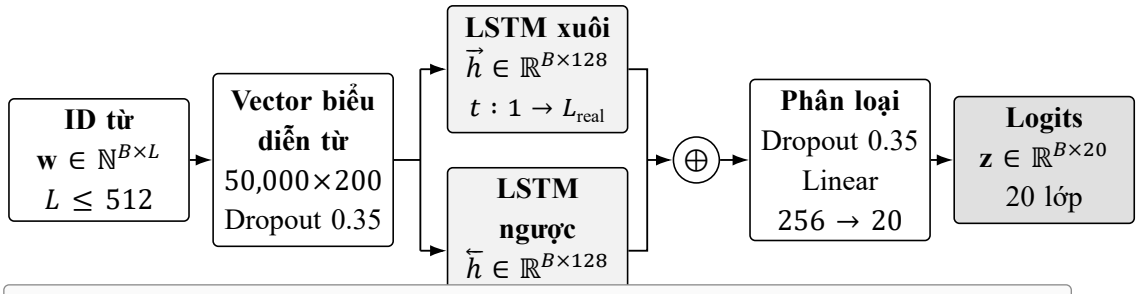
4.2.2 Cơ chế cổng và trạng thái chuỗi

LSTM duy trì trạng thái ẩn h_t cùng trạng thái ô nhớ c_t. Cổng quên quyết định phần trạng thái cũ giữ lại, cổng đầu vào điều chỉnh phần thông tin mới ghi vào, cổng đầu ra điều chỉnh thông tin đưa ra trạng thái ẩn. Dạng cập nhật chuẩn giải thích vai trò của các cổng trong lớp hồi tiếp được dùng:

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \qquad h_t = o_t \odot \tanh(c_t). \tag{4.6}$$

Các vector cổng có giá trị sigmoid và được học từ vector biểu diễn từ hiện tại cùng trạng thái ẩn trước đó; trạng thái ô nhớ ứng viên dùng biến đổi phi tuyến. Đây là trạng thái theo chuỗi, không phải một đặc trưng TF–IDF được coi tùy ý như trục thời gian. Cổng cho phép điều chỉnh truyền thông tin nhưng không bảo đảm nhớ đủ mọi chi tiết qua một bài dài [8].

Hai hướng của BiLSTM có tham số riêng và quét theo hai thứ tự ngược nhau. Chúng cung cấp hai cách tổng hợp cùng chuỗi đã giữ, rồi đầu phân loại nhận vector nối; số lớp hồi tiếp vẫn là một, không biến thành mạng nhiều tầng vì có hai hướng. Dropout bên ngoài lớp hồi tiếp có vai trò điều chuẩn, không bổ sung token hoặc tri thức ngôn ngữ tiền huấn luyện.



Thông số BiLSTM (10,343,060 tham số): Vector biểu diễn từ chiếm 10,000,000 tham số ($50{,}000 \times 200$), lớp recurrent BiLSTM một tầng chiếm 337,920 tham số, đầu phân loại Linear chiếm 5,140 tham số ($256 \times 20 + 20$). Dùng packed sequence bỏ padding; lấy trạng thái cuối thực tế h_{end} của hai hướng.

Hình 4.2: BiLSTM thực thi trong notebook: vector biểu diễn từ học từ đầu, packed sequence, ghép hidden cuối hai hướng và đầu phân loại 20 lớp. Dropout vector biểu diễn từ được lược trong khối để giữ sơ đồ gọn.

4.2.3 Trạng thái hai chiều và đầu phân loại

Vector biểu diễn từ có chiều 200; một lớp hồi tiếp có trạng thái ẩn 128 chiều cho mỗi hướng. Các cổng quên, đầu vào và đầu ra lần lượt điều chỉnh thông tin cũ giữ lại, thông tin mới ghi vào trạng thái ô nhớ và phần trạng thái được xuất theo chuỗi [8]. Mô hình quét chuỗi đã cắt ở cả hai hướng, rồi ghép trạng thái kết thúc phép quét xuôi và ngược:

$$r = [\vec{h}_{\text{end}}; \overleftarrow{h}_{\text{end}}] \in \mathbb{R}^{256}, \qquad z = W\,\text{Dropout}(r) + b \in \mathbb{R}^{20}. \tag{4.7}$$

Trạng thái kết thúc hướng ngược không phải trạng thái ẩn tại vị trí cuối theo thứ tự đọc xuôi. Mã nguồn lấy hai trạng thái ẩn cuối của hai hướng từ chuỗi nén theo độ dài thực (packed sequence), không lấy trung bình các token. Dropout, tức ngẫu nhiên bỏ một phần phần tử khi huấn luyện để hạn chế phụ thuộc quá mức, có tỷ lệ 0.35 và đặt sau vector biểu diễn từ và trước lớp tuyến tính; dropout giữa các tầng hồi tiếp bằng 0 vì chỉ có một tầng.

Mô hình có 10,343,060 tham số: vector biểu diễn từ chiếm 10,000,000, BiLSTM 337,920 và đầu phân loại 5,140. Phần lớn tham số thuộc bảng từ, không phải lớp hồi tiếp. Kích thước nhỏ hơn PhoBERT không tự xác định chất lượng; từ vựng, số từ giữ, cách tổng hợp chuỗi và chế độ tiền huấn luyện đều khác nhau. Phần tiếp theo trình bày encoder ngữ cảnh và cấu hình PhoBERT được dùng trong cùng bài toán.

4.3 PhoBERT, BPE và Head–Tail

Với tin tức giao thoa chủ đề, cùng một từ như "thị trường" có thể chỉ thị trường tài chính, du lịch hoặc tiêu dùng; encoder tạo biểu diễn phụ thuộc đoạn văn bản được giữ để cung cấp tín hiệu cho đầu phân loại.

Encoder (bộ mã hóa) Transformer là thành phần chuyển chuỗi token thành các vector ngữ cảnh. Nó tạo biểu diễn của mỗi vị trí dựa trên các vị trí còn lại trong đoạn văn bản được giữ. Mô hình tiền huấn luyện cung cấp tham số đã học các quy luật ngôn ngữ; fine-tuning điều chỉnh

biểu diễn và đầu phân loại theo 20 nhãn của bài toán. BERT là một cơ sở của hướng học biểu diễn hai chiều và fine-tuning cho tác vụ cụ thể [4]; RoBERTa nghiên cứu các thay đổi trong quy trình tiền huấn luyện BERT [9]. PhoBERT tập trung vào tiếng Việt [11].

Bài tập lớn sử dụng vinai/phobert-base-v2. Theo tài liệu mô hình chính thức, bản base-v2 có quy mô khoảng 135 triệu tham số, độ dài tối đa 256 và tập dữ liệu tiền huấn luyện gồm 20 GB Wikipedia/tin tức cùng 120 GB OSCAR-2301 [18]. Tập dữ liệu này là dữ liệu tiền huấn luyện của mô hình nền. Dữ liệu có nhãn của bài tập lớn dùng để fine-tuning và đánh giá theo phép chia đã trình bày ở chương dữ liệu. Báo cáo không coi số liệu hiệu năng của nhà phát triển PhoBERT ở các benchmark khác là kết quả của bài tập lớn.

4.3.1 Phân đoạn từ và mã hóa BPE

Sau PyVi, chuỗi được mã hóa bởi PhobertTokenizer cùng vocab.txt và bpe.codes. Các từ phổ biến có thể được biểu diễn gọn, trong khi một từ ít gặp có thể bị chia thành nhiều subword. Do đó, số token không bằng số từ, và một bài có cùng số từ với bài khác vẫn có thể cần số vị trí khác nhau.

Mã hóa sinh các ID số nguyên, không truyền chuỗi tiếng Việt trực tiếp vào mạng nơ-ron. ID được tra trong ma trận embedding để lấy vector biểu diễn token; attention mask cho biết vị trí nào thuộc văn bản thật. Từ vựng có 64,001 mục, bao gồm các token đặc biệt. Trong cấu hình, token bắt đầu có ID 0, padding có ID 1 và token kết thúc có ID 2. Những ID này phải được lấy từ tokenizer tương ứng với bản lưu mô hình; thay tokenizer bằng một phiên bản khác có thể làm tensor vẫn đúng kích thước nhưng sai ý nghĩa.

Tokenizer và cấu hình nhãn là một phần của gói mô hình, cùng với trọng số và tham số hiệu chỉnh. Dịch vụ sử dụng local_files_only=True, nên suy luận không phụ thuộc vào việc tải một tokenizer mới từ mạng trong lúc khởi động. Đây là điều kiện quan trọng để đối chiếu notebook với ứng dụng.

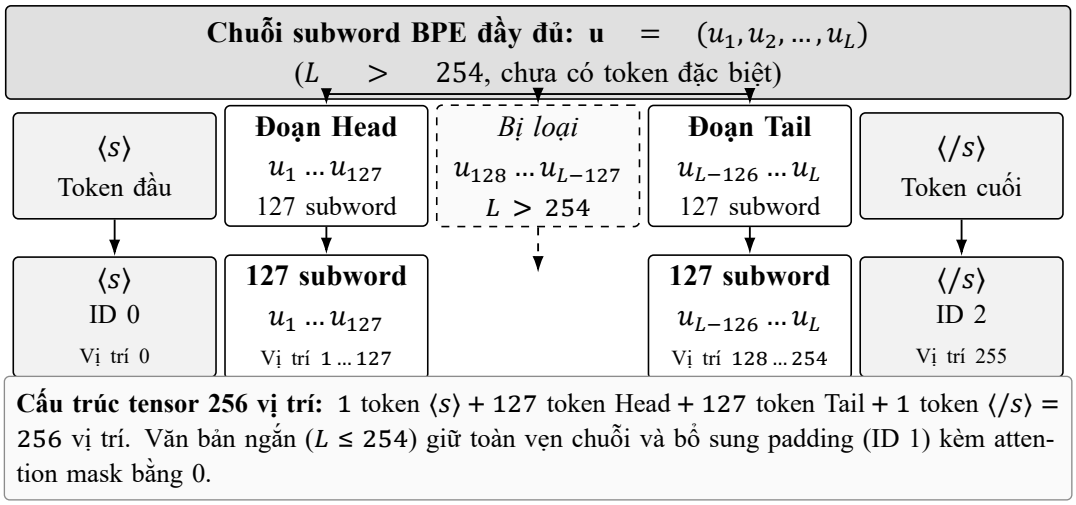
4.3.2 Lựa chọn Head–Tail cho bài báo dài

Giới hạn 256 vị trí gồm cả hai token đặc biệt. Nếu chuỗi BPE không có token đặc biệt dài $L > 254$, đầu vào được tạo như sau:

$$s = [\langle s\rangle, u_1, \dots, u_{127}, u_{L-126}, \dots, u_L, \langle /s\rangle]. \tag{4.8}$$

Nếu $L \leq 254$, chuỗi được mã hóa đầy đủ, thêm token bắt đầu/kết thúc và padding đến 256 vị trí. Attention mask bằng 1 ở các vị trí có nội dung hoặc token đặc biệt và bằng 0 ở padding. Hai nhánh được kiểm tra ở các ranh giới 253, 254, 255 và 256 token để tránh lỗi thêm token đặc biệt hoặc cắt lệch một vị trí.

Với bài dài, phần đầu (head) chứa tiêu đề và đoạn mở đầu, trong khi phần cuối (tail) chứa các đoạn kết. Giả thiết sử dụng là hai vùng này có thể chứa tín hiệu chủ đề hữu ích. Tuy nhiên, phần giữa có thể chứa lập luận, tên tổ chức hoặc sự kiện quyết định nhãn; toàn bộ vùng đó bị loại nếu vượt giới hạn. Head–Tail cũng nối hai vùng không kề nhau trong bản gốc thành hai đoạn kề nhau trong tensor. Không có dấu phân cách chuyên biệt để mô hình biết khoảng giữa bị bỏ.



Hình 4.3: Cách ghép Head–Tail; dấu token được minh họa theo ký hiệu của tokenizer PhoBERT.

Ở mức token, lựa chọn được thực hiện sau BPE nên có thể cắt giữa các subword của một từ. Điều này khác với lấy 127 từ đầu và 127 từ cuối. Các vị trí được đánh lại theo chuỗi ghép 256 token; chúng không giữ tọa độ tuyệt đối trong bài báo dài. Đây là một phép nén đầu vào có mất thông tin, không phải cơ chế attention trên toàn bộ bài.

4.3.3 Chi phí và các phương án so sánh

Attention chuẩn xét các cặp vị trí nên ma trận attention mỗi đầu attention có L^2 phần tử. Giới hạn $L = 256$ giúp kiểm soát bộ nhớ và thời gian khi fine-tuning. Tăng gấp đôi chiều dài làm số phần tử ma trận cặp tăng gấp bốn, trước khi tính các chi phí khác. FFN và phép chiếu cũng đóng góp đáng kể; không thể mô tả toàn bộ quá trình thực thi chỉ bằng hạng L^2.

Các phương án cần so sánh trong một thực nghiệm bổ sung gồm chỉ giữ đoạn đầu (head-only), chỉ giữ đoạn cuối (tail-only), lấy đoạn trượt với tổng hợp logits, biểu diễn phân cấp theo đoạn và encoder ngữ cảnh dài. Sản phẩm hiện có một cấu hình Head–Tail; không có phép ablation đã huấn luyện để chứng minh cấu hình này tối ưu hoặc tốt hơn head-only bao nhiêu. Số liệu độ dài hỗ trợ lý do nghiên cứu cách cắt, nhưng không thay thế phép so sánh thực nghiệm.

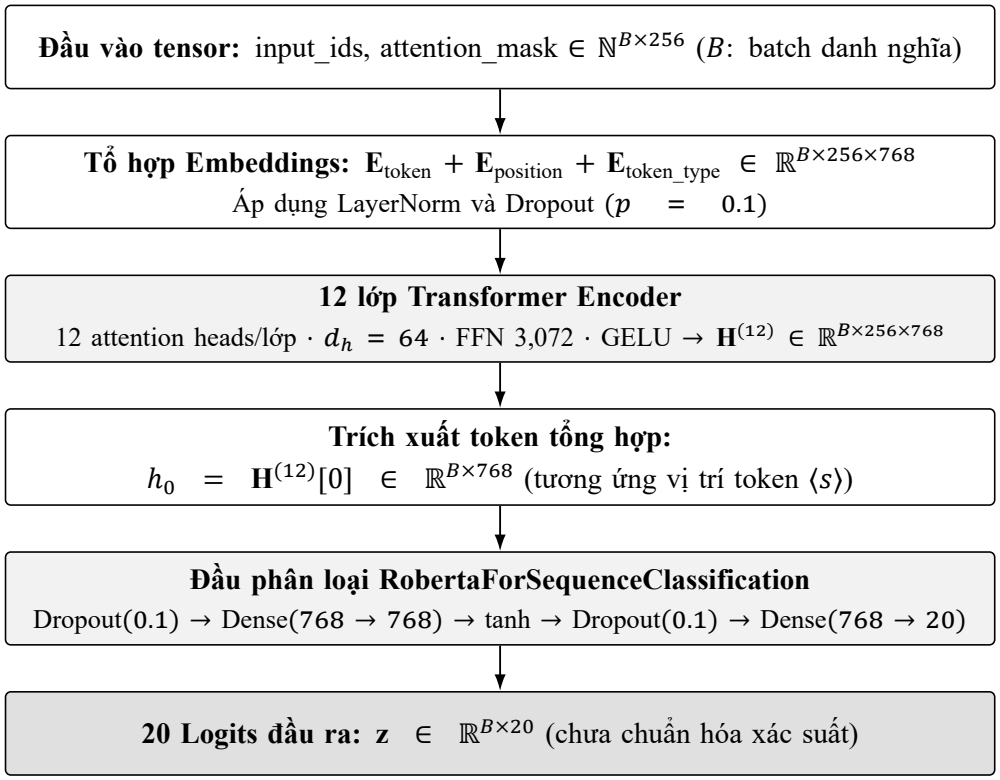
4.3.4 Cấu hình kiến trúc thực tế

Giá trị 258 của bảng vị trí không có nghĩa hệ thống nhận bài dài 258 token văn bản. Giới hạn quy trình phân loại là 256, còn chỉ số vị trí của RoBERTa có quy ước liên quan đến padding và offset. Không sử dụng một decoder sinh token hay cross-attention; cấu hình is_decoder=False và add_cross_attention=False phù hợp với encoder phân loại.

Với batch B, input IDs và mask có kích thước $B \times 256$. Lớp embedding và mỗi tầng encoder tạo tensor $B \times 256 \times 768$. Đầu phân loại lấy biểu diễn vị trí đầu tiên và sinh logits $B \times 20$. Vị trí đầu là token tổng hợp cho tác vụ phân loại; đây không phải lấy trung bình các token và cũng không phải sử dụng một vector TF–IDF.

Bảng 4.2: Thông số đọc từ config.json của bản lưu mô hình.

Thuộc tính	Giá trị
Kiến trúc	RobertaForSequenceClassification
Số lớp encoder	12
Chiều trạng thái ẩn	768
Số đầu attention	12
Chiều mỗi đầu attention	64
Chiều trung gian FFN	3,072
Từ vựng size	64,001
Số vị trí trong bảng embedding	258
Hàm kích hoạt	GELU
Số nhãn đầu ra	20



Quy mô tham số: PhoBERT-base-v2 có xấp xỉ 135 triệu tham số. Đầu phân loại dùng biểu diễn h_0 của token bắt đầu ⟨s⟩, không lấy trung bình chuỗi và không tạo đặc trưng TF–IDF.

Hình 4.4: PhoBERT và đầu phân loại trong RobertaForSequenceClassification.

4.4 Cơ chế self-attention, encoder và đầu phân loại

4.4.1 Vector biểu diễn từ và thông tin vị trí

Lớp embedding đầu vào kết hợp vector token, vector vị trí và vector loại token (token type). Bộ token type có một loại trong cấu hình này, nên không tạo hai segment độc lập cho tiêu đề và nội dung. LayerNorm và dropout được áp dụng trong thành phần vector biểu diễn từ trước encoder. Vector vị trí giúp mạng phân biệt thứ tự, vì phép attention tự nó không biết một từ đứng ở đầu hay cuối nếu không có thông tin vị trí.

Vì chuỗi Head–Tail được ghép trước khi mã hóa qua encoder, vector biểu diễn từ vị trí thể hiện thứ tự của chuỗi đã ghép. Mạng có thể học đặc trưng của đoạn đầu và đoạn cuối trong cách biểu diễn này, nhưng không được cung cấp số token bị loại ở giữa. Một giả thuyết cải thiện là bổ sung cơ chế biểu diễn theo đoạn; giả thuyết đó cần thay đổi thiết kế và đánh giá riêng.

4.4.2 Self-attention và xử lý theo ngữ cảnh

Theo cơ chế attention của Transformer [17], ở một đầu attention, biểu diễn H được chiếu thành query, key và value:

$$Q = HW_Q, \quad K = HW_K, \quad V = HW_V. \tag{4.9}$$

Các độ tương thích được chuẩn hóa theo chiều của đầu attention và chuyển thành trọng số:

$$A = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right), \qquad O = AV, \quad d_k = 64. \tag{4.10}$$

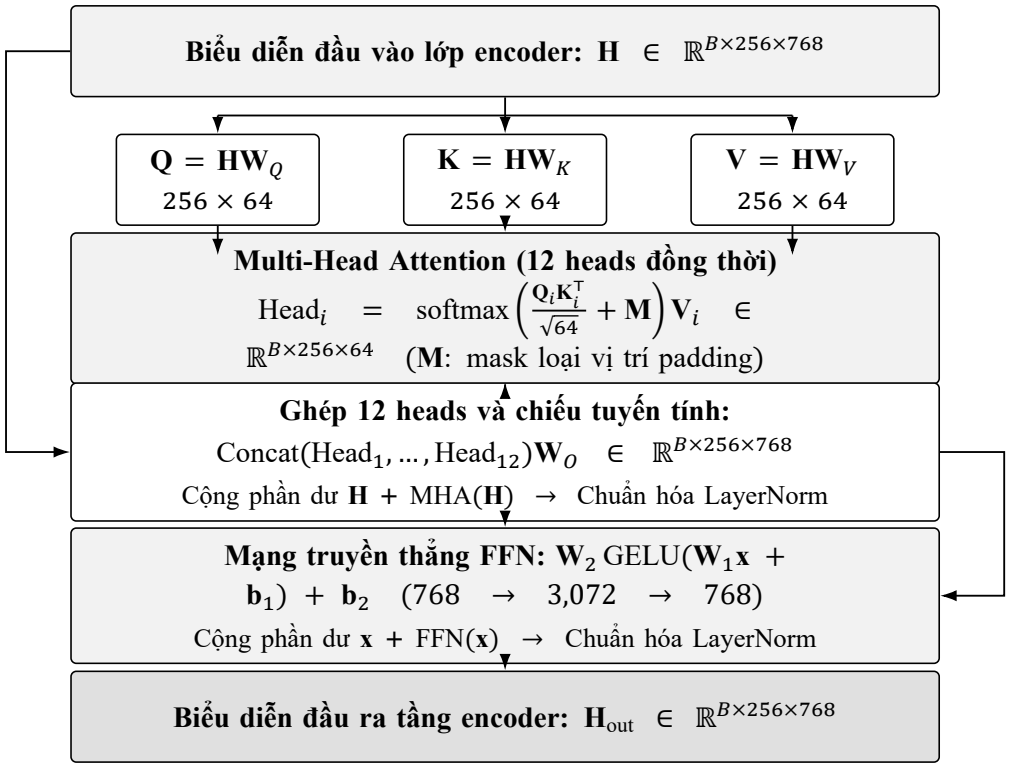
M là attention mask đã chuyển thành dạng cộng để các vị trí padding không được chọn làm key hữu ích. Attention trong encoder là hai chiều trên các vị trí hợp lệ, không dùng causal mask kiểu dự đoán token tiếp theo. Nhờ vậy, một vị trí có thể kết hợp ngữ cảnh ở cả phía trước và phía sau trong đoạn được giữ.

Mười hai đầu attention cung cấp các phép chiếu học được khác nhau; đầu ra được nối và chiếu về chiều 768. Không nên gán sẵn mỗi đầu attention cho một chức năng như "nhận biết pháp luật" nếu chưa có phân tích thực nghiệm. Attention là thành phần tính toán tạo biểu diễn, không tự động là lời giải thích nhân quả của nhãn cuối.

4.4.3 Residual, LayerNorm và feed-forward

Mỗi tầng có kết nối tắt (residual connection) và LayerNorm quanh các thành phần attention và FFN theo kiến trúc RoBERTa. Residual tạo đường truyền để biểu diễn đầu vào được giữ cùng phần biến đổi học được. LayerNorm ổn định thang giá trị trong chiều đặc trưng. FFN áp dụng các phép chiếu tại từng vị trí với chiều trung gian 3,072 và activation GELU, rồi trả về 768.

Attention cho phép trao đổi thông tin giữa các vị trí; FFN biến đổi đặc trưng của từng vị trí sau trao đổi. Qua 12 tầng, biểu diễn đầu vào không còn là vector từ độc lập mà đã kết hợp các



Hình 4.5: Tính toán bên trong một lớp encoder; mask loại vị trí padding khỏi attention.

quan hệ trong đoạn văn bản. Tuy nhiên, mọi quan hệ vẫn giới hạn ở các token đã chọn. Không tầng nào có thể đọc lại đoạn giữa bị bỏ bởi Head–Tail.

4.4.4 Đầu phân loại và logits

RobertaForSequenceClassification sử dụng đầu phân loại trên trạng thái ẩn của token đầu, gồm dropout, đặc $768 \rightarrow 768$, tanh, dropout và phép chiếu $768 \rightarrow 20$. Dropout hoạt động ở chế độ train; dịch vụ gọi eval() để tắt ngẫu nhiên dropout khi suy luận. Logits là điểm chưa chuẩn hóa; chúng có thể âm hoặc dương và không phải xác suất.

Softmax chuẩn chuyển logits thành phân bố:

$$p_c = \frac{\exp(z_c)}{\sum_{j=1}^{20} \exp(z_j)}. \tag{4.11}$$

Xác suất tổng bằng 1 giữa 20 lớp trong hệ thống chuyên mục. Điều đó không bảo đảm bài nằm trong hệ thống chuyên mục hoặc xác suất là ước lượng đúng của xác suất thực. Một đầu vào ngoài miền vẫn bị buộc vào một trong 20 lớp nếu không có cơ chế từ chối độc lập.

4.4.5 Quy mô tham số và ý nghĩa của fine-tuning

Bản lưu mô hình có 135,013,652 tham số. Các lớp embedding chiếm 49,353,216; 12 lớp encoder chiếm 85,054,464; đầu phân loại chiếm 605,972. Tổng số tham số được tính từ kiến trúc và tensor của gói mô hình, không suy ra bằng cách làm tròn nhãn "135M".

Fine-tuning cập nhật mô hình cho tác vụ chuyên mục, thay vì tiền huấn luyện lại từ đầu trên tập dữ liệu tin tức này. Đầu phân loại tương thích 20 lớp được khởi tạo khi tạo mô hình cho tác vụ; encoder nhận tham số mô hình nền. Toàn bộ quá trình dùng nhãn giám sát của tập dữ liệu. Đối chứng ở chương 6 cho biết hiệu quả các quy trình phân loại trên cùng test, nhưng chưa cô lập phần lợi ích riêng của tiền huấn luyện khỏi kiến trúc và biểu diễn.

Ở bước fine-tuning, gradient của đầu phân loại truyền qua biểu diễn h_0 vào encoder và vector biểu diễn từ. Encoder được cập nhật nhưng vẫn khởi đầu từ tri thức của bản lưu mô hình nền; "train từ đầu" trong một lượt huấn luyện mới không có nghĩa khởi tạo ngẫu nhiên toàn PhoBERT. Điều đó khác BiLSTM, nơi cả bảng vector biểu diễn từ lẫn lớp hồi tiếp học từ tập dữ liệu có giám sát. Đối chứng không có một PhoBERT khởi tạo ngẫu nhiên cùng kiến trúc để định lượng riêng đóng góp tiền huấn luyện.

4.4.6 Đọc một đầu attention và giới hạn giải thích

Với một bài, Q, K, V của từng đầu attention có 256 hàng và 64 chiều; ma trận $QK^{\top}$ có 256×256 điểm. Softmax theo các vị trí key cho mỗi query tạo trọng số để tổng hợp các hàng của V. Hệ số $1/\sqrt{d_k}$ điều chỉnh thang tích vô hướng trước chuẩn hóa; nó không là hệ số quyết định theo lớp τ_c. Padding mask tác động đến các vị trí được dùng làm key, không mang nhãn chuyên mục.

Mười hai đầu attention học các phép chiếu khác nhau, rồi nối đầu ra trước chiếu về chiều 768. Residual giữ đường truyền biểu diễn ban đầu cạnh phần biến đổi; FFN chuyển đặc trưng tại từng vị trí sau trao đổi thông tin. Qua nhiều tầng, token đầu có thể tổng hợp tín hiệu của đoạn đã giữ. Tuy nhiên, attention weight lớn không tự chứng minh token gây ra nhãn; muốn giải thích nhân quả cần một thiết kế thí nghiệm thay đổi có kiểm soát đầu vào hoặc phân tích đóng góp của đặc trưng, chưa có trong bài tập lớn.

4.5 Đối chiếu thông tin đầu vào và giới hạn diễn giải

Bốn quy trình phân loại cùng giải một bài toán và được đánh giá trên cùng tập test, nhưng không sử dụng cùng cơ chế biểu diễn hoặc lượng văn bản quan sát. SVM/LR khai thác TF–IDF toàn văn với tiêu đề tăng tần suất; BiLSTM xử lý tối đa 512 từ; PhoBERT sử dụng 256 subword với tiền huấn luyện. Vì vậy, chênh lệch thực nghiệm phản ánh toàn bộ cấu hình xử lý, chưa cô lập đóng góp riêng của kiến trúc.

BiLSTM có thể học trật tự token trong chuỗi nhưng chưa có tri thức từ một tập dữ liệu tiền huấn luyện. PhoBERT có tri thức ngôn ngữ nền song chỉ nhìn đoạn đã giữ; TF–IDF quan sát phần giữa mà hai mô hình nơ-ron có thể bỏ. Một đối chứng cố định lượng thông tin, nguồn vector biểu diễn từ và ngân sách tối ưu cần được thiết kế riêng trước khi kết luận nguyên nhân của khoảng cách F1.

5. Huấn luyện, lựa chọn cấu hình và hiệu chỉnh

5.1 Giao thức lựa chọn và thông số thực nghiệm

Các mô hình dùng cùng tập dữ liệu và phép chia, nhưng có mục tiêu tối ưu, trọng số và ngân sách lựa chọn khác nhau. Tất cả cấu hình được đánh giá trên test được chọn bằng validation. Từ vựng/IDF, từ vựng chuỗi và trọng số lớp chỉ học từ train; test không dùng chọn cấu hình, epoch, temperature hoặc hệ số quyết định. Validation còn được dùng ước lượng tham

Bảng 5.1: Thiết lập lựa chọn và thiết bị; cấu hình biểu diễn chi tiết ở chương 4.

Mô hình	Ngân sách lựa chọn	Tiêu chí và tối ưu	Thiết bị
SVM	12 cấu hình; chỉ học từ tập huấn luyện TF–IDF	Hội tụ squared hinge; Macro-F1 validation	CPU, 4 luồng
LR	12 cấu hình; chỉ học từ tập huấn luyện TF–IDF	Hội tụ mất mát logarit; Macro-F1 validation	CPU, 4 luồng
BiLSTM	3 cấu hình; tối đa 10 epoch/lượt	AdamW; bản lưu mô hình theo Macro-F1	RTX A3000
PhoBERT	Cấu hình cố định; tối đa 7 epoch	AdamW; bản lưu mô hình theo Macro-F1	RTX A3000

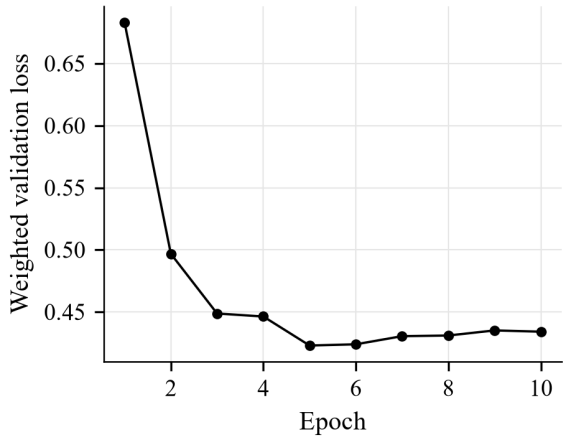
số hiệu chỉnh nên kết quả có phụ thuộc vào tập này; một tập hiệu chỉnh xác suất riêng là hướng kiểm tra thêm. Seed 42 khóa phép chia trong bản dữ liệu, chưa bảo đảm phép tính GPU giống bit giữa thiết bị/phiên bản. Ngân sách tìm cấu hình khác nhau cần được giữ khi diễn giải đánh đổi, thay vì coi đây là một phép thay kiến trúc có kiểm soát mọi yếu tố.

5.2 Huấn luyện SVM/LR và BiLSTM

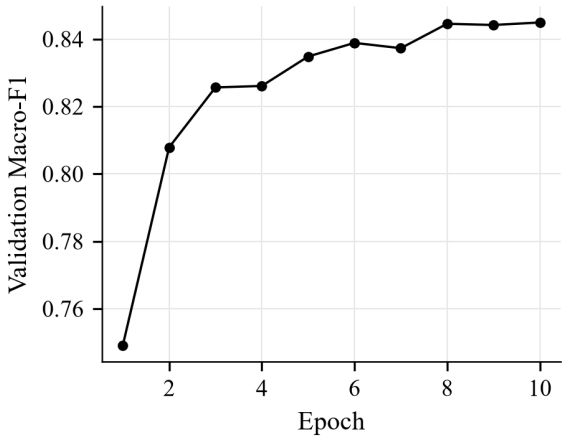
SVM và LR mỗi mô hình duyệt 12 cấu hình: hai cách tạo đặc trưng: từ đơn (unigram) và từ đơn kèm cặp từ liên tiếp (unigram–bigram), ba giá trị $C \in \{0.5; 1.5; 3.0\}$ và hai cách đặt trọng số lớp: bằng nhau (uniform) hoặc nghịch tần suất (balanced). Các cách biểu diễn TF–IDF chỉ học từ tập huấn luyện; mỗi bộ phân loại dùng ma trận của cách biểu diễn tương ứng. Validation chọn Macro-F1, rồi Weighted-F1 và Accuracy khi bằng nhau; không huấn luyện lại trên dữ liệu gộp train và validation. Cả 12 cấu hình của mỗi mô hình đều hội tụ; bảng 4.1 ghi nghiệm được chọn. Không có đường học theo epoch cho hai bộ phân loại này.

BiLSTM khảo sát ba cấu hình từ chiều dài 256/512 từ và số mũ trọng số 0.5/1.0. Cấu hình chọn giữ 512 từ và $\alpha = 0.5$; các thành phần kiến trúc ở mục 4.2 được cập nhật bằng AdamW. Trọng số dựa vào tần suất train và chuẩn hóa để trung bình theo số bài bằng 1:

$$\widetilde{w}_c = \left(\frac{N_{train}}{20 n_c}\right)^{\alpha}, \qquad w_c = \frac{\widetilde{w}_c}{\sum_j (n_j / N_{train}) \widetilde{w}_j}. \tag{5.1}$$



(a) Mất mát trên tập xác thực có trọng số.



(b) Macro-F1 trên tập xác thực.

Hình 5.1: Validation của cấu hình BiLSTM được chọn; cực tiểu loss và bản lưu mô hình tốt nhất thuộc các epoch khác nhau.

Nông thôn mới có trọng số 3.3510 trong cấu hình BiLSTM này, khác trọng số balanced của PhoBERT. Loss batch chia tổng cross-entropy có trọng số cho tổng weight các nhãn; loss epoch cộng tử số và mẫu số, không lấy trung bình ngang nhau giữa các batch có số mẫu khác nhau. Shuffle giữ phân bố train, không oversample validation/test.

Trọng số nghịch tần suất và căn bậc hai của trọng số này thể hiện mức ưu tiên khác nhau. Cấu hình $\alpha = 0.5$ làm chênh lệch weight bớt mạnh so với balanced đầy đủ; phép chuẩn hóa giữ thang trung bình theo phân bố train. Đây là quy tắc được khảo sát trong các ứng viên validation, không phải hệ số thêm sau khi thấy lớp hiếm trên test yếu. Không thể từ một nghiệm tốt nhất kết luận số mũ này tối ưu trên mọi bản dữ liệu.

Tính loss epoch bằng tổng tử và mẫu giúp batch cuối nhỏ không đóng góp như một batch đầy chỉ vì có một scalar loss. Gradient vẫn được tạo qua từng mini-batch để cập nhật tham số. Loss validation và F1 đánh giá khác nhau: loss nhạy với độ tự tin và trọng số nhãn, F1 chỉ phụ thuộc quyết định đúng/sai theo lớp. Giảm một đại lượng không bảo đảm tăng đại lượng còn lại.

Learning rate khởi đầu 10^{-3}, weight decay 10^{-4} và giới hạn chuẩn gradient ở 1.0. Batch train 64, validation/test 128, BF16 trên RTX A3000. Bộ điều chỉnh learning rate ReduceLROnPlateau theo dõi Macro-F1: giảm learning rate còn một nửa khi không đạt mức cải thiện tuyệt đối 0.001 (factor 0.5, patience 0) và learning rate tối thiểu 10^{-5}. Bản lưu mô hình giữ điểm validation tốt nhất, còn cơ chế dừng sớm cần vượt mốc trước ít nhất 0.001, patience 2. Hai tiêu chí không hoàn toàn đồng nhất. Loss validation thấp nhất ở epoch 5 (0.4230), Macro-F1 cao nhất ở epoch 10 (0.8449). Lượt đã chạy đủ 10 epoch; bản lưu mô hình vẫn giữ cải thiện nhỏ ở epoch cuối dù bộ đếm early stopping đạt patience. Learning rate cuối là 0.000125. Những diễn biến này không đủ để quy mọi biến thiên F1 cho overfitting hoặc khẳng định early stopping dừng trước giới hạn.

Điều kiện hội tụ của SVM/LR xác nhận optimizer đã đạt tiêu chí số của cấu hình, không chứng minh mô hình tối ưu về nhãn hay tổng quát hóa. Với LR, L-BFGS tối ưu mất mát logarit có điều chuẩn; với LinearSVC, mục tiêu squared hinge theo các bài toán một-chống-còn-lại. Cùng Macro-F1 validation để lựa chọn không làm hai mục tiêu train trở thành giống nhau. Số

vòng tối ưu vì thế không so trực tiếp như số epoch của mạng nơ-ron.

Mỗi cấu hình ứng viên được học từ train trước khi đo trên validation. Không dùng test để loại cấu hình ứng viên hội tụ nhưng có điểm thấp, và không gộp train/validation rồi ước lượng lại một gói mô hình có điều kiện khác với gói mô hình đo test. Kết quả được báo cáo thuộc cấu hình đã chọn, còn chi phí tìm cấu hình tính toàn bộ ứng viên. Khoảng giữa thời gian huấn luyện cấu hình được chọn và tìm cấu hình phản ánh khác biệt giữa dùng lại một thiết lập và tìm ra thiết lập đó.

Với BiLSTM, loss train giảm chưa là tiêu chí nạp bản lưu mô hình cuối. Chọn bản lưu mô hình theo Macro-F1 và bộ đếm early stopping có ngưỡng cải thiện riêng, nên một epoch có thể tạo bản lưu mô hình tốt nhất dù không đặt lại bộ đếm dừng sớm. Cơ chế này giải thích vì sao lịch sử đủ 10 điểm và bản lưu được chọn ở epoch 10 cùng tồn tại; không cần suy một đợt train khác hoặc nối hai lịch sử.

5.3 Fine-tuning PhoBERT và diễn biến validation

Mô hình khởi tạo từ vinai/phobert-base-v2; đầu phân loại 20 lớp được tạo cho tác vụ. Toàn bộ encoder và đầu phân loại được cập nhật qua lan truyền ngược, không giữ cố định bộ mã hóa nền. Train tensor có $139{,}975 \times 256$ vị trí; validation/test có $29{,}995 \times 256$. Input IDs, attention mask và nhãn giữ thứ tự, train shuffle batch còn các tập đánh giá giữ phân bố thực tế.

Với n_c là số bài lớp c trong train, PhoBERT dùng balanced weight:

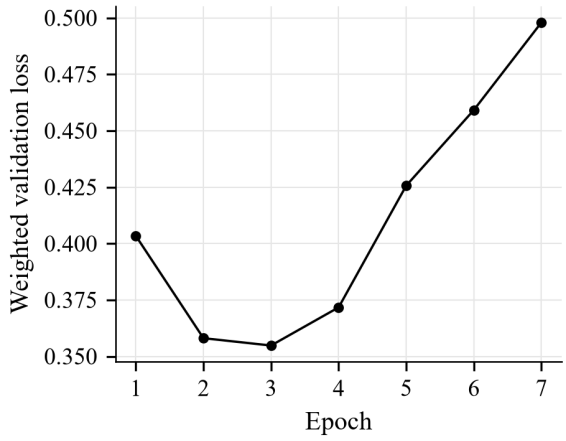
$$w_c = \frac{N_{train}}{20 n_c}, \qquad \mathcal{L}_{\mathcal{B}} = \frac{-\sum_{i \in \mathcal{B}} w_{y_i} \log p_{i,y_i}}{\sum_{i \in \mathcal{B}} w_{y_i}}. \tag{5.2}$$

Không tăng thêm trọng số cho một chuyên mục bằng hệ số đặt thủ công. Nông thôn mới, Dân tộc thiểu số và miền núi, Kinh doanh có trọng số lần lượt 10.3226; 9.1847; 0.7908. Trọng số thay đổi mức đóng góp của lỗi, không bổ sung dữ liệu hoặc làm sạch nhãn; nếu lớp nhỏ có nhiễu, tăng mức phạt trong hàm mất mát có thể khuếch đại ảnh hưởng đó. Mất mát đánh giá có trọng số cũng khác NLL hiệu chỉnh xác suất không trọng số.

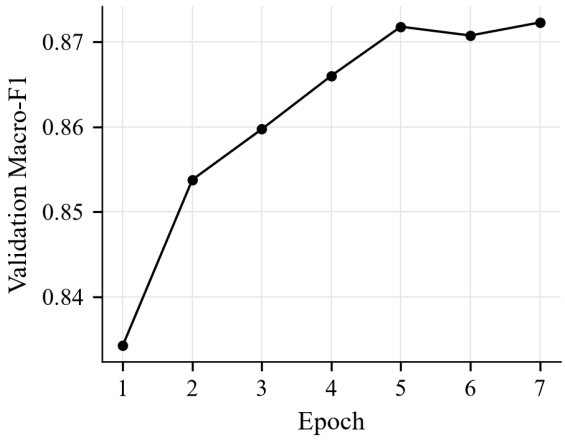
Bảng 5.2: Cấu hình fine-tuning PhoBERT trên một RTX A3000 Laptop 12 GB.

Thiết lập	Giá trị
Batch train / tích lũy gradient	32 / 2
Effective batch / batch đánh giá	64 / 64
Optimizer / weight decay	AdamW fused / 0.01
Learning rate cực đại / warmup	2×10^{-5} / 200 bước
Độ chính xác số / TF32	BF16 / bật
Epoch tối đa / bản lưu được chọn	7 / 7
Dừng sớm: số epoch chờ / mức cải thiện	2 / 0.001
Evaluation và lưu bản lưu mô hình	Cuối mỗi epoch
Lưu lại tính toán gradient / biên dịch mô hình	Tắt / tắt

AdamW tách weight decay khỏi cập nhật thích nghi [10]. Scheduler warmup 200 bước rồi giảm theo tiến độ. Mỗi epoch có $\lceil 139{,}975/32 \rceil = 4{,}375$ mini-batch, tạo 2,188 bước cập



(a) Mất mát trên tập xác thực có trọng số.



(b) Macro-F1 trên tập xác thực.

Hình 5.2: PhoBERT qua bảy epoch; lựa chọn bản lưu mô hình theo Macro-F1 không trùng cực tiểu loss.

nhật sau tích lũy; bảy epoch có 15,316 bước. Batch cuối có thể nhỏ hơn effective batch 64, nên con số này là kích thước danh nghĩa.

Trainer chọn bằng Macro-F1 validation và nạp bản lưu mô hình tốt nhất ở cuối. Lần thực nghiệm chạy đủ bảy epoch; không mô tả như dừng sớm. Loss validation nhỏ nhất epoch 3 là 0.3548, trong khi bản lưu mô hình chọn epoch 7 có Macro-F1 khoảng 0.8723. Bảng 5.3 giữ mốc validation; test không dùng đổi tiêu chí sau khi xem kết quả. Loss tăng về cuối trong khi

Bảng 5.3: Đánh giá cuối epoch trên validation PhoBERT.

Epoch	Val loss	Val Macro-F1
1	0.4034	0.8343
2	0.3581	0.8538
3	0.3548	0.8597
4	0.3717	0.8660
5	0.4257	0.8718
6	0.4592	0.8708
7	0.4980	0.8723

F1 nhích lên phản ánh hai mục tiêu đánh giá khác nhau. Một số bài sai với xác suất tự tin có thể tăng mất mát logarit mà không làm đổi số nhãn đúng theo cùng cách. Đây là cách diễn giải cần đối chiếu với hiệu chỉnh xác suất; các đường học không tự chứng minh một cơ chế lỗi riêng hay xác lập epoch tối ưu cho mọi seed. Không so train loss ghi theo bước với validation loss như hai đại lượng được tổng hợp đồng nhất.

5.3.1 Chọn bản lưu mô hình theo mục tiêu đánh giá

Argmax và mất mát logarit phản ứng khác nhau với một thay đổi logits. Nếu xác suất nhãn tham chiếu thay đổi nhưng nhãn đứng đầu giữ nguyên, F1 không đổi; hàm mất mát có trọng số vẫn đổi. Nếu một số bài của lớp nhỏ đổi từ sai sang đúng, Macro-F1 có thể tăng đáng kể dù

nhiều bài khó khác bị tự tin sai hơn. Bởi vậy, chọn bản lưu mô hình theo F1 và theo cực tiểu validation loss có thể dẫn tới hai trọng số khác nhau mà không có mâu thuẫn số liệu.

Bản lưu mô hình được xác định bằng validation sau từng epoch; test chỉ được dùng sau khi lựa chọn cố định. Bảng epoch ghi cùng split và cách tổng hợp, không lấy một epoch có loss thấp ở lượt khác ghép với F1 của lượt hiện tại. Không dùng đường train loss thấp nhất làm quy tắc chọn thêm khi đã xác định Macro-F1. Sự tách biệt này ngăn một quyết định hậu nghiệm trông như thiết kế đã công bố trước đánh giá.

Early stopping là điều kiện dừng theo tiến triển validation, chưa chứng minh đạt nghiệm tối ưu. Với giới hạn bảy epoch của PhoBERT, chạy đủ giới hạn là một kết quả hợp lệ của cơ chế; với BiLSTM, bản lưu mô hình tốt nhất có thể xảy ra ở lượt chạm patience do ngưỡng cải thiện của bộ đếm. Muốn xác định độ bền của mốc chọn cần nhiều seed, không suy từ một đường cong mượt hoặc một giá trị ở cuối.

Khác biệt hàm mất mát có trọng số và NLL cần giữ xuyên suốt hiệu chỉnh xác suất. Validation loss phục vụ theo dõi cùng mục tiêu có trọng số lớp, còn temperature tối ưu NLL không trọng số để điều chỉnh phân bố xác suất. Một trọng số lớp cao không làm mọi nhãn hiếm chắc chắn có xác suất được hiệu chỉnh tốt hơn. Sau fine-tuning, hiệu chỉnh xác suất phải được ước lượng và đánh giá theo giao thức của chính gói mô hình được chọn.

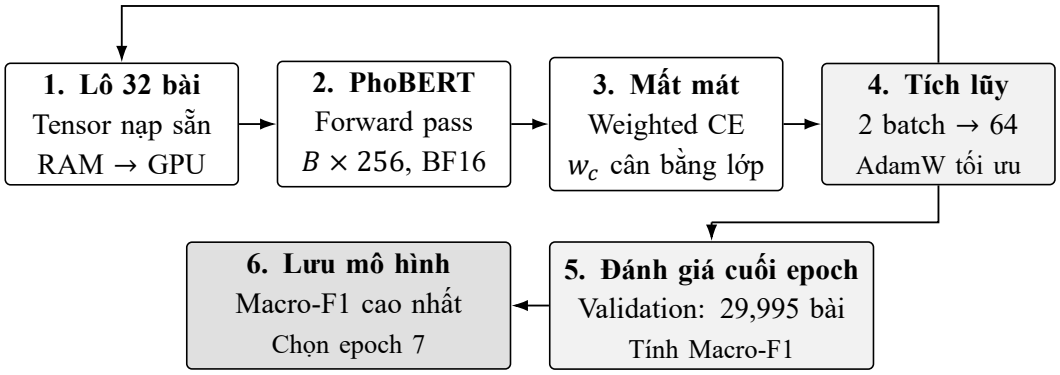
5.3.2 Tính toán mini-batch và precision

Tích lũy gradient (gradient accumulation) cho phép cộng gradient từ hai mini-batch trước một bước optimizer, giữ batch thực 32 để phù hợp bộ nhớ. Nó không tăng ngữ cảnh: mỗi bài vẫn có tối đa 256 vị trí. Effective batch 64 mô tả số bài danh nghĩa đóng góp trước cập nhật, trong khi batch cuối và cách chuẩn hóa hàm mất mát có trọng số cần được phân biệt với một lần forward chứa đủ 64 bài.

BF16 là kiểu biểu diễn số dùng cho các phép tính được tự động lựa chọn trong autocast, không có nghĩa mọi tensor bản lưu mô hình được lưu bằng BF16. Chế độ đánh giá (eval) tắt dropout khi đánh giá; thứ tự validation/test giữ cố định để liên kết logits và thông tin mô tả. Dataloader shuffle train thay đổi thứ tự tối ưu nhưng không thay vai trò các tập. Những bất biến này là điều kiện đối chiếu gói mô hình với output, không một chứng nhận mọi kernel GPU có kết quả giống bit.

Bản lưu mô hình tốt nhất được nạp trước hiệu chỉnh xác suất, giúp T và τ_c gắn đúng trọng số được chọn. Nếu dùng logits từ một epoch khác để ước lượng rồi gắn hiệu chỉnh xác suất vào gói mô hình cuối, hình thức file vẫn có thể hợp lệ nhưng độ tin cậy không còn thuộc mô hình đó. Bài tập lớn lưu mã băm và bảng ánh xạ nhãn để phát hiện sự lệch gói mô hình; file thông tin mô tả cùng số lớp chưa đủ khi không đối chiếu trọng số.

Một lượt huấn luyện mới (fresh) của PhoBERT khởi tạo từ bộ mã hóa nền với bộ tối ưu và lịch learning rate mới. Chế độ huấn luyện tiếp (continue) nạp trọng số tương thích nhưng vẫn khởi tạo lại trạng thái tối ưu, không khôi phục đầy đủ trạng thái giữa epoch. Bản dữ liệu dùng một lượt huấn luyện mới bảy epoch; các điểm trên đường đánh giá validation không là tổng của nhiều lần Run All. Chế độ thực thi và mã nhận diện dữ liệu là bằng chứng tái hiện, không được dùng suy thêm một seed hoặc ablation chưa chạy.



Giao thức tối ưu: RTX A3000 Laptop 12 GB, 7 epoch; mỗi epoch có 4,375 lô và 2,188 bước cập nhật. Chọn epoch 7 theo Macro-F1 validation; mất mát validation nhỏ nhất ở epoch 3.

Hình 5.3: Huấn luyện có tích lũy gradient và chọn bản lưu mô hình theo Macro-F1.

5.3.3 Validation dùng lại và nguy cơ phụ thuộc lựa chọn

Tìm nhiều cấu hình trên cùng validation cung cấp tiêu chí thống nhất nhưng tạo khả năng phụ thuộc vào những mẫu cụ thể của tập này. Cấu hình đứng đầu trong 12 ứng viên không có nghĩa điểm validation là ước lượng không thiên lệch cho chất lượng cuối. Test giữ độc lập giúp đo gói mô hình sau lựa chọn; nó không được quay lại thành tiêu chí chọn ứng viên khác khi kết quả thấp hơn kỳ vọng.

PhoBERT dùng validation cho bản lưu mô hình rồi temperature và hệ số lớp. Các quyết định này liên tiếp tận dụng cùng tập, nên một tập dữ liệu hiệu chỉnh riêng hoặc thiết kế kiểm định chéo có thể khảo sát độ ổn định tốt hơn. Tuy vậy, thực nghiệm hiện có không được đổi tên thành đã dùng kiểm định chéo hoặc ba seed. Báo cáo giữ đúng giao thức và nêu giới hạn thay vì đưa thêm một thủ tục không có trong output.

5.4 Temperature scaling và quyết định theo lớp

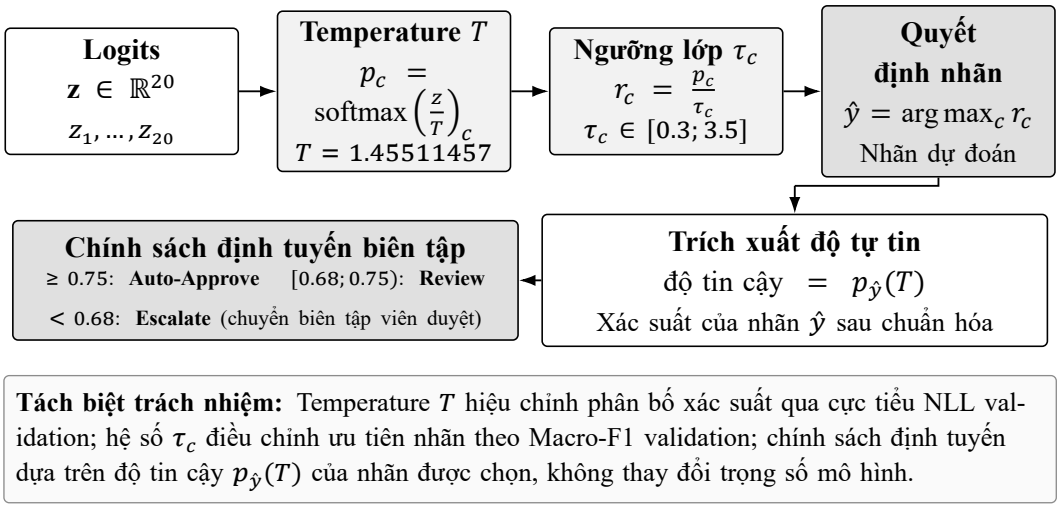
SVM sinh margin, LR và các mô hình nơ-ron sinh logits. Một phép softmax trực tiếp từ margin chưa bảo đảm xác suất có ý nghĩa. Cả bốn ước lượng tham số temperature dương bằng NLL trên validation rồi giữ cố định ở test [6]:

$$p_c(T) = \frac{\exp(z_c/T)}{\sum_j \exp(z_j/T)}, \qquad \mathrm{NLL}(T) = -\frac{1}{N}\sum_i \log(p_{i,y_i}(T) + 10^{-10}). \tag{5.3}$$

Với SVM, z trong công thức là margin. $T > 0$ không đổi thứ tự điểm số, nên argmax và các chỉ số nhãn không đổi. PhoBERT tìm T trong $[0.5; 5.0]$, giữ $T = 1$ nếu nghiệm không giảm NLL validation; nghiệm được dùng là 1.45511457. Các đối chứng có tham số riêng, không dùng chung temperature của PhoBERT.

Bước độc lập dành riêng PhoBERT đổi ưu tiên nhãn bằng

$$r_c = \frac{p_c(T)}{\tau_c}, \qquad \hat{y} = \arg\max_c r_c. \tag{5.4}$$



Hình 5.4: Hiệu chỉnh xác suất, chọn nhãn và định tuyến biên tập là các bước riêng.

Hệ số lớn giảm ưu tiên tương đối, hệ số nhỏ tăng ưu tiên. Tìm kiếm tọa độ khởi tạo 20 hệ số bằng 1, duyệt ba lượt và 200 giá trị mỗi lớp trong $[0.3; 3.5]$. Mỗi ứng viên được đánh giá bằng Macro-F1 toàn bộ 20 lớp validation; cải thiện cần vượt 10^{-5}. Khi điểm bằng nhau, chọn ID lớp nhỏ hơn. Đây là tìm kiếm tham lam, có thể phụ thuộc thứ tự lớp; chưa có bảo đảm tối ưu toàn cục. r là điểm quyết định, không phải xác suất hiệu chuẩn. Top-k xếp theo r_c, còn độ tin cậy là $p_{\hat{y}}(T)$ của nhãn cuối và có thể nhỏ hơn xác suất cực đại. Margin dùng chênh lệch hai điểm lớn nhất của $q_c = r_c / \sum_j r_j$; q chưa được kiểm chứng hiệu chỉnh xác suất. Quy tắc này vẫn chỉ xuất một nhãn, không phải 20 ngưỡng phân loại đa nhãn.

Class weights được tính từ train; T và τ_c được chọn bằng validation; các phép đo cuối dùng test. ECE trong kết quả dùng độ tin cậy cực đại và argmax chuẩn của $p(T)$, chưa đo tính hiệu chuẩn của q hay của nhãn sau điều chỉnh hệ số. Phân luồng là ứng dụng tiếp theo của kết quả, với chính sách nghiệp vụ trình bày ở Phụ lục B.

6. Kết quả thực nghiệm, so sánh và phân tích lỗi

6.1 Điều kiện đánh giá chung

So sánh dùng tập dữ liệu 199,965 bài, hệ thống chuyên mục 20 lớp và cùng phép chia phân tầng 70/15/15, seed 42. Đối chiếu trực tiếp xác nhận mảng chỉ số train, validation và test của bốn notebook giống nhau. Trên test, toàn bộ 29,995 URL, nhãn tham chiếu và thứ tự mẫu khớp giữa ba đối chứng và thông tin mô tả PhoBERT. Số lượng bằng nhau hoặc chuỗi mã nhận diện dữ liệu đơn lẻ chưa đủ cho kết luận này: PhoBERT và các đối chứng dùng cách tạo mã nhận diện khác nhau.

Các số được đọc từ metrics, scores/logits, predictions, ma trận và bảng precision, recall và F1 theo lớp đã xuất. Tái tính từ từng hàng dự đoán xác nhận Accuracy, Macro-F1, Weighted-F1 và tổng số mẫu. Mỗi mô hình đi vào test với duy nhất cấu hình/bản lưu mô hình đã chọn trên validation. SVM/LR được tìm trong 12 cấu hình mỗi mô hình, BiLSTM trong ba cấu hình, PhoBERT dùng cấu hình fine-tuning ở chương 5. Ngân sách lựa chọn không bằng nhau; đây là so sánh các quy trình phân loại thực thi, không cô lập ưu thế kiến trúc.

Với lớp c, các chỉ số phân biệt đúng dương (TP), sai dương (FP) và sai âm (FN):

$$P_c = \frac{TP_c}{TP_c + FP_c}, \quad R_c = \frac{TP_c}{TP_c + FN_c}, \quad F1_c = \frac{2TP_c}{2TP_c + FP_c + FN_c}. \tag{6.1}$$

Macro-F1 là $\frac{1}{20}\sum_c F1_c$; Weighted-F1 là $\sum_c (n_c/N)F1_c$. Accuracy là tỷ lệ đúng toàn tập. Mẫu số bằng không nhận 0; micro-F1 bằng Accuracy trong phân loại đơn nhãn đầy đủ lớp. Một kết quả cao theo số lượng chưa bảo đảm các lớp nhỏ có chất lượng tương ứng.

Cùng số lượng test không đủ cho một phép so sánh ghép cặp. Thông tin mô tả có article index, URL và label ID; dự đoán được đối chiếu bằng khóa này trước khi tính số mô hình cùng đúng. Một hoán vị đúng của nhãn và dự đoán vẫn có thể cho điểm tổng đúng, nhưng nếu ghép sai thứ tự giữa mô hình thì số lỗi chung và bootstrap chênh lệch sẽ sai. Kiểm tra đối chiếu vì vậy kiểm tra cả mảng split, các URL và từng hàng nhãn, không chỉ ba chỉ số tổng hợp.

Phần so sánh chính dùng argmax điểm số của bốn quy trình phân loại, không dùng nhãn cuối sau hệ số PhoBERT để tăng riêng một dòng. Temperature dương giữ thứ tự điểm số nên có thể đánh giá hiệu chỉnh xác suất mà không đổi giao thức nhãn. Accuracy, Macro-F1 và Weighted-F1 là thuộc test cuối; các điểm validation trong bảng cấu hình chỉ giải thích quyết định lựa chọn. Không coi chúng như hai lần đánh giá test độc lập.

6.2 Kết quả tổng thể bốn phương pháp

PhoBERT đạt Macro-F1 87.22%, SVM 85.33%, LR 84.98% và BiLSTM 84.60%. Khoảng cách PhoBERT–SVM là 1.89 điểm phần trăm Macro-F1 và 1.17 điểm Accuracy, tương ứng 350 bài đúng ròng. SVM có 26,970 bài đúng, so với 26,714 của LR và 26,595 của BiLSTM. Những giá trị này là kết quả tập dữ liệu hiện tại, không lấy từ bảng nghiên cứu ở chương 2.

Bảng 6.1: Chất lượng bốn mô hình với quyết định argmax điểm số; chưa dùng hệ số điều chỉnh lớp của PhoBERT. Chỉ số phần trăm, làm tròn bốn chữ số trên cùng 29,995 bài test.

Mô hình	Macro-F1 val (%)	Accuracy (%)	Macro-F1 (%)	Weighted-F1 (%)	Số đúng
SVM	85.1132	89.9150	85.3308	89.8771	26,970
LR	84.9166	89.0615	84.9797	89.0983	26,714
BiLSTM	84.4932	88.6648	84.5995	88.7105	26,595
PhoBERT	87.2298	91.0818	87.2191	91.1176	27,320

Temperature dương không đổi argmax ở cả bốn mô hình. Riêng hệ số lớp của PhoBERT thay nhãn sau temperature, nâng Accuracy từ 91.08% lên 91.13% và Macro-F1 từ 87.22% lên 87.25%, đạt 27,333 bài đúng. Trạng thái này phục vụ ứng dụng ở Phụ lục B; không dùng thay dòng argmax trong đối chứng chính.

Kết quả cho thấy TF–IDF toàn văn đã cung cấp đối chứng mạnh. BiLSTM học từ đầu chưa vượt hai mô hình tuyến tính trong cấu hình đã khảo sát. Điều đó không chứng minh thứ tự từ vô ích, LSTM nói chung kém hơn SVM, hay toàn bộ mức tăng của PhoBERT đến từ tiền huấn luyện. Cách cắt, từ dừng, lặp tiêu đề, trọng số lớp và ngân sách tối ưu đều là biến đồng thời thay đổi.

Bảng 6.2: PhoBERT trước/sau điều chỉnh theo lớp trên cùng test; chỉ số ở thang 0–1, chênh lệch là sau trừ trước.

Chỉ số	Trước	Sau	Chênh lệch
Accuracy	0.910818	0.911252	0.000433
Weighted-F1	0.911176	0.911450	0.000273
Macro-F1	0.872191	0.872529	0.000337

Theo nhãn đã lưu, PhoBERT đúng 27,320 bài trước và 27,333 bài sau điều chỉnh. Quy tắc sửa đúng 112 bài nhưng đổi thành sai 99 bài; ròng tăng 13/29,995 bài. Macro-F1 tăng 0.0337 điểm phần trăm, là mức nhỏ và không chứng minh lợi ích ổn định ở mọi lớp hoặc lần huấn luyện. Temperature riêng không tạo mức tăng này vì argmax của nó giữ nguyên.

Macro-F1 trung bình ngang nhau giữa các lớp, nên khoảng cách thể hiện cả những chuyên mục ít bài mà Accuracy có thể làm mờ. Weighted-F1 tăng trọng lượng lớp đông; khoảng cách giữa hai F1 là một tín hiệu cần phân tích theo lớp, không một công thức đo mất cân bằng duy nhất. Hai mô hình có cùng Accuracy cũng có thể phân bố lỗi khác nhau và đạt Macro-F1 khác. Vì vậy, bảng tổng không xác định lớp nào cần rà soát.

PhoBERT dẫn đầu trong cả ba chỉ số argmax của bản dữ liệu, nhưng SVM vẫn gần và huấn luyện được trên CPU. Kết quả này làm baseline từ vựng trở thành đối chứng thực chất, thay vì chỉ một mức tham chiếu dễ vượt. Ngược lại, BiLSTM chưa vượt SVM/LR không chứng minh vector biểu diễn từ chuỗi không hữu ích: nó học từ đầu, dùng một tầng recurrent, giữ chuỗi giới hạn và có ngân sách ứng viên khác. Tên họ mô hình không thay thế cấu hình cụ thể đã đánh giá.

Mức tăng sau hệ số lớp cần đọc như một đổi quy tắc quyết định của cùng PhoBERT. Số bài đúng ròng bằng sửa đúng trừ đổi sai; nó không cho thấy 112 trường hợp là lợi ích mà bỏ qua

99 trường hợp bị hại. Tăng Macro-F1 nhỏ cũng không bảo đảm các luồng nghiệp vụ được cải thiện như nhau. Test chỉ mô tả tác động của tham số đã chọn trên validation, không dùng chọn lại các hệ số để tối đa hóa kết quả cuối.

6.3 Kết quả theo 20 chuyên mục

Bảng 6.3: F1 (%) theo 20 chuyên mục với argmax, cùng số mẫu test; DTTS là Dân tộc thiểu số. Giá trị làm tròn có thể che chênh lệch rất nhỏ.

ID	Chuyên mục	Số mẫu	SVM	LR	BiLSTM	PhoBERT
0	Bạn đọc	1,818	95.65	95.07	94.48	95.63
1	Bất động sản	1,846	92.39	92.01	92.13	93.43
2	Chính trị	1,836	87.92	87.25	87.03	90.63
3	Công nghiệp hỗ trợ	194	90.46	88.36	88.56	91.58
4	Công nghệ	1,659	88.94	87.48	87.18	89.48
5	Du lịch	1,647	87.91	87.67	86.98	88.75
6	Dân tộc - Tôn giáo	555	66.67	66.38	62.41	67.14
7	DTTS và miền núi	163	58.06	59.24	59.53	69.38
8	Giáo dục	1,839	92.45	91.68	91.14	93.61
9	Kinh doanh	1,897	84.10	83.40	81.24	84.64
10	Nông thôn mới	146	39.53	47.06	48.24	45.57
11	Nội dung chuyên đề	1,885	76.57	74.18	75.02	79.74
12	Sức khỏe	1,857	94.50	93.66	93.42	95.08
13	Thế giới	1,784	97.75	97.27	97.22	98.27
14	Thể thao	1,840	98.78	98.31	98.21	98.78
15	Thời sự	1,863	91.34	90.58	90.09	92.70
16	Tuần Việt Nam	1,691	88.30	86.70	87.72	91.86
17	Văn hóa - Giải trí	1,847	93.55	93.01	93.10	95.41
18	Ô tô - Xe máy	1,845	97.67	97.04	97.20	97.78
19	Đời sống	1,783	84.06	83.23	81.10	84.92

Thể thao, Thế giới và Ô tô – Xe máy đạt F1 cao ở cả bốn quy trình phân loại. SVM và PhoBERT đều khoảng 98.78% ở Thể thao; khác biệt tại chữ số nhỏ không đủ để coi một mô hình tốt hơn có ý nghĩa theo lớp này. Ngược lại, Dân tộc thiểu số và miền núi đạt 69.38% với PhoBERT, cao hơn mức 58.06–59.53% của ba đối chứng. Nội dung chuyên đề đạt 79.74% với PhoBERT, so với 74.18–76.57%. Lợi thế tổng thể vì vậy không phân bố đều trên mọi chuyên mục.

6.3.1 Nông thôn mới: đánh đổi độ chính xác và khả năng nhận ra bài thuộc lớp

BiLSTM đạt F1 48.24%, LR 47.06%, PhoBERT argmax 45.57% và SVM 39.53%. Ngay cả PhoBERT sau điều chỉnh lớp đạt 46.39%, vẫn thấp hơn hai giá trị đầu trong mẫu test này.

Bảng 6.4: Nông thôn mới: precision, recall và F1 của bốn mô hình trước điều chỉnh nhãn; số mẫu là 146 bài.

Mô hình	Precision (%)	Recall (%)	F1 (%)	Số đúng / 146
SVM	45.54	34.93	39.53	51
LR	41.24	54.79	47.06	80
BiLSTM	39.91	60.96	48.24	89
PhoBERT	42.35	49.32	45.57	72

SVM nhận đúng 51/146 bài, LR 80, BiLSTM 89 và PhoBERT argmax 72. Recall cao hơn của BiLSTM đi kèm precision chỉ 39.91%; đây không phải cải thiện đồng thời mọi tiêu chí.

Ma trận cho thấy SVM chuyển 86 bài Nông thôn mới sang Nội dung chuyên đề. Ở chiều ngược, LR chuyển 106 bài Nội dung chuyên đề sang Nông thôn mới, BiLSTM chuyển 128 bài. Những lỗi từ lớp lớn góp phần làm precision của lớp hiếm thấp. Trọng số loss, số mẫu và đặc điểm nội dung cùng ảnh hưởng ranh giới; chưa có ablation để xác định nguyên nhân riêng. Với 146 mẫu, thứ hạng F1 theo lớp cần được kiểm chứng trên nhiều seed và một tập gán nhãn được rà soát.

Các lớp được định nghĩa không cùng một kiểu: có nhãn lĩnh vực như Thể thao, có nhãn bình luận như Tuần Việt Nam, và có chuyên đề/chính sách. Một vector từ vựng có thể đặc trưng rõ lĩnh vực nhưng khó nhận ra quyết định tổ chức xuất bản. Tương tự, encoder ngữ cảnh không được cung cấp breadcrumb để phân biệt một bài đăng theo chuyên đề với bài cùng nội dung ở mục khác. Đây là giới hạn của mục tiêu suy chuyên mục chỉ từ tiêu đề/nội dung, không phải bằng chứng mô hình đã đọc sai toàn bộ ngữ nghĩa.

Điều chỉnh hệ số PhoBERT không đồng thời cải thiện mọi lớp. Nông thôn mới tăng từ 45.57% lên 46.39%, còn Dân tộc thiểu số và miền núi giảm từ 69.38% xuống 68.77%. Tối ưu Macro-F1 validation là đánh đổi toàn cục, không cam kết precision/recall của từng lớp test tăng. Các hệ số nằm trong tệp kết quả, không chọn lại theo test để làm đẹp bảng.

6.3.2 Lợi thế không phân bố đều giữa các chuyên mục

Hai mô hình đạt F1 gần bằng nhau ở lớp dễ chưa có nghĩa chúng đúng trên cùng từng bài. F1 tổng hợp TP, FP và FN, không giữ danh sách URL; số đúng chung và đúng riêng trong phân tích ghép cặp bổ sung thông tin này. Do đó, không chọn một mô hình để thay toàn bộ mô hình khác chỉ vì vài lớp có số làm tròn bằng nhau. Cũng không coi lợi ích ensemble là đã xác nhận từ việc các lỗi khác nhau.

Nhóm Thể thao, Thế giới và Ô tô – Xe máy có điểm cao ở nhiều biểu diễn, trong khi Nội dung chuyên đề và các nhãn dân tộc phân tách mạnh hơn. Xu hướng này giúp đặt giả thuyết về mức tập trung từ vựng và ranh giới xuất bản. Nó không tự định lượng tác động phần giữa bị cắt vì chưa có so sánh head-only/Head–Tail/chunked trong cùng mô hình. Cách diễn giải giữ ranh giới giữa quan sát theo lớp và nguyên nhân cần thí nghiệm thêm.

Một lớp lớn có thể tạo nhiều bài bị gán nhầm vào một lớp nhỏ dù tỷ lệ nhầm trên hàng của lớp lớn thấp. Đây là lý do cần xem cả chiều đi và chiều về trong ma trận nhầm lẫn, thay

vì chỉ chọn ô có màu đậm. Với Nông thôn mới–Nội dung chuyên đề, số mẫu hai bên rất khác, nên recall lớp hiếm và precision của dự đoán lớp hiếm phụ thuộc hai nguồn mẫu số khác nhau. Phân tích P/R ở bảng lớp hiếm giúp tránh gọi một sự tăng dự đoán đơn thuần là chất lượng tăng đồng đều.

Kết quả theo nhãn cũng không cung cấp hiệu năng cho một nhãn mới chưa xuất hiện trong hệ thống chuyên mục. Một bài thuộc lĩnh vực mới hoặc một mục con đổi cách tổ chức vẫn bị ép vào một trong 20 đầu ra nếu đưa vào bộ phân loại. Top-k mở thêm ứng viên cho người rà soát, không biến bài toán thành mô hình multi-label hoặc zero-shot. Những giới hạn này cần được giữ khi chuyển từ đánh giá chuyên mục sang sử dụng gợi ý nhãn.

6.3.3 Số mẫu và ranh giới nhãn

Với Nông thôn mới, recall trả lời bao nhiêu bài của lớp thật được nhận ra, còn precision trả lời bao nhiêu bài được gọi là lớp này thực sự thuộc lớp. Tăng lượng dự đoán có thể tăng recall nhưng hút bài của Nội dung chuyên đề vào, làm precision thấp. F1 kết hợp hai phía; không chọn một chiều để tuyên bố mô hình "giải quyết lớp hiếm". Với số mẫu 146, một số nhỏ bài đổi nhãn cũng làm chỉ số biến động rõ.

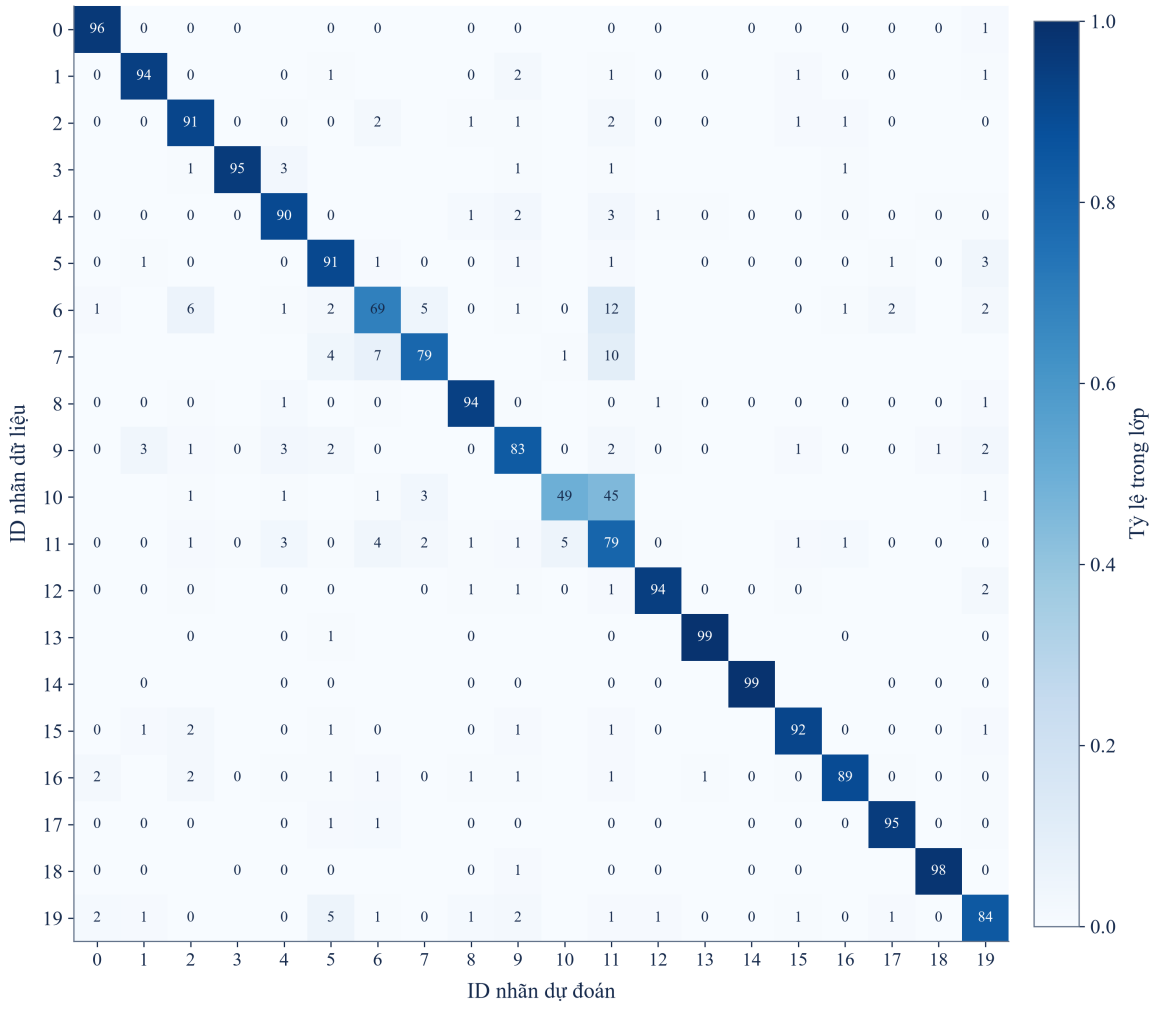
Những lớp dân tộc cho thấy nguồn khó khác với Nông thôn mới. Cùng bài về chính sách, du lịch hoặc văn hóa địa phương có thể xuất hiện trong các khuôn chuyên mục khác nhau. Bước xác minh breadcrumb ngăn lấy nhãn của trang danh sách nhầm, nhưng không cung cấp đặc trưng này cho mô hình test. Vì vậy, dataset đúng chính sách nhãn và mô hình khó học nhãn từ văn bản có thể đồng thời tồn tại.

Các lớp tập trung như Thể thao hay Ô tô – Xe máy có nhiều dấu hiệu thuật ngữ, nhưng điểm cao chưa chứng minh một thuật ngữ riêng gây ra dự đoán. Còn với chuyên mục bình luận, tín hiệu có thể nằm ở giọng điệu, cấu trúc hoặc cách xuất bản mà vector n-gram và chuỗi đã cắt giữ không đầy đủ. Các giả thuyết này chỉ định nơi cần đọc lỗi và ablation, không được trình bày như kết quả nhân quả đã đo.

6.4 Ma trận nhầm lẫn và phân tích lỗi bài thật

Hàng ma trận là nhãn tham chiếu, cột là nhãn dự đoán; tổng hàng bằng số mẫu và toàn ma trận bằng 29,995. Chuẩn hóa theo hàng cho biết phân bố dự đoán khi biết lớp thực, khác precision của nhãn được chọn. ID đối chiếu bảng 3.2; ma trận của ba baseline nằm ở Phụ lục A. Nông thôn mới bị chuyển sang Nội dung chuyên đề ở 66/146 bài, trong khi chiều ngược có 94/1,885 bài. Cùng lượng từ về địa phương, sinh kế và chương trình phát triển có thể xuất hiện ở cả hai lớp; hướng nhầm không đối xứng do khác số mẫu và ranh giới mô hình. Đời sống–Du lịch, Kinh doanh–Bất động sản cũng có vùng giao thoa, nhưng ma trận chưa cho biết thiếu phần giữa bài, mất chữ số hay nhãn biên tập là nguyên nhân riêng.

Cả bốn mô hình cùng đúng ở 24,677 bài và cùng sai ở 1,251 bài. Trong nhóm cùng sai, Nội dung chuyên đề có 186 bài, Kinh doanh 169 và Đời sống 156; Nông thôn mới có 24/146 bài, Dân tộc – Tôn giáo 83/555 bài. Số tuyệt đối và tỷ lệ trong lớp thể hiện hai mặt khác nhau của độ khó, không được dùng thay nhau.



Hình 6.1: PhoBERT chuẩn hóa theo hàng, argmax trước hệ số lớp; thang tỷ lệ 0–1.

Bảng 6.5: Các hướng nhầm nổi bật của PhoBERT argmax; tỷ lệ lấy số mẫu nhãn tham chiếu làm mẫu số.

Nhãn tham chiếu	Nhãn dự đoán	Số bài	Tỷ lệ hàng
Nội dung chuyên đề	Nông thôn mới	94	4.99%
Đời sống	Du lịch	87	4.88%
Dân tộc - Tôn giáo	Nội dung chuyên đề	68	12.25%
Nội dung chuyên đề	Dân tộc - Tôn giáo	66	3.50%
Nông thôn mới	Nội dung chuyên đề	66	45.21%
Kinh doanh	Bất động sản	61	3.22%
Nội dung chuyên đề	Công nghệ	56	2.97%
Du lịch	Đời sống	56	3.40%

Bảng 6.6: Số mô hình dự đoán đúng từng bài trong bốn quyết định argmax; tổng bằng 29,995.

Số mô hình dự đoán đúng	Số bài
0	1,251
1	1,065
2	1,180
3	1,822
4	24,677

Ba ví dụ chung có thể truy vết từ tệp kết quả: "Google tích hợp AI Gemini vào hệ sinh thái sản phẩm" có nhãn Giáo dục nhưng cả bốn dự đoán Công nghệ; "The Sonata – sống tận hưởng tại 'tọa độ quốc tế' bên sông Hàn" có nhãn Kinh doanh nhưng cả bốn chọn Bất động sản; "Ô tô mới có thể được miễn đăng kiểm lần đầu từ năm 2023" có nhãn Thời sự nhưng cả bốn chọn Ô tô – Xe máy. URL tương ứng là:

- VietNamNet, bài 2281849: Google tích hợp AI Gemini;
- VietNamNet, bài 2348982: The Sonata bên sông Hàn;
- VietNamNet, bài 2094970: Miễn đăng kiểm lần đầu.

Những trường hợp này cho thấy nhãn chuyên mục có thể phụ thuộc cách tổ chức biên tập hơn tên chủ đề dễ nhận thấy. Không tự đổi nhãn tham chiếu vì nhiều mô hình đồng ý với nhau. Cần rà soát bài gốc, quy tắc hệ thống chuyên mục và bằng chứng chuyên mục trước khi kết luận nhãn sai hoặc mô hình sai theo nghĩa ngữ nghĩa.

Các ví dụ trên được chọn theo giao thức argmax chung; không trộn nhãn sau hệ số PhoBERT vào lỗi bốn mô hình. Việc nhiều mô hình cùng sai có thể do tín hiệu chủ đề nổi bật, cách cắt hoặc cùng khó với hệ thống chuyên mục. Để phân biệt, cần kiểm toán bài và nhãn thay vì đổi nhãn tham chiếu theo đa số dự đoán.

6.4.1 Diễn giải các ví dụ có thể truy vết

Ở bài Gemini, chủ thể Google và sản phẩm AI cung cấp tín hiệu rõ cho Công nghệ, trong khi nhãn tham chiếu là Giáo dục. Việc cả bốn chọn cùng một lớp phù hợp với tiêu đề chưa đủ kết luận nhãn gốc sai: cần đọc nội dung và bối cảnh chuyên mục. Đây là ví dụ ranh giới giữa chủ đề nổi bật trong văn bản và mục xuất bản, đúng với định nghĩa tác vụ đơn nhãn đã nêu.

Bài The Sonata có nhãn Kinh doanh nhưng dự đoán chung Bất động sản, minh họa vùng nội dung giao thoa giữa giới thiệu dự án và hoạt động doanh nghiệp. TF–IDF toàn văn lẫn hai mô hình chuỗi đều gặp lỗi, nên không thể giải thích riêng bằng việc PhoBERT bỏ phần giữa. Điều này cũng chưa chứng minh cách cắt vô hại: các mô hình có thể cùng sai vì những lý do khác nhau, dù nhãn cuối giống nhau.

Bài miễn đăng kiểm có nhãn Thời sự và cùng dự đoán Ô tô – Xe máy. Đơn vị phương tiện, quy định đăng kiểm và năm xuất bản có thể tạo tín hiệu lĩnh vực cạnh tranh với loại tin thời sự; mô hình chuẩn hóa còn bỏ dãy số. Không có thí nghiệm giữ chữ số để xác định tác động của bước này. Ba ví dụ được chọn có chủ đích, không đại diện tỷ lệ của từng kiểu lỗi trong toàn tập

dữ liệu.

6.4.2 Sai số do mục tiêu đơn nhãn và quan sát đầu vào

Nhãn chuyên mục chỉ giữ một quyết định dù bài có nhiều lĩnh vực. Một mô hình có thể nhận ra chủ đề dễ thấy nhưng vẫn sai mục tiêu xuất bản, như các ví dụ Kinh doanh–Bất động sản hoặc Thời sự–Ô tô. Ngược lại, mô hình khớp nhãn không có nghĩa nó hiểu mọi chi tiết bài báo. Accuracy của chuyên mục vì vậy không đo tính đúng của nội dung, khả năng đọc hiểu hoặc chất lượng thông tin.

URL và breadcrumb rất hữu ích xác minh dữ liệu, nhưng đưa chúng vào đặc trưng đầu vào sẽ đổi bài toán sang khai thác chính cấu trúc xuất bản. Project không đưa chúng vào bộ phân loại để đánh giá dự đoán từ văn bản. Chính lựa chọn đầu vào này tạo một giới hạn học được khi hệ thống chuyên mục dùng tín hiệu không hiện rõ trong tiêu đề/nội dung. Khi đề xuất cải tiến, cần quyết định có giữ nguyên nhiệm vụ không, thay vì âm thầm thêm đặc trưng rồi đối chiếu điểm như cùng điều kiện.

Trích xuất cũng là một bước trước mô hình: lỗi thiếu đoạn, lẫn nội dung liên quan hoặc ghép từ có thể làm văn bản khác bài gốc. Các kiểm tra không rỗng và chuyên mục hợp lệ ngăn một số lỗi cấu trúc, chưa bảo đảm chất lượng toàn văn. Nếu lỗi trích xuất tồn tại ở cùng bản ghi, bốn quy trình phân loại có thể cùng chịu ảnh hưởng. Kiểm tra đối chiếu mẫu khó nên xem nguồn văn bản trước khi quy lỗi cho encoder.

6.4.3 Từ lỗi chung tới kiểm toán dữ liệu

Nhóm cùng sai là điểm bắt đầu cho kiểm toán vì không mô hình nào trong bốn cấu hình sửa được bằng cơ chế hiện có. Tuy nhiên, đồng thuận sai không là một bộ gán nhãn thay thế. Để phân loại nguyên nhân, cần xem trích xuất có thiếu/ghép nhầm đoạn không, breadcrumb có quy đúng nhãn cha không và văn bản có đủ thông tin phân biệt mục hay không. Mỗi nguyên nhân dẫn đến hành động khác: sửa bản ghi, làm rõ hệ thống chuyên mục hoặc bổ sung mẫu học.

Một nhãn có nhiều bài cùng sai theo số tuyệt đối có thể chỉ vì số mẫu lớn. Tỷ lệ cùng sai trong lớp cung cấp cách nhìn khác, nhưng với lớp ít mẫu lại có bất định lớn hơn. Cả số lượng và mẫu số cần được giữ khi ưu tiên kiểm toán. Báo cáo không thay nhãn test hoặc tính lại một điểm "sau sửa nhãn" không có lượt đánh giá đã xác định.

6.5 Đánh giá ghép cặp và bất định thống kê

Hai mô hình dự đoán cùng bài nên cần xét chênh lệch ghép cặp, không chỉ nhìn khoảng tin cậy riêng. Phân tích dùng bootstrap ghép cặp: lấy mẫu có hoàn lại từ các bài kiểm tra và áp dụng cùng mẫu cho cả bốn mô hình. Có 1,000 lần lấy mẫu theo giả định các bài độc lập và cùng phân phối (IID), dùng seed 42 bằng numpy.random.default_rng, mỗi lần lấy có hoàn lại 29,995 vị trí. Cùng một mảng vị trí được áp dụng cho cả bốn mô hình; F1 luôn tính trên đủ 20 nhãn,

với mẫu số bằng không nhận 0. Với cặp A, B:

$$\Delta^{(b)} = \text{MacroF1}(y_{I_b}, \hat{y}^A_{I_b}) - \text{MacroF1}(y_{I_b}, \hat{y}^B_{I_b}). \tag{6.2}$$

Khoảng tin cậy 95% theo phương pháp phân vị lấy các mốc 2.5 và 97.5 của $\Delta^{(b)}$. Đây là hậu phân tích từ dự đoán đã xuất, không chạy lại notebook hoặc huấn luyện. Các mô hình và tham số giữ cố định; kết quả khác khoảng riêng 500 lần của từng notebook vì mục tiêu là chênh lệch có bảo toàn ghép cặp. Các khoảng PhoBERT–SVM/LR/BiLSTM đều nằm trên 0 trong thiết lập

Bảng 6.7: Chênh lệch Macro-F1 ghép cặp với argmax; khoảng tin cậy là từng cặp cho mô hình cố định, không phải khoảng đồng thời của toàn bộ so sánh.

Cặp $A - B$	Δ Macro-F1 (điểm %)	CI 95% (điểm %)	A đúng/B sai B đúng/A sai
PhoBERT – SVM	1.89	[1.20; 2.58]	1439 / 1089
PhoBERT – LR	2.24	[1.62; 2.89]	1652 / 1046
PhoBERT – BiLSTM	2.62	[2.06; 3.23]	1687 / 962
SVM – LR	0.35	[-0.09; 0.75]	546 / 290
LR – BiLSTM	0.38	[-0.17; 0.95]	1232 / 1113

này. Khoảng SVM–LR là $[-0.09; 0.75]$ điểm phần trăm, LR–BiLSTM là $[-0.17; 0.95]$, đều chứa 0. Vì vậy, thứ hạng điểm mẫu giữa các đối chứng gần nhau chưa đủ cho kết luận mạnh về thứ hạng tổng quát. Bootstrap không đo biến thiên do seed huấn luyện, không xử lý phụ thuộc giữa bài cùng sự kiện và không thay thế test theo thời gian hoặc nguồn.

PhoBERT đúng/SVM sai ở 1,439 bài, còn SVM đúng/PhoBERT sai ở 1,089 bài. Chênh lệch ròng 350 bài không có nghĩa lỗi SVM là một tập con của lỗi PhoBERT. Hai quy trình phân loại có vùng mạnh khác nhau; việc tận dụng sự khác biệt bằng ensemble là một giả thuyết, chưa phải kết quả đo trong báo cáo.

Khoảng của chênh lệch trực tiếp là bằng chứng thích hợp hơn suy diễn từ hai khoảng riêng. Hai mô hình có lỗi giao nhau nên các chỉ số trên chúng phụ thuộc; lấy cùng vị trí bootstrap giữ phụ thuộc đó. Tuy nhiên, phép lấy mẫu IID vẫn xem mỗi bài như một quan sát độc lập. Nếu nhiều bài chia sẻ sự kiện hoặc bản tin nguồn, độ bất định theo nhóm có thể khác; bootstrap hiện tại chưa đo điều này.

Bootstrap cố định mô hình hỏi điểm chênh có thể dao động ra sao nếu thay mẫu đánh giá theo giả định lấy mẫu hiện tại. Nó không hỏi kết quả dao động thế nào khi khởi tạo khác, shuffle khác hoặc tìm cấu hình bằng validation khác. Với SVM/LR, nghiệm tối ưu còn gắn từ vựng của train; với BiLSTM/PhoBERT, lịch optimizer và bản lưu mô hình phụ thuộc validation. Các yếu tố đó không thay đổi trong 1,000 lần lấy mẫu lại.

Khoảng từng cặp cũng không là một khoảng đồng thời cho tất cả so sánh. Việc thực hiện nhiều cặp cần được công bố để tránh chuyển một dấu dương quan sát thành khẳng định thắng chắc mọi mô hình. Kết luận được giữ ở mức khoảng PhoBERT–SVM nằm trên 0 theo giao thức này, còn các cặp baseline gần nhau có khoảng chứa 0. Không biến kết quả này thành quy luật thứ hạng ở mọi nguồn báo.

Phép chia cùng nguồn, ngẫu nhiên sau loại bỏ bài trùng lặp vẫn có thể đặt tin cùng sự kiện ở cả train và test. Nếu cấu trúc phụ thuộc đó quan trọng, lấy mẫu lại theo bài không mô phỏng

bất định theo nhóm sự kiện. Một test theo thời gian hoặc nguồn khác thay đổi câu hỏi đánh giá, không chỉ làm thêm bootstrap nhiều lần. Bởi vậy, tăng số lần lấy mẫu không tự khắc phục giới hạn khi áp dụng kết luận ngoài điều kiện thực nghiệm.

6.6 Hiệu chỉnh xác suất và độ tin cậy

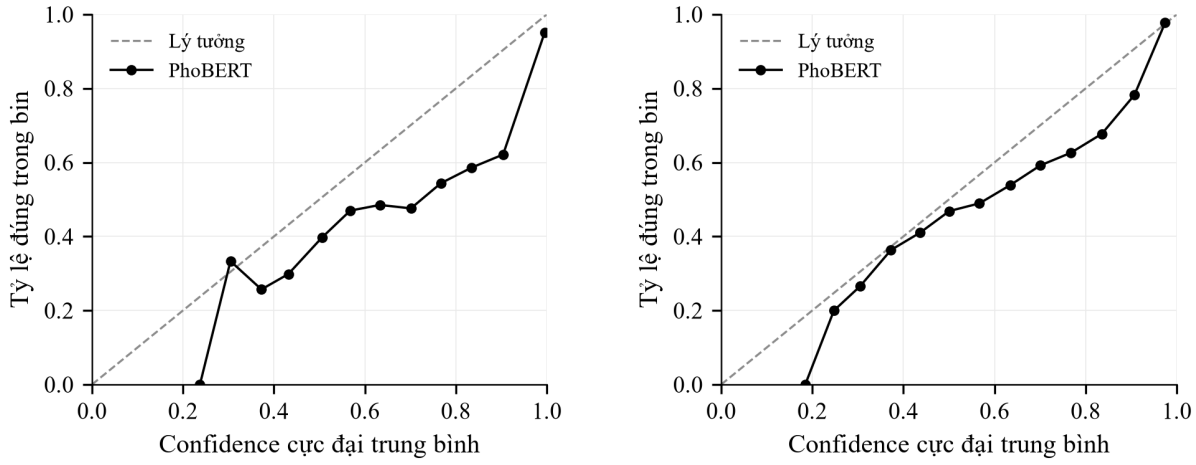
Bảng 6.8: NLL và ECE với 15 khoảng xác suất trước/sau temperature; độ tin cậy là xác suất cực đại trước hệ số quyết định lớp.

Mô hình	T	NLL trước	NLL sau	ECE trước	ECE sau
SVM	0.2718	1.2241	0.3540	0.5457	0.0207
LR	0.7950	0.3653	0.3472	0.0383	0.0119
BiLSTM	1.4685	0.4163	0.3681	0.0532	0.0115
PhoBERT	1.4551	0.3839	0.3220	0.0603	0.0251

SVM giảm NLL từ 1.2241 xuống 0.3540 và ECE từ 0.5457 xuống 0.0207 với $T = 0.2718$. Đây là hiệu chỉnh thang margin: softmax trực tiếp từ margin chưa phải xác suất đã hiệu chỉnh. LR dùng $T = 0.7950$; BiLSTM và PhoBERT dùng $T > 1$, làm phân bố bớt tập trung. Không suy ra chỉ từ dấu $T - 1$ rằng mọi lớp hoặc mọi mức độ tin cậy đều có cùng loại sai lệch.

Sau temperature, BiLSTM/LR có ECE khoảng 0.0115/0.0119, thấp hơn PhoBERT 0.0251; PhoBERT có NLL thấp nhất, 0.3220. ECE là tổng sai lệch độ tin cậy–accuracy theo các khoảng xác suất, còn NLL xét xác suất nhãn tham chiếu của từng mẫu. Mô hình có ECE thấp nhất không đồng nghĩa mô hình có F1 cao nhất hoặc xác suất tối ưu theo mọi tiêu chí. Không dùng ngưỡng độ tin cậy của app PhoBERT cho một mô hình khác mà chưa kiểm chứng lại định tuyến.

ECE dùng 15 khoảng đều và correctness của argmax chuẩn; khoảng không rỗng đóng góp theo số mẫu. Quy ước mã nguồn có cận trên mở, nên xác suất đúng bằng 1 không nằm trong



(a) Softmax chưa hiệu chỉnh. **(b)** Sau temperature scaling.

Hình 6.2: Biểu đồ độ tin cậy của PhoBERT trên cùng test, cùng thang trục và 15 khoảng xác suất; độ tin cậy cực đại trước hệ số quyết định theo lớp.

khoảng cuối; mẫu số là tổng bài thuộc các khoảng. ECE phụ thuộc cách chia khoảng và có thể che sai lệch ở lớp hiếm; không chứng nhận xác suất của từng bài.

Với PhoBERT, NLL giảm từ 0.383892 xuống 0.322030, ECE từ 0.060291 xuống 0.025071. Các giá trị mô tả $p(T)$, chưa xác nhận hiệu chỉnh xác suất của q hoặc độ tin cậy nhãn cuối khi τ_c đổi nhãn. Việc áp dụng ngưỡng độ tin cậy cho tự động duyệt phải được kiểm tra theo chính luồng quyết định đó.

Phân tích dự đoán có chọn lọc, tức chỉ giữ các bài đạt ngưỡng độ tin cậy trên test cho thấy ngưỡng 0.75 giữ 27,644 bài (tỷ lệ bài được giữ 92.16%), Accuracy nhóm 94.55%; ngưỡng 0.95 giữ 22,322 bài (74.42%) với Accuracy nhóm 98.36%. Đây là Accuracy có điều kiện trên nhóm được giữ, không thay Accuracy toàn bộ test và không là hiệu quả sản xuất thực tế. Ngưỡng 0.99 không có mẫu đạt, nên Accuracy không xác định. Đường tỷ lệ bài được giữ–Accuracy và chính sách phân luồng được trình bày ở Phụ lục B.

NLL sử dụng xác suất của nhãn tham chiếu cho từng bài. Một dự đoán sai nhưng rất tự tin làm xác suất nhãn thật nhỏ và bị phạt mạnh; một quyết định đúng vẫn có thể có NLL cao nếu xác suất phân bố chưa tập trung vào nhãn đó. F1 không giữ mức độ tự tin, nên thay T có thể cải thiện NLL mà F1 giữ nguyên. Đây là lý do không gọi temperature scaling là một lần huấn luyện bộ phân loại để nâng Accuracy.

ECE tập hợp bài theo độ tin cậy cực đại rồi so trung bình độ tin cậy với tỷ lệ đúng trong khoảng. Sai lệch có thể được bù trong tổng hợp và số khoảng ảnh hưởng kết quả. Một mô hình phân loại ít chính xác hơn vẫn có thể tự tin phù hợp với mức đúng thấp hơn, đạt ECE nhỏ. Vì thế, ECE BiLSTM/LR thấp hơn PhoBERT không phủ định thứ hạng Macro-F1; chúng đo những yêu cầu khác nhau của đầu ra.

Quy tắc τ_c có thể chọn nhãn không phải argmax xác suất, nên độ tin cậy dùng trong app cũng không luôn là cực đại. Chứng cứ reliability trước/sau temperature chỉ đánh giá phân bố $p(T)$ theo giao thức đã công bố. Nếu muốn dùng độ tin cậy của nhãn cuối cho duyệt tự động, cần kiểm tra lỗi và hiệu chỉnh xác suất trực tiếp ở luồng đó, theo lớp và thời điểm. Hiện các số mô phỏng tỷ lệ bài được giữ là mô tả test, không một ngưỡng bảo đảm cho dữ liệu vận hành.

6.7 Chi phí tính toán và trả lời RQ1–RQ3

Bảng 6.9: Thời gian thực nghiệm của bốn phương pháp; các phạm vi đo được giải thích trong nội dung.

Mô hình	Thiết bị	Fit chọn (s)	Tìm cấu hình (s)	Test (s)
SVM	CPU	27.319	758.245	12.689
LR	CPU	239.531	2,370.248	13.125
BiLSTM	GPU	1,779.429	4,473.369	9.233
PhoBERT	GPU	12,429.912	–	106.322

SVM huấn luyện bộ phân loại được chọn trong 27.319 giây, LR trong 239.531 giây, đều dùng CPU với bốn luồng. Tổng tìm 12 cấu hình là 758.245 và 2,370.248 giây, gồm tạo TF–IDF và các lượt tối ưu. BiLSTM train cấu hình chọn trong 1,779.429 giây (29.66 phút), tìm ba cấu

hình trong 4,473.369 giây (74.56 phút). PhoBERT fine-tuning bảy epoch mất 12,429.912 giây (207.17 phút), không tính chi phí tiền huấn luyện mô hình nền. Phép đo thời gian huấn luyện SVM/LR chỉ đo tối ưu bộ phân loại; phép đo thời gian huấn luyện mạng nơ-ron gồm vòng train, validation theo epoch và lưu bản lưu mô hình, nên không phải các hạng chi phí hoàn toàn đồng nhất.

Phạm vi suy luận khác nhau. SVM/LR gồm TF–IDF transform và decision function trên CPU, không gồm phân đoạn tiếng Việt. BiLSTM gồm DataLoader, chuyển tensor sang GPU và forward, không gồm phân đoạn/mã hóa; batch test là 128. Phép đo thời gian test PhoBERT là 106.322 giây trên GPU, không gồm nạp mô hình; batch test là 64 và input đã mã hóa. Các thời gian 12.689/13.125/9.233 giây của ba đối chứng phản ánh khối lượng công việc được ghi, không phải độ trễ từ URL đến nhãn trong app. Chưa có benchmark phục vụ suy luận CPU đồng nhất để xếp hạng độ trễ triển khai.

BiLSTM có 10.34 triệu tham số, PhoBERT 135.01 triệu; hai mô hình tuyến tính lưu hệ số, từ vựng và IDF, không có encoder lớn. Tệp kết quả BiLSTM ghi bộ nhớ GPU cấp phát cực đại 0.564 GiB trong huấn luyện cấu hình được chọn, thông tin mô tả PhoBERT ghi 5.388 GiB ở lượt đánh giá. Hai mốc đo khác giai đoạn; chưa có bộ nhớ RAM/VRAM cực đại toàn quy trình đồng nhất cho cả bốn mô hình. Không dùng dung lượng file nén hoặc bộ nhớ bộ nhớ CUDA dự trữ thay cho bộ nhớ thực thi được đo.

6.7.1 Chi phí của biểu diễn và cập nhật tham số

TF–IDF có chi phí đọc, đếm và biến đổi văn bản trước tối ưu bộ phân loại. Ma trận thưa giúp tính trên các phần tử có giá trị thay vì một tensor đặc toàn bộ 150,000 chiều mỗi bài. Thời gian huấn luyện bộ phân loại chọn không chứa toàn bộ công việc tạo ra nó, nên một mốc CPU ngắn không đồng nghĩa quy trình phân loại từ tập dữ liệu thô đến tệp kết quả chỉ mất từng đó giây. Tổng tìm cấu hình có phạm vi rộng hơn và được trình bày riêng.

BiLSTM cập nhật vector biểu diễn từ học từ train cùng lớp hồi tiếp/đầu phân loại; packed sequence tránh quét PAD nhưng vẫn có phụ thuộc trạng thái theo chiều thời gian. PhoBERT tạo các phép attention và FFN trên chuỗi 256, cập nhật bộ mã hóa nền lớn đã tiền huấn luyện. Những khác biệt cơ chế giúp hiểu yêu cầu tính toán, nhưng chưa đủ phân rã chính xác số giây cho từng phép toán. Không dùng riêng chiều dài 512 từ và 256 subword để suy ra mạng nơ-ron nào tất yếu nhanh hơn: hai đơn vị và phép tính khác nhau.

GPU xử lý theo lô trong evaluation dùng nhiều bài mỗi forward, trong khi app nhận request qua API và có thể chạy CPU. Một thông lượng lớn nhờ batch chưa bảo đảm độ trễ thấp khi bài đến lẻ hoặc hàng đợi dài. Các đo kiểm đồng nhất cần khóa lượng văn bản, preprocessor, batch, precision, thiết bị và điểm bắt đầu/kết thúc phép đo thời gian. Bản dữ liệu hiện tại cung cấp các phép đo thời gian của lượt thực nghiệm, chưa cung cấp toàn bộ phép đo phục vụ suy luận này.

6.7.2 Phạm vi đo và ý nghĩa đối với lựa chọn mô hình

Chi phí huấn luyện cấu hình được chọn phù hợp câu hỏi dùng lại một cấu hình đã biết; tổng tìm cấu hình phù hợp câu hỏi tài nguyên để chọn ra cấu hình đó. SVM/LR có số ứng viên

bằng nhau nhưng solver và tiêu chí tối ưu khác, còn mạng nơ-ron bao gồm validation và bản lưu mô hình theo epoch. Một ratio từ các phép đo thời gian này chỉ mô tả lượt chạy đã ghi, không là tốc độ tuyệt đối của một họ thuật toán. Tiền huấn luyện PhoBERT còn là chi phí bên ngoài lượt fine-tuning, chưa được tính vào bảng.

Phép đo suy luận trong đánh giá theo batch cũng khác một yêu cầu phục vụ đơn. Trong app còn có trích xuất URL, tiền xử lý, mã hóa, transport, truy cập database và thời gian hàng đợi. Những bước không nằm trong phép đo thời gian offline không được suy bằng cách chia tổng giây cho số test rồi gọi độ trễ HTTP. Container phục vụ CPU trong khi mô hình nơ-ron trong đánh giá đo GPU, càng cần một benchmark cùng điều kiện trước khi kết luận mô hình nào phục vụ nhanh nhất.

Tài nguyên lưu trữ và tài nguyên thực thi cũng khác nhau. File trọng số, từ vựng và tensor cache hỗ trợ tái hiện nhưng không đều phải nằm trên GPU khi forward. Số tham số cung cấp quy mô kiến trúc, chưa đo bộ nhớ RAM cực đại toàn quy trình. Các mốc VRAM hiện có thuộc hai giai đoạn khác nhau; bảng không có số peak đồng nhất cho cả bốn quy trình phân loại và không tự bổ sung bằng ước lượng.

Một quyết định triển khai còn phụ thuộc hậu quả của lỗi từng lớp và khả năng rà soát. Chênh lệch Macro-F1 có thể đáng giá khi cải thiện chuyên mục khó quan trọng, nhưng không đủ nếu lỗi tự động ở một lớp hiếm gây chi phí lớn. Vì vậy, câu trả lời RQ2 giữ điều kiện đo và liên kết với RQ3, thay vì chuyển một thứ hạng F1 thành quyết định duy nhất cho mọi tải và chính sách.

6.7.3 Diễn giải theo câu hỏi nghiên cứu

RQ1: PhoBERT đạt Macro-F1 cao nhất trong thực nghiệm. Đánh giá ghép cặp ủng hộ chênh lệch với ba đối chứng khi giữ mô hình cố định, nhưng chưa xác nhận thứ hạng SVM–LR–BiLSTM qua nhiều lần huấn luyện.

RQ2: mức tăng khoảng 1.89 điểm phần trăm Macro-F1 so với SVM đi kèm thời gian fine-tuning dài hơn và bộ mã hóa lớn hơn. Các phép đo hiện có mô tả chi phí thực nghiệm; chưa đủ để xếp hạng độ trễ và bộ nhớ phục vụ suy luận trong cùng điều kiện.

RQ3: BiLSTM/LR có F1 cao hơn ở Nông thôn mới, PhoBERT tốt hơn rõ ở Dân tộc thiểu số và miền núi. Lỗi chung tại ranh giới chuyên mục cho thấy cần rà soát nhãn và bài khó, bên cạnh cải tiến mô hình.

Kết luận chỉ áp dụng cho nguồn dữ liệu, phép chia và các cấu hình đã công bố. Đánh giá theo thời gian, nhiều seed và ablation có kiểm soát là các hướng kiểm chứng tiếp theo. Ứng dụng minh họa dùng gói PhoBERT với tham số hiệu chỉnh đã được xác định.

7. Kết luận và giới hạn nghiên cứu

7.1 Kết luận từ bằng chứng thực nghiệm

Báo cáo khảo sát phân loại đơn nhãn 20 chuyên mục VietNamNet từ tiêu đề và nội dung. Xác minh chuyên mục cấp bài, quy mục con về cha và loại bỏ bài trùng lặp tạo tập dữ liệu 199,965 bài; bốn quy trình phân loại sử dụng cùng train/validation/test phân tầng 70/15/15. TF–IDF với SVM/LR, vector biểu diễn từ chuỗi với BiLSTM và PhoBERT tiền huấn luyện được đánh giá bằng cùng nhãn tham chiếu, với lựa chọn cấu hình và hiệu chỉnh giữ ngoài test.

Trên cùng 29,995 bài test, PhoBERT đạt Macro-F1 87.22%, hơn Linear SVM 1.89 điểm phần trăm; LR và BiLSTM đạt 84.98% và 84.60%. Khoảng bootstrap ghép cặp PhoBERT–SVM nằm trên 0 khi mô hình cố định; các baseline gần nhau chưa có bằng chứng cho một thứ hạng ổn định qua các lần train. SVM là đối chứng mạnh về chi phí huấn luyện trong phạm vi đo trên CPU; các phép đo thời gian không tạo benchmark độ trễ phục vụ suy luận đồng nhất.

Kết quả theo lớp cho thấy đứng đầu tổng thể không bảo đảm F1 tốt nhất ở chuyên mục ít mẫu. BiLSTM/LR tăng recall Nông thôn mới nhưng còn precision thấp; các lỗi chung cần đọc cùng quy tắc chuyên mục. Hiệu chỉnh xác suất, lựa chọn nhãn và chi phí rà soát là những khía cạnh liên quan nhưng khác nhau. Ứng dụng PhoBERT minh họa đề xuất nhãn và phản hồi có truy vết, không thay thế đánh giá offline (Phụ lục B).

7.2 Giới hạn và hướng kiểm chứng tiếp theo

Thực nghiệm chỉ có một nguồn báo và một seed. Phép chia ngẫu nhiên trong bản dữ liệu chưa đo tin tương lai, nguồn khác hay độ biến thiên huấn luyện; kiểm tra các bài trùng khớp hoàn toàn chưa đánh giá bài gần giống nhau hoặc phụ thuộc sự kiện. Bootstrap dự đoán cố định mô tả bất định lấy mẫu test, không bù cho các giới hạn này.

Các quy trình phân loại khác nhau về tiền huấn luyện, từ dừng, tiêu đề, lượng văn bản giữ và ngân sách tìm cấu hình. Do đó, chưa quy được khoảng cách cho kiến trúc riêng hoặc một bước tiền xử lý. Khoảng độ tin cậy sau temperature không tự xác nhận hiệu chỉnh xác suất sau điều chỉnh hệ số điều chỉnh theo lớp; các phép đo chi phí cũng cần cùng phạm vi, thiết bị và khối lượng công việc trước khi suy ra lựa chọn phục vụ suy luận.

Giới hạn nhãn và giới hạn mô hình cần được xử lý theo hai đường khác nhau. Rà soát bài gốc và hệ thống chuyên mục giúp xác định trường hợp dữ liệu chưa đủ đáng tin; ablation trên tập dữ liệu đã khóa giúp xác định ảnh hưởng của một lựa chọn xử lý. Nếu đổi đồng thời nhãn, split và kiến trúc, một điểm F1 mới không giải thích được nguyên nhân cải thiện. Thiết kế tiếp theo cần giữ đối chứng rõ cho từng giả thuyết.

Các bước đánh giá mở rộng cũng cần khóa phạm vi. Test theo thời gian hỏi khả năng xử lý tin đến sau; nhiều seed hỏi độ ổn định của huấn luyện; tập dữ liệu hiệu chỉnh riêng hỏi mức phụ thuộc lựa chọn vào validation. Chúng bổ sung những mặt khác nhau và không thay nhau. Một

hệ thống có thể ổn định trong bản dữ liệu mà vẫn suy giảm khi sự kiện hoặc cách đặt chuyên mục thay đổi.

Ưu tiên tiếp theo là kiểm toán ranh giới nhãn ở lớp hiếm và nhóm cùng sai, phát hiện gần trùng trước split, đánh giá theo thời gian và lặp nhiều seed. Ablation có kiểm soát cho Head–Tail, phân đoạn, bỏ số, từ dừng và lặp tiêu đề giúp xác định yếu tố cần giữ. Một tập hiệu chỉnh xác suất riêng và benchmark từ văn bản đến nhãn bổ sung căn cứ trước khi chuyển kết quả của bản dữ liệu sang một môi trường có lưu lượng mới.

Tài liệu tham khảo

[1] Bùi Khánh Linh, Nguyễn Thị Thu Hà, Nguyễn Thị Ngọc Tú, and Đào Thanh Tĩnh. Phân loại văn bản tiếng Việt dựa trên mô hình chủ đề. In *Kỷ yếu Hội nghị khoa học quốc gia lần thứ IX: Nghiên cứu cơ bản và ứng dụng Công nghệ thông tin (FAIR'9)*, pages 532–537, 2017. doi: 10.15625/vap.2016.00065. Hội nghị tại Cần Thơ, ngày 4–5/08/2016; metadata xuất bản ghi năm 2017.

[2] Bùi Quang Tấn Kiệt and Nguyễn Thị Lang. Phân tích và thực nghiệm các phương pháp phân loại bài báo tiếng Việt. Bản nghiên cứu PDF; chưa xác minh nơi và năm công bố; metadata PDF ghi sửa đổi 30/06/2025, s.d.

[3] Bao Nhan Chau, Dat Duong, and Phuoc Tran. A Large-Scale Vietnamese News Dataset for Text Classification: Construction and Evaluation. *IEEE Access*, 14:109797–109808, 2026. doi: 10.1109/ACCESS.2026.3711994.

[4] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In *Proceedings of NAACL-HLT*, pages 4171–4186, 2019. doi: 10.18653/v1/N19-1423. URL https://aclanthology.org/N19-1423/.

[5] Huu-Thanh Duong and Vinh Truong Hoang. A Survey on the Multiple Classifier for New Benchmark Dataset of Vietnamese News Classification. In *2019 11th International Conference on Knowledge and Smart Technology (KST)*, pages 23–28. IEEE, 2019. doi: 10.1109/KST.2019.8687509.

[6] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On Calibration of Modern Neural Networks. In *Proceedings of the 34th International Conference on Machine Learning*, volume 70, pages 1321–1330, 2017. URL https://proceedings.mlr.press/v70/guo17a.html.

[7] Vu Cong Duy Hoang, Dien Dinh, Nguyen Le Nguyen, and Hung Quoc Ngo. A Comparative Study on Vietnamese Text Classification Methods. In *2007 International Conference on Research, Innovation and Vision for the Future*, pages 267–273. IEEE, 2007. doi: 10.1109/RIVF.2007.369167.

[8] Kamran Kowsari, Kiana Jafari Meimandi, Mojtaba Heidarysafa, Sanjana Mendu, Laura Barnes, and Donald Brown. Text Classification Algorithms: A Survey. *Information*, 10 (4):150, 2019. doi: 10.3390/info10040150. Bài số 150.

[9] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. RoBERTa: A Robustly Optimized BERT Pretraining Approach, 2019. URL https://arxiv.org/abs/1907.11692.

[10] Ilya Loshchilov and Frank Hutter. Decoupled Weight Decay Regularization. In *International Conference on Learning Representations*, 2019. URL https://arxiv.org/abs/1711.05101.

[11] Dat Quoc Nguyen and Anh Tuan Nguyen. PhoBERT: Pre-trained language models for Vietnamese. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 1037–1042, 2020. doi: 10.18653/v1/2020.findings-emnlp.92. URL https://aclanthology.org/2020.findings-emnlp.92/.

[12] Thi Hien Nguyen, Thi Thoa Bui, and Nguyen Hoang Hoa Luong. A Study on Deep Learning for Vietnamese Text Classification. *Journal of Military Science and Technology*, 95:85–94, 2024. doi: 10.54939/1859-1043.j.mst.95.2024.85-94. URL https://en.jmst.info/index.php/jmst/article/view/1091.

[13] Nguyễn Chí Hiếu. Khảo sát các mô hình phân loại văn bản tiếng Việt. *Tạp chí Khoa học và Công nghệ, Trường Đại học Công nghiệp Thành phố Hồ Chí Minh*, 57(03):99–109, 2022. doi: 10.46242/jstiuh.v57i03.4395.

[14] Khanh Quoc Tran, Phap Ngoc Trinh, Khoa Nguyen-Anh Tran, An Tran-Hoai Le, Luan Van Ha, and Kiet Van Nguyen. An Empirical Investigation of Online News Classification on an Open-Domain, Large-Scale and High-Quality Dataset in Vietnamese. In *New Trends in Intelligent Software Methodologies, Tools and Techniques*, volume 337 of *Frontiers in Artificial Intelligence and Applications*, pages 367–379. IOS Press, 2021. doi: 10.3233/FAIA210036.

[15] Viet Trung Tran. PyVi: Python Vietnamese Toolkit, s.d. URL https://github.com/trungtv/pyvi. Mã nguồn toolkit tách từ tiếng Việt; truy cập tháng 10/2026.

[16] Trần Cao Đệ and Phạm Nguyên Khang. Phân loại văn bản với máy học vector hỗ trợ và cây quyết định. *Tạp chí Khoa học, Trường Đại học Cần Thơ*, 21a:52–63, 2012. URL https://sj.ctu.edu.vn/ql/docgia/download/baibao-5654/trongtruong_so21a_07.pdf.

[17] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention Is All You Need. In *Advances in Neural Information Processing Systems*, volume 30, 2017. URL https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html.

[18] VinAI Research. PhoBERT-base-v2 model card. Hugging Face, s.d. URL https://huggingface.co/vinai/phobert-base-v2. Truy cập tháng 10/2026.

[19] Quan-Hoang Vo, Huy-Tien Nguyen, Bac Le, and Minh-Le Nguyen. Multi-channel LSTM-CNN Model for Vietnamese Sentiment Analysis. In *2017 9th International Conference on Knowledge and Systems Engineering (KSE)*, pages 24–29. IEEE, 2017. doi: 10.1109/KSE.2017.8119429.

[20] Thanh Vu, Dat Quoc Nguyen, Dai Quoc Nguyen, Mark Dras, and Mark Johnson. VnCoreNLP: A Vietnamese Natural Language Processing Toolkit. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Demonstrations*, pages 56–60. Association for Computational Linguistics, 2018. doi: 10.18653/v1/N18-5012. URL https://aclanthology.org/N18-5012/.

A. Bằng chứng, thực thi và tái hiện

A.1 Nguồn bằng chứng và môi trường

Năm notebook chứa mã nguồn và kết quả thực nghiệm. Dữ liệu được lưu trong 20 tệp Parquet và bốn JSON xác minh; PhoBERT dùng result/evaluation/, ba đối chứng dùng result/<model>/evaluation/ với <model> là svm, logistic hoặc lstm. Tệp chỉ số và cấu hình được chọn liên kết các số liệu tổng hợp với bảng đánh giá theo lớp, ma trận và dự đoán từng bài. split_manifest.json cùng article_metadata.parquet xác định đúng thứ tự mẫu, không chỉ số lượng.

Thông tin mô tả PhoBERT ghi Python 3.14.7, PyTorch 2.11.0+cu128, CUDA 12.8, Transformers 5.17.0, NumPy 2.5.2, pandas 3.0.6, scikit-learn 1.9.1, PyArrow 26.0.0 và PyVi 0.1.1. Các mạng nơ-ron dùng RTX A3000 Laptop 12 GB; các notebook đối chứng ghi CPU/GPU cùng phạm vi phép đo thời gian riêng. Đổi phiên bản, kernel hoặc precision có thể làm thay đổi tốc độ và điểm số sát ranh giới.

A.2 Tái hiện và kiểm tra tính toàn vẹn

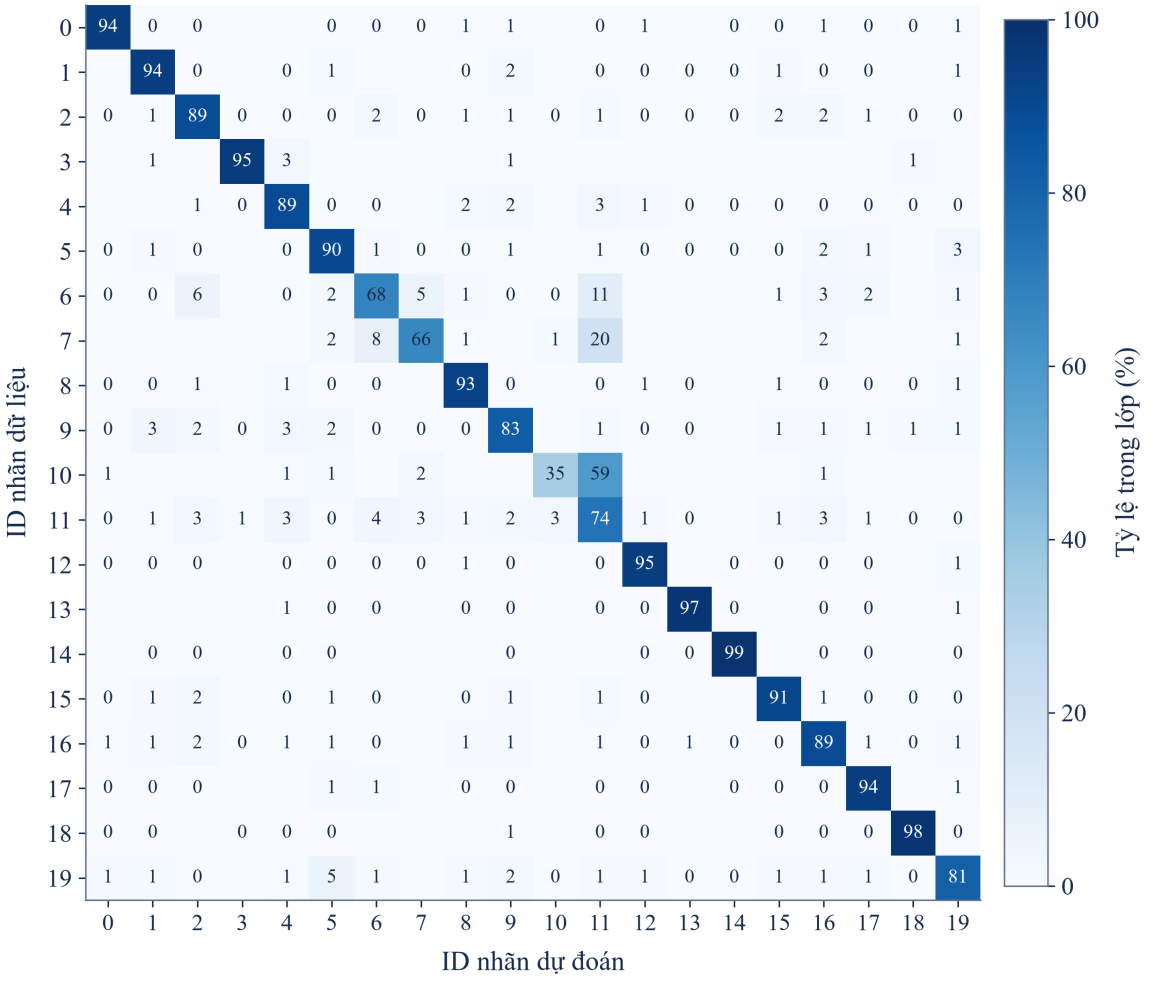
Đọc output và các file evaluation cho phép kiểm tra kết quả mà không train lại. Scores/logits và predictions được tái tính để xác nhận Accuracy, F1, số mẫu; tổng mỗi ma trận bằng 29,995. Mảng split của bốn mô hình giống nhau, toàn bộ URL/nhãn test khớp theo thứ tự; chuỗi mã nhận diện có thể khác vì cách tạo hash khác nhau. Các bảng ánh xạ nhãn và hiệu chỉnh xác suất phải được đối chiếu cùng bản lưu mô hình thay vì nạp một tokenizer bất kỳ.

Với tập dữ liệu đã cố định, mỗi notebook mô hình thực thi độc lập. Chế độ fresh tạo một lượt huấn luyện mới; evaluate đánh giá gói mô hình có sẵn và tương thích. Chế độ continue của BiLSTM/PhoBERT nạp trọng số tương thích nhưng tạo lại bộ tối ưu và lịch learning rate, không khôi phục đầy đủ trạng thái giữa epoch. Crawl lại có thể đổi bản dữ liệu vì HTML và phạm vi xuất bản thay đổi. README chứa lệnh vận hành và đường dẫn chi tiết.

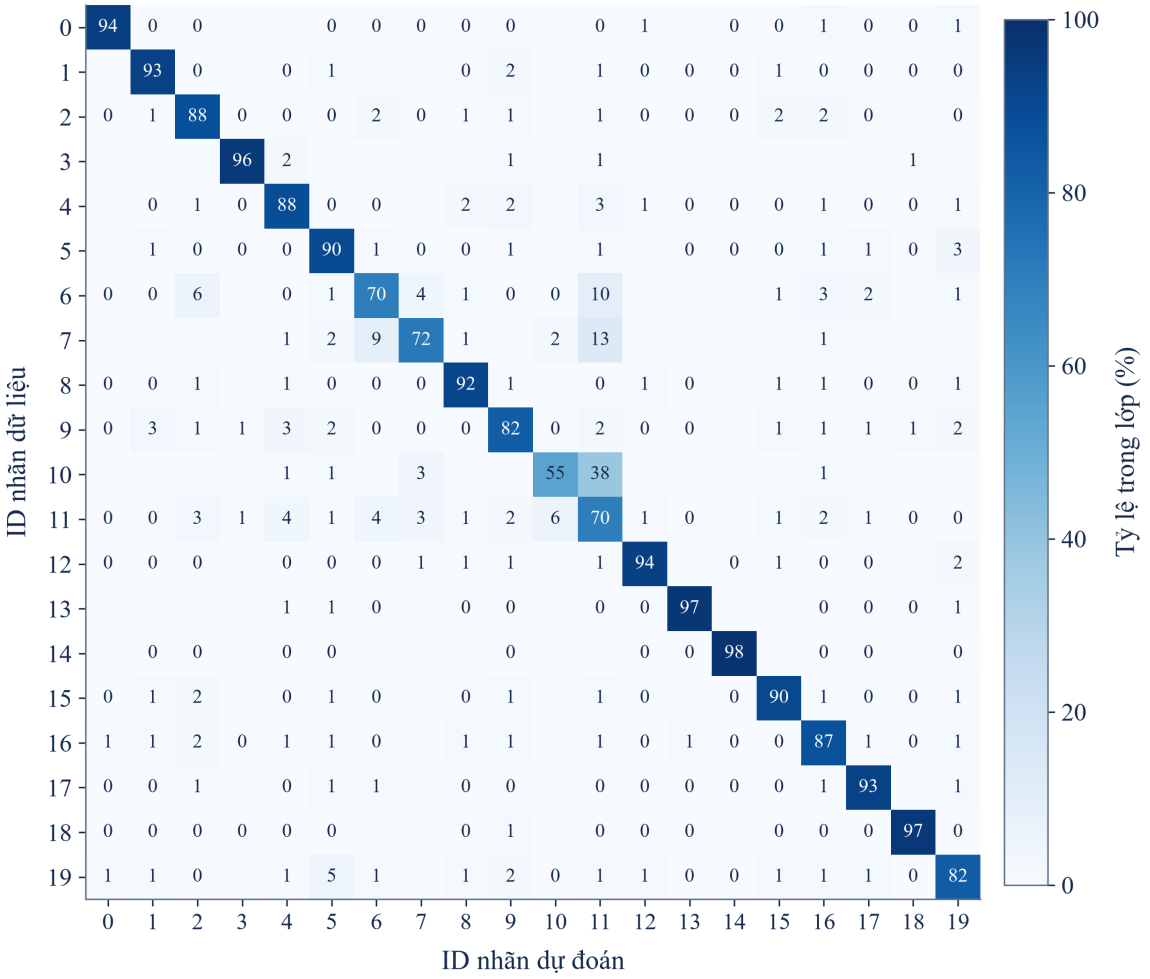
Gói đang được dùng của app có SHA trọng số bắt đầu 607f3240; mapping, Head–Tail, tiền xử lý và hiệu chỉnh xác suất khớp gói PhoBERT. SHA xác nhận đúng byte của tệp kết quả, không xác nhận nhãn ngữ nghĩa của mọi bài. Các biểu đồ đặt cạnh nhau trong báo cáo dùng cùng số liệu nguồn; ma trận 20 lớp vẫn hiển thị riêng để giữ khả năng đọc. Đường PR từng lớp, history chi tiết và các chẩn đoán khác được giữ ở assets/output notebook, không cần đưa toàn bộ vào PDF.

A.3 Ma trận chuẩn hóa các đối chứng

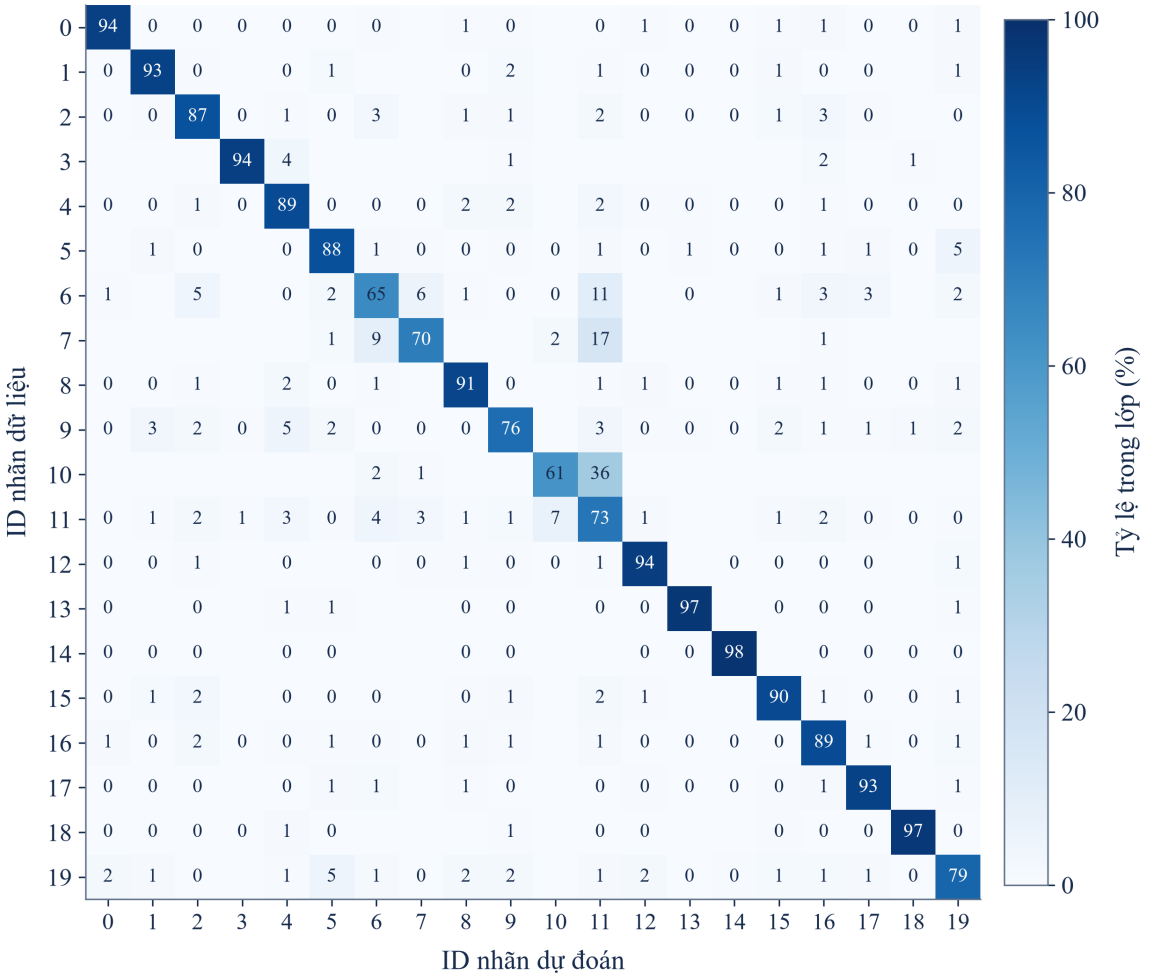
Ba hình dùng cùng ID ở bảng 3.2, đơn vị phần trăm theo số mẫu hàng. Đối chiếu với ma trận PhoBERT cần đổi thang 0–1 thành phần trăm; không so màu mà bỏ qua đơn vị.



Hình A.1: Linear SVM, argmax trên 29,995 bài test; chuẩn hóa theo hàng (%).



Hình A.2: Logistic Regression, cùng test và hệ thống chuyên mục; chuẩn hóa theo hàng (%).



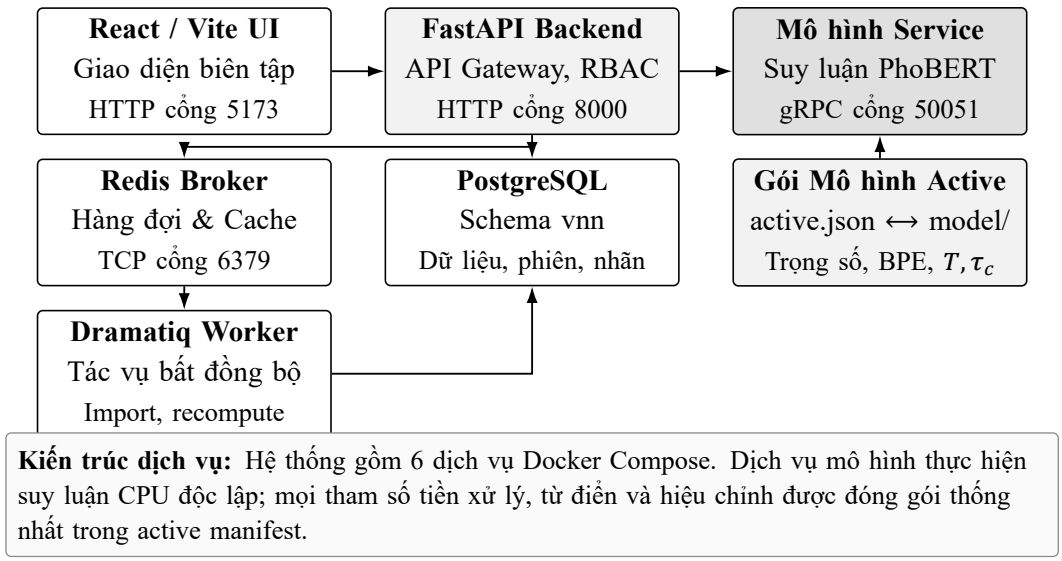
Hình A.3: BiLSTM, cùng test và hệ thống chuyên mục; chuẩn hóa theo hàng (%).

B. Ứng dụng hỗ trợ biên tập

B.1 Kiến trúc dịch vụ và yêu cầu nhất quán khi suy luận

Ứng dụng đưa gói PhoBERT vào quy trình nhập bài, đề xuất nhãn, rà soát và lưu phản hồi. Sáu dịch vụ trong Docker Compose gồm React/Vite UI, FastAPI API, dịch vụ mô hình gRPC, PostgreSQL, Redis và Dramatiq worker. UI dùng HTTP 5173, API 8000, dịch vụ mô hình gRPC 50051; lược đồ cơ sở dữ liệu vnn lưu bài, prediction, phản hồi, phiên và registry. Redis hỗ trợ hàng đợi, worker xử lý import hoặc recompute monitoring. Dịch vụ mô hình nạp gói mô hình theo app/artifacts/active.json: trọng số PhoBERT, bộ mã hóa token được lưu cùng gói, hệ thống chuyên mục 20 lớp, Head–Tail 256, temperature và toàn bộ hệ số lớp. Khi khởi động, dịch vụ kiểm tra tệp, bảng ánh xạ nhãn và mã băm SHA của trọng số; mô hình được đặt ở chế độ đánh giá (eval), tắt dropout. Ba gói SVM/LR/BiLSTM là đối chứng offline, chưa là lựa chọn mô hình trong UI. Với container hiện tại, suy luận dùng CPU float32; notebook mạng nơ-ron dùng GPU BF16, nên logits sát ranh giới có thể khác nhỏ dù cùng quy tắc.

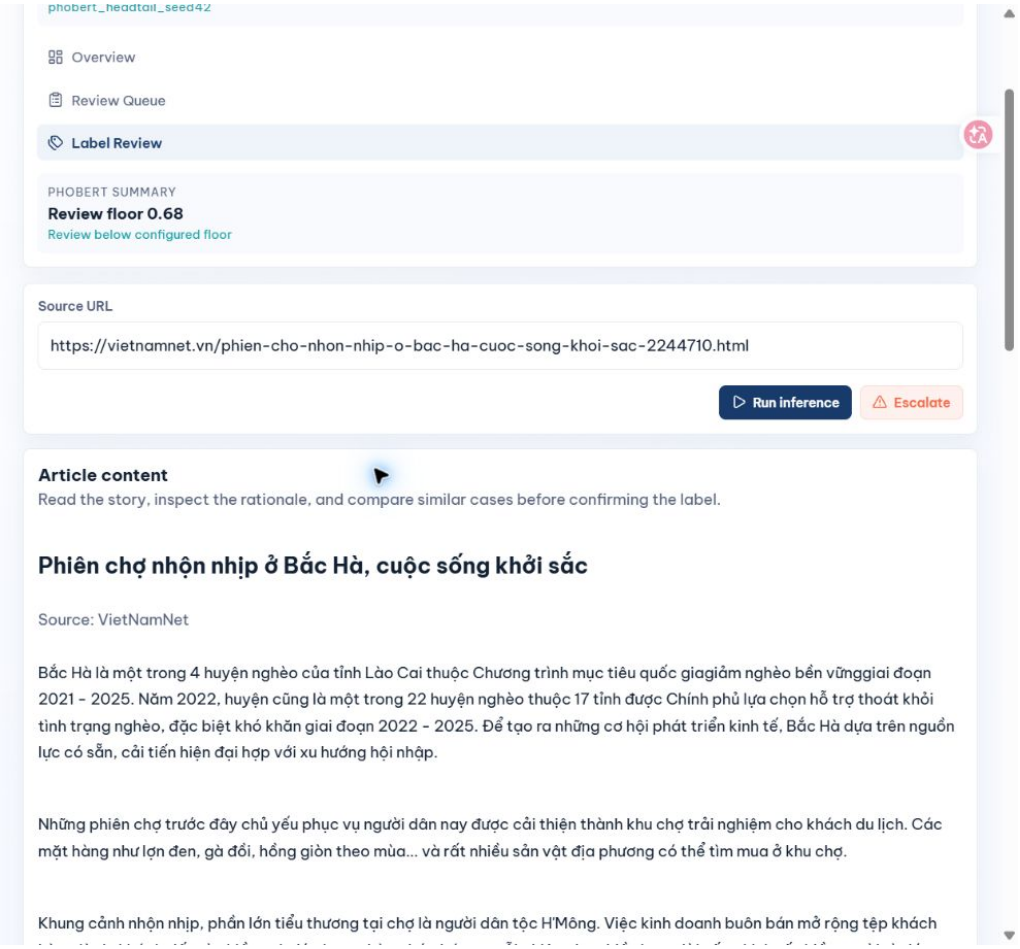
Ba vai trò Editor, Admin và Data Scientist có quyền tương ứng ở API. Phân quyền không chỉ dựa vào việc ẩn nút trong UI. Gói mô hình bao gồm thông tin mô tả và tokenizer cùng trọng số; chỉ có config/tokenizer trong clone mà thiếu trọng số không đủ để chạy dịch vụ. Các yêu cầu này giúp tránh mô hình nạp được tensor nhưng dùng sai nhãn hoặc sai tiền xử lý.



Hình B.1: Sáu dịch vụ của ứng dụng và gói mô hình dùng cho suy luận.

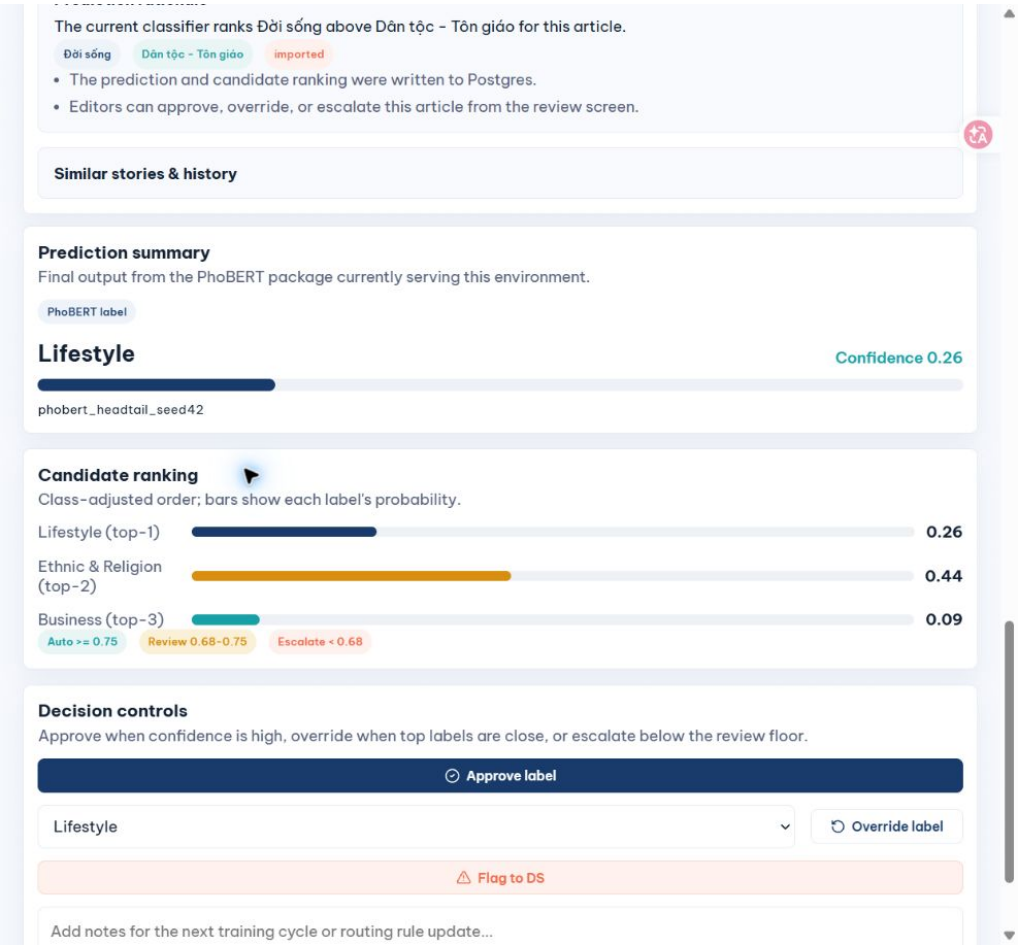
B.2 Quy trình dự đoán, đọc bài và sửa nhãn

Editor nhập URL VietNamNet hoặc dán tiêu đề/nội dung. Dịch vụ kiểm tra đầu vào có văn bản sử dụng được, lưu nội dung đầy đủ và gọi inference; công việc bất đồng bộ có job ID để theo dõi. Lỗi tải và đầu vào rỗng không được thay bằng dự đoán giả. Các bài nhập trong app không tự được đưa vào tập dữ liệu notebook. Ví dụ "Phiên chợ nhộn nhịp ở Bắc Hà, cuộc

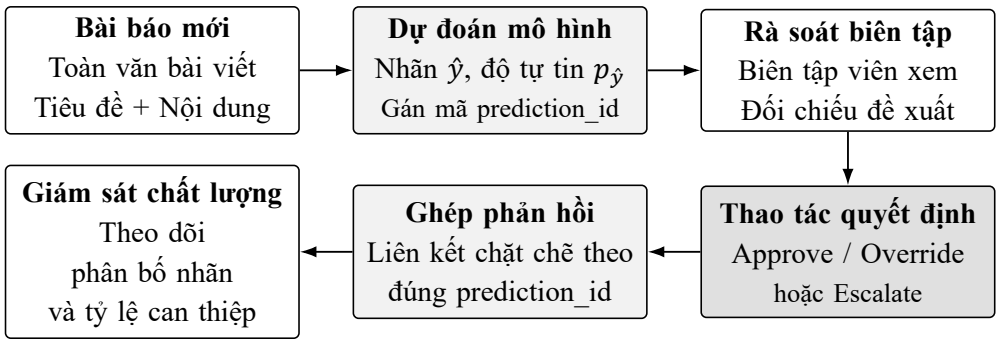


Hình B.2: Nội dung bài và URL nguồn trong màn hình rà soát.

sống khởi sắc" có nội dung du lịch, sinh kế và giảm nghèo. Mô hình chọn Đời sống với độ tin cậy khoảng 0.26, trong khi xác suất Dân tộc – Tôn giáo khoảng 0.44. Điều này phù hợp với hệ số quyết định: nhãn xếp đầu theo $r = p/\tau$ có thể không có xác suất lớn nhất. Độ tin cậy thấp chuyển bài cho người xử lý chuyên sâu (escalate); không coi ví dụ này như một đánh giá test mới. Ba thao tác biên tập là Approve (chấp nhận nhãn đề xuất), Override (chọn nhãn khác trong danh sách chuyên mục) và Escalate (chuyển bài khó để xử lý chuyên sâu). API từ chối approve với nhãn không phải top-1 hoặc khi chưa có prediction hợp lệ. Phản hồi gắn đúng prediction ID; suy luận lại tạo prediction mới, không tự chuyển phản hồi cho lần cũ thành nhãn tham chiếu của lần mới. Các khối từ khóa trên giao diện không phải lời giải thích đóng góp của attention.



Hình B.3: Nhãn gợi ý, độ tin cậy, các ứng viên và thao tác biên tập.

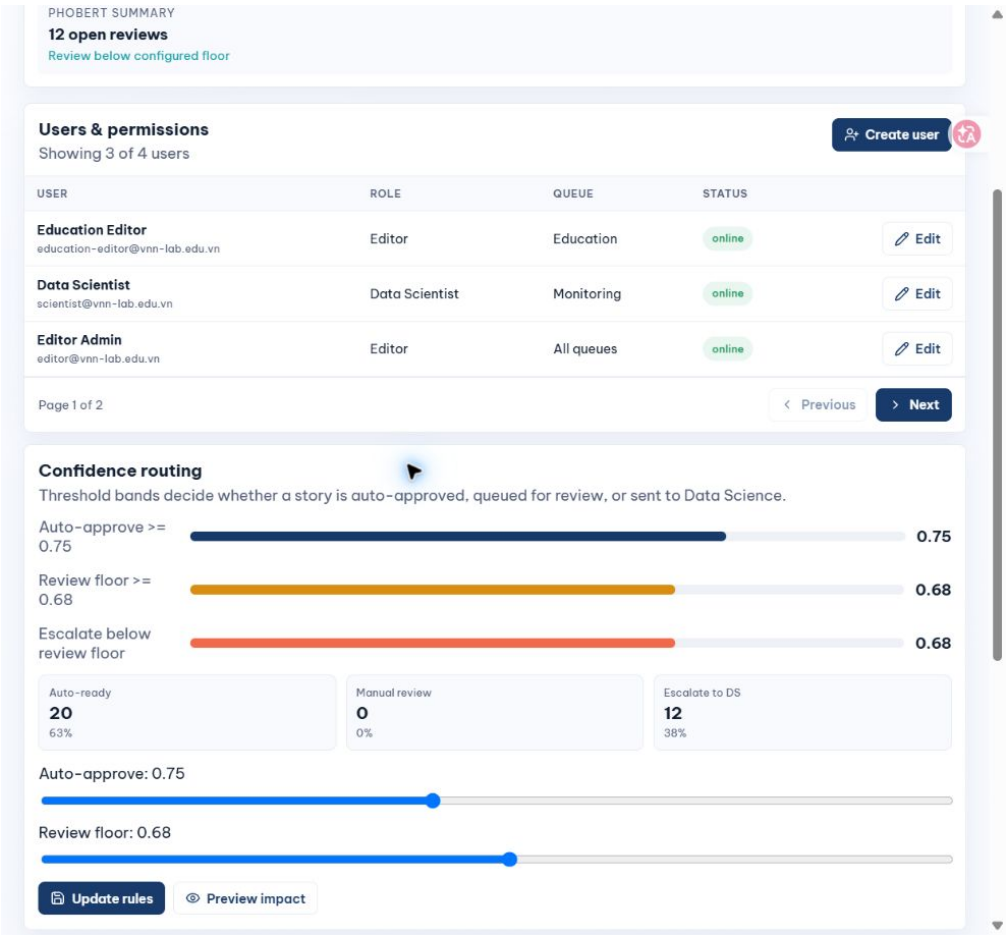


Nguyên tắc toàn vẹn dữ liệu: Mỗi lần suy luận sinh một prediction_id bất biến. Phản hồi của biên tập viên gắn chặt với ID đó; suy luận lại tạo bản ghi mới, không dùng phản hồi cũ làm nhãn tham chiếu cho dự đoán mới.

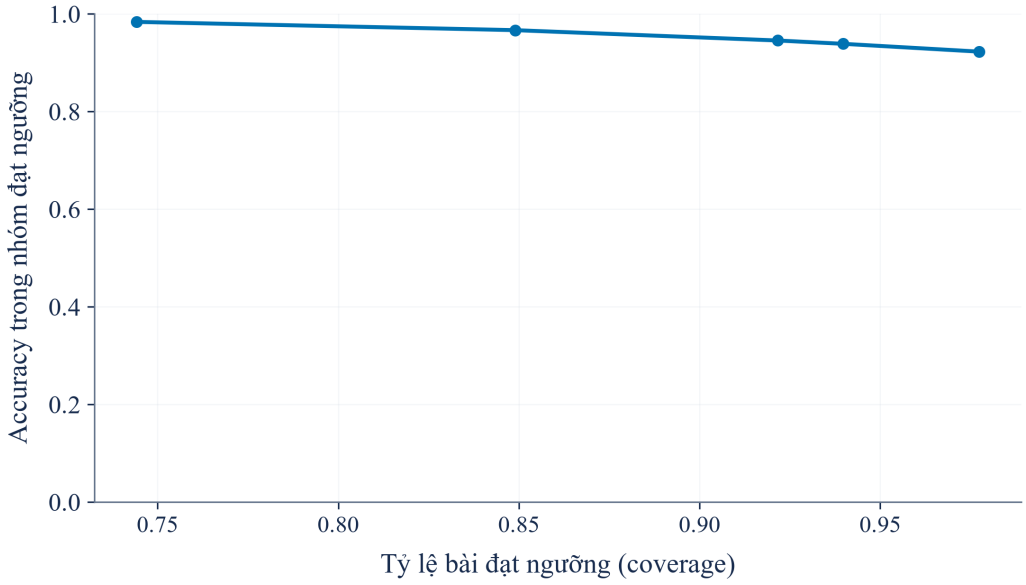
Hình B.4: Vòng phản hồi có truy vết phiên bản mô hình và lần dự đoán.

B.3 Phân luồng và vận hành

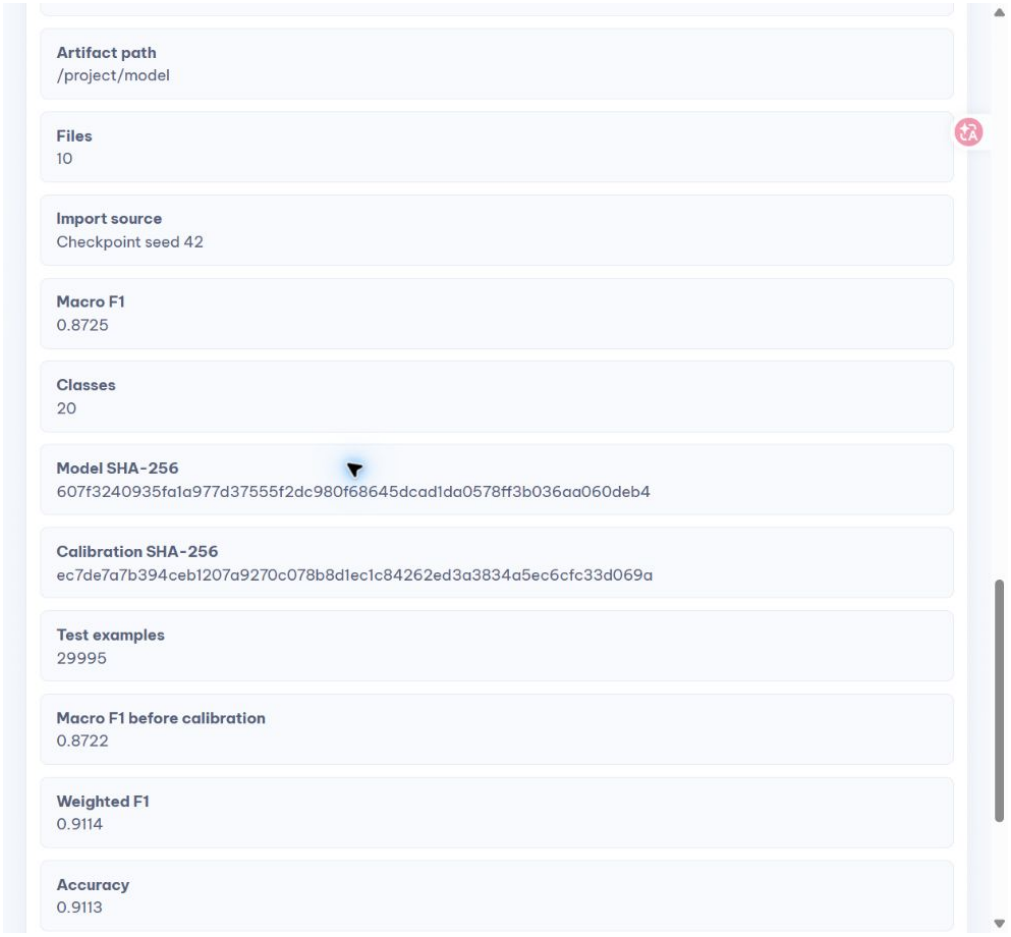
Chính sách cơ sở dữ liệu dùng độ tin cậy $p_{\hat{y}}(T)$: từ 0.75 là duyệt tự động; từ 0.68 đến dưới 0.75 là rà soát (review); thấp hơn 0.68 là xử lý chuyên sâu (escalate). Các ngưỡng phân luồng khác hệ số τ_c và khác margin trên $q = r/\sum r$. Thay ngưỡng không fine-tune mô hình, không ước lượng lại temperature và không tạo xác suất calibrated cho q. Preview tính lượng bài trong từng luồng trước khi áp dụng chính sách. Offline selective prediction ở hình B.6 cho thấy đổi ngưỡng giảm khối lượng tự động nhưng không loại bỏ mọi lỗi. Accuracy trên nhóm giữ lại khác Accuracy toàn tập; threshold không phải bảo đảm an toàn hoặc SLA. Danh mục phiên bản mô hình (registry) hiển thị thông tin mô tả, chỉ số offline, file tệp kết quả và trạng thái active. Upload kiểm tra path/tên, thông tin mô tả và khả năng nạp suy luận trước đăng ký. Kích hoạt kiểm tra gói mô hình, lấy khóa triển khai, thay manifest bằng thao tác os.replace, health check đúng run ID rồi cập nhật cơ sở dữ liệu. Nếu thất bại, mã nguồn phục hồi manifest cũ; cơ chế này chưa chứng minh an toàn giao dịch toàn hệ thống dưới mọi lỗi tiến trình.



Hình B.5: Admin xem preview và điều chỉnh hai ngưỡng phân luồng của dữ liệu vận hành.



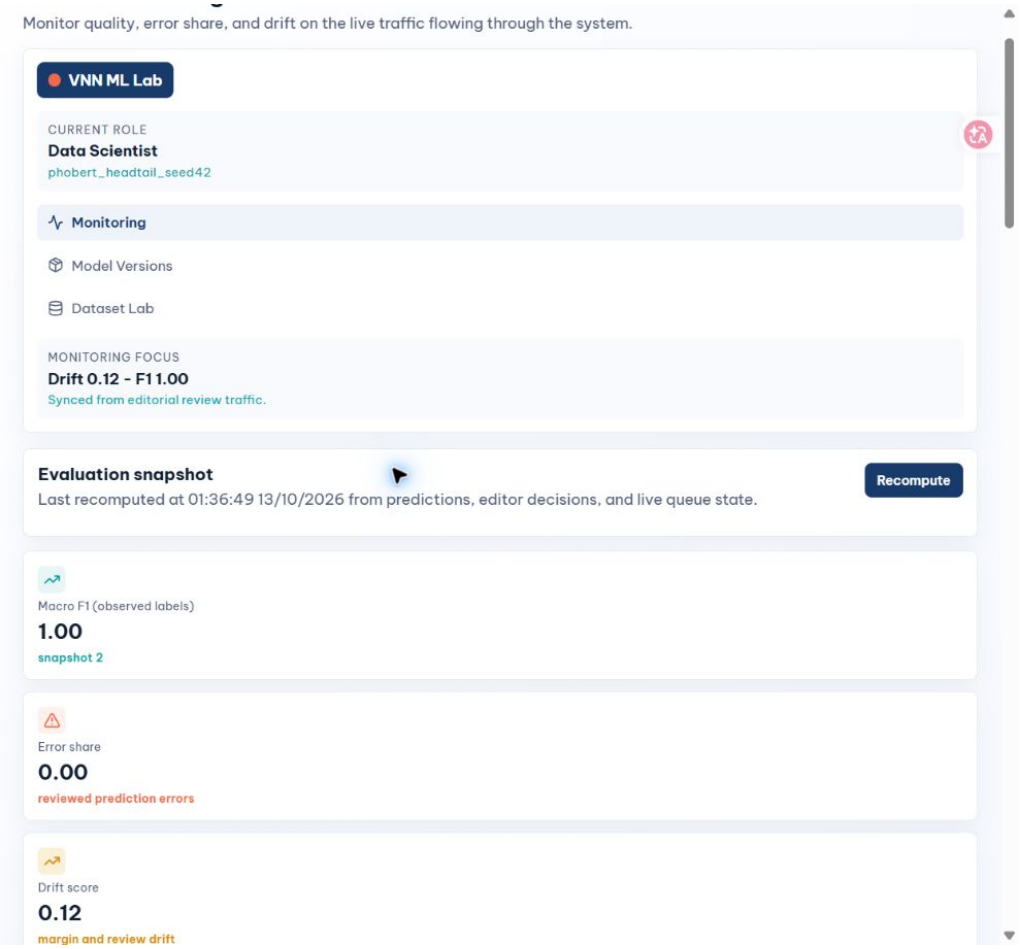
Hình B.6: Tỷ lệ bài được giữ và Accuracy có điều kiện của nhóm đạt ngưỡng trên test; đây là mô phỏng offline.



Hình B.7: Danh mục phiên bản PhoBERT: phiên bản, hiệu chỉnh xác suất và kết quả offline từ tệp kết quả.

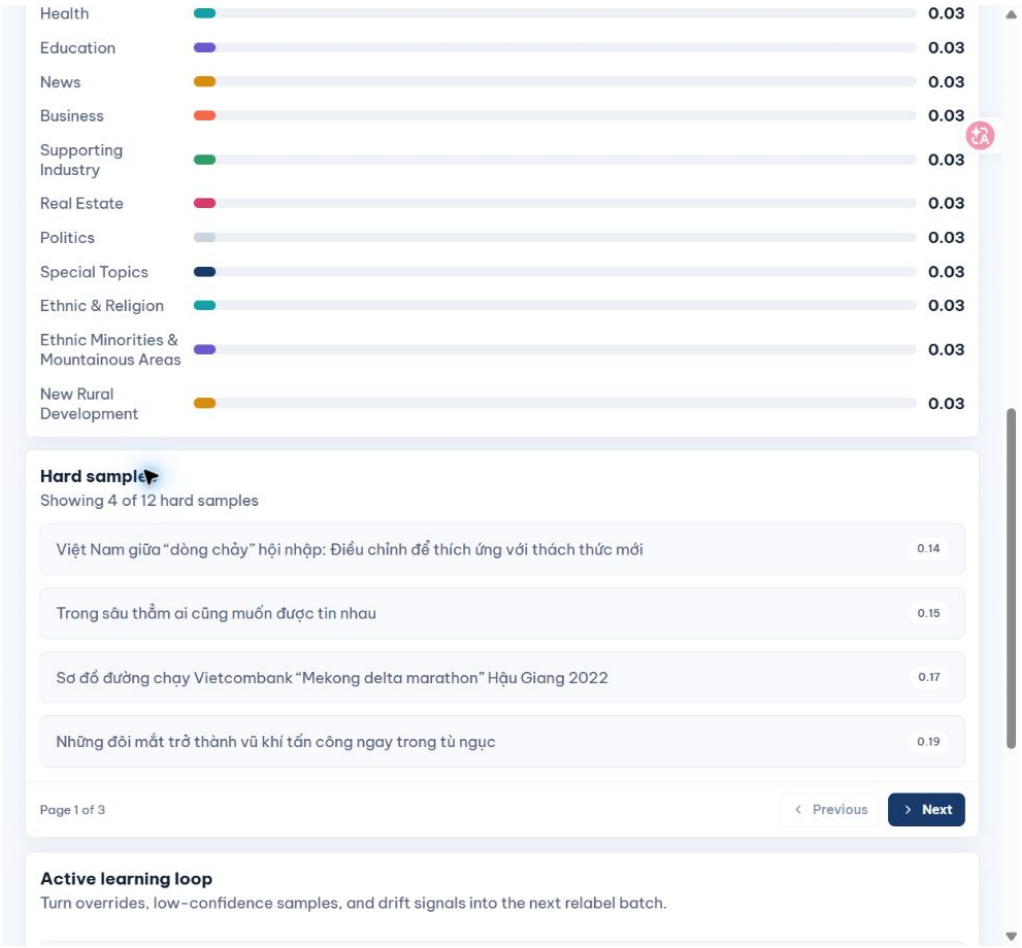
B.4 Monitoring và Dataset Lab

Chức năng giám sát ghép phản hồi với đúng prediction. Macro-F1 ở đây tính trên các nhãn quan sát được trong nhóm có phản hồi, không mặc định đủ 20 lớp. Các bài được chọn rà soát có thiên lệch, nên không đối chiếu trực tiếp số trên UI với Macro-F1 test offline. Điểm cảnh báo thay đổi dữ liệu kết hợp chênh lệch điểm giữa hai nhãn đầu và sai khác phản hồi theo quy tắc kinh nghiệm, chưa là kiểm định phân bố. Dataset Lab trình bày bài khó, độ tin cậy thấp và các



Hình B.8: Monitoring theo phản hồi gắn với đúng prediction.

bài cần xem xét lại nhãn. Hệ thống lưu phản hồi và job, chưa có vòng tự fine-tuning rồi tự triển khai bản lưu mô hình. Bản lưu cơ sở dữ liệu minh họa có 32 bài từ tập dữ liệu với dự đoán thật; phân bố được chọn để minh họa lớp và tình huống khó, không đại diện tập dữ liệu huấn luyện. Backup chứa schema ứng dụng, không chứa toàn bộ dataset và trọng số.



Hình B.9: Dataset Lab: phân bố và ứng viên rà soát trong dữ liệu vận hành.

B.5 Kiểm chứng và giới hạn

Các nguồn có thể kiểm tra lại gồm output notebook, gói active, source API/dịch vụ mô hình, ảnh giao diện và bản lưu cơ sở dữ liệu. Notebook giữ kết quả nạp lại tệp kết quả và suy luận kiểm tra trên validation; các điều kiện từ chối đầu vào rỗng, mapping sai, hiệu chỉnh xác suất không hữu hạn hoặc tệp kết quả thiếu nằm trong mã nguồn. Báo cáo không coi logic kiểm tra tồn tại như bằng chứng mọi testcase quá trình thực thi đã được chạy lại.

Kiểm tra trạng thái dịch vụ, phân quyền theo vai trò (RBAC), suy luận nhất quán, kích hoạt tệp kết quả, worker và văn bản rỗng là các nhóm kiểm chứng liên quan đến quy trình phân loại. Tài liệu kiểm chứng của bài tập lớn nêu 46 kiểm tra tự động, nhưng nhật ký từng trường hợp kiểm thử không được giữ trong bản dữ liệu hiện tại; vì vậy không dùng số đó làm chứng nhận test có thể tái kiểm toán. Ảnh giao diện chứng minh trạng thái minh họa đã lưu, không chứng minh accuracy hoặc khả năng hoạt động ổn định trong môi trường thực tế.

Triển khai của bài tập lớn giới hạn localhost. Môi trường có lưu lượng mới cần quản lý thông tin bí mật, mã hóa kết nối TLS, khả năng chịu tải và thời hạn lưu dữ liệu và đánh giá lỗi tự động theo từng lớp. Một bài nằm ngoài các chuyên mục được hỗ trợ vẫn có thể được gán nhãn với độ tin cậy cao; monitoring không cung cấp bộ phát hiện ngoài miền đã kiểm chứng. Các giới hạn vận hành này tách biệt với kết quả test của bốn mô hình.