ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO BÀI TẬP

Môn: Cách tiếp cận hiện đại trong xử lý ngôn ngữ tự nhiên

Phân loại chủ đề tin tức tiếng Việt bằng PhoBERT và ứng dụng hỗ trợ biên tập

Dữ liệu – Mô hình – Ứng dụng

CO5087 – Học kỳ 261 (2026–2027)

Giảng viên: Lê Thành Sách, Nguyễn Quốc Minh

Thực hiện

Đặng Nguyễn Tấn Tài 2570357

Lớp: CH01

Thành phố Hồ Chí Minh, 10/2026

Tóm tắt

Phân loại chuyên mục giúp tổ chức bài báo tiếng Việt và hỗ trợ điều phối biên tập. Báo cáo trình bày một quy trình gồm thu thập VietNamNet, xác minh chuyên mục trên từng bài, làm sạch corpus, biểu diễn tiếng Việt, fine-tuning PhoBERT và triển khai đề xuất nhãn có người rà soát. Bài toán sử dụng 20 lớp; nhãn mục con được quy về lớp cha trong taxonomy.

Thu thập tạo 205.463 lượt URL, tương ứng 204.280 URL duy nhất. Sau xác minh, dataset có 200.337 bài; khử trùng văn bản và loại xung đột nhãn tạo corpus 199.965 bài. Phép chia phân tầng seed 42 tạo 139.975 mẫu train, 29.995 mẫu validation và 29.995 mẫu test. Các tập không giao nhau theo URL, văn bản thô và văn bản sau tiền xử lý. Validation chọn checkpoint và fit hiệu chỉnh; test phục vụ đánh giá cuối.

PhoBERT-base-v2 được fine-tune toàn bộ encoder và đầu phân loại bằng weighted cross-entropy, trọng số tính từ train. Head–Tail giữ 127 token đầu và 127 token cuối, cộng hai token đặc biệt thành 256 vị trí. Huấn luyện chạy đủ bảy epoch trên RTX A3000 Laptop 12 GB, trong 207,17 phút; checkpoint epoch 7 đạt Macro-F1 validation 0,8723. Trên test, Accuracy đạt 91,08% và Macro-F1 đạt 87,22%; sau hiệu chỉnh đạt 91,13% và 87,25%. Temperature scaling giảm NLL từ 0,3839 xuống 0,3220 và ECE từ 0,0603 xuống 0,0251.

Chất lượng khác biệt đáng kể theo lớp. Nông thôn mới đạt F1 0,4639, trong khi Thể thao đạt 0,9880. Báo cáo phân tích mất cân bằng, giao thoa chuyên mục, giới hạn văn bản dài, chuyển đổi đúng/sai và các ví dụ truy vết được về dữ liệu. Mức tăng sau hiệu chỉnh chỉ là 13 bài đúng ròng; không đủ cơ sở kết luận vượt trội thống kê. Chưa có baseline cùng giao thức, thực nghiệm nhiều seed hay kiểm tra theo thời gian và ngoài miền.

Ứng dụng sáu dịch vụ dùng cùng trọng số, tokenizer, mapping và hiệu chỉnh của notebook. Các chức năng nhập bài, dự đoán, rà soát, quản lý ngưỡng, registry và monitoring được kiểm tra với dữ liệu minh họa từ corpus. Chỉ số offline, mô phỏng định tuyến và monitoring từ phản hồi được trình bày theo đúng phạm vi, tránh coi bộ ví dụ giao diện là một tập kiểm tra độc lập.

Danh mục thuật ngữ

Thuật ngữ	Ý nghĩa trong báo cáo
Corpus	Tập bài báo, nhãn chuyên mục và metadata nguồn.
Phân đoạn từ	Xác định từ tiếng Việt gồm một hoặc nhiều âm tiết.
BPE	Mã hóa từ thành các đơn vị subword của tokenizer.
Head–Tail	Giữ đầu và cuối chuỗi token khi vượt giới hạn đầu vào.
Fine-tuning	Cập nhật mô hình tiền huấn luyện cho tác vụ chuyên mục.
Validation	Chọn checkpoint và xác định tham số hiệu chỉnh.
Test độc lập	Tập đánh giá cuối không tham gia chọn hoặc fit tham số.
Macro-F1	Trung bình F1 của 20 lớp, mỗi lớp đóng góp bằng nhau.
Weighted-F1	Trung bình F1 theo số mẫu của từng lớp.
NLL	Mất mát log xác suất nhãn tham chiếu, không trọng số lớp.
ECE	Sai lệch confidence và tỷ lệ đúng theo 15 khoảng xác suất.
Temperature	Tham số dương T chia logits trước softmax.
Hệ số lớp	τ_c trong điểm quyết định $p_c(T)/\tau_c$.
Confidence	Xác suất của nhãn được chọn bởi quy tắc quyết định.
Routing	Phân luồng auto-approve, review hoặc escalate.
Artifact	Trọng số, tokenizer, mapping và cấu hình suy luận.
Prediction ID	Khóa lần suy luận để gắn phản hồi đúng kết quả.

Mục lục

Tóm tắt **i**

Danh mục thuật ngữ **ii**

1 Bài toán và thiết kế thực nghiệm **1**

1.1 Bối cảnh và vấn đề cần giải quyết 1

1.2 Phát biểu bài toán 1

1.3 Mục tiêu và câu hỏi nghiên cứu 1

1.4 Phạm vi và sản phẩm 2

1.5 Giao thức train, validation và test 2

1.6 Tiêu chí đánh giá và bằng chứng 3

1.7 Tổ chức báo cáo 3

2 Dữ liệu và tiền xử lý tiếng Việt **4**

2.1 Nguồn và đơn vị thu thập 4

2.2 Taxonomy và nhãn cha–con 4

2.3 Kết quả thu thập và chuẩn hóa 5

2.4 Bốn tệp URL và hợp đồng dataset 9

2.5 Phân bố lớp và mất cân bằng 10

2.6 Độ dài ở ba mức biểu diễn 12

2.7 Ghép và chuẩn hóa văn bản 15

2.8 Khử trùng trước chia tập 17

2.9 Cache, truy vết và giới hạn dữ liệu 18

3 Biểu diễn văn bản và kiến trúc PhoBERT **19**

3.1 Từ đặc trưng bề mặt đến biểu diễn theo ngữ cảnh 19

3.2 Phân đoạn từ và mã hóa BPE 19

3.3 Lựa chọn Head–Tail cho bài báo dài 20

3.3.1 Chi phí và các phương án so sánh 20

3.4 Cấu hình kiến trúc thực tế 21

3.5 Embedding và thông tin vị trí 22

3.6 Self-attention và xử lý theo ngữ cảnh 23

3.7 Residual, LayerNorm và feed-forward 24

3.8 Đầu phân loại và logits . . . 24
3.9 Quy mô tham số và ý nghĩa của fine-tuning . . . 24

4 Huấn luyện và hiệu chỉnh dự đoán 25
4.1 Chuẩn bị ba tập và tensor . . . 25
4.2 Fine-tuning toàn bộ mô hình . . . 25
4.3 Weighted cross-entropy . . . 25
4.4 Optimizer và siêu tham số . . . 28
4.5 Checkpoint và early stopping . . . 28
4.6 Chế độ thực thi và lịch sử . . . 34
4.7 Temperature scaling trên validation . . . 34
4.8 Điều chỉnh quyết định theo lớp . . . 34
4.9 Xác suất, điểm quyết định và định tuyến . . . 35

5 Kết quả và phân tích lỗi 36
5.1 Nguồn bằng chứng và giao thức đo . . . 36
5.2 Định nghĩa chỉ số . . . 36
5.3 Kết quả tổng thể . . . 36
5.4 Chất lượng theo từng chuyên mục . . . 38
5.4.1 Nông thôn mới . . . 42
5.4.2 Dân tộc và các lớp gần nhau . . . 43
5.4.3 Lớp có dấu hiệu chủ đề tập trung . . . 43
5.4.4 Ảnh hưởng không đồng đều của hiệu chỉnh . . . 44
5.5 Ma trận nhầm lẫn và hướng lỗi . . . 47
5.6 NLL, ECE và độ tin cậy xác suất . . . 54
5.7 Coverage, ngưỡng định tuyến và margin . . . 58
5.8 Ví dụ lỗi truy vết được . . . 60
5.9 Precision–Recall một-chống-phần-còn-lại . . . 61
5.10 Phản biện và độ vững của kết luận . . . 61
5.10.1 Hợp lệ nội tại . . . 61
5.10.2 Hợp lệ thống kê . . . 61
5.10.3 Hợp lệ bên ngoài . . . 61
5.10.4 Baseline và ablation còn thiếu . . . 61

6 Ứng dụng hỗ trợ biên tập 62
6.1 Vai trò của ứng dụng trong bài toán NLP . . . 62

6.2 Kiến trúc triển khai và hợp đồng model 62
6.3 Đăng nhập và nhập bài 63
6.4 Đọc bài và ra quyết định 66
6.5 Chính sách định tuyến và quản trị 70
6.6 Registry, monitoring và Dataset Lab 71
6.7 Phạm vi minh họa và vận hành 74

7 Kiểm chứng và khả năng tái hiện 75
7.1 Phân cấp bằng chứng 75
7.2 Đối chiếu dữ liệu và kết quả 75
7.3 Kiểm tra ứng dụng 75
7.4 Trình tự tái hiện 76
7.5 Giới hạn tái hiện 76

8 Kết luận và hướng phát triển 77
8.1 Bài toán được giải quyết 77
8.2 Phương pháp và kết quả 77
8.3 Các giới hạn quyết định mức thuyết phục 77
8.4 Ưu tiên phát triển 77

A Bằng chứng và chỉ dẫn đối chiếu 79
A.1 Môi trường thực nghiệm 79
A.2 Chỉ dẫn đọc từng cell notebook PhoBERT 79
A.3 Các kiểm tra ứng dụng được thực thi 83
A.4 Ví dụ truy vết của lỗi test 84
A.4.1 Ví dụ 1 84
A.4.2 Ví dụ 2 85
A.4.3 Ví dụ 3 85
A.4.4 Ví dụ 4 85
A.4.5 Ví dụ 5 86
A.4.6 Ví dụ 6 86
A.4.7 Ví dụ 7 86
A.4.8 Ví dụ 8 87
A.4.9 Ví dụ 9 87
A.4.10 Ví dụ 10 87
A.5 Các hình chẩn đoán riêng trước hiệu chỉnh 88

A.6 Hai mươi đường Precision–Recall 90
A.6.1 ID 0: Bạn đọc 91
A.6.2 ID 1: Bất động sản 91
A.6.3 ID 2: Chính trị 92
A.6.4 ID 3: Công nghiệp hỗ trợ 92
A.6.5 ID 4: Công nghệ 93
A.6.6 ID 5: Du lịch 93
A.6.7 ID 6: Dân tộc - Tôn giáo 94
A.6.8 ID 7: Dân tộc thiểu số và miền núi 94
A.6.9 ID 8: Giáo dục 95
A.6.10 ID 9: Kinh doanh 95
A.6.11 ID 10: Nông thôn mới 96
A.6.12 ID 11: Nội dung chuyên đề 96
A.6.13 ID 12: Sức khỏe 97
A.6.14 ID 13: Thế giới 97
A.6.15 ID 14: Thể thao 98
A.6.16 ID 15: Thời sự 98
A.6.17 ID 16: Tuần Việt Nam 99
A.6.18 ID 17: Văn hóa - Giải trí 99
A.6.19 ID 18: Ô tô - Xe máy 100
A.6.20 ID 19: Đời sống 100

Danh sách hình vẽ

1.1 Quy trình NLP từ dữ liệu đến ứng dụng hỗ trợ biên tập. 2
1.2 Ba tập có vai trò tách biệt; test nằm ngoài cập nhật, chọn checkpoint và hiệu chỉnh. 3

2.1 Phân bố 200.337 bài sạch theo chuyên mục sau xác minh URL và nội dung. . . 6
2.2 Phân bố URL theo chuyên mục nguồn và bài theo class sau chuẩn hóa. 7
2.3 Các quyết định làm sạch từ output notebook dữ liệu. 8
2.4 Quan hệ chuyên mục nguồn–đích; cùng một bài có thể đóng góp nhiều quan hệ nguồn. 9
2.5 Phân bố 20 lớp trong đầu vào huấn luyện, trước khử trùng văn bản. 11
2.6 Độ dài tiêu đề theo các đơn vị tách bằng khoảng trắng. 12
2.7 Độ dài nội dung trước phân đoạn từ, không đồng nghĩa độ dài BPE. 12
2.8 Độ dài nội dung theo chuyên mục, dùng để xem khác biệt phân bố. 13
2.9 Độ dài nội dung theo ký tự; histogram giới hạn vùng hiển thị để đọc được phần phân bố chính. 14
2.10 Độ dài văn bản sau phân đoạn từ tiếng Việt. 14
2.11 Khảo sát độ dài BPE trên 1.000 bài. 15
2.12 Tỷ lệ token giữ trong giới hạn 256; không đo lượng thông tin ngữ nghĩa còn lại. 15
2.13 Thứ tự tiền xử lý chính xác của văn bản tiếng Việt. 16
2.14 Kiểm tra giao nhau giữa ba tập trên URL, văn bản thô và văn bản sạch. 18

3.1 Cách ghép Head–Tail; dấu token được minh họa theo ký hiệu của tokenizer PhoBERT. 20
3.2 PhoBERT và đầu phân loại trong RobertaForSequenceClassification. 22
3.3 Tính toán bên trong một lớp encoder; mask loại vị trí padding khỏi attention. . 23

4.1 Trọng số loss của 20 lớp; ID được đối chiếu với bảng taxonomy. 26
4.2 Số mẫu train, validation và test theo từng lớp sau khử trùng. 27
4.3 Huấn luyện có tích lũy gradient và chọn checkpoint theo Macro-F1. 28
4.4 Loss train được ghi theo bước cập nhật. 29
4.5 Loss validation theo epoch; thấp nhất tại epoch 3. 30
4.6 Accuracy validation qua bảy epoch. 30
4.7 Macro-F1 validation dùng chọn checkpoint. 31
4.8 Weighted-F1 validation, bổ sung góc nhìn theo support. 31

4.9 Loss train và validation trong một biểu đồ độc lập; cách tổng hợp cần được phân biệt. 32
4.10 Learning rate của optimizer, gồm warmup và giai đoạn giảm. 32
4.11 Gradient norm tại những bước có log; không trực tiếp giải thích nhãn của một bài. 33
4.12 Thời gian mỗi epoch bao gồm huấn luyện và kiểm định. 33
4.13 Hiệu chỉnh xác suất, chọn nhãn và định tuyến biên tập là các bước riêng. 35

5.1 Các nhóm quyết định giữ đúng, sửa đúng, đổi sai và cả hai sai. 37
5.2 Precision trước/sau cho 20 lớp, trong một hình riêng. 40
5.3 Recall trước/sau, tách khỏi precision để đọc rõ. 41
5.4 F1 theo lớp, cho thấy khác biệt mà chỉ số tổng hợp che khuất. 42
5.5 Support test và F1 từng lớp: tương quan quan sát không phải quan hệ nhân quả. 43
5.6 Mức tăng và giảm F1 của từng lớp, không cộng thành cam kết triển khai. . . . 45
5.7 Hệ số lớp; đường 1 là mức không điều chỉnh ưu tiên tương đối. 47
5.8 Ma trận số lượng trước hiệu chỉnh, tổng 29.995 bài. 48
5.9 Ma trận số lượng sau hiệu chỉnh trên cùng test độc lập. 49
5.10 Ma trận trước hiệu chỉnh chuẩn hóa theo hàng. 50
5.11 Ma trận sau hiệu chỉnh chuẩn hóa theo hàng. 51
5.12 Các hướng lỗi nổi bật trước hiệu chỉnh. 53
5.13 Các hướng lỗi nổi bật sau hiệu chỉnh. 54
5.14 Reliability diagram của softmax chưa hiệu chỉnh. 55
5.15 Reliability diagram sau temperature fit trên validation. 56
5.16 Phân bố confidence cực đại theo nhóm đúng/sai trước temperature. 56
5.17 Phân bố sau temperature; lỗi vẫn có thể mang confidence cao. 57
5.18 So sánh NLL trước/sau temperature trên test. 57
5.19 So sánh ECE với cùng quy ước 15 bins. 58
5.20 Đánh đổi mức bao phủ và Accuracy của nhóm giữ lại. 59
5.21 Phân bố margin theo nhóm đúng/sai của quyết định cuối. 60

6.1 Sáu dịch vụ của ứng dụng và gói mô hình dùng cho suy luận. 62
6.2 Trang đăng nhập phân vai trò, sử dụng taxonomy 20 lớp. 63
6.3 Tổng quan Editor với 32 bài minh họa và các số đo từ dự đoán đang lưu. 64
6.4 Hàng đợi ưu tiên bài confidence thấp và margin nhỏ; đây là dữ liệu minh họa có chọn mẫu. 65
6.5 Nội dung bài “Phiên chợ nhộn nhịp ở Bắc Hà, cuộc sống khởi sắc” trong màn hình rà soát. 66
6.6 Nhãn, confidence, ứng viên và thao tác biên tập được chụp riêng để đọc rõ. . . 67

6.7 Vòng phản hồi có truy vết phiên bản mô hình và lần dự đoán. 68
6.8 Bảng tất cả bài đã phân loại, gồm confidence, margin, trạng thái và phân trang. 69
6.9 Admin cấu hình confidence routing, xem preview và thông tin vận hành. 70
6.10 Registry của gói PhoBERT 20 lớp; chỉ số offline đọc từ artifact. 71
6.11 Kiểm tra và kích hoạt một gói mô hình có kiểm soát. 72
6.12 Monitoring từ nhóm prediction có phản hồi minh họa, không phải chỉ số test offline. 73
6.13 Dataset Lab theo dõi corpus vận hành và bài khó; không ghi đè dataset huấn luyện. 74

A.1 Precision theo 20 lớp trước hiệu chỉnh. 88
A.2 Recall theo 20 lớp trước hiệu chỉnh. 89
A.3 F1 theo 20 lớp trước hiệu chỉnh. 90
A.4 Precision–Recall của Bạn đọc, trên test độc lập. 91
A.5 Precision–Recall của Bất động sản, trên test độc lập. 91
A.6 Precision–Recall của Chính trị, trên test độc lập. 92
A.7 Precision–Recall của Công nghiệp hỗ trợ, trên test độc lập. 92
A.8 Precision–Recall của Công nghệ, trên test độc lập. 93
A.9 Precision–Recall của Du lịch, trên test độc lập. 93
A.10 Precision–Recall của Dân tộc - Tôn giáo, trên test độc lập. 94
A.11 Precision–Recall của Dân tộc thiểu số và miền núi, trên test độc lập. 94
A.12 Precision–Recall của Giáo dục, trên test độc lập. 95
A.13 Precision–Recall của Kinh doanh, trên test độc lập. 95
A.14 Precision–Recall của Nông thôn mới, trên test độc lập. 96
A.15 Precision–Recall của Nội dung chuyên đề, trên test độc lập. 96
A.16 Precision–Recall của Sức khỏe, trên test độc lập. 97
A.17 Precision–Recall của Thế giới, trên test độc lập. 97
A.18 Precision–Recall của Thể thao, trên test độc lập. 98
A.19 Precision–Recall của Thời sự, trên test độc lập. 98
A.20 Precision–Recall của Tuần Việt Nam, trên test độc lập. 99
A.21 Precision–Recall của Văn hóa - Giải trí, trên test độc lập. 99
A.22 Precision–Recall của Ô tô - Xe máy, trên test độc lập. 100
A.23 Precision–Recall của Đời sống, trên test độc lập. 100

Danh sách bảng

2.1 Các đơn vị đếm trong quy trình: lượt URL, URL duy nhất và số dòng văn bản có ý nghĩa khác nhau. 5
2.2 Số dòng Parquet, corpus sau khử trùng và số mẫu ba tập. ID 0–19 thống nhất giữa notebook và app. 10
2.3 Trích đoạn thực tế của bài UNIQLO trong output notebook, qua từng bước xử lý. 17

3.1 Thông số đọc từ config.json của checkpoint. 21

4.1 Trọng số balanced tính từ số mẫu train. 26
4.2 Cấu hình thực thi fine-tuning trên máy local. 28
4.3 Bảy lần đánh giá cuối epoch trên validation. 29

5.1 Chỉ số test trước và sau hiệu chỉnh fit trên validation. Chênh lệch là giá trị sau trừ trước. 36
5.2 Chuyển đổi đúng/sai trên cùng 29.995 mẫu. 37
5.3 Precision, recall, F1 và support trước hiệu chỉnh. 38
5.4 Precision, recall, F1 và support sau hiệu chỉnh. 39
5.5 Chênh lệch precision, recall và F1 theo lớp. 44
5.6 Hai mươi hệ số chia xác suất dùng cố định khi suy luận. 46
5.7 Mười lăm hướng nhầm nhiều nhất trước hiệu chỉnh. 52
5.8 Mười lăm hướng nhầm nhiều nhất sau hiệu chỉnh; tỷ lệ dùng support hàng. . . 52
5.9 Đo trên test với argmax chuẩn của xác suất; chưa áp dụng hệ số lớp. 54
5.10 Mô phỏng ngưỡng trên test, giữ bài có xác suất nhãn cuối đạt ngưỡng. 58

7.1 Phạm vi kiểm chứng trên sản phẩm. 75

A.1 Chỉ dẫn cell PhoBERT 1–29. 80
A.2 Chỉ dẫn cell PhoBERT 30–58. 81
A.3 Chỉ dẫn cell PhoBERT 59–87. 82
A.4 Kiểm tra hợp đồng model và ứng dụng 1–23. 83
A.5 Kiểm tra hợp đồng model và ứng dụng 24–46. 84

1. Bài toán và thiết kế thực nghiệm

1.1 Bối cảnh và vấn đề cần giải quyết

Một tòa soạn tổ chức bài viết theo chuyên mục để tìm kiếm, điều phối biên tập và phân phối nội dung. Tin tức thường giao thoa: một bài về phát triển du lịch ở vùng dân tộc có thể chứa đồng thời kinh tế, văn hóa và chính sách xã hội. Người biên tập cần xác định trọng tâm cùng quy ước tổ chức của nguồn tin. Một hệ thống chỉ dựa vào vài từ khóa dễ nhầm giữa các chuyên mục có vốn từ chung.

Bài tập lớn xây dựng bộ phân loại 20 chuyên mục VietNamNet. Đầu vào là tiêu đề và nội dung; đầu ra gồm một nhãn chính, các nhãn cạnh tranh và điểm số hỗ trợ rà soát. Mục tiêu là giảm công việc phân loại lặp lại, ưu tiên bài mơ hồ cho người xử lý và lưu phản hồi có truy vết. Hệ thống không coi confidence cao là bảo đảm bài được phân loại đúng.

Khó khăn gồm ranh giới chuyên mục không đồng nhất, lớp ít mẫu, tiếng Việt cần phân đoạn từ và bài báo dài vượt ngữ cảnh mô hình. Một bài xuất hiện ở trang chuyên mục không nhất thiết mang nhãn của trang đó. Chất lượng corpus vì vậy là một phần của bài toán NLP, trước cả lựa chọn kiến trúc neural.

1.2 Phát biểu bài toán

Với $x_i = (t_i, b_i)$ gồm tiêu đề và nội dung, $y_i \in \mathcal{C}$, $|\mathcal{C}| = 20$, corpus giám sát là

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{199\,965}. \tag{1.1}$$

Pipeline g chuẩn hóa văn bản, phân đoạn từ, BPE và Head–Tail. Mô hình sinh $z_i = f_\theta(g(x_i)) \in \mathbb{R}^{20}$. Nhãn cuối là $\hat{y}_i = \arg\max_c \{\mathrm{softmax}(z_i/T)_c/\tau_c\}$. URL và breadcrumb xác định nguồn cùng nhãn tham chiếu; chúng không được đưa vào tensor đầu vào mô hình.

Đây là phân loại đa lớp đơn nhãn. Top-k là các phương án cạnh tranh, không phải một tập nhãn cùng đúng. Nhãn tham chiếu phản ánh taxonomy của tòa soạn; đánh giá đo sự phù hợp với taxonomy này, không đo tính đúng sai của thông tin trong bài hoặc mức độ phù hợp với mọi cách phân chia chủ đề.

1.3 Mục tiêu và câu hỏi nghiên cứu

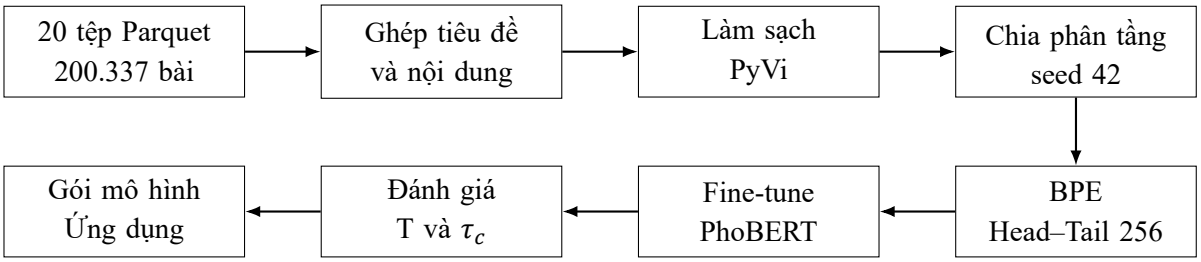
Báo cáo trả lời ba vấn đề: hệ thống giải quyết khó khăn gì, giải quyết bằng quy trình nào và kết quả hỗ trợ được kết luận gì. Cụ thể, cần xác định nhãn ở cấp bài thay vì trang danh sách; kiểm toán dữ liệu trùng trước chia tập; đánh giá cách giới hạn đầu vào; giải thích trọng số lớp, optimizer và chọn checkpoint; tách hiệu chỉnh xác suất khỏi điều chỉnh nhãn; phân tích sai số theo chuyên mục và kiểm tra tính nhất quán khi phục vụ.

Lựa chọn thiết kế và kết quả thực nghiệm có vai trò khác nhau. Weighted cross-entropy nhằm tăng đóng góp của lớp ít mẫu, nhưng lợi ích riêng của nó chỉ được xác nhận bằng đối chứng. Head–Tail giữ hai vùng của bài, nhưng chưa có phép so sánh chứng minh tốt hơn head-only trên corpus này. Báo cáo phân biệt quan sát từ output với giả thuyết cần khảo sát.

1.4 Phạm vi và sản phẩm

Hai notebook đảm nhiệm hai đầu ra độc lập: notebook dữ liệu tạo corpus sạch; notebook PhoBERT huấn luyện, hiệu chỉnh, đánh giá và xuất gói model. Project chứa dataset, cache, model, kết quả trực quan, ứng dụng hỗ trợ biên tập và nguồn báo cáo. README ở thư mục gốc mô tả toàn bộ quy trình vận hành.

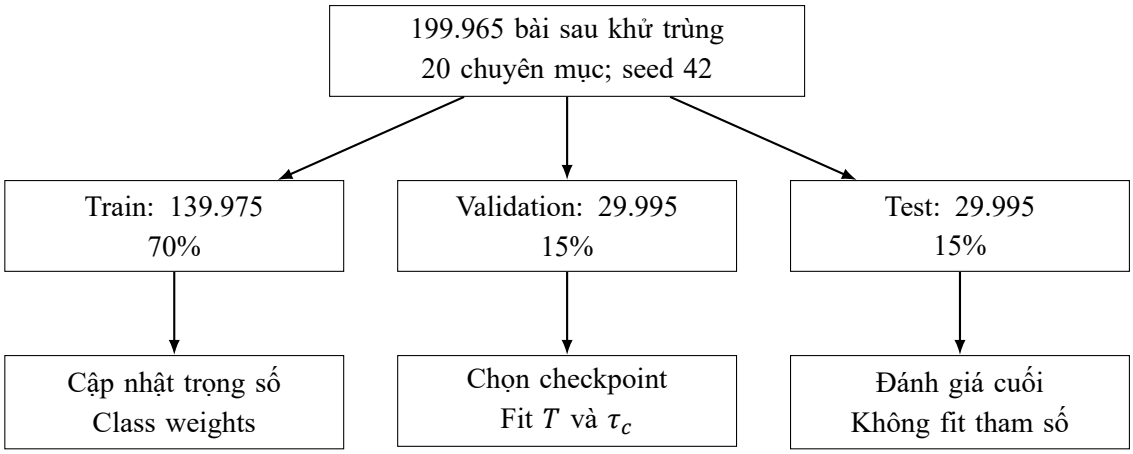
Tác vụ không bao gồm sinh bài, tóm tắt, nhận dạng thực thể hoặc kiểm chứng thông tin. Mô hình chưa có bộ phát hiện ngoài taxonomy. Phản hồi biên tập được lưu để rà soát và chuẩn bị dữ liệu; ứng dụng không tự train lại. Giao diện top-k và các khối mô tả dự đoán không phải attribution của Transformer.



Hình 1.1: Quy trình NLP từ dữ liệu đến ứng dụng hỗ trợ biên tập.

1.5 Giao thức train, validation và test

Sau khử trùng văn bản, phép chia phân tầng seed 42 tạo train 139.975 bài, validation 29.995 bài và test 29.995 bài. Train cập nhật trọng số và tính class weights. Validation đánh giá cuối epoch, chọn checkpoint, tìm temperature cùng hệ số lớp. Test được giữ ngoài các bước fit này và dùng tính chỉ số cuối.



Hình 1.2: Ba tập có vai trò tách biệt; test nằm ngoài cập nhật, chọn checkpoint và hiệu chỉnh.

Không có giao nhau chính xác theo URL, văn bản thô hoặc văn bản sạch giữa ba tập. Test không tham gia chọn checkpoint hay tìm hiệu chỉnh. Tính độc lập này không loại trừ bài gần trùng về ngữ nghĩa, sự kiện chung hoặc khả năng corpus tiền huấn luyện chứa bài từ cùng nguồn.

Validation được dùng cho cả lựa chọn checkpoint và hiệu chỉnh. Điều đó tạo phụ thuộc giữa hai quyết định thiết kế, nhưng không đưa nhãn test vào tối ưu. Một phép chia calibration riêng hoặc cross-validation có thể khảo sát độ ổn định tham số khi đủ tài nguyên. Dataset đến từ một nguồn; phép chia ngẫu nhiên chưa mô phỏng yêu cầu dự đoán tin ở thời điểm tương lai.

1.6 Tiêu chí đánh giá và bằng chứng

Macro-F1 là tiêu chí chọn checkpoint để mỗi lớp đóng góp ngang nhau. Accuracy và Weighted-F1 bổ sung góc nhìn theo số lượng bài. Precision, recall, confusion matrix và các ví dụ truy vết được chỉ ra nơi sai số tập trung. NLL, ECE và reliability diagram xem xét xác suất; coverage–accuracy đo đánh đổi khối lượng tự động và sai số.

Tính đúng của ứng dụng được kiểm tra riêng qua artifact, pipeline suy luận, phân quyền, nhập bài, lưu dự đoán, phản hồi, worker và registry. Các ví dụ giao diện được chọn từ corpus để minh họa chức năng, không được cộng vào test hay dùng chứng minh tổng quát hóa. Chỉ số monitoring phụ thuộc nhóm đã được phản hồi và không thay thế đánh giá offline trên 20 lớp.

1.7 Tổ chức báo cáo

Chương 2 trình bày thu thập, chuẩn hóa nhãn và tiền xử lý. Chương 3 giải thích PhoBERT và biểu diễn đầu vào. Chương 4 trình bày tối ưu cùng hiệu chỉnh. Chương 5 phân tích kết quả, độ tin cậy và giới hạn. Chương 6 mô tả chức năng ứng dụng bằng màn hình thực tế. Chương 7 cung cấp kiểm chứng và tái hiện; chương 8 xác định kết luận cùng hướng cải thiện. Phụ lục có hướng dẫn đọc cell, ví dụ lỗi và từng đường Precision–Recall riêng.

2. Dữ liệu và tiền xử lý tiếng Việt

2.1 Nguồn và đơn vị thu thập

Corpus gồm tin VietNamNet trong 20 chuyên mục. Notebook lấy URL trên tối đa 500 trang cho mỗi chuyên mục, rồi tải HTML bằng 32 worker. Giới hạn 500 áp dụng cho số trang danh sách, không phải số bài; một trang có nhiều URL và một URL có thể hiện ở nhiều chuyên mục. Chuyên mục ngắn kết thúc khi hết dữ liệu hợp lệ. Phạm vi này không đồng nghĩa thu thập toàn bộ kho tin của website.

Danh sách trang được dùng để phát hiện bài, còn nhãn phải được xác minh trên chính bài đó. Tiêu đề, nội dung, URL canonical và bằng chứng chuyên mục được lấy trong cùng lượt tải HTML, giúp tránh một lượt tải riêng chỉ để phân loại URL. Lỗi tải, thiếu nội dung hoặc bằng chứng chưa đủ được thử lại tối đa ba lượt; trường hợp không đạt bị ghi vào danh sách loại.

2.2 Taxonomy và nhãn cha–con

Mỗi class có một mã ổn định dùng làm tên Parquet. Đường dẫn Công nghiệp hỗ trợ là hop-tac/cong-nghiep-ho-tro, nhưng class và tên file là cong-nghiep-ho-tro. Prefix đường dẫn không trở thành một nhãn bổ sung. Sắc màu Việt Nam là mục con của Dân tộc – Tôn giáo và được quy về lớp cha này.

Quy tắc xác minh sử dụng đường dẫn chuyên mục và breadcrumb ở cấp bài. Nếu bài thuộc class nguồn, giữ lại. Nếu bằng chứng chỉ tới một class khác trong taxonomy, chuyển cả URL và nội dung về class đó. Nếu chuyên mục xác định nằm ngoài taxonomy, loại khỏi corpus huấn luyện. Không dùng mô hình phân loại đang huấn luyện để tự gán nhãn cho dữ liệu của chính nó, vì cách đó tạo vòng lặp củng cố sai số.

Chính trị xuất hiện trong trang Dân tộc – Tôn giáo là một tình huống có thật: metadata ghi 225 quan hệ nguồn Dân tộc – Tôn giáo tới đích Chính trị. Tương tự, Tuần Việt Nam tới Nội dung chuyên đề có 204 quan hệ. Các quan hệ này cho thấy cần xác minh từng bài, đồng thời không đủ để coi toàn bộ trang nguồn là sai nhãn.

2.3 Kết quả thu thập và chuẩn hóa

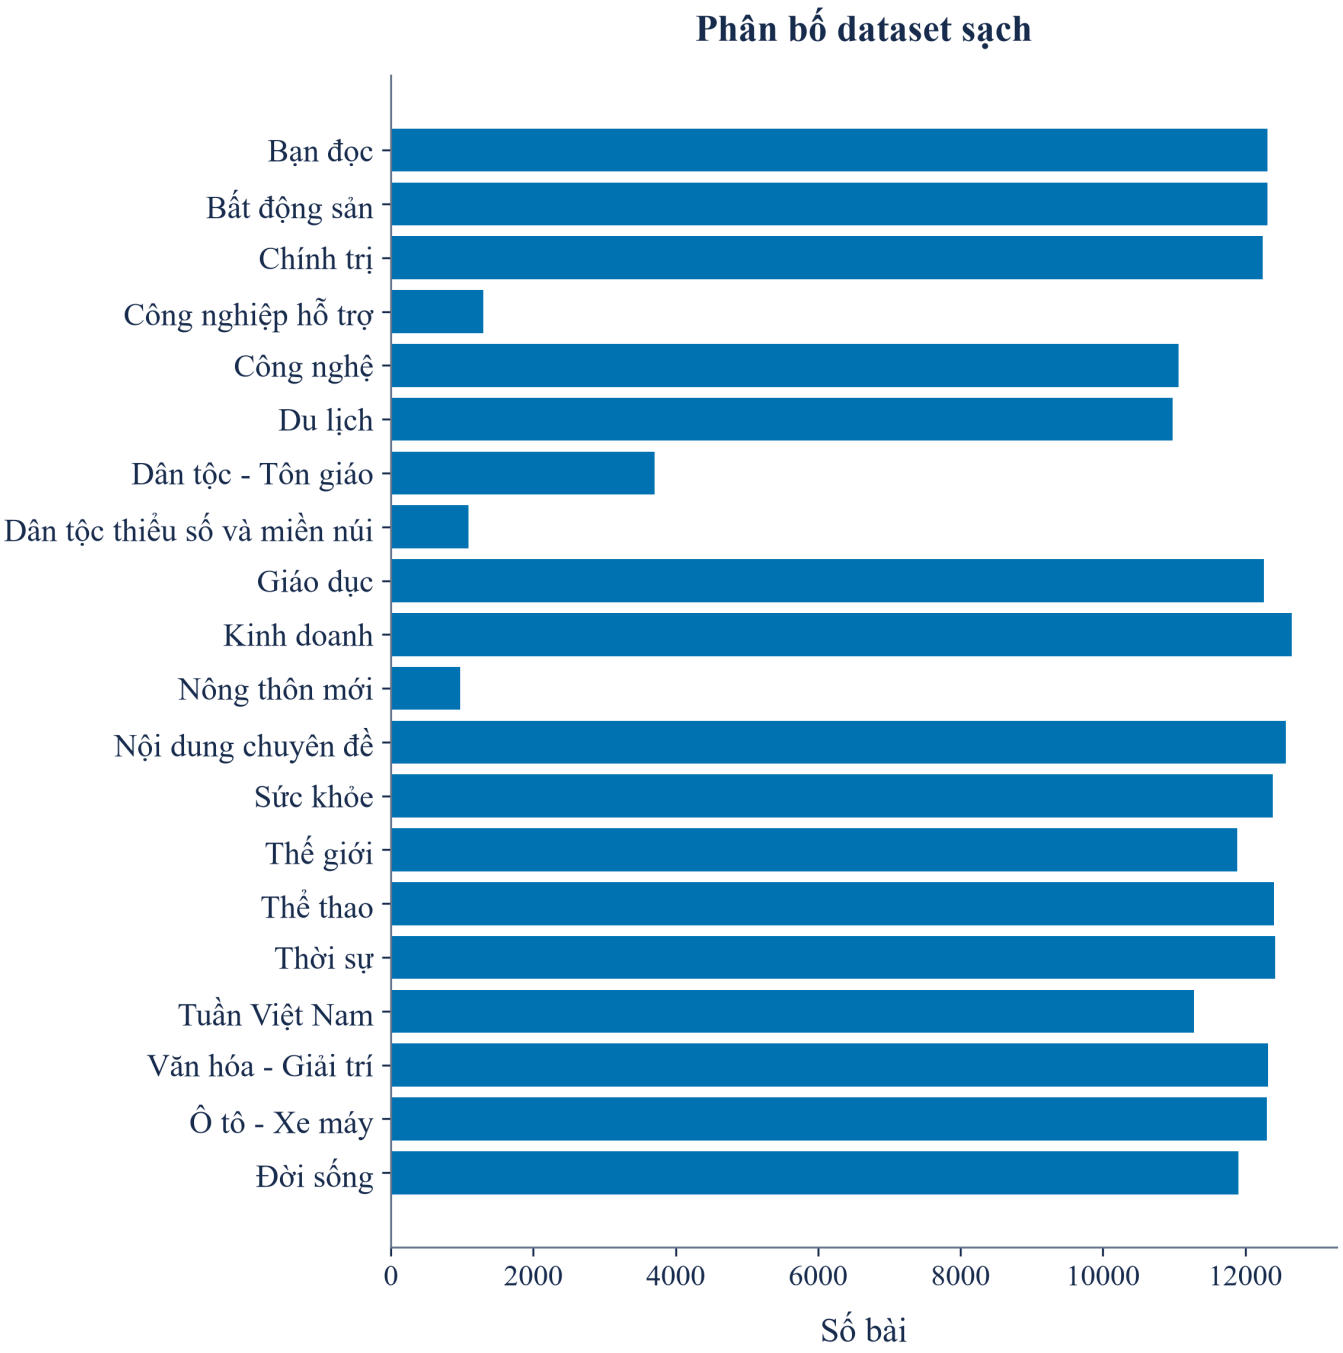
Bảng 2.1: Các đơn vị đếm trong quy trình: lượt URL, URL duy nhất và số dòng văn bản có ý nghĩa khác nhau.

Giai đoạn	Số lượng
Lượt URL ở các chuyên mục	205.463
URL đầu vào duy nhất	204.280
Giữ ở chuyên mục nguồn	199.463
Chuyển sang chuyên mục trong taxonomy	874
Loại ngoài taxonomy	3.866
Loại sau ba lượt tải/kiểm tra	76
Gộp request trùng canonical	1
Dataset sạch theo URL	200.337
Loại dòng xung đột nhãn sau xử lý	8
Loại dòng văn bản trùng cùng nhãn	364
Corpus dùng chia tập	199.965

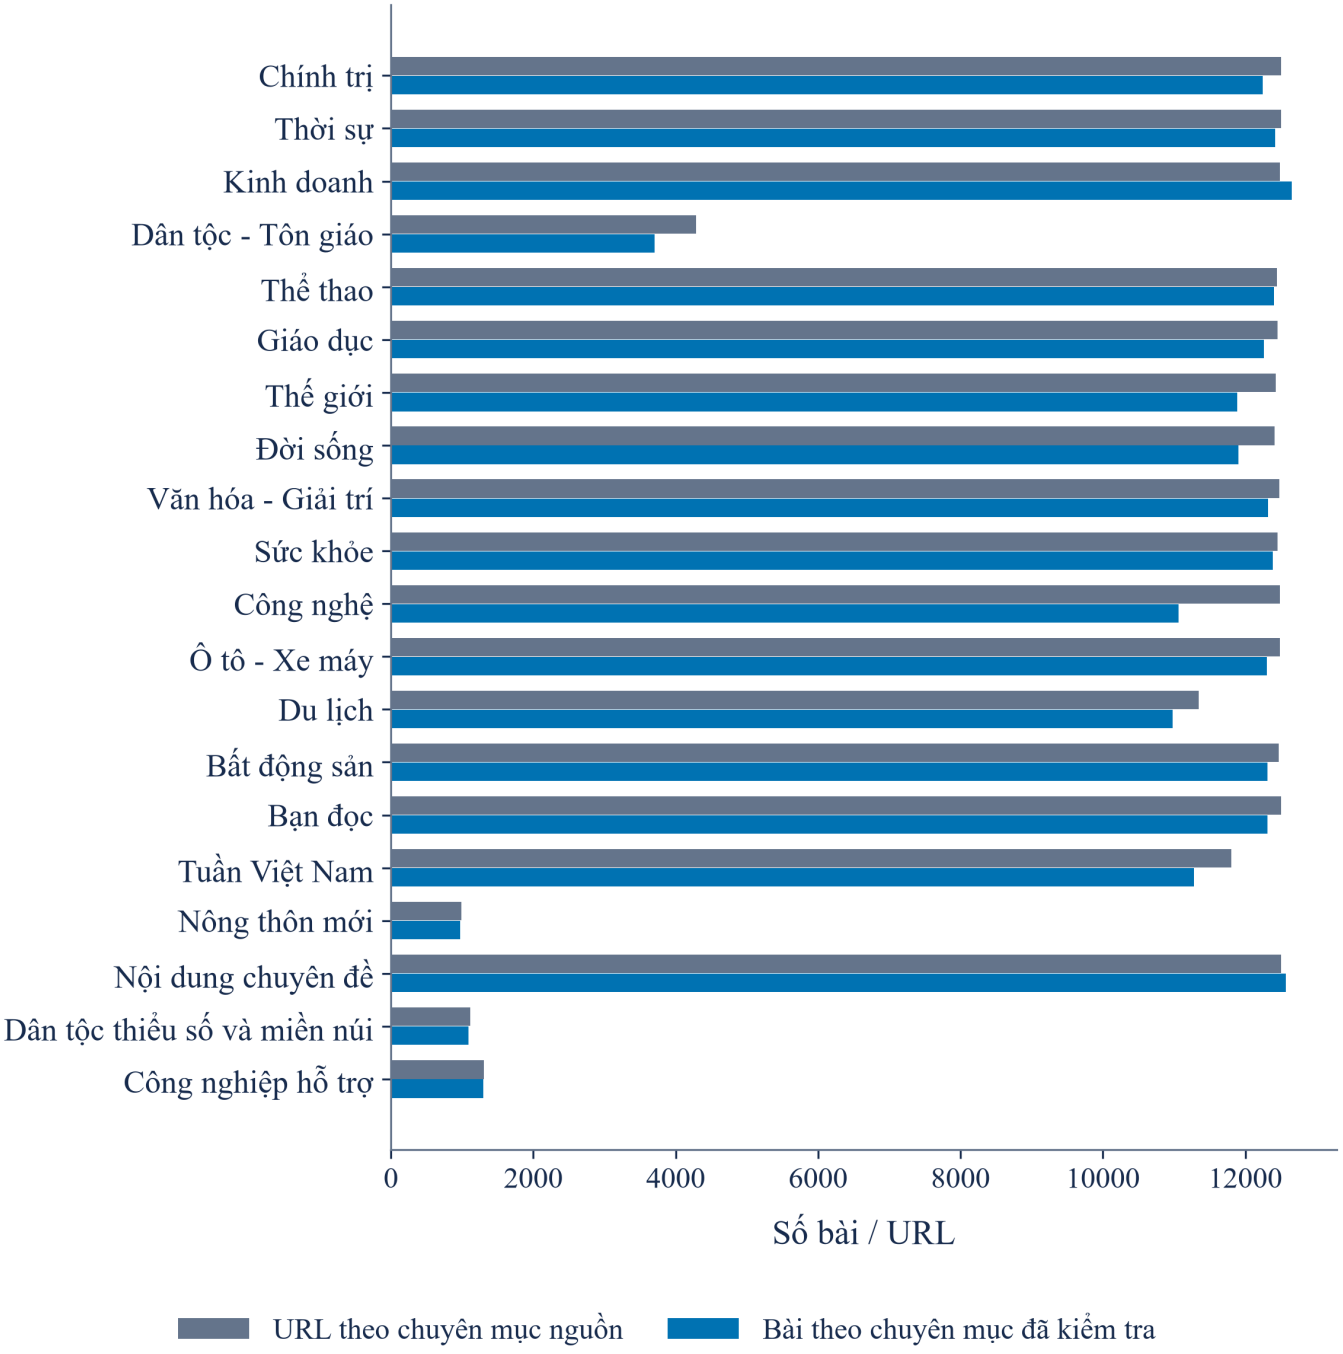
205.463 lượt URL tạo 204.280 URL duy nhất; 1.183 lượt lặp được gộp trước xử lý nội dung. Dataset giữ 199.463 bài ở chuyên mục nguồn, chuyển 874 bài về class phù hợp, loại 3.866 bài ngoài taxonomy, loại 76 URL không đạt sau ba lượt và gộp một request trùng canonical. Đối chiếu bảo toàn số lượng:

$$204\,280 = 200\,337 + 3\,866 + 76 + 1. \tag{2.1}$$

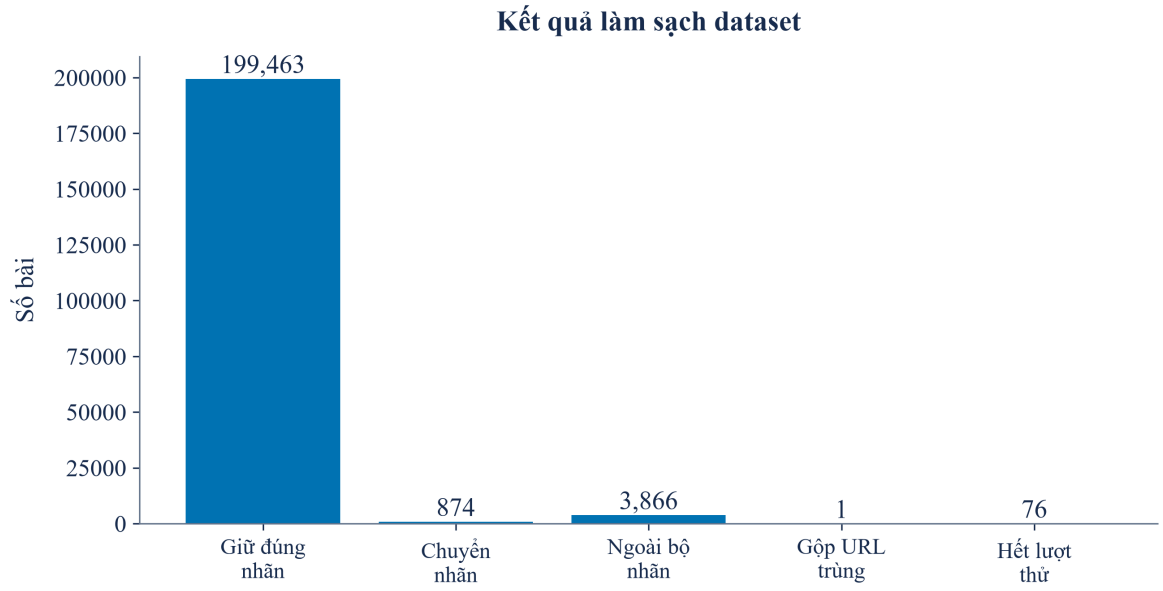
874 bài chuyển được tính theo URL duy nhất. Ma trận quan hệ nguồn–đích có 201.444 quan hệ cho 200.337 bài giữ lại và 1.981 quan hệ ngoài đường chéo, do một bài có thể mang nhiều chuyên mục nguồn. Không cộng số ô ngoài đường chéo rồi gọi đó là số bài được chuyển.



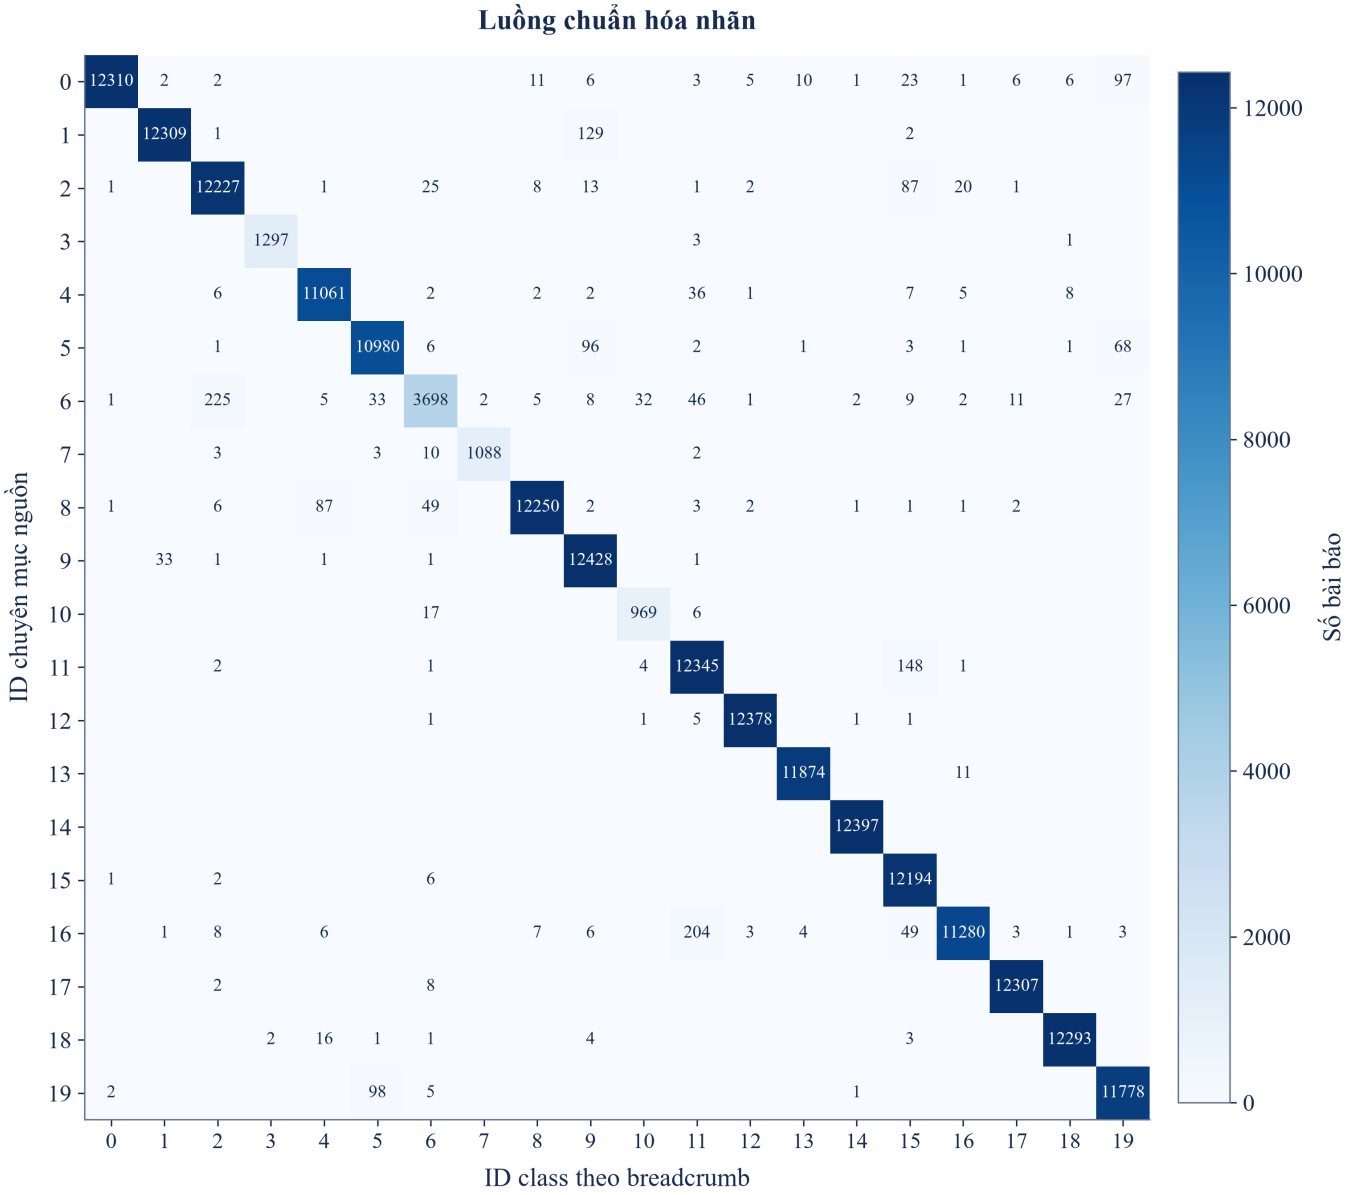
Hình 2.1: Phân bố 200.337 bài sạch theo chuyên mục sau xác minh URL và nội dung.



Hình 2.2: Phân bố URL theo chuyên mục nguồn và bài theo class sau chuẩn hóa.



Hình 2.3: Các quyết định làm sạch từ output notebook dữ liệu.



Hình 2.4: Quan hệ chuyên mục nguồn–đích; cùng một bài có thể đóng góp nhiều quan hệ nguồn.

2.4 Bốn tệp URL và hợp đồng dataset

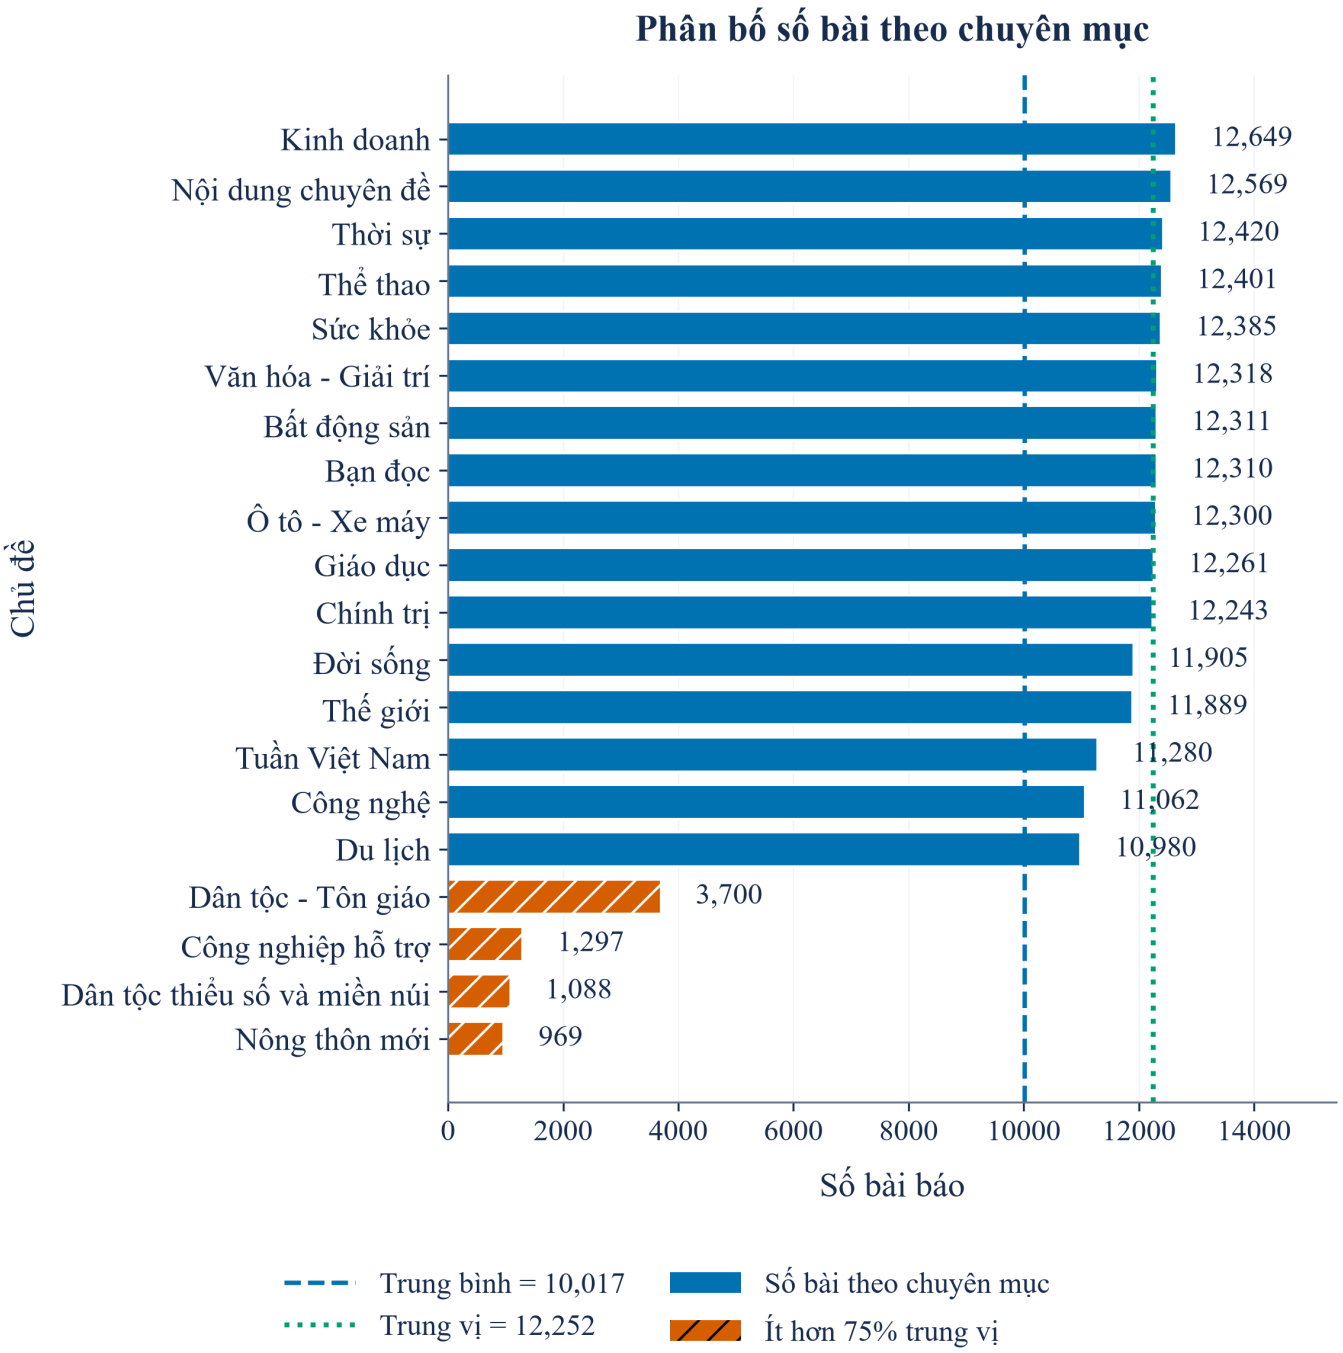
data_URLs_raw.json lưu snapshot theo chuyên mục phát hiện. data_URLs_removed.json giữ lý do loại hoặc gộp để truy vết. data_URLs_meta.json chứa cấu hình, hash và số lượng. data_URLs_clean.json lưu URL canonical theo nhãn cuối. Bảng trước chuẩn hóa dùng raw; bảng sau chuẩn hóa dùng clean. Không dùng hai đơn vị đếm thay thế nhau.

Mỗi Parquet giữ URL, tiêu đề, nội dung, class và bằng chứng xác minh. Notebook huấn luyện chỉ tiếp nhận corpus vượt qua kiểm tra số lượng, mapping, hash, URL sạch, Parquet và bằng chứng chuyên mục từng bản ghi. Đối chiếu thành công xác nhận tính nhất quán của artifact theo chính sách xác minh, không chứng minh mọi nhãn đều đúng theo ngữ nghĩa hay được chuyên gia gán nhãn thủ công.

2.5 Phân bố lớp và mất cân bằng

Bảng 2.2: Số dòng Parquet, corpus sau khử trùng và số mẫu ba tập. ID 0–19 thống nhất giữa notebook và app.

ID	Chuyên mục	Parquet	Sau khử trùng	Train	Val	Test
0	Bạn đọc	12.310	12.119	8.483	1.818	1.818
1	Bất động sản	12.311	12.309	8.616	1.847	1.846
2	Chính trị	12.243	12.242	8.569	1.837	1.836
3	Công nghiệp hỗ trợ	1.297	1.292	905	193	194
4	Công nghệ	11.062	11.061	7.743	1.659	1.659
5	Du lịch	10.980	10.979	7.685	1.647	1.647
6	Dân tộc - Tôn giáo	3.700	3.700	2.590	555	555
7	Dân tộc thiểu số và miền núi	1.088	1.088	762	163	163
8	Giáo dục	12.261	12.259	8.581	1.839	1.839
9	Kinh doanh	12.649	12.643	8.850	1.896	1.897
10	Nông thôn mới	969	969	678	145	146
11	Nội dung chuyên đề	12.569	12.568	8.798	1.885	1.885
12	Sức khỏe	12.385	12.385	8.670	1.858	1.857
13	Thế giới	11.889	11.889	8.322	1.783	1.784
14	Thể thao	12.401	12.267	8.587	1.840	1.840
15	Thời sự	12.420	12.420	8.694	1.863	1.863
16	Tuần Việt Nam	11.280	11.276	7.893	1.692	1.691
17	Văn hóa - Giải trí	12.318	12.317	8.622	1.848	1.847
18	Ô tô - Xe máy	12.300	12.299	8.609	1.845	1.845
19	Đời sống	11.905	11.883	8.318	1.782	1.783



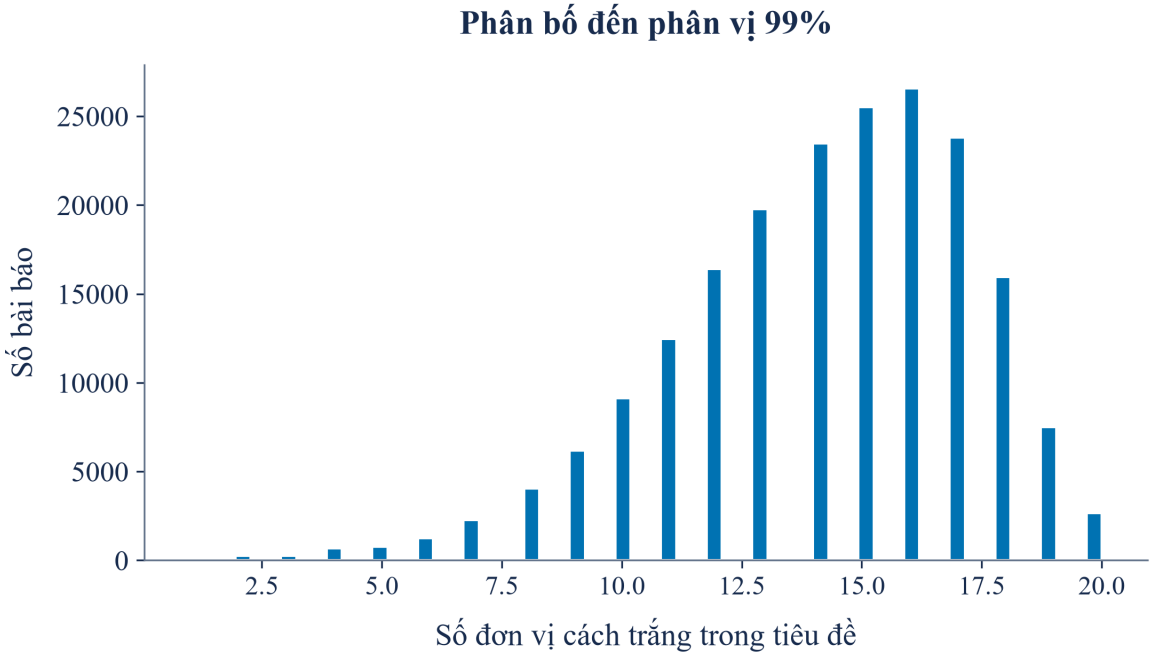
Hình 2.5: Phân bố 20 lớp trong đầu vào huấn luyện, trước khử trùng văn bản.

Kinh doanh có 12.649 bài, Nông thôn mới có 969 bài, chênh lệch khoảng 13,05 lần. Dân tộc thiểu số và miền núi có 1.088 bài; Công nghiệp hỗ trợ có 1.297 bài. Accuracy chịu ảnh hưởng mạnh của lớp lớn, vì vậy chỉ số theo lớp và Macro-F1 là cần thiết. Nhiều lớp lớn có số lượng gần nhau do phạm vi phân trang; đây không phải mẫu ngẫu nhiên đại diện phân bố tin của tòa soạn.

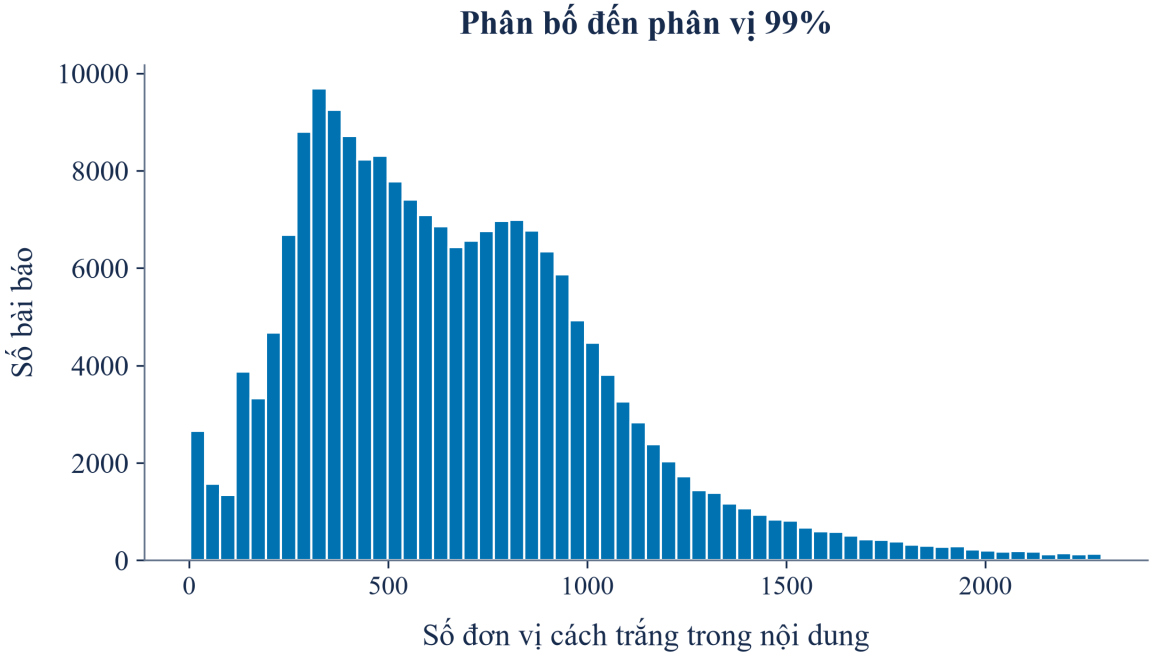
Không phải mọi lớp ít mẫu đều yếu: Công nghiệp hỗ trợ có ít dữ liệu nhưng F1 cao. Khó khăn còn phụ thuộc mức tập trung chủ đề, quy ước chuyên mục, nhiễu nhãn và giao thoa nội dung. Tăng trọng số lớp không tự bổ sung ngữ cảnh hoặc tạo một ranh giới taxonomy rõ hơn.

2.6 Độ dài ở ba mức biểu diễn

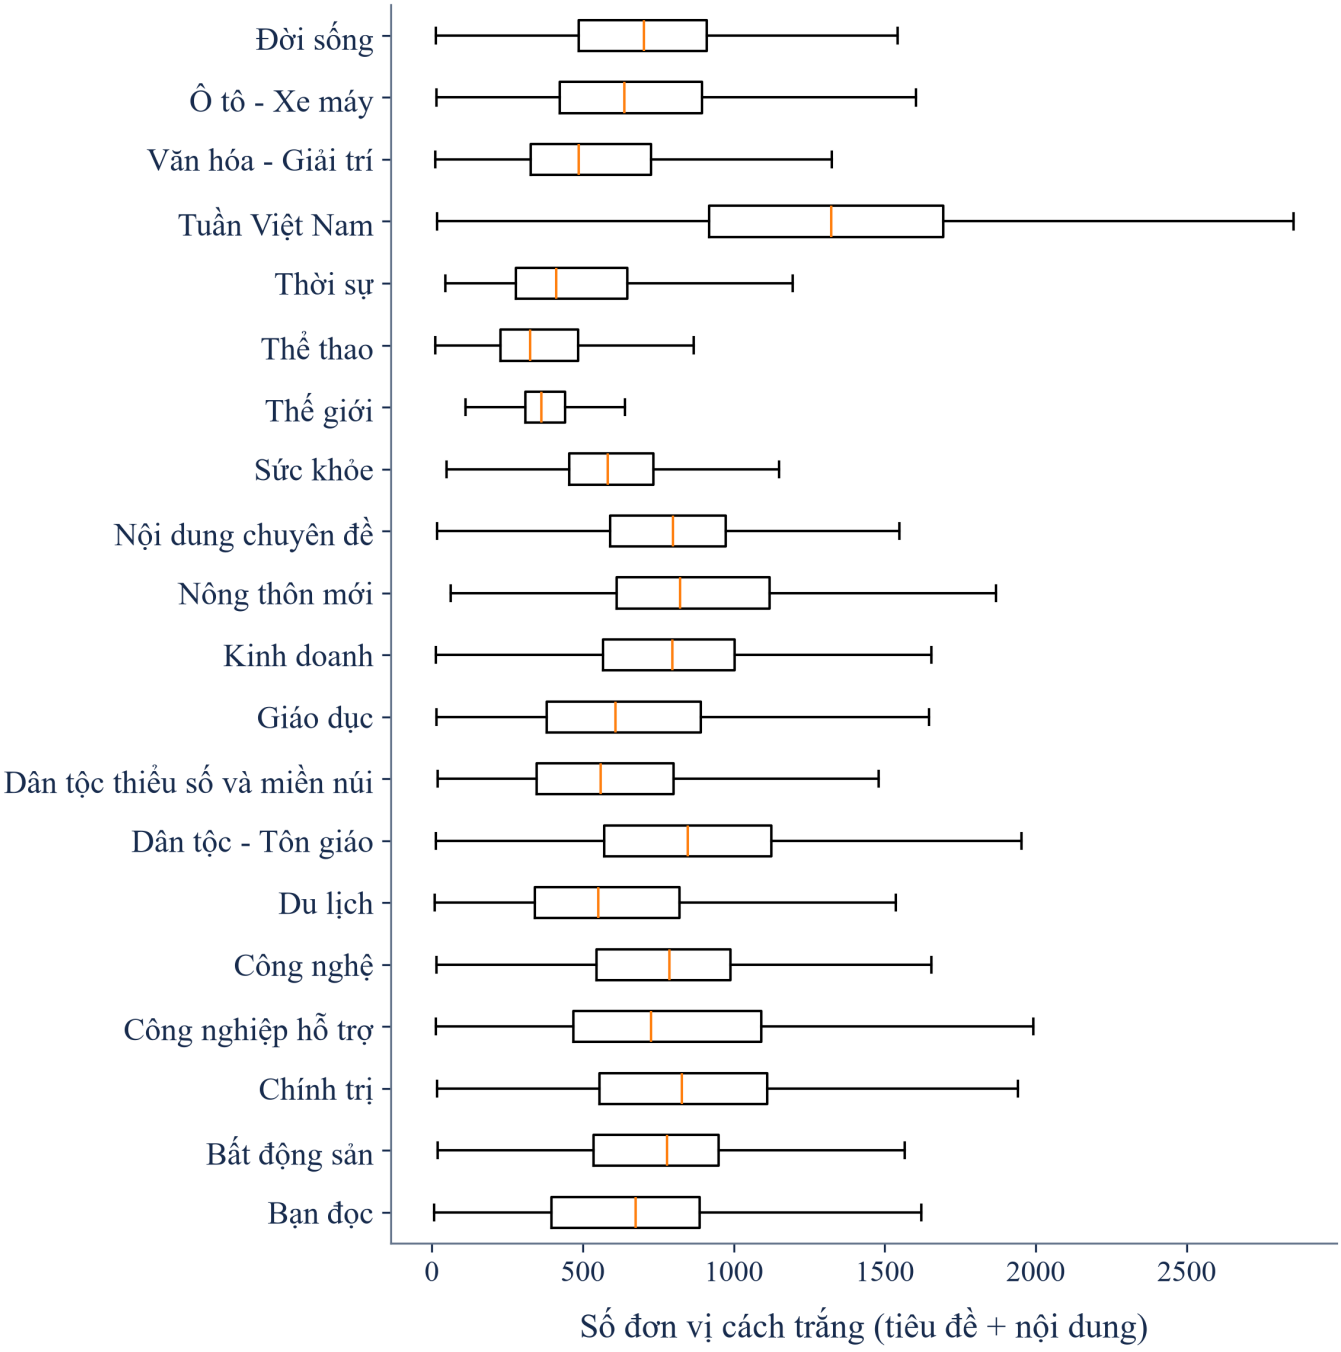
Trước khử trùng, tiêu đề có trung bình 14,26 đơn vị tách bằng khoảng trắng, trung vị 15; nội dung có trung bình 693,28 và trung vị 617. Đây chưa phải từ sau PyVi hoặc token BPE. Trên corpus 199.965 bài dùng chia tập, nội dung có trung vị 2.840 ký tự, trung bình 3.198,85 và lớn nhất 131.081; văn bản sạch có trung vị 465 đơn vị, trung bình 524,16 và lớn nhất 20.547.



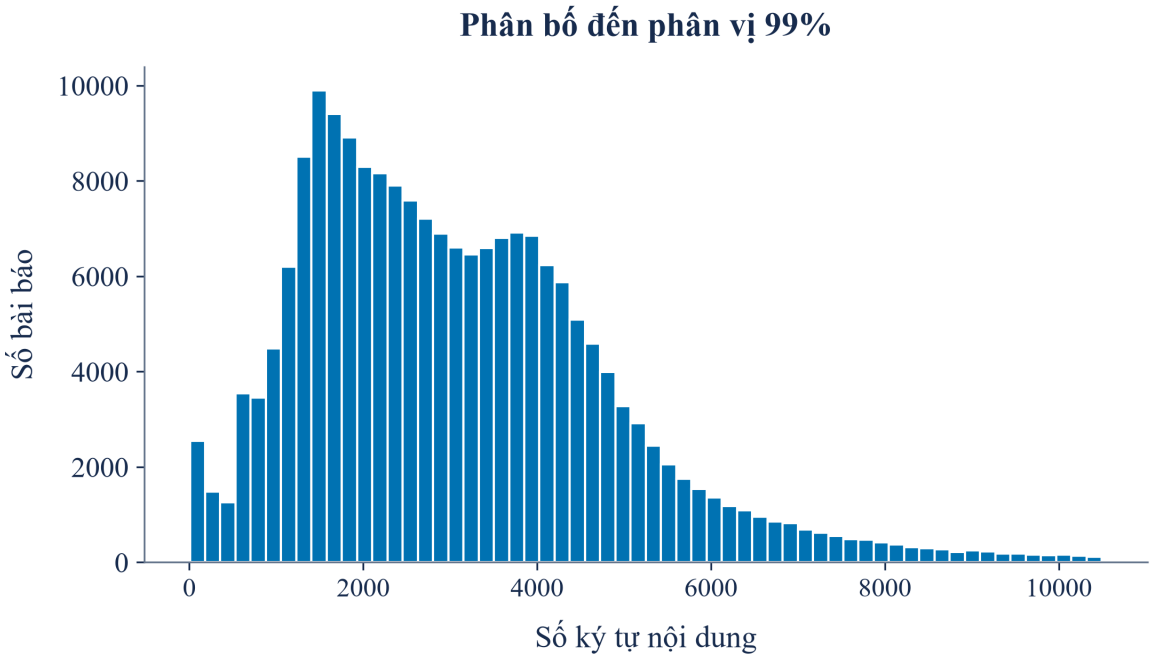
Hình 2.6: Độ dài tiêu đề theo các đơn vị tách bằng khoảng trắng.



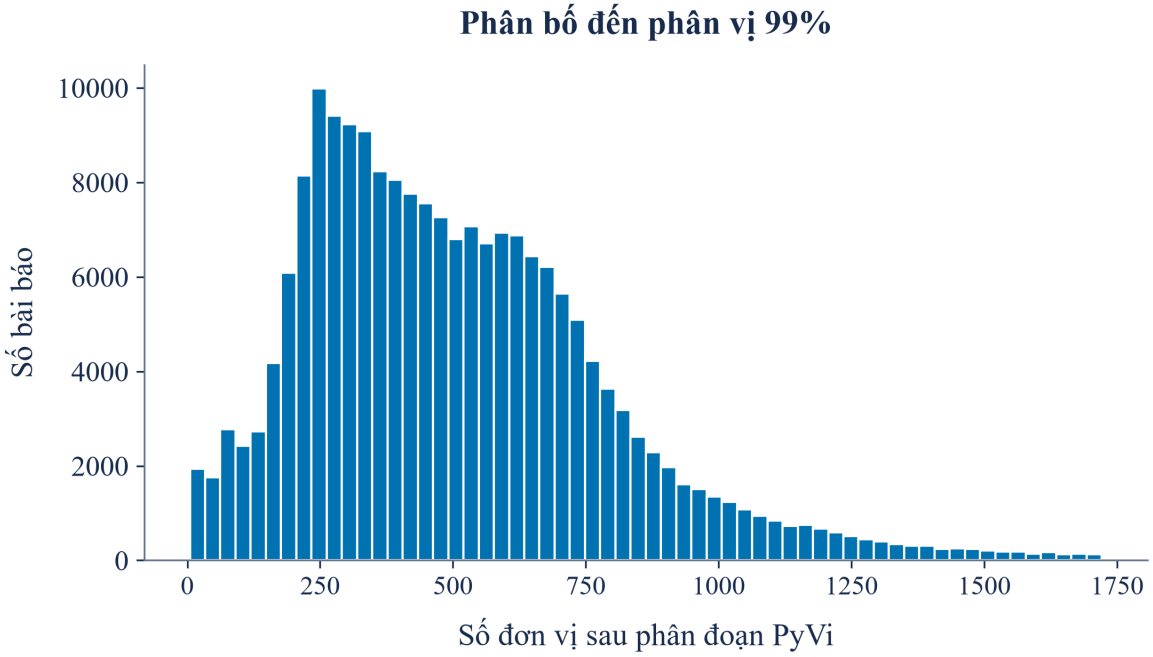
Hình 2.7: Độ dài nội dung trước phân đoạn từ, không đồng nghĩa độ dài BPE.



Hình 2.8: Độ dài nội dung theo chuyên mục, dùng để xem khác biệt phân bố.

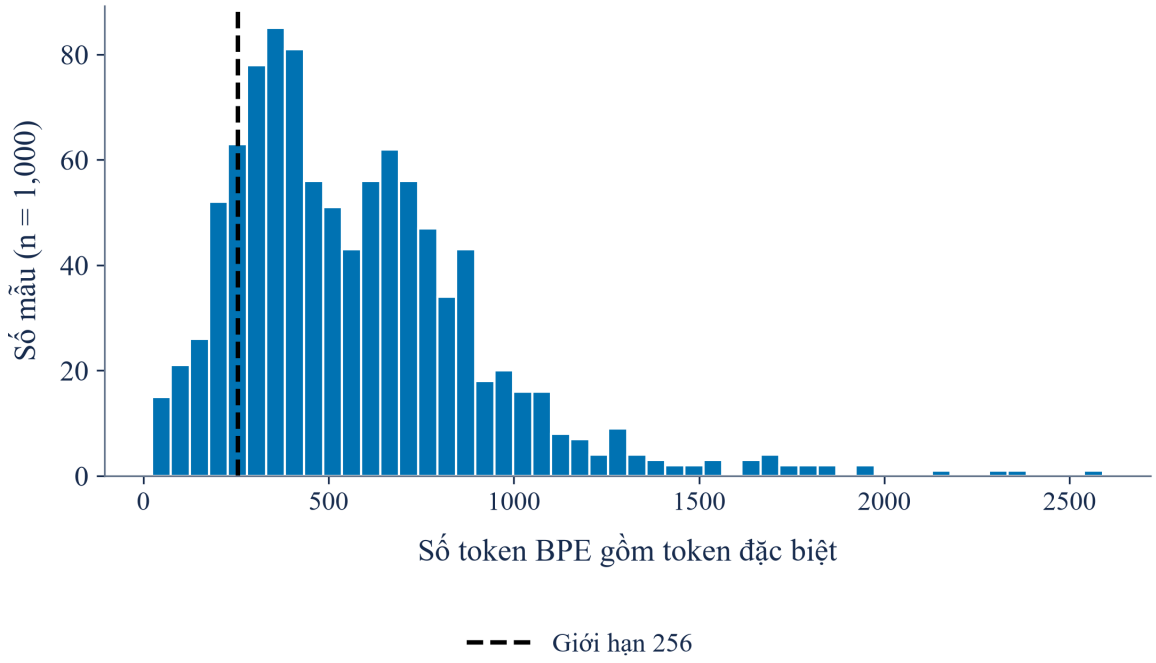


Hình 2.9: Độ dài nội dung theo ký tự; histogram giới hạn vùng hiển thị để đọc được phần phân bố chính.

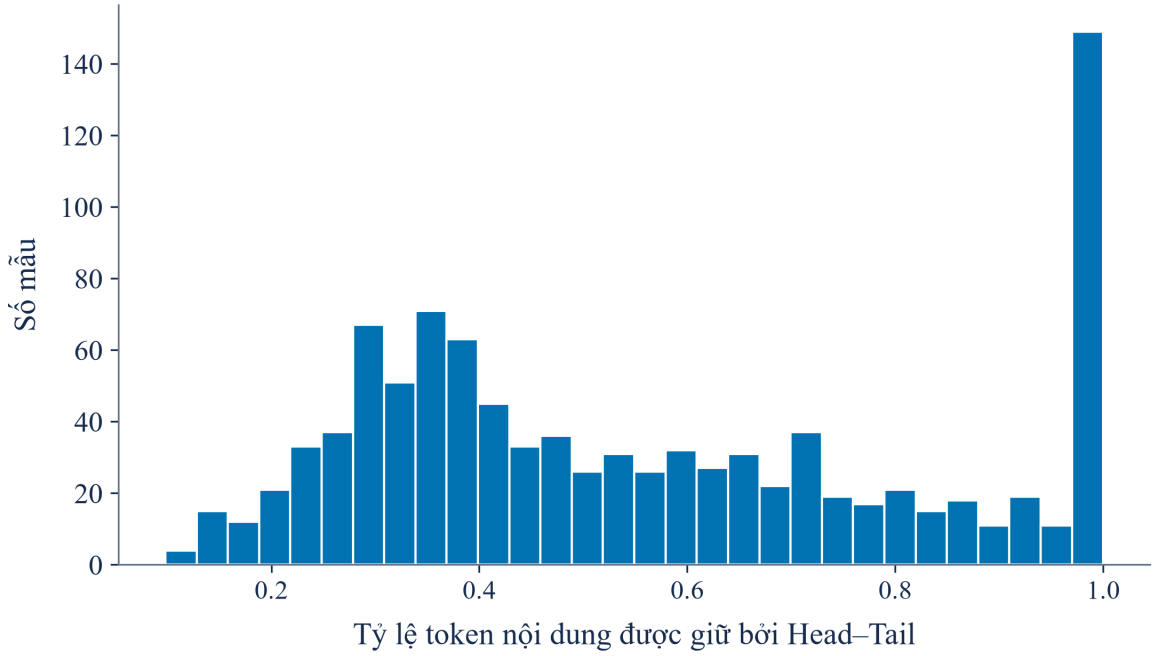


Hình 2.10: Độ dài văn bản sau phân đoạn từ tiếng Việt.

Khảo sát BPE trên 1.000 mẫu seed 42, tính cả token đặc biệt, có trung bình 572,973 token, trung vị 510,5, lớn nhất 2.590; 85,4% vượt 256 token. Tỷ lệ giữ token trung bình là 56,32%. Các tỷ lệ này thuộc mẫu khảo sát, không phải số đếm trên toàn corpus hay tỷ lệ thông tin ngữ nghĩa bảo toàn. Bài dài là trường hợp phổ biến; phần bị cắt cần được xem như một giới hạn phương pháp.



Hình 2.11: Khảo sát độ dài BPE trên 1.000 bài.

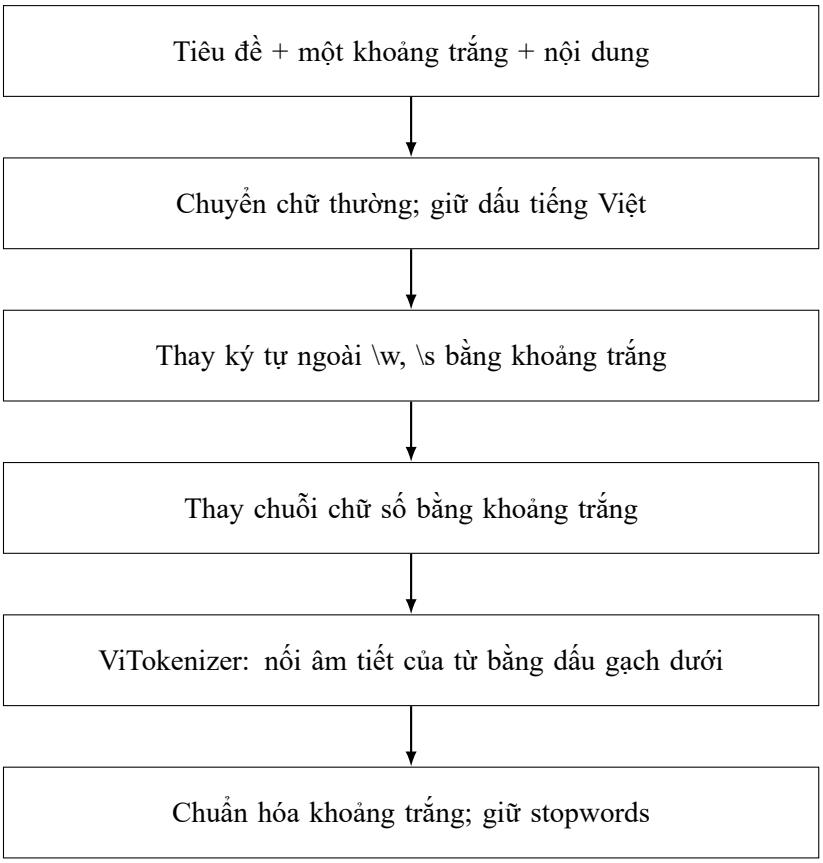


Hình 2.12: Tỷ lệ token giữ trong giới hạn 256; không đo lượng thông tin ngữ nghĩa còn lại.

2.7 Ghép và chuẩn hóa văn bản

Đầu vào là tiêu đề, một khoảng trắng và nội dung. Tiêu đề xuất hiện một lần, nằm ở đầu nên thường được giữ trong head. Pipeline chuyển chữ thường, thay dấu câu và chữ số bằng

khoảng trắng, gọi PyVi, chuẩn hóa khoảng trắng và giữ stopwords. Dấu tiếng Việt trong văn bản Unicode thông thường được giữ; dấu gạch dưới thể hiện từ nhiều âm tiết.



Hình 2.13: Thứ tự tiền xử lý chính xác của văn bản tiếng Việt.

Bảng 2.3: Trích đoạn thực tế của bài UNIQLO trong output notebook, qua từng bước xử lý.

Bước	Trích đoạn thực tế
Ghép đầu vào	1 triệu trang phục UNIQLO tặng trẻ em, nạn nhân thiên tai, người tị nạn toàn cầu Đây là năm thứ 2 UNIQLO duy trì hoạt động quyên góp quần áo nằm trong khuôn khổ…
Chữ thường	1 triệu trang phục uniqlo tặng trẻ em, nạn nhân thiên tai, người tị nạn toàn cầu đây là năm thứ 2 uniqlo duy trì hoạt động quyên góp quần áo nằm trong khuôn khổ…
Thay dấu câu	1 triệu trang phục uniqlo tặng trẻ em nạn nhân thiên tai người tị nạn toàn cầu đây là năm thứ 2 uniqlo duy trì hoạt động quyên góp quần áo nằm trong khuôn khổ…
Bỏ chữ số	triệu trang phục uniqlo tặng trẻ em nạn nhân thiên tai người tị nạn toàn cầu đây là năm thứ uniqlo duy trì hoạt động quyên góp quần áo nằm trong khuôn khổ…
Phân đoạn từ	triệu trang_phục uniqlo tặng trẻ_em nạn_nhân thiên_tai người tị_nạn toàn_cầu đây là năm thứ uniqlo duy_trì hoạt_động quyên_góp quần_áo nằm trong khuôn_khổ sáng_…
Chuẩn hóa khoảng trắng	triệu trang_phục uniqlo tặng trẻ_em nạn_nhân thiên_tai người tị_nạn toàn_cầu đây là năm thứ uniqlo duy_trì hoạt_động quyên_góp quần_áo nằm trong khuôn_khổ sáng_…

Phân đoạn từ và BPE có hai nhiệm vụ khác nhau. Tiếng Việt có khoảng trắng giữa âm tiết; PyVi nối các tổ hợp thành đơn vị từ [6]. Tokenizer PhoBERT tiếp tục biểu diễn chúng bằng subword. PhoBERT được tiền huấn luyện với phân đoạn của VnCoreNLP và khuyến nghị công cụ tương ứng [8]; dùng PyVi tạo khác biệt với tiền huấn luyện, dù train và app nhất quán với nhau.

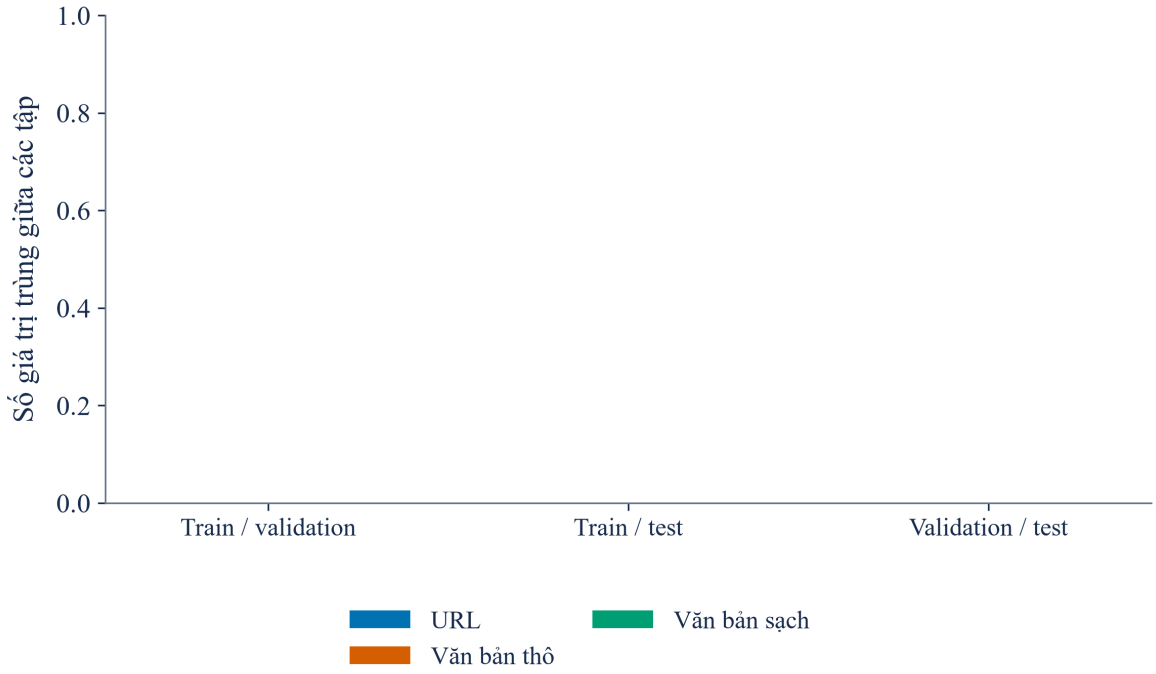
Chuyển chữ thường làm mất tín hiệu tên riêng; bỏ chữ số làm mất năm, giá, số hiệu và tỷ số; bỏ dấu câu làm mất một phần ranh giới câu. Không có ablation xác nhận mỗi bước đều tăng F1. Pipeline cũng không có bước NFC riêng, nên không thể cam kết bảo toàn mọi dạng dấu Unicode tổ hợp. Đây là các lựa chọn cần khảo sát trước khi thay đổi cách xử lý của model đã train.

2.8 Khử trùng trước chia tập

Văn bản đã chuẩn hóa được dùng nhận diện nhóm trùng. Có tám dòng thuộc nhóm trùng nhưng xung đột nhãn bị loại và 364 dòng trùng cùng nhãn dư bị gộp, tạo 199.965 bài. Không chọn một nhãn tùy ý cho đầu vào giống nhau nhưng nhãn khác nhau. Việc khử trùng theo văn bản diễn ra trước chia tập để tránh đưa cùng đầu vào vào train và test.

Audit xác nhận số nhóm lặp theo URL, văn bản thô và văn bản sạch đều bằng không trong corpus dùng chia tập. Chín phép đối chiếu, gồm ba loại khóa trên ba cặp tập, đều không giao nhau. Kiểm tra exact hash chưa phát hiện gần trùng, viết lại hoặc nhiều bài về cùng một sự kiện. Một thiết kế theo thời gian, nhóm sự kiện hoặc near-duplicate sẽ đánh giá tổng quát hóa nghiêm

ngặt hơn.



Hình 2.14: Kiểm tra giao nhau giữa ba tập trên URL, văn bản thô và văn bản sạch.

2.9 Cache, truy vết và giới hạn dữ liệu

Cache trong temp/ giữ văn bản xử lý và ba tập tensor Head–Tail. Fingerprint gắn dữ liệu, mapping, phép chia, tokenizer và chiều dài. Số dòng giống nhau không đủ chứng minh cache đúng; điều kiện tái sử dụng cần signature khớp. Cache phục vụ tốc độ tái thực thi, không tham gia dịch vụ suy luận.

Corpus là snapshot một nguồn với nhãn từ tòa soạn. Một số bài có đoạn quảng bá, thông tin liên quan hoặc khoảng trắng trích xuất chưa tự nhiên; độ dài cực lớn cần rà soát. Không có kiểm toán ngữ nghĩa thủ công toàn bộ corpus. Vì vậy, dataset sạch được hiểu là đạt quy tắc và kiểm tra cấu trúc đã công bố, không phải không còn mọi dạng nhiễu.

3. Biểu diễn văn bản và kiến trúc PhoBERT

3.1 Từ đặc trưng bề mặt đến biểu diễn theo ngữ cảnh

Trong phân loại văn bản, một cách tiếp cận truyền thống là đếm từ hoặc sử dụng TF–IDF rồi huấn luyện bộ phân loại tuyến tính. Cách này có lợi thế về chi phí và khả năng kiểm tra trọng số, nhưng biểu diễn một từ chủ yếu dựa trên sự xuất hiện của nó. Với tin tức giao thoa chủ đề, cùng một từ như "thị trường" có thể chỉ thị trường tài chính, thị trường du lịch hoặc thị trường tiêu dùng. Ngữ cảnh xung quanh quyết định cách hiểu hữu ích cho chuyên mục.

Encoder Transformer tạo biểu diễn của mỗi vị trí dựa trên các vị trí còn lại trong đoạn văn bản được giữ. Mô hình tiền huấn luyện cung cấp tham số đã học các quy luật ngôn ngữ; fine-tuning điều chỉnh biểu diễn và đầu phân loại theo 20 nhãn của bài toán. BERT là một cơ sở của hướng học biểu diễn hai chiều và fine-tuning cho tác vụ downstream [1]; RoBERTa nghiên cứu các thay đổi trong quy trình tiền huấn luyện BERT [3]. PhoBERT tập trung vào tiếng Việt [5].

Bài tập lớn sử dụng vinai/phobert-base-v2. Theo model card chính thức, bản base-v2 có quy mô khoảng 135 triệu tham số, độ dài tối đa 256 và corpus tiền huấn luyện gồm 20 GB Wikipedia/tin tức cùng 120 GB OSCAR-2301 [8]. Corpus này là dữ liệu tiền huấn luyện của mô hình nền. Dataset dự án có 200.337 bài sạch theo chuyên mục; sau khử trùng văn bản, 199.965 bài được chia thành ba tập phục vụ fine-tuning và đánh giá. Báo cáo không coi số liệu hiệu năng của nhà phát triển PhoBERT ở các benchmark khác là kết quả của bài tập lớn.

3.2 Phân đoạn từ và mã hóa BPE

Sau PyVi, chuỗi được mã hóa bởi PhobertTokenizer cùng vocab.txt và bpe.codes. Các từ phổ biến có thể được biểu diễn gọn, trong khi một từ ít gặp có thể bị chia thành nhiều subword. Do đó, số token không bằng số từ, và một bài có cùng số từ với bài khác vẫn có thể cần số vị trí khác nhau.

Mã hóa sinh các ID số nguyên, không truyền chuỗi tiếng Việt trực tiếp vào mạng neural. ID được tra trong ma trận embedding; attention mask cho biết vị trí nào thuộc văn bản thật. Từ vựng có 64.001 mục, bao gồm các token đặc biệt. Trong cấu hình, token bắt đầu có ID 0, padding có ID 1 và token kết thúc có ID 2. Những ID này phải được lấy từ tokenizer tương ứng với checkpoint; thay tokenizer bằng một phiên bản khác có thể làm tensor vẫn đúng kích thước nhưng sai ý nghĩa.

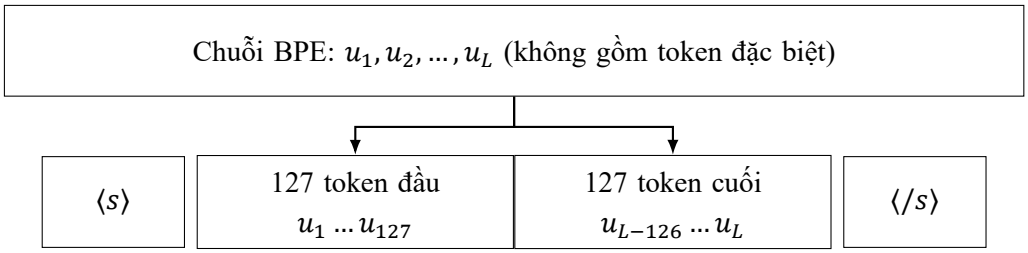
Tokenizer và cấu hình nhãn là một phần của gói mô hình, cùng với trọng số và tham số hiệu chỉnh. Dịch vụ sử dụng local_files_only=True, nên suy luận không phụ thuộc vào việc tải một tokenizer mới từ mạng trong lúc khởi động. Đây là điều kiện quan trọng để đối chiếu notebook với ứng dụng.

3.3 Lựa chọn Head–Tail cho bài báo dài

Giới hạn 256 vị trí gồm cả hai token đặc biệt. Nếu chuỗi BPE không có token đặc biệt dài $L > 254$, đầu vào được tạo như sau:

$$s = [\langle s\rangle, u_1, \dots, u_{127}, u_{L-126}, \dots, u_L, \langle /s\rangle]. \quad (3.1)$$

Nếu $L \leq 254$, chuỗi được mã hóa đầy đủ, thêm token bắt đầu/kết thúc và padding đến 256 vị trí. Attention mask bằng 1 ở các vị trí có nội dung hoặc token đặc biệt và bằng 0 ở padding. Hai nhánh được kiểm tra ở các ranh giới 253, 254, 255 và 256 token để tránh lỗi thêm token đặc biệt hoặc cắt lệch một vị trí.



Tổng 256 token; phần giữa bị loại khi $L > 254$. Văn bản ngắn giữ toàn bộ, thêm token đặc biệt và padding.

Hình 3.1: Cách ghép Head–Tail; dấu token được minh họa theo ký hiệu của tokenizer PhoBERT.

Với bài dài, phần head có tiêu đề và đoạn mở đầu, trong khi phần tail có các đoạn kết. Giả thiết sử dụng là hai vùng này có thể chứa tín hiệu chủ đề hữu ích. Tuy nhiên, phần giữa có thể chứa lập luận, tên tổ chức hoặc sự kiện quyết định nhãn; toàn bộ vùng đó bị loại nếu vượt giới hạn. Head–Tail cũng nối hai vùng không kề nhau trong bản gốc thành hai đoạn kề nhau trong tensor. Không có dấu phân cách chuyên biệt để mô hình biết khoảng giữa bị bỏ.

Ở mức token, lựa chọn được thực hiện sau BPE nên có thể cắt giữa các subword của một từ. Điều này khác với lấy 127 từ đầu và 127 từ cuối. Các vị trí được đánh lại theo chuỗi ghép 256 token; chúng không giữ tọa độ tuyệt đối trong bài báo dài. Đây là một phép nén đầu vào có mất thông tin, không phải cơ chế attention trên toàn bộ bài.

3.3.1 Chi phí và các phương án so sánh

Attention chuẩn xét các cặp vị trí nên ma trận attention mỗi head có L^2 phần tử. Giới hạn $L = 256$ giúp kiểm soát bộ nhớ và thời gian khi fine-tuning. Tăng gấp đôi chiều dài làm số phần tử ma trận cặp tăng gấp bốn, trước khi tính các chi phí khác. FFN và phép chiếu cũng đóng góp đáng kể; không thể mô tả toàn bộ runtime chỉ bằng hạng L^2.

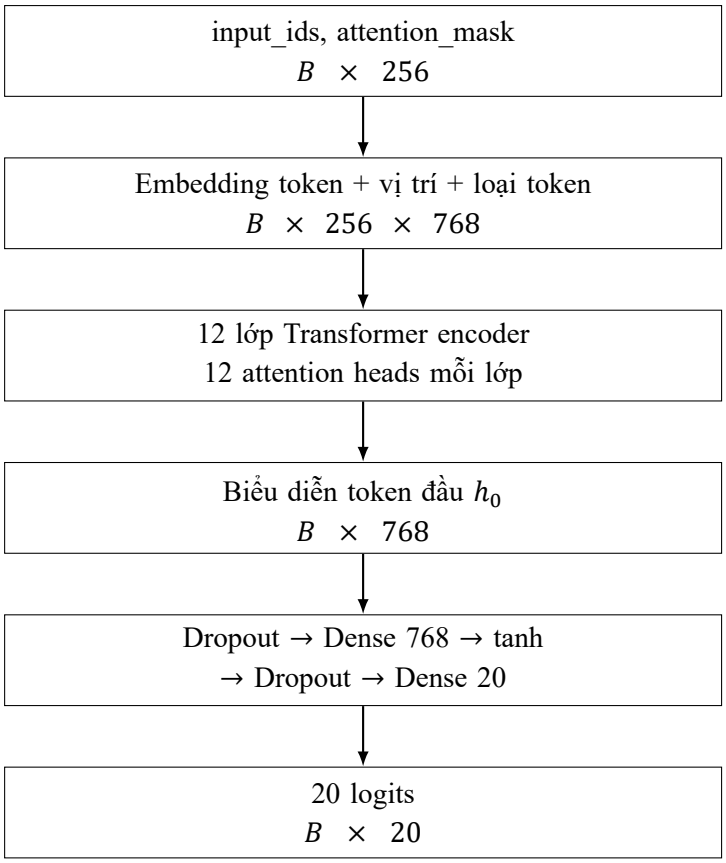
Các phương án cần so sánh trong một thực nghiệm bổ sung gồm head-only, tail-only, lấy đoạn trượt với tổng hợp logits, biểu diễn phân cấp theo đoạn và encoder ngữ cảnh dài. Sản phẩm hiện có một cấu hình Head–Tail; không có phép ablation đã huấn luyện để chứng minh cấu hình này tối ưu hoặc tốt hơn head-only bao nhiêu. Số liệu độ dài hỗ trợ lý do nghiên cứu cách cắt, nhưng không thay thế phép so sánh thực nghiệm.

3.4 Cấu hình kiến trúc thực tế

Bảng 3.1: Thông số đọc từ config.json của checkpoint.

Thuộc tính	Giá trị
Kiến trúc	RobertaForSequenceClassification
Số lớp encoder	12
Hidden size	768
Attention heads	12
Chiều mỗi head	64
Intermediate size	3.072
Vocabulary size	64.001
Max position embeddings	258
Token type vocabulary size	1
Hidden / attention dropout	0,1 / 0,1
LayerNorm epsilon	10^{-5}
Activation	GELU
Số nhãn đầu ra	20

Giá trị 258 của bảng vị trí không có nghĩa hệ thống nhận bài dài 258 token văn bản. Giới hạn pipeline là 256, còn chỉ số vị trí của RoBERTa có quy ước liên quan đến padding và offset. Không sử dụng một decoder sinh token hay cross-attention; cấu hình is_decoder=False và add_cross_attention=False phù hợp với encoder phân loại.



Hình 3.2: PhoBERT và đầu phân loại trong RobertaForSequenceClassification.

Với batch B, input IDs và mask có kích thước $B \times 256$. Embedding và mỗi tầng encoder tạo tensor $B \times 256 \times 768$. Đầu phân loại lấy biểu diễn vị trí đầu tiên và sinh logits $B \times 20$. Vị trí đầu là token tổng hợp cho tác vụ phân loại; đây không phải lấy trung bình các token và cũng không phải sử dụng một vector TF–IDF.

3.5 Embedding và thông tin vị trí

Embedding đầu vào kết hợp vector token, vị trí và token type. Bộ token type có một loại trong cấu hình này, nên không tạo hai segment độc lập cho tiêu đề và nội dung. LayerNorm và dropout được áp dụng trong thành phần embedding trước encoder. Vector vị trí giúp mạng phân biệt thứ tự, vì phép attention tự nó không biết một từ đứng ở đầu hay cuối nếu không có thông tin vị trí.

Vì chuỗi Head–Tail được ghép trước khi mã hóa qua encoder, embedding vị trí thể hiện thứ tự của chuỗi đã ghép. Mạng có thể học đặc trưng của đoạn đầu và đoạn cuối trong cách biểu diễn này, nhưng không được cung cấp số token bị loại ở giữa. Một giả thuyết cải thiện là bổ sung cơ chế biểu diễn theo đoạn; giả thuyết đó cần thay đổi thiết kế và đánh giá riêng.

3.6 Self-attention và xử lý theo ngữ cảnh

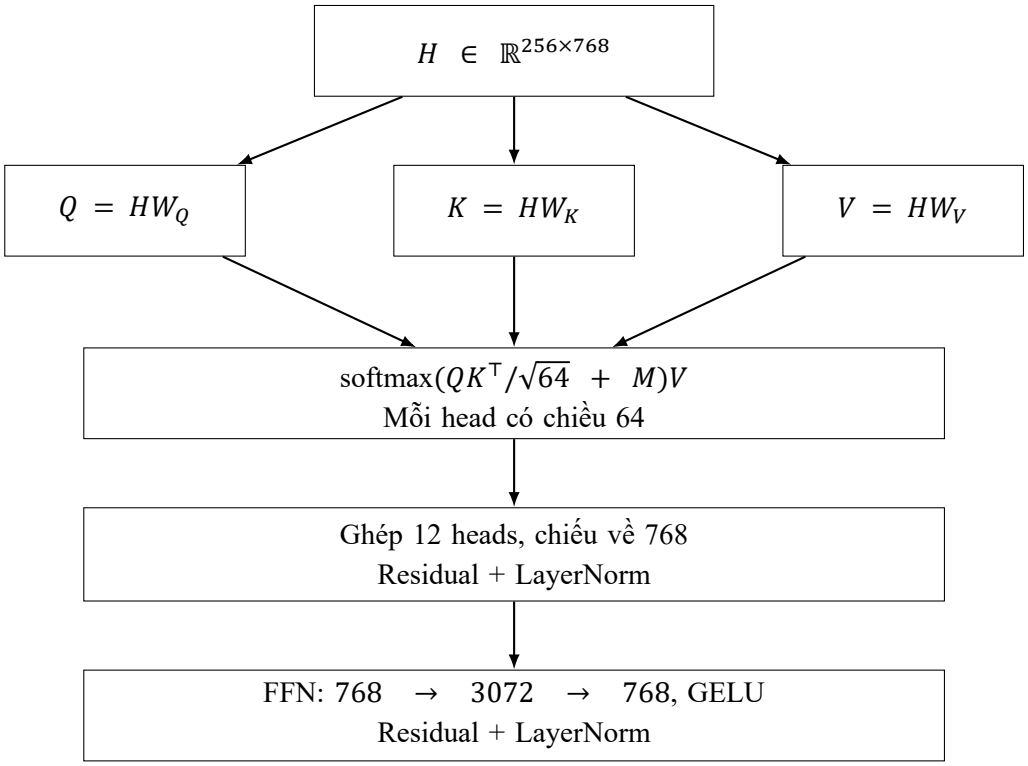
Theo cơ chế attention của Transformer [7], ở một head, biểu diễn H được chiếu thành query, key và value:

$$Q = HW_Q, \quad K = HW_K, \quad V = HW_V. \tag{3.2}$$

Các độ tương thích được chuẩn hóa theo chiều head và chuyển thành trọng số:

$$A = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right), \qquad O = AV, \quad d_k = 64. \tag{3.3}$$

M là attention mask đã chuyển thành dạng cộng để các vị trí padding không được chọn làm key hữu ích. Attention trong encoder là hai chiều trên các vị trí hợp lệ, không dùng causal mask kiểu dự đoán token tiếp theo. Nhờ vậy, một vị trí có thể kết hợp ngữ cảnh ở cả phía trước và phía sau trong đoạn được giữ.



Hình 3.3: Tính toán bên trong một lớp encoder; mask loại vị trí padding khỏi attention.

Mười hai head cung cấp các phép chiếu học được khác nhau; đầu ra được nối và chiếu về chiều 768. Không nên gán sẵn mỗi head cho một chức năng như "nhận biết pháp luật" nếu chưa có phân tích thực nghiệm. Attention là thành phần tính toán tạo biểu diễn, không tự động là lời giải thích nhân quả của nhãn cuối.

3.7 Residual, LayerNorm và feed-forward

Mỗi tầng có residual connection và LayerNorm quanh các thành phần attention và FFN theo kiến trúc RoBERTa. Residual tạo đường truyền để biểu diễn đầu vào được giữ cùng phần biến đổi học được. LayerNorm ổn định thang giá trị trong chiều đặc trưng. FFN áp dụng các phép chiếu tại từng vị trí với chiều trung gian 3.072 và activation GELU, rồi trả về 768.

Attention cho phép trao đổi thông tin giữa các vị trí; FFN biến đổi đặc trưng của từng vị trí sau trao đổi. Qua 12 tầng, biểu diễn đầu vào không còn là vector từ độc lập mà đã kết hợp các quan hệ trong đoạn văn bản. Tuy nhiên, mọi quan hệ vẫn giới hạn ở các token đã chọn. Không tầng nào có thể đọc lại đoạn giữa bị bỏ bởi Head–Tail.

3.8 Đầu phân loại và logits

RobertaForSequenceClassification sử dụng đầu phân loại trên hidden state của token đầu, gồm dropout, dense $768 \rightarrow 768$, tanh, dropout và phép chiếu $768 \rightarrow 20$. Dropout hoạt động ở chế độ train; dịch vụ gọi eval() để tắt ngẫu nhiên dropout khi suy luận. Logits là điểm chưa chuẩn hóa; chúng có thể âm hoặc dương và không phải xác suất.

Softmax chuẩn chuyển logits thành phân bố:

$$p_c = \frac{\exp(z_c)}{\sum_{j=1}^{20} \exp(z_j)}. \tag{3.4}$$

Xác suất tổng bằng 1 giữa 20 lớp trong taxonomy. Điều đó không bảo đảm bài nằm trong taxonomy hoặc xác suất là ước lượng đúng của xác suất thực. Một đầu vào ngoài miền vẫn bị buộc vào một trong 20 lớp nếu không có cơ chế từ chối độc lập.

3.9 Quy mô tham số và ý nghĩa của fine-tuning

Checkpoint có 135.013.652 tham số. Embedding chiếm 49.353.216; 12 lớp encoder chiếm 85.054.464; đầu phân loại chiếm 605.972. Tổng số tham số được tính từ kiến trúc và tensor của gói mô hình, không suy ra bằng cách làm tròn nhãn "135M".

Fine-tuning cập nhật mô hình cho tác vụ chuyên mục, thay vì tiền huấn luyện lại từ đầu trên corpus tin tức này. Đầu phân loại tương thích 20 lớp được khởi tạo khi tạo mô hình cho tác vụ; encoder nhận tham số mô hình nền. Toàn bộ quá trình dùng nhãn giám sát của corpus. Lợi ích kỳ vọng là tận dụng biểu diễn tiếng Việt, nhưng không có baseline cùng dữ liệu để định lượng phần lợi ích riêng của tiền huấn luyện.

4. Huấn luyện và hiệu chỉnh dự đoán

4.1 Chuẩn bị ba tập và tensor

Phân tầng được thực hiện sau khử trùng, seed 42, theo tỷ lệ 70/15/15. Các tensor input IDs, attention mask và nhãn bảo toàn thứ tự bài. Cache train, validation và test có chiều lần lượt $139\,975 \times 256$, $29\,995 \times 256$ và $29\,995 \times 256$. Padding không tham gia attention như token văn bản. Dataloader train xáo trộn mẫu; validation và test giữ phân bố lớp thực tế.

Seed giúp tái tạo các lựa chọn ngẫu nhiên có kiểm soát, nhưng không bảo đảm mọi phép tính GPU giống bit giữa các phiên bản và thiết bị. Thực nghiệm sử dụng một seed; độ biến thiên do khởi tạo và thứ tự batch chưa được đo.

4.2 Fine-tuning toàn bộ mô hình

Mô hình được khởi tạo từ vinai/phobert-base-v2; đầu phân loại có 20 nhãn. Toàn bộ encoder và head được cập nhật qua backward, không đóng băng backbone và không chỉ huấn luyện lớp tuyến tính cuối. Đây là học chuyển giao có giám sát; corpus dự án không được dùng tiền huấn luyện mô hình ngôn ngữ từ đầu.

4.3 Weighted cross-entropy

Với n_c là số mẫu class c trong train, trọng số là

$$w_c = \frac{N_{train}}{20 n_c}. \tag{4.1}$$

Không có boost thủ công. Lớp Kinh doanh có trọng số 0,7908, Nông thôn mới 10,3226, Dân tộc thiểu số và miền núi 9,1847. Trọng số phản ánh train, không lấy support test để xác định ưu tiên tối ưu. Hàm mất mát trên mini-batch $\mathcal{B}$ của PyTorch dùng reduction mean có trọng số:

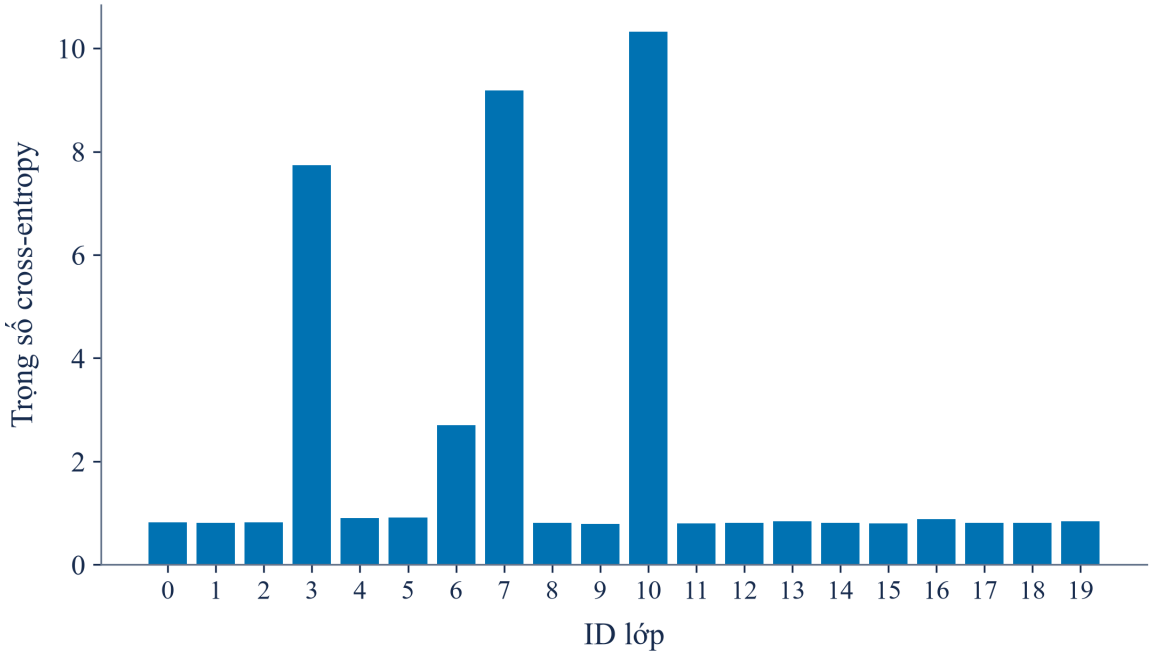
$$\mathcal{L}_{\mathcal{B}} = \frac{-\sum_{i \in \mathcal{B}} w_{y_i} \log p_{i,y_i}}{\sum_{i \in \mathcal{B}} w_{y_i}}. \tag{4.2}$$

Trọng số thay đổi đóng góp lỗi, không làm tăng số bài hay khử nhiễu. Nếu lớp nhỏ có nhãn mơ hồ, ưu tiên lỗi lớn có thể tăng tác động của nhiễu. Sampler vẫn ngẫu nhiên theo phân bố corpus; validation và test không oversample.

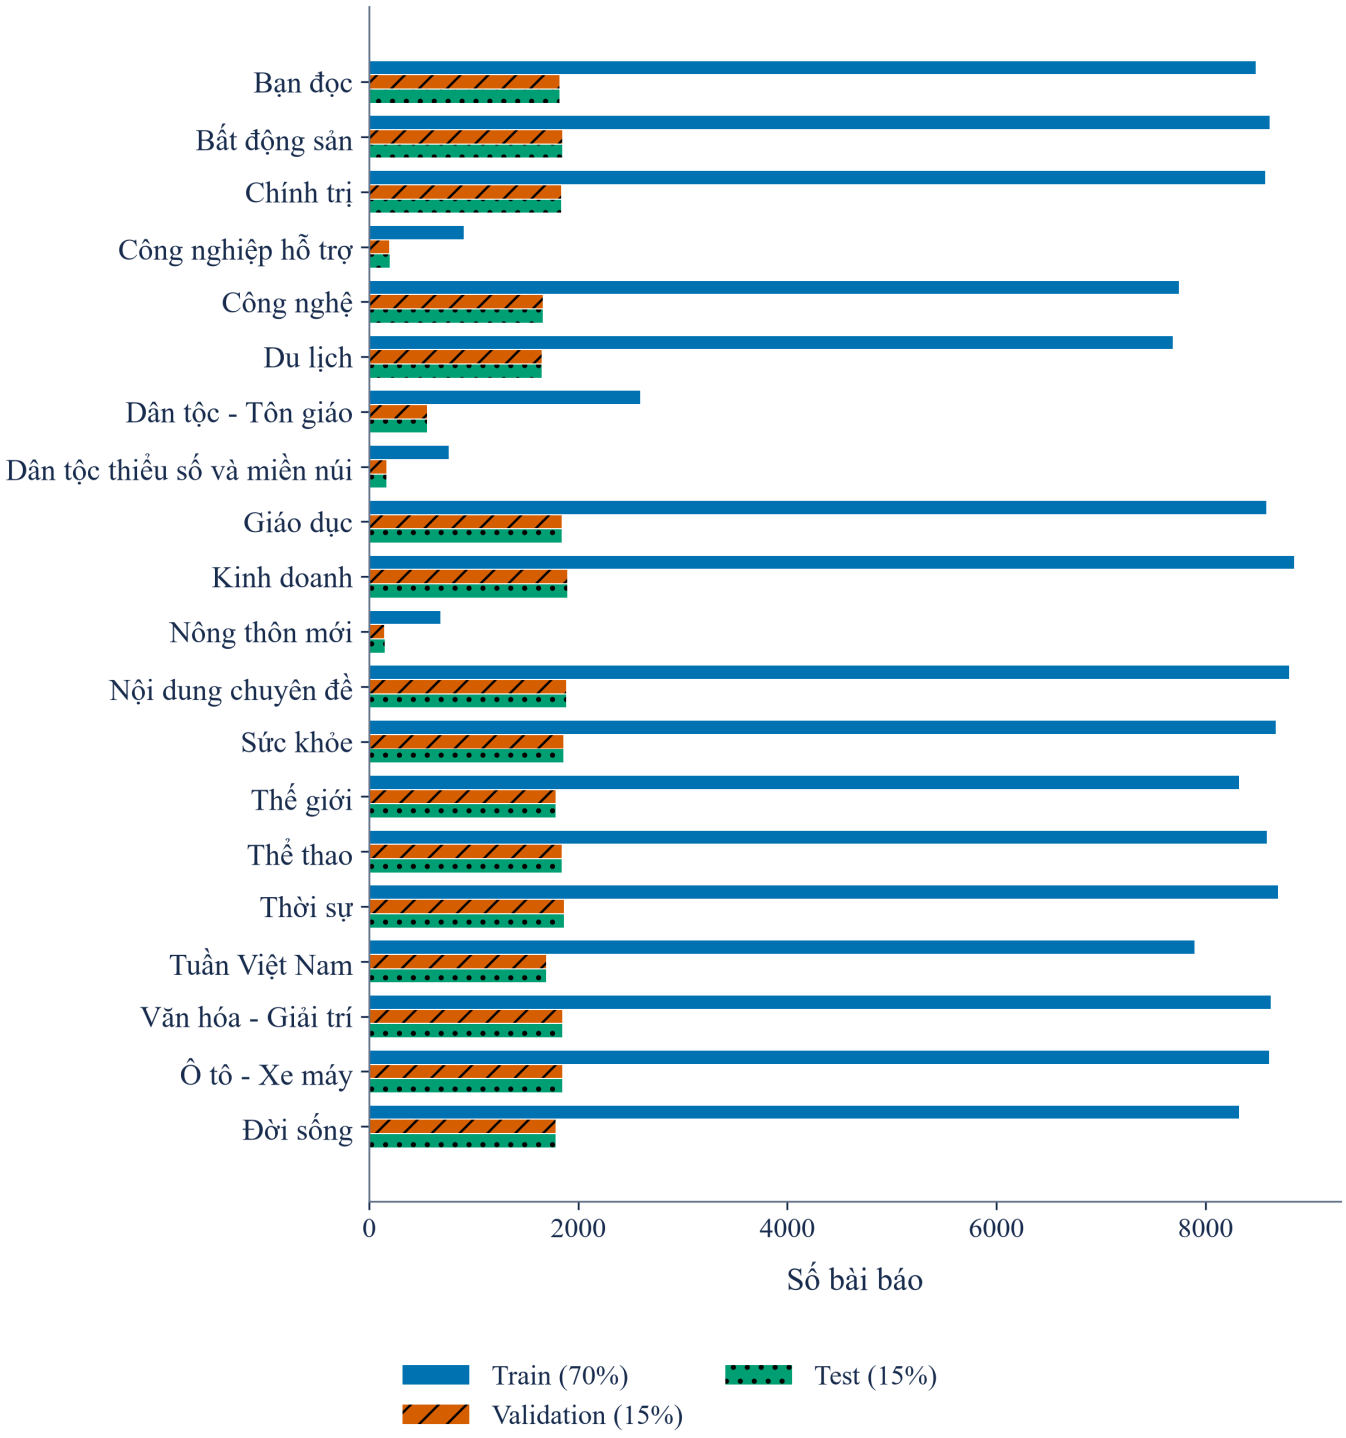
Evaluation loss của WeightedTrainer dùng hàm mất mát có trọng số; NLL ở calibration là trung bình log xác suất không trọng số. Hai đại lượng có đơn vị log-loss nhưng khác cách tính, nên không trực tiếp đồng nhất trị số.

Bảng 4.1: Trọng số balanced tính từ số mẫu train.

ID	Chuyên mục	Train	Trọng số
0	Bạn đọc	8.483	0,8250
1	Bất động sản	8.616	0,8123
2	Chính trị	8.569	0,8168
3	Công nghiệp hỗ trợ	905	7,7334
4	Công nghệ	7.743	0,9039
5	Du lịch	7.685	0,9107
6	Dân tộc - Tôn giáo	2.590	2,7022
7	Dân tộc thiểu số và miền núi	762	9,1847
8	Giáo dục	8.581	0,8156
9	Kinh doanh	8.850	0,7908
10	Nông thôn mới	678	10,3226
11	Nội dung chuyên đề	8.798	0,7955
12	Sức khỏe	8.670	0,8072
13	Thế giới	8.322	0,8410
14	Thể thao	8.587	0,8150
15	Thời sự	8.694	0,8050
16	Tuần Việt Nam	7.893	0,8867
17	Văn hóa - Giải trí	8.622	0,8117
18	Ô tô - Xe máy	8.609	0,8130
19	Đời sống	8.318	0,8414



Hình 4.1: Trọng số loss của 20 lớp; ID được đối chiếu với bảng taxonomy.



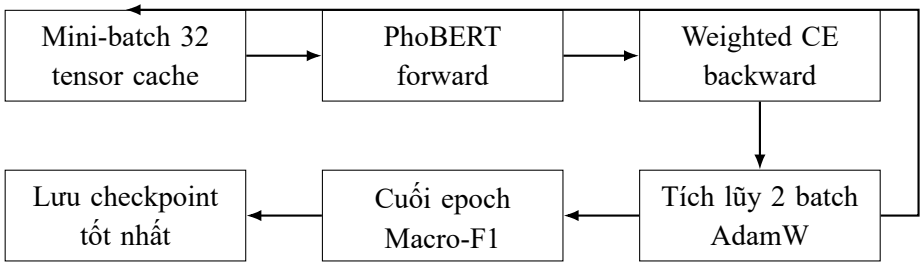
Hình 4.2: Số mẫu train, validation và test theo từng lớp sau khử trùng.

4.4 Optimizer và siêu tham số

Bảng 4.2: Cấu hình thực thi fine-tuning trên máy local.

Thuộc tính	Giá trị
GPU	RTX A3000 Laptop, 12 GB
Backbone / đầu vào	PhoBERT-base-v2 / Head–Tail 256
Train batch / tích lũy	32 / 2
Effective batch / eval batch	64 / 64
Epoch tối đa	7
Learning rate cực đại	2×10^{-5}
Weight decay / warmup	0,01 / 200 bước
Optimizer	AdamW fused
Mixed precision / TF32	BF16 / bật
Evaluation và checkpoint	Cuối mỗi epoch
Tiêu chí best checkpoint	Macro-F1 validation
Early stopping	Patience 2; ngưỡng 0,001
Logging / dataloader workers	100 bước / 0
Gradient checkpointing / compile	Tắt / tắt

AdamW tách weight decay khỏi cập nhật thích nghi [4]. Scheduler tăng learning rate trong 200 bước warmup và giảm theo tiến độ. Số mini-batch mỗi epoch là $\lceil 139\,975/32 \rceil = 4\,375$; tích lũy hai batch tạo 2.188 bước cập nhật. Bảy epoch có 15.316 bước. Batch cuối không nhất thiết đủ 64 mẫu.



Hình 4.3: Huấn luyện có tích lũy gradient và chọn checkpoint theo Macro-F1.

BF16 và TF32 là cấu hình tính toán; checkpoint không phải toàn bộ được lưu dưới dạng BF16. Bộ nhớ GPU allocated cực đại trong metadata là 5,39 GiB, reserved khoảng 5,72 GiB. Phân đoạn 200.337 bài dùng bốn tiến trình trong 362 giây; mã hóa ba tập mất khoảng 191, 40 và 41 giây. Các số này thuộc lần thực thi cụ thể, không là cam kết thời gian trên mọi máy.

4.5 Checkpoint và early stopping

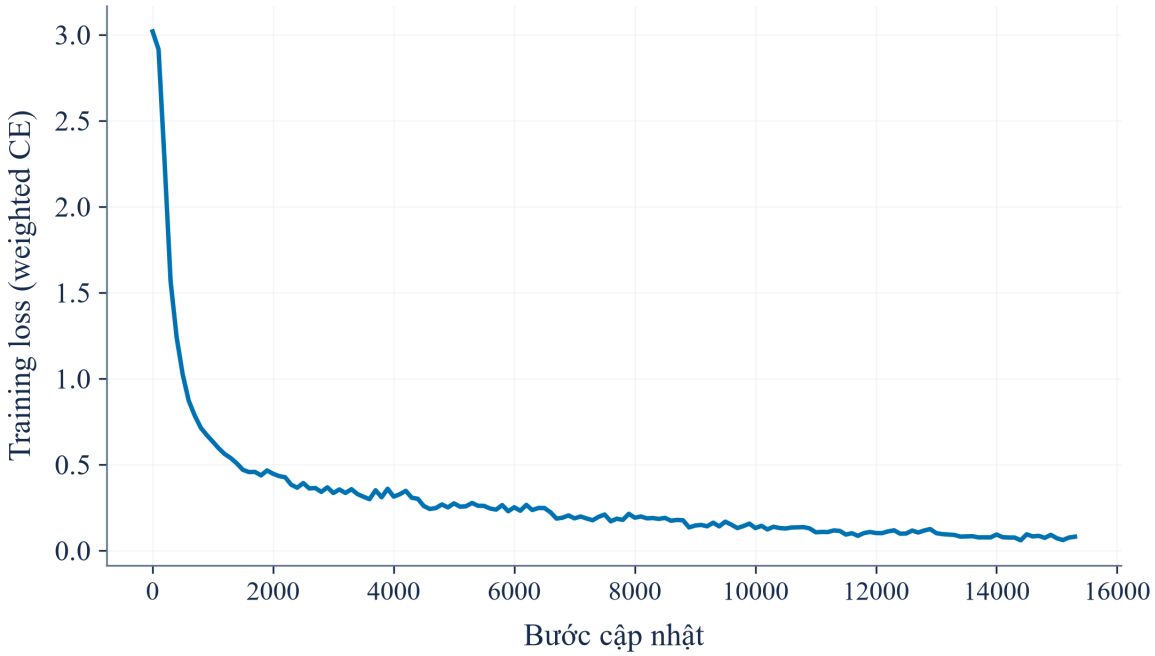
Trainer đánh giá, lưu và chọn theo Macro-F1 validation; load_best_model_at_end nạp trọng số tốt nhất. Early stopping có patience 2 và cải thiện tối thiểu 0,001. Lần thực nghiệm

chạy đủ bảy epoch; không được mô tả như đã dừng sớm trước giới hạn.

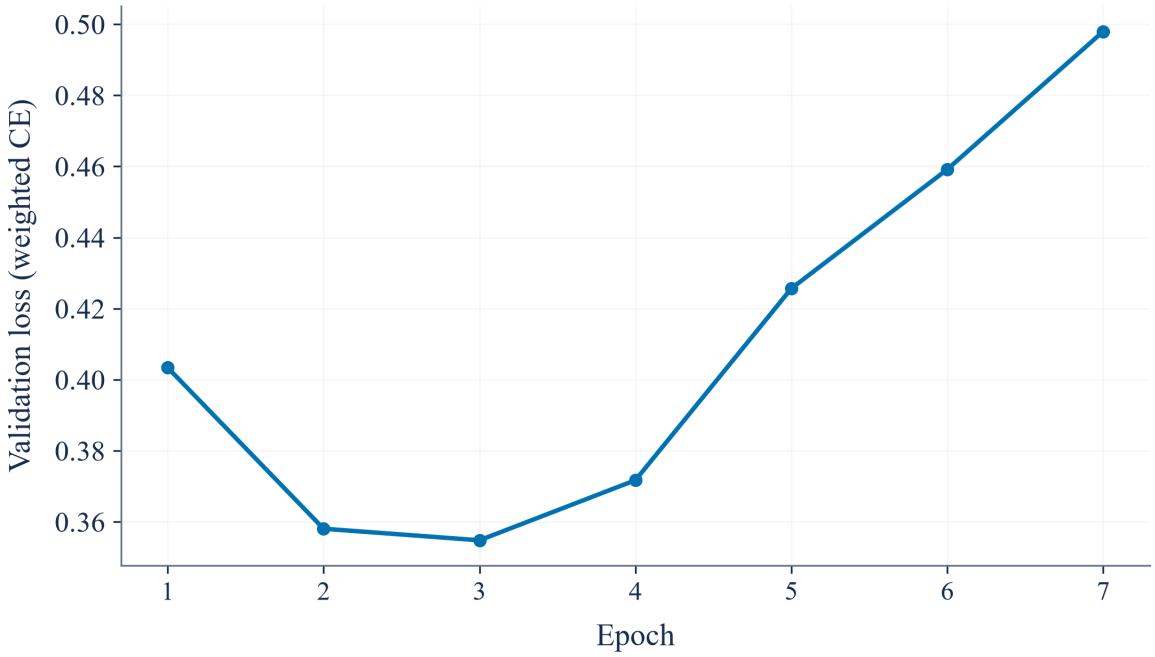
Macro-F1 validation cao nhất là 0,87229785 ở epoch 7. Loss validation thấp nhất ở epoch 3 là 0,3548, sau đó tăng đến 0,4980 ở epoch 7. F1 cao hơn nhưng loss tăng là tín hiệu cần xem xét sự tự tin ở các mẫu sai; hai tiêu chí có thể chọn epoch khác nhau. Tiêu chí được xác định trước là Macro-F1, không đổi sang loss sau khi xem test.

Bảng 4.3: Bảy lần đánh giá cuối epoch trên validation.

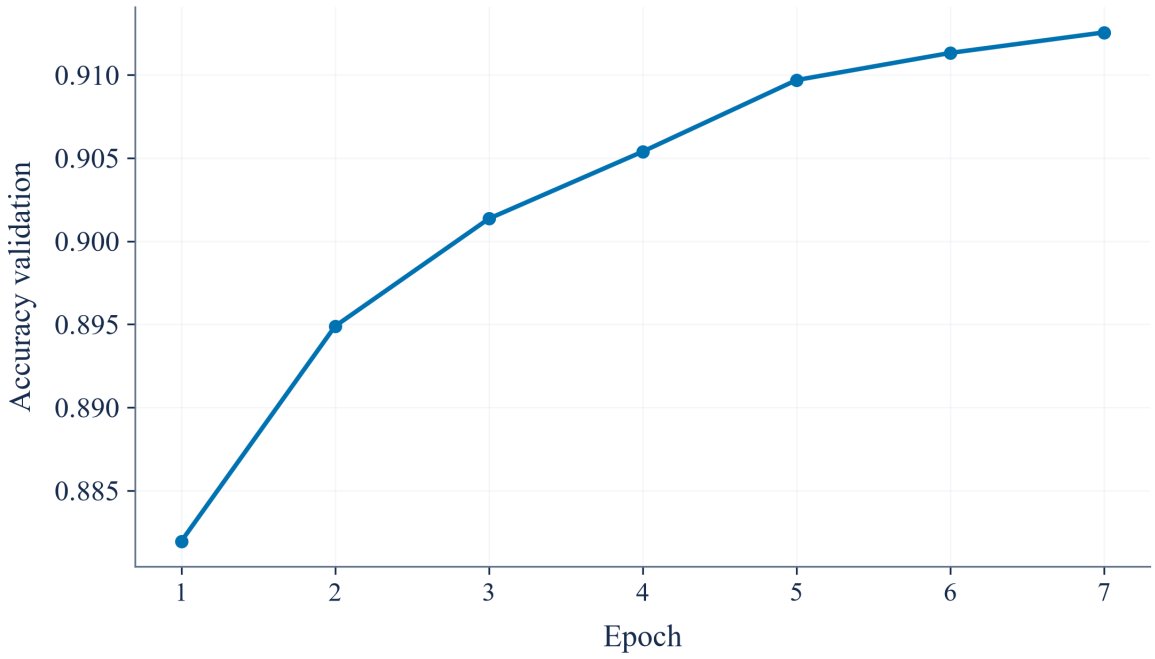
Epoch	Bước	Val loss	Val Accuracy	Val Weighted-F1	Val Macro-F1
1	2.188	0,4034	0,8819	0,8832	0,8343
2	4.376	0,3581	0,8949	0,8967	0,8538
3	6.564	0,3548	0,9014	0,9031	0,8597
4	8.752	0,3717	0,9054	0,9067	0,8660
5	10.940	0,4257	0,9097	0,9104	0,8718
6	13.128	0,4592	0,9113	0,9119	0,8708
7	15.316	0,4980	0,9126	0,9130	0,8723



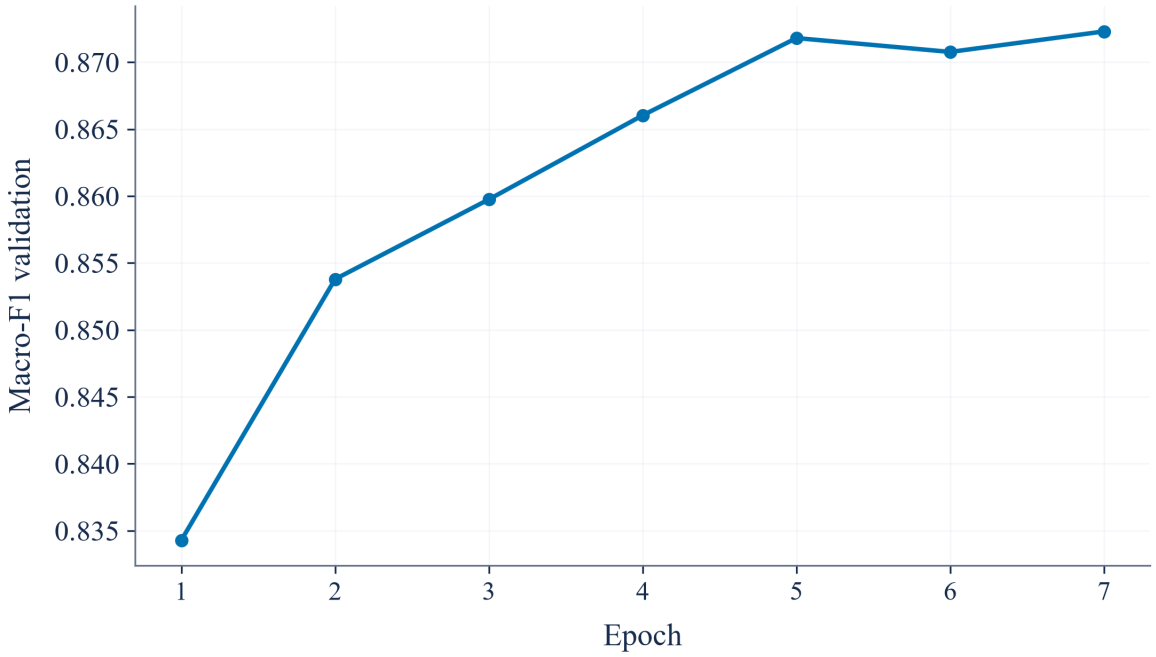
Hình 4.4: Loss train được ghi theo bước cập nhật.



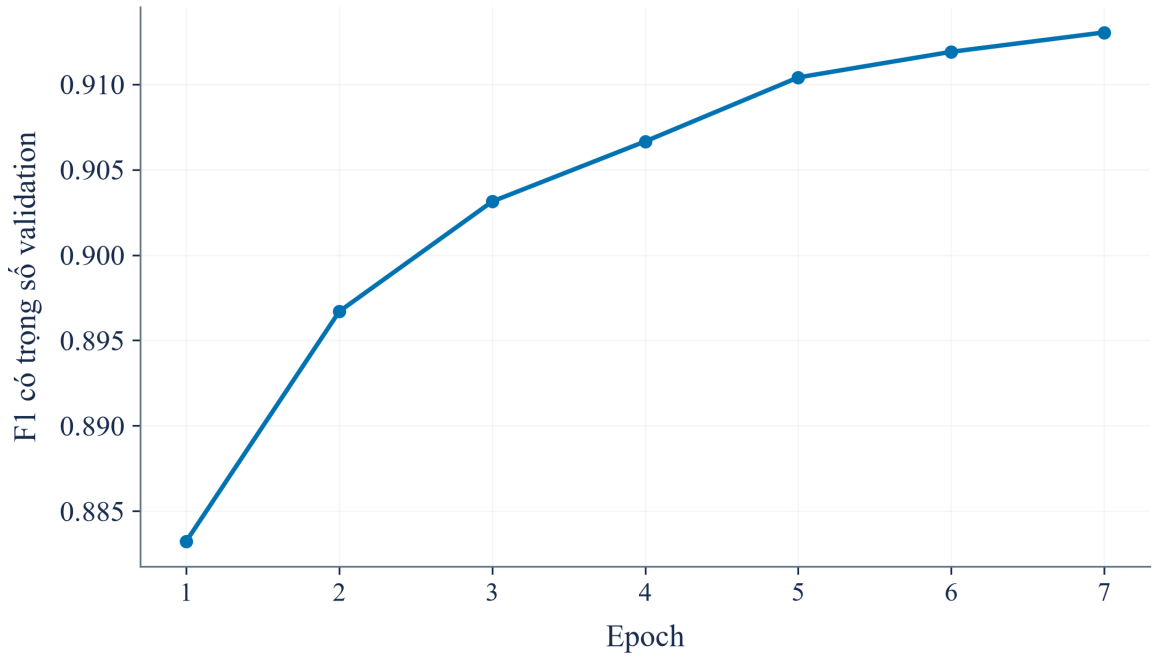
Hình 4.5: Loss validation theo epoch; thấp nhất tại epoch 3.



Hình 4.6: Accuracy validation qua bảy epoch.



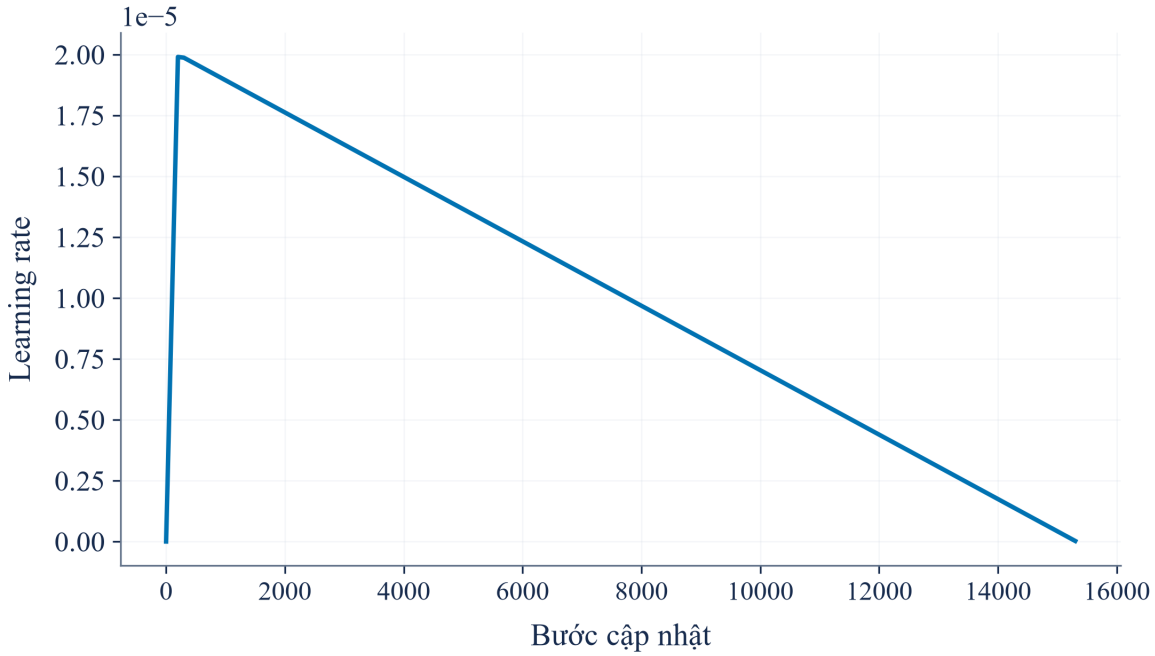
Hình 4.7: Macro-F1 validation dùng chọn checkpoint.



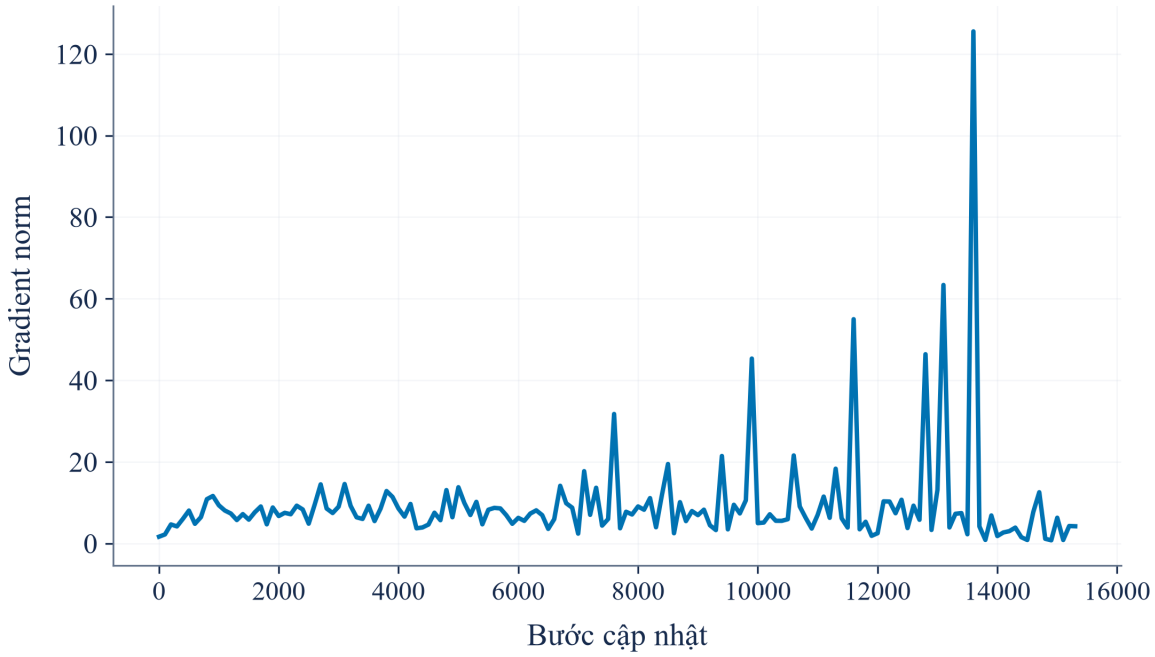
Hình 4.8: Weighted-F1 validation, bổ sung góc nhìn theo support.



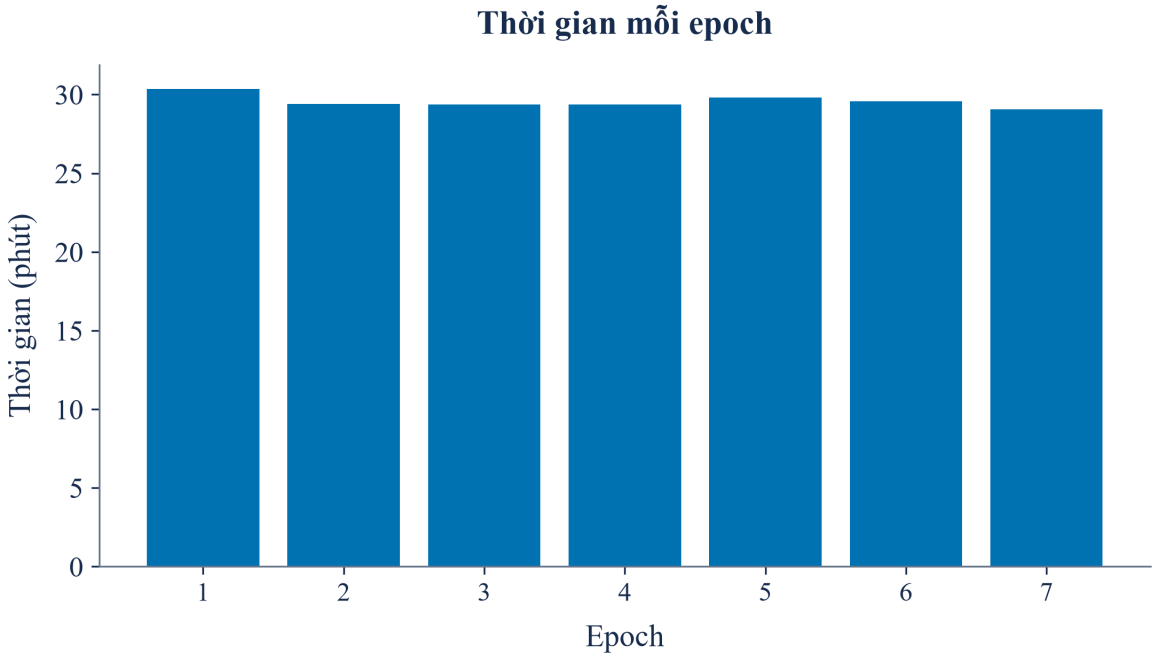
Hình 4.9: Loss train và validation trong một biểu đồ độc lập; cách tổng hợp cần được phân biệt.



Hình 4.10: Learning rate của optimizer, gồm warmup và giai đoạn giảm.



Hình 4.11: Gradient norm tại những bước có log; không trực tiếp giải thích nhãn của một bài.



Hình 4.12: Thời gian mỗi epoch bao gồm huấn luyện và kiểm định.

Tổng thời gian fine-tuning là 12.429,91 giây, khoảng 207,17 phút. Dự đoán test theo batch 64 mất 106,32 giây, khoảng 282,11 mẫu/giây, không bao gồm nạp model. Throughput GPU theo batch không đồng nghĩa độ trễ một yêu cầu HTTP/gRPC chạy CPU trong Docker.

4.6 Chế độ thực thi và lịch sử

fresh là mặc định, khởi tạo từ backbone và optimizer/scheduler mới. continue nạp trọng số khi dữ liệu, mapping, tiền xử lý và fingerprint ba tập tương thích; optimizer/scheduler khởi tạo mới, không khôi phục bước đang chạy dở. Model đầu vào được giữ nếu lượt fine-tuning không cải thiện Macro-F1 validation. evaluate chỉ đánh giá gói tương thích.

Lịch sử continue nối các record với offset epoch và bước, nên bảy epoch nối thêm bảy epoch có thể tạo đường học 14 epoch nếu không dừng trước. Lượt fresh tạo lịch sử của lượt mới. Điều này khác resume checkpoint ở giữa một epoch. Lần thực nghiệm trong báo cáo là một lượt fresh bảy epoch; không cộng điểm của các lượt khác.

4.7 Temperature scaling trên validation

Với nhiệt độ $T > 0$,

$$p_c(T) = \frac{\exp(z_c/T)}{\sum_j \exp(z_j/T)}. \tag{4.3}$$

Temperature scaling hiệu chỉnh độ tập trung của xác suất [2]. Một nhiệt độ chung không đổi argmax. Notebook tìm T trong $[0,5; 5,0]$ bằng tối thiểu hóa NLL validation, giữ $T = 1$ nếu nghiệm không giảm NLL validation:

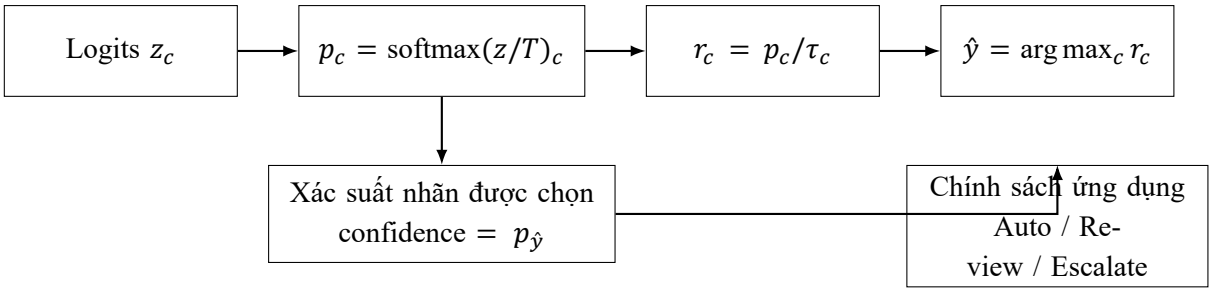
$$\mathrm{NLL}(T) = -\frac{1}{N}\sum_i \log(p_{i,y_i}(T) + 10^{-10}). \tag{4.4}$$

Nhiệt độ cố định dùng trên test là 1,45511457. Test không được dùng fit lại giá trị này. Khi $T > 1$, phân bố mềm hơn; nhãn argmax chuẩn không thay đổi.

4.8 Điều chỉnh quyết định theo lớp

Quy tắc quyết định là $r_c = p_c(T)/\tau_c$, $\hat{y} = \arg\max_c r_c$. Hệ số lớn giảm ưu tiên tương đối, hệ số nhỏ tăng ưu tiên. Đây không phải kiểm tra nhiều ngưỡng để xuất nhiều nhãn, và r_c không phải xác suất.

Tìm kiếm tọa độ khởi tạo 20 hệ số bằng 1, duyệt ba lượt; mỗi lớp thử 200 giá trị đều từ 0,3 đến 3,5. Giữ các hệ số khác, thử nhãn của toàn bộ validation và đánh giá **Macro-F1 của toàn bộ 20 lớp**; cập nhật nếu tăng hơn 10^{-5}. Tie được xử lý theo ID nhỏ hơn. Tìm kiếm này là tham lam theo từng tọa độ, không bảo đảm nghiệm tối ưu toàn cục và có thể phụ thuộc thứ tự lớp.



Hình 4.13: Hiệu chỉnh xác suất, chọn nhãn và định tuyến biên tập là các bước riêng.

4.9 Xác suất, điểm quyết định và định tuyến

Top-k xếp theo r_c, nhưng thanh xác suất hiển thị $p_c(T)$. Confidence là $p_{\hat{y}}(T)$ của nhãn cuối, có thể nhỏ hơn xác suất cực đại. Margin là chênh lệch hai điểm lớn nhất trong $q_c = r_c / \sum_j r_j$; q không được chứng minh là xác suất đúng. Top-k không đổi nhãn hoặc margin vì chúng tính trên toàn bộ 20 lớp.

Ngưỡng nghiệp vụ mặc định auto-approve 0,75 và review floor 0,68 dùng confidence: đạt 0,75 chuyển auto; từ 0,68 đến dưới 0,75 chuyển review; dưới 0,68 chuyển escalate. Hai ngưỡng này khác 20 hệ số τ_c và không sửa trọng số model. ECE trong notebook dùng confidence cực đại cùng argmax chuẩn của $p(T)$; không phải ECE của q hay của quyết định cuối sau hệ số.

5. Kết quả và phân tích lỗi

5.1 Nguồn bằng chứng và giao thức đo

Notebook xuất logits, dự đoán, ma trận, history và metadata cho validation/test. Các số trong chương này dùng 29.995 mẫu test độc lập sau khi tham số chọn trên validation đã cố định. Sáu chỉ số trước/sau trong metrics khớp output notebook; nhãn dự đoán, support và ma trận được tái tính từ logits. Không chạy fine-tuning bổ sung để tạo số cho báo cáo.

Hàng ma trận là nhãn tham chiếu, cột là nhãn dự đoán; tổng hàng bằng support lớp và tổng ma trận bằng 29.995. Metadata liên kết test position với article index và URL của bài. Đây là điều kiện để phân tích lỗi từ bài thật, thay vì xây ví dụ rồi tự gán xác suất.

5.2 Định nghĩa chỉ số

Với lớp c, TP_c, FP_c, FN_c là đúng dương, sai dương và sai âm:

$$P_c = \frac{TP_c}{TP_c + FP_c}, \quad R_c = \frac{TP_c}{TP_c + FN_c}, \quad F1_c = \frac{2TP_c}{2TP_c + FP_c + FN_c}. \tag{5.1}$$

Mẫu số bằng không nhận giá trị 0. Accuracy là tỷ lệ đúng toàn bộ mẫu; Macro-F1 là $\frac{1}{20}\sum_c F1_c$ và Weighted-F1 là $\sum_c (n_c/N)F1_c$. Trong phân loại đơn nhãn với đầy đủ lớp, micro-F1 bằng Accuracy; báo cáo ưu tiên các chỉ số cung cấp thêm thông tin về mất cân bằng.

5.3 Kết quả tổng thể

Bảng 5.1: Chỉ số test trước và sau hiệu chỉnh fit trên validation. Chênh lệch là giá trị sau trừ trước.

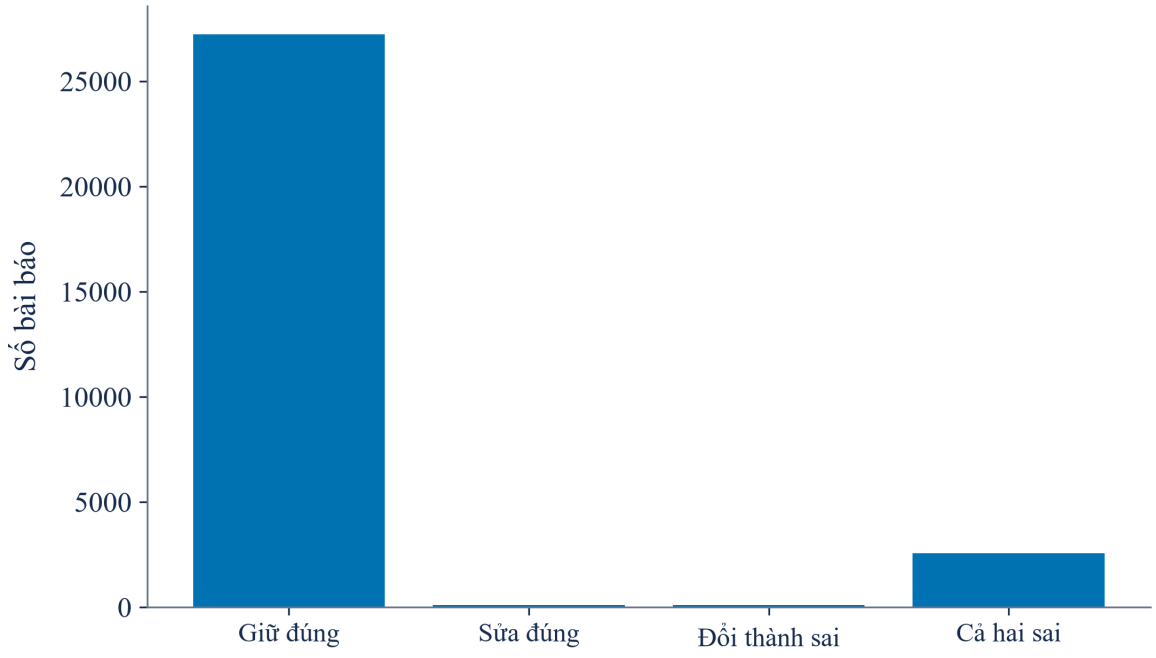
Chỉ số	Trước	Sau	Chênh lệch
Accuracy	0,910818	0,911252	0,000433
Weighted-F1	0,911176	0,911450	0,000273
Macro-F1	0,872191	0,872529	0,000337

Accuracy từ 91,0818% lên 91,1252%, tăng 0,0433 điểm phần trăm. Macro-F1 từ 0,872191 lên 0,872529, tăng 0,0337 điểm phần trăm; Weighted-F1 từ 0,911176 lên 0,911450. Đây là mức tăng nhỏ, không thể diễn đạt như cải thiện mạnh chất lượng phân loại. Macro-F1 thấp hơn Weighted-F1 khoảng 3,89 điểm phần trăm sau hiệu chỉnh, cho thấy cần xem kỹ các lớp nhỏ hoặc khó.

Có 27.333 bài đúng trước hiệu chỉnh và 27.346 bài đúng sau hiệu chỉnh; số lỗi giảm từ 2.662 xuống 2.649. Hiệu chỉnh sửa đúng 112 bài nhưng đổi thành sai 99 bài, giảm ròng 13 lỗi. Nhóm cả hai sai gồm 2.563 bài, có thể giữ nhãn sai hoặc đổi giữa hai nhãn sai.

Bảng 5.2: Chuyển đổi đúng/sai trên cùng 29.995 mẫu.

Trạng thái	Số bài
Giữ đúng	27.221
Sửa đúng	112
Đổi thành sai	99
Cả hai sai	2.563



Hình 5.1: Các nhóm quyết định giữ đúng, sửa đúng, đổi sai và cả hai sai.

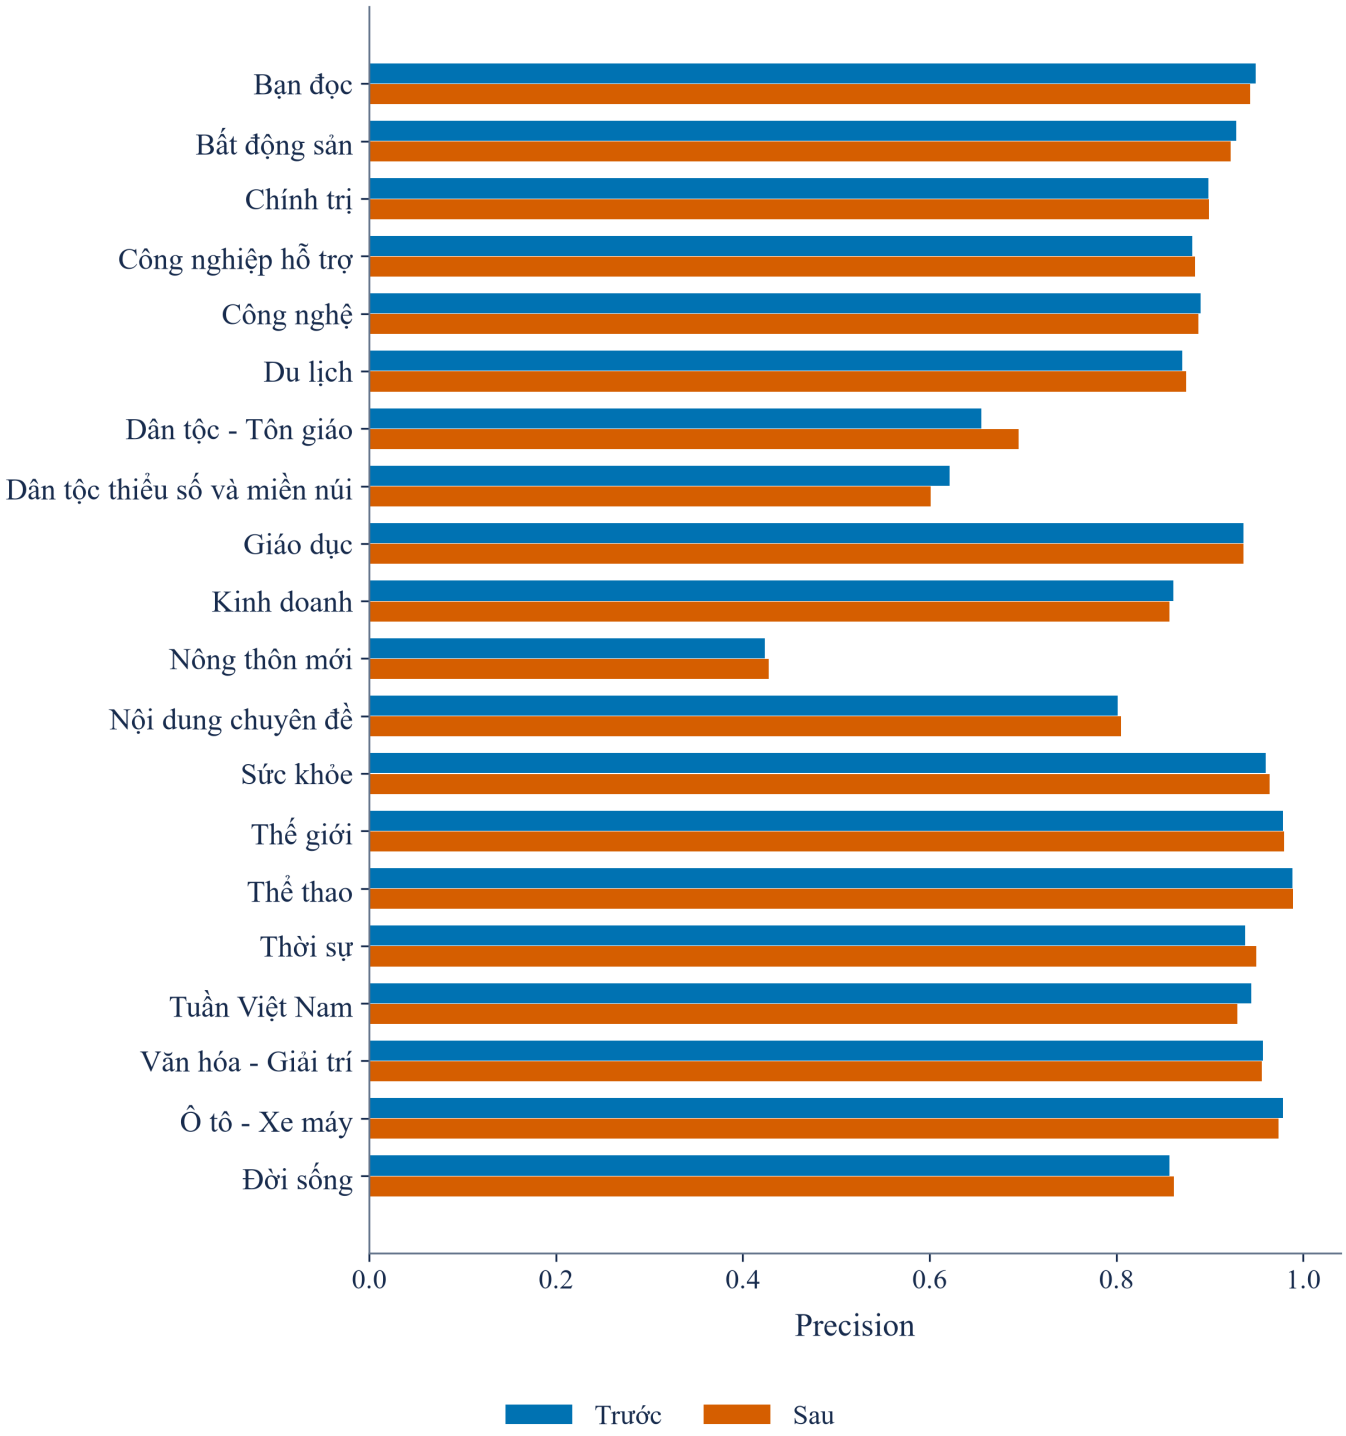
5.4 Chất lượng theo từng chuyên mục

Bảng 5.3: Precision, recall, F1 và support trước hiệu chỉnh.

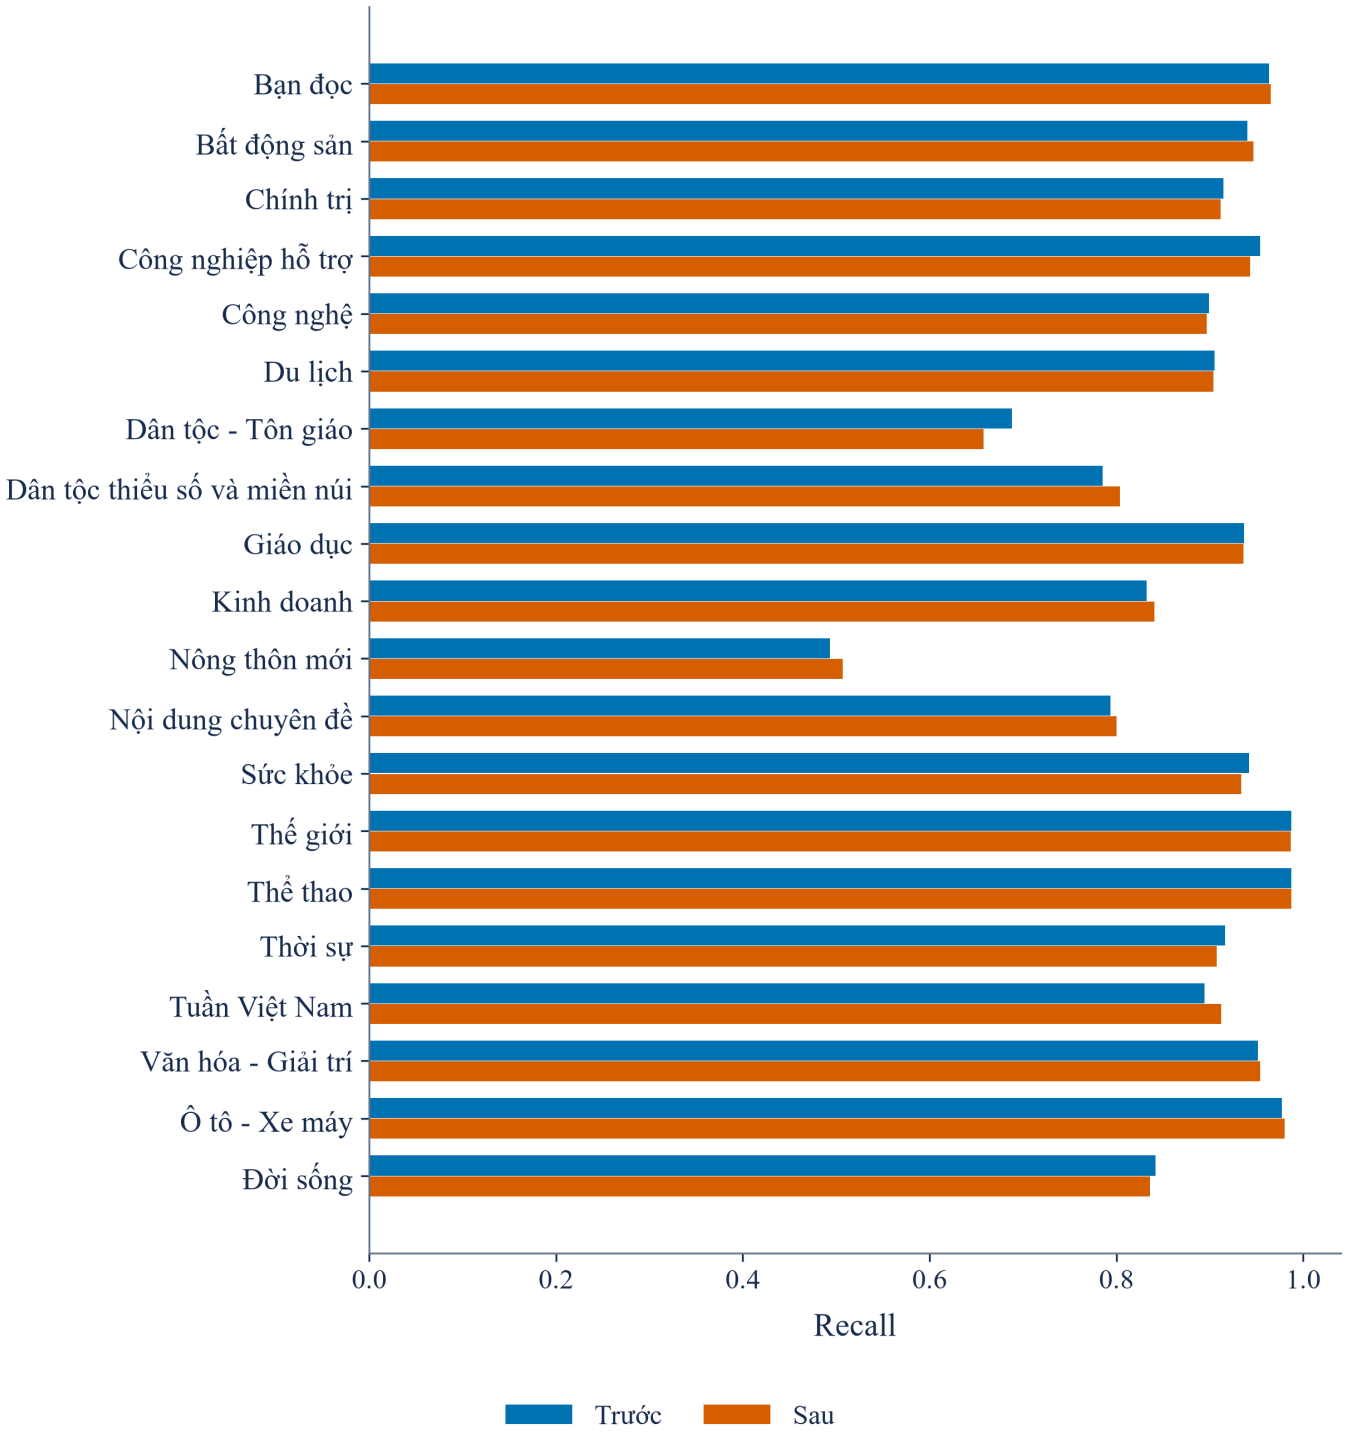
ID	Chuyên mục	Precision	Recall	F1	Support
0	Bạn đọc	0,9491	0,9637	0,9563	1.818
1	Bất động sản	0,9283	0,9404	0,9343	1.846
2	Chính trị	0,8983	0,9145	0,9063	1.836
3	Công nghiệp hỗ trợ	0,8810	0,9536	0,9158	194
4	Công nghệ	0,8902	0,8993	0,8948	1.659
5	Du lịch	0,8704	0,9053	0,8875	1.647
6	Dân tộc - Tôn giáo	0,6552	0,6883	0,6714	555
7	Dân tộc thiểu số và miền núi	0,6214	0,7853	0,6938	163
8	Giáo dục	0,9359	0,9364	0,9361	1.839
9	Kinh doanh	0,8610	0,8324	0,8464	1.897
10	Nông thôn mới	0,4235	0,4932	0,4557	146
11	Nội dung chuyên đề	0,8013	0,7936	0,7974	1.885
12	Sức khỏe	0,9599	0,9418	0,9508	1.857
13	Thế giới	0,9783	0,9871	0,9827	1.784
14	Thể thao	0,9886	0,9870	0,9878	1.840
15	Thời sự	0,9379	0,9163	0,9270	1.863
16	Tuần Việt Nam	0,9444	0,8941	0,9186	1.691
17	Văn hóa - Giải trí	0,9570	0,9513	0,9541	1.847
18	Ô tô - Xe máy	0,9783	0,9772	0,9778	1.845
19	Đời sống	0,8567	0,8418	0,8492	1.783

Bảng 5.4: Precision, recall, F1 và support sau hiệu chỉnh.

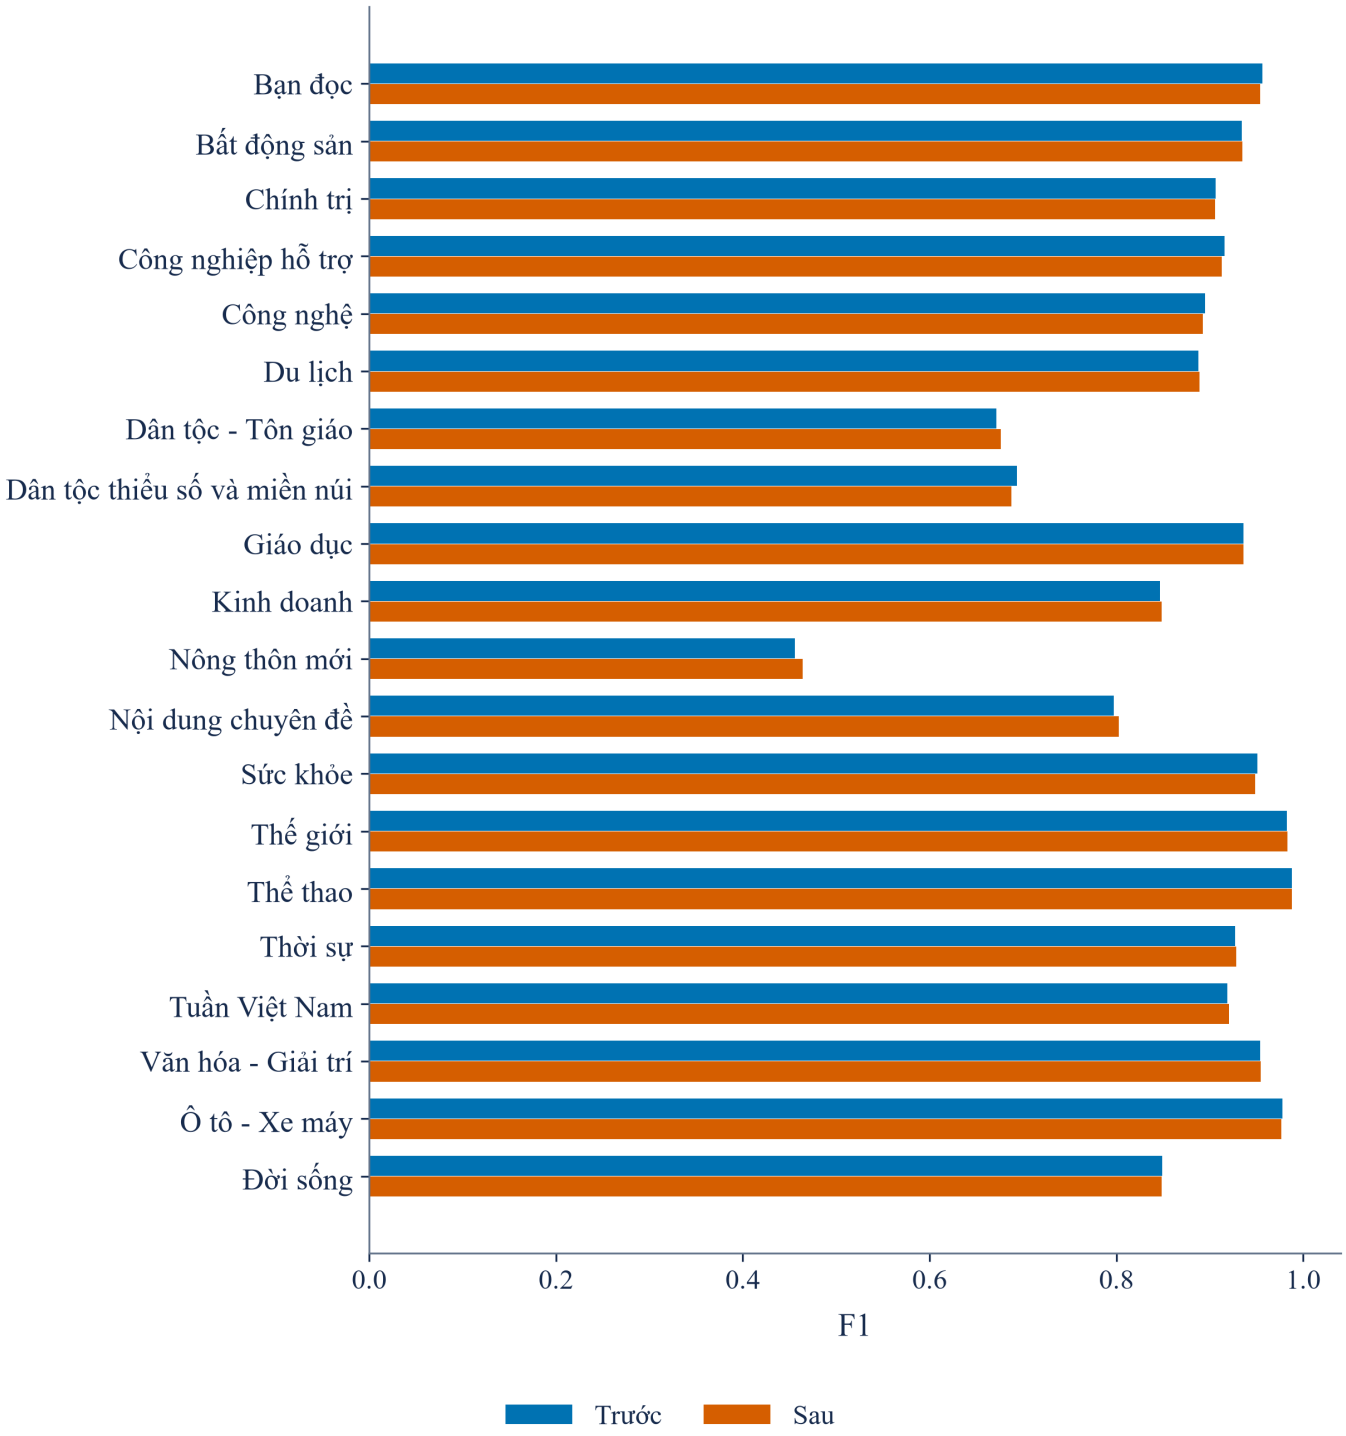
ID	Chuyên mục	Precision	Recall	F1	Support
0	Bạn đọc	0,9430	0,9653	0,9541	1.818
1	Bất động sản	0,9224	0,9469	0,9345	1.846
2	Chính trị	0,8990	0,9118	0,9054	1.836
3	Công nghiệp hỗ trợ	0,8841	0,9433	0,9127	194
4	Công nghệ	0,8878	0,8969	0,8924	1.659
5	Du lịch	0,8743	0,9041	0,8890	1.647
6	Dân tộc - Tôn giáo	0,6952	0,6577	0,6759	555
7	Dân tộc thiểu số và miền núi	0,6009	0,8037	0,6877	163
8	Giáo dục	0,9358	0,9358	0,9358	1.839
9	Kinh doanh	0,8566	0,8408	0,8486	1.897
10	Nông thôn mới	0,4277	0,5068	0,4639	146
11	Nội dung chuyên đề	0,8047	0,8000	0,8023	1.885
12	Sức khỏe	0,9639	0,9338	0,9486	1.857
13	Thế giới	0,9794	0,9865	0,9830	1.784
14	Thể thao	0,9891	0,9870	0,9880	1.840
15	Thời sự	0,9500	0,9071	0,9281	1.863
16	Tuần Việt Nam	0,9295	0,9119	0,9206	1.691
17	Văn hóa - Giải trí	0,9555	0,9540	0,9548	1.847
18	Ô tô - Xe máy	0,9736	0,9799	0,9768	1.845
19	Đời sống	0,8618	0,8357	0,8485	1.783



Hình 5.2: Precision trước/sau cho 20 lớp, trong một hình riêng.



Hình 5.3: Recall trước/sau, tách khỏi precision để đọc rõ.



Hình 5.4: F1 theo lớp, cho thấy khác biệt mà chỉ số tổng hợp che khuất.

5.4.1 Nông thôn mới

Lớp có 146 mẫu test, precision 0,4277, recall 0,5068 và F1 0,4639. Chỉ 74 bài được nhận đúng; 64 bài bị chuyển thành Nội dung chuyên đề, tương đương 43,84% support. Chiều ngược có 95 bài Nội dung chuyên đề bị chọn thành Nông thôn mới. Số bài lớp khác bị hút vào còn lớn hơn số bài lớp này nhận đúng; đây là hạn chế đáng kể nếu tự động điều phối lớp này.

Trọng số train 10,3226 giúp ưu tiên lỗi nhưng không giải quyết ranh giới giữa các bài về giảm nghèo, chính sách địa phương và phát triển nông thôn. Thông tin chuyên mục có thể nằm trong cấu trúc xuất bản hơn là một nhóm từ khóa riêng. Cần rà soát ranh giới nhãn và bổ sung mẫu phân biệt, thay vì chỉ tăng trọng số.

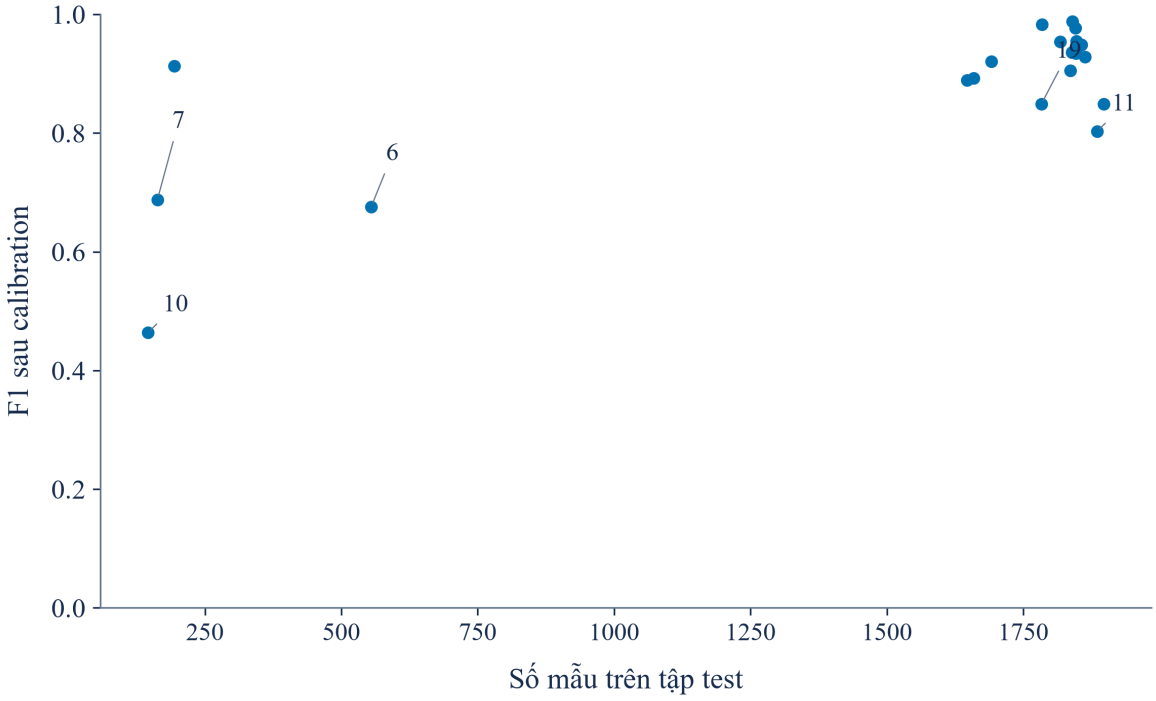
5.4.2 Dân tộc và các lớp gần nhau

Dân tộc – Tôn giáo có F1 0,6759, precision 0,6952 và recall 0,6577 trên 555 mẫu. Dân tộc thiểu số và miền núi có F1 0,6877, precision 0,6009 và recall 0,8037 trên 163 mẫu. Lớp thứ hai thu hồi được nhiều mẫu nhưng sai dương cao. Hiệu chỉnh làm F1 lớp này giảm 0,0061, dù Macro-F1 toàn cục tăng.

Tin về sinh kế, lễ hội và chính sách vùng dân tộc có thể giao thoa Nội dung chuyên đề, Văn hóa – Giải trí và Du lịch. Việc quy đúng class cha giúp sửa sai ở bước thu thập, nhưng không khiến ngữ nghĩa của các class hoàn toàn tách biệt. Những nhầm lẫn cần đọc cùng breadcrumb và nội dung; không mặc định mọi lỗi là do số mẫu ít.

5.4.3 Lớp có dấu hiệu chủ đề tập trung

Thể thao đạt F1 0,9880, Thế giới 0,9830 và Ô tô – Xe máy 0,9768. Công nghiệp hỗ trợ đạt 0,9127 dù chỉ có 194 mẫu test. Kết quả cho thấy số lượng không quyết định đơn độc độ khó. Từ vựng chuyên biệt, nội dung tập trung và quy ước gán nhãn có thể góp phần, nhưng cần ablation hoặc phân tích dữ liệu mới để khẳng định quan hệ nhân quả.



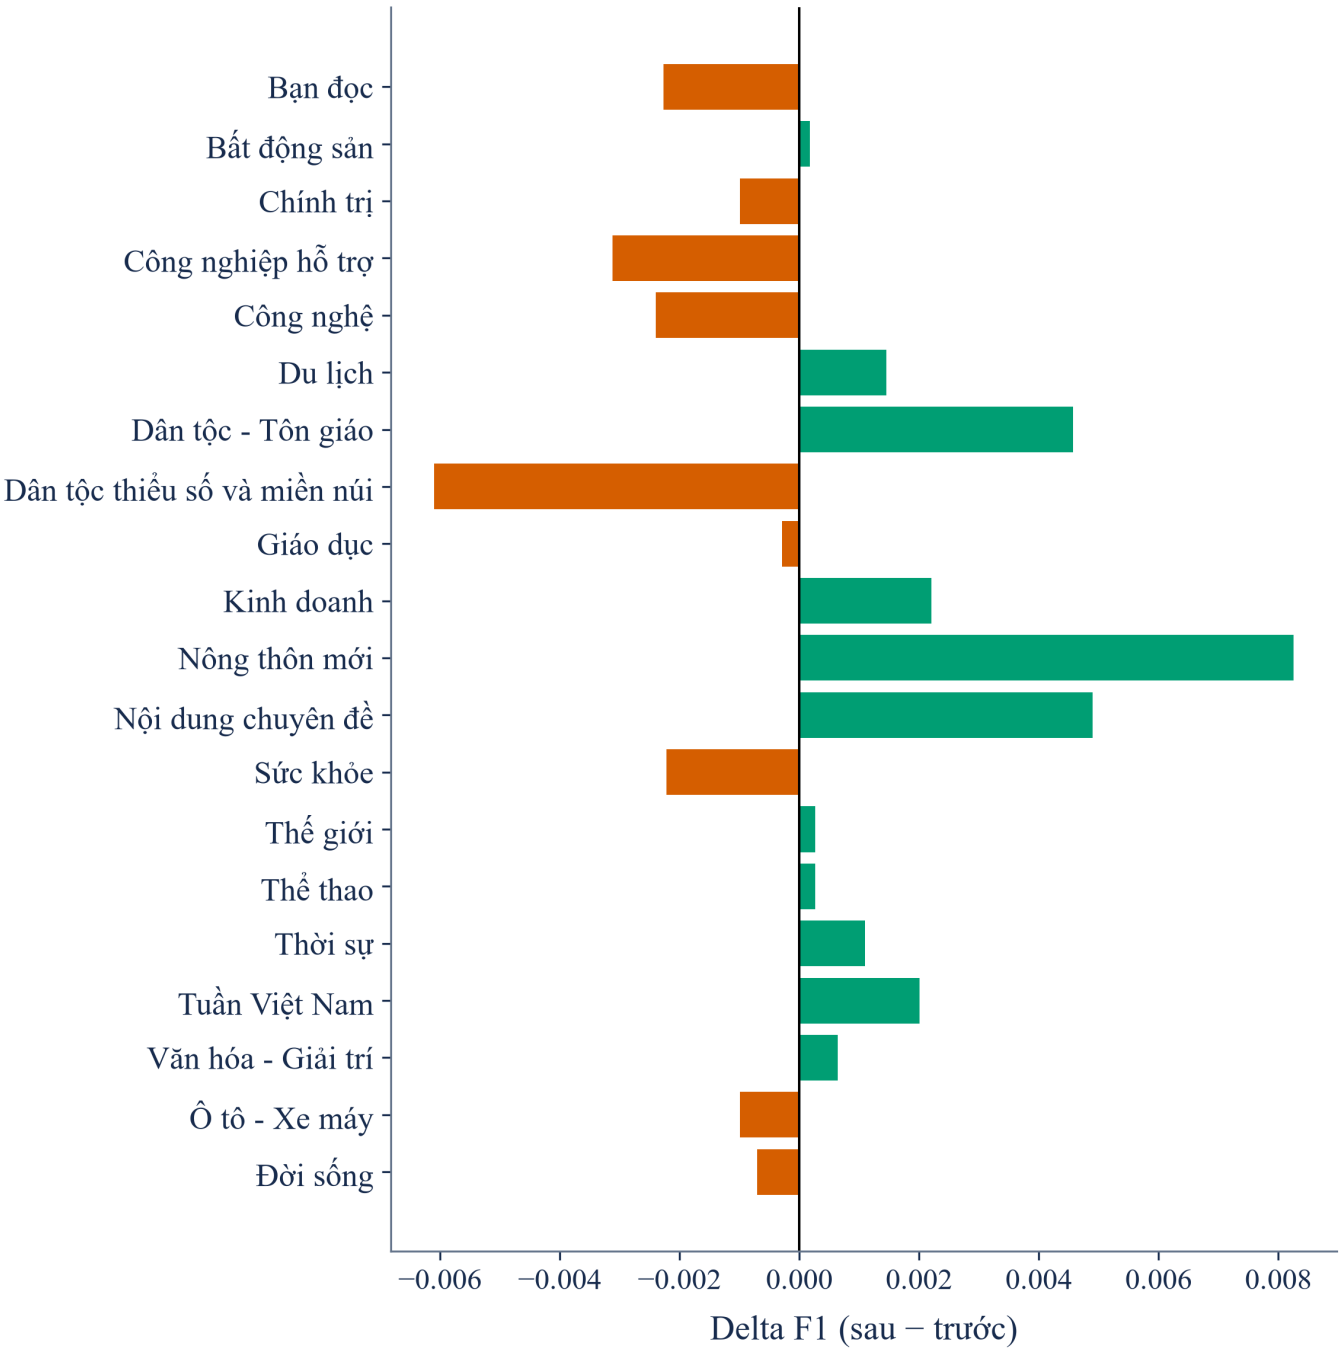
Hình 5.5: Support test và F1 từng lớp: tương quan quan sát không phải quan hệ nhân quả.

5.4.4 Ảnh hưởng không đồng đều của hiệu chỉnh

Nông thôn mới tăng F1 0,0083; Nội dung chuyên đề tăng 0,0049; Dân tộc – Tôn giáo tăng 0,0046. Dân tộc thiểu số và miền núi, Công nghiệp hỗ trợ, Công nghệ và một số lớp khác giảm. Tối ưu Macro-F1 validation không bảo đảm mọi lớp tăng trên test.

Bảng 5.5: Chênh lệch precision, recall và F1 theo lớp.

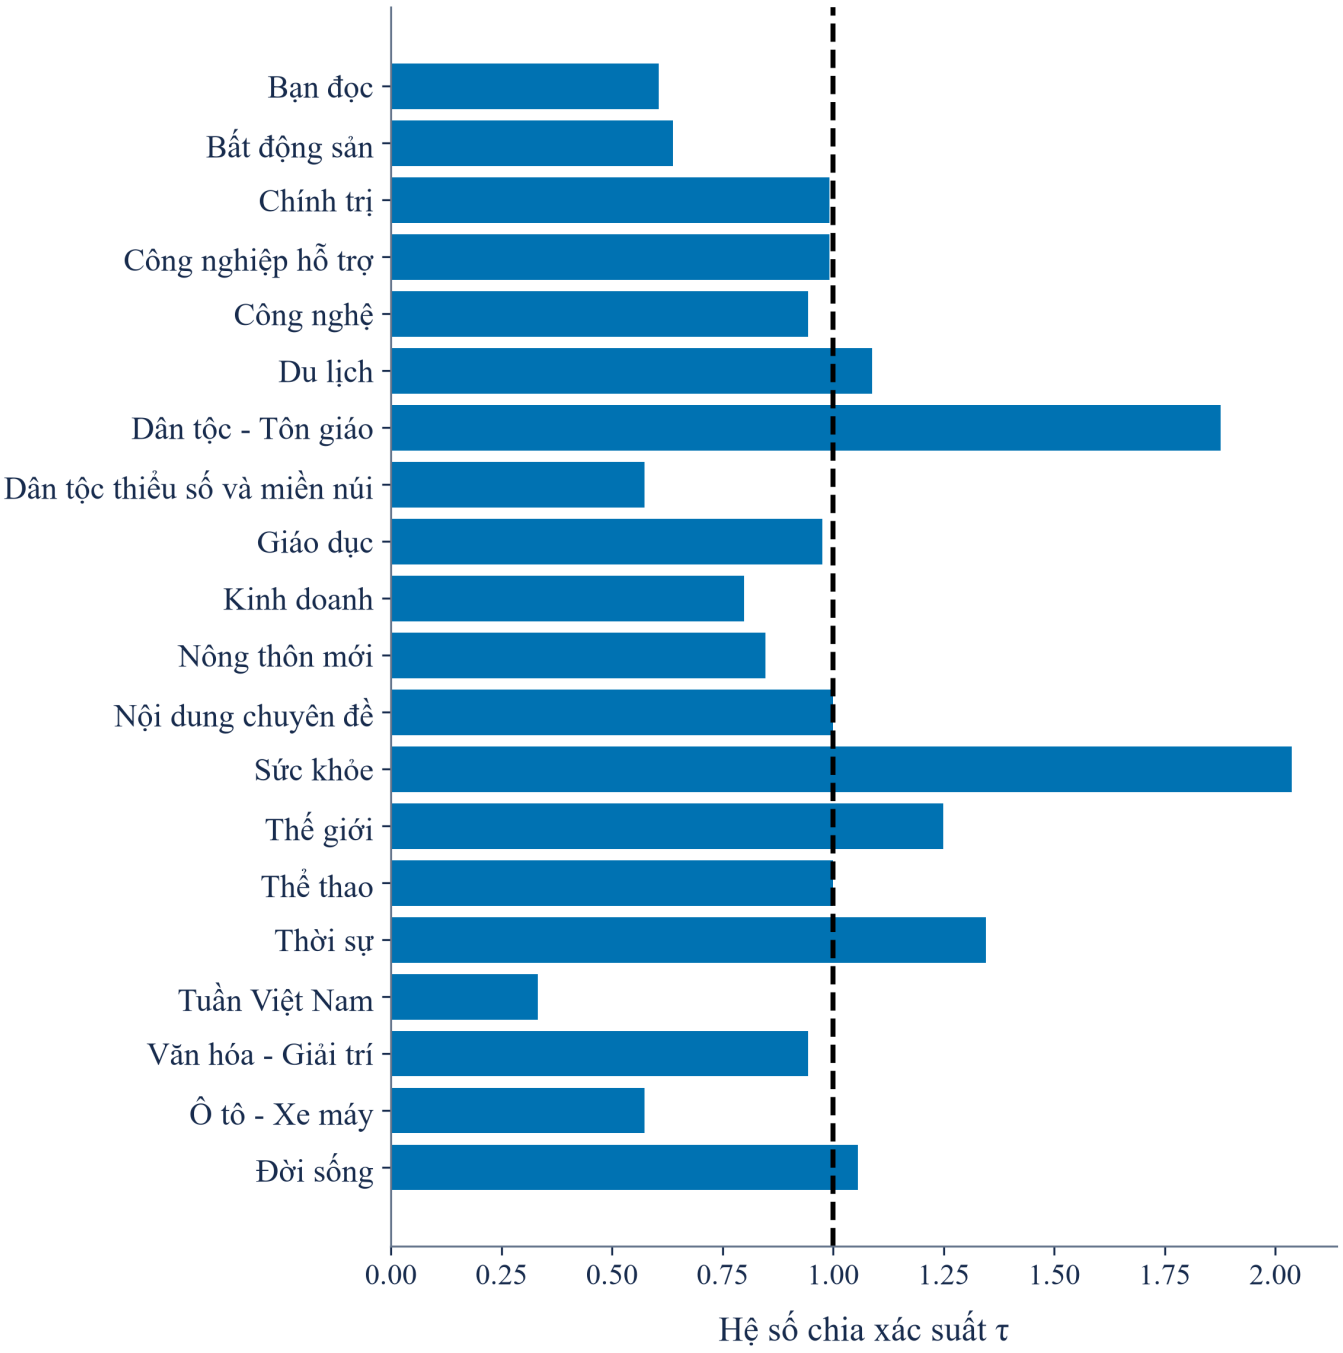
Chuyên mục	ΔP	ΔR	$\Delta F1$
Bạn đọc	-0,0060	0,0017	-0,0023
Bất động sản	-0,0059	0,0065	0,0002
Chính trị	0,0007	-0,0027	-0,0010
Công nghiệp hỗ trợ	0,0031	-0,0103	-0,0031
Công nghệ	-0,0024	-0,0024	-0,0024
Du lịch	0,0039	-0,0012	0,0015
Dân tộc - Tôn giáo	0,0400	-0,0306	0,0046
Dân tộc thiểu số và miền núi	-0,0204	0,0184	-0,0061
Giáo dục	-0,0000	-0,0005	-0,0003
Kinh doanh	-0,0044	0,0084	0,0022
Nông thôn mới	0,0042	0,0137	0,0083
Nội dung chuyên đề	0,0034	0,0064	0,0049
Sức khỏe	0,0039	-0,0081	-0,0022
Thế giới	0,0011	-0,0006	0,0003
Thể thao	0,0005	0,0000	0,0003
Thời sự	0,0121	-0,0091	0,0011
Tuần Việt Nam	-0,0149	0,0177	0,0020
Văn hóa - Giải trí	-0,0014	0,0027	0,0006
Ô tô - Xe máy	-0,0047	0,0027	-0,0010
Đời sống	0,0050	-0,0062	-0,0007



Hình 5.6: Mức tăng và giảm F1 của từng lớp, không cộng thành cam kết triển khai.

Bảng 5.6: Hai mươi hệ số chia xác suất dùng cố định khi suy luận.

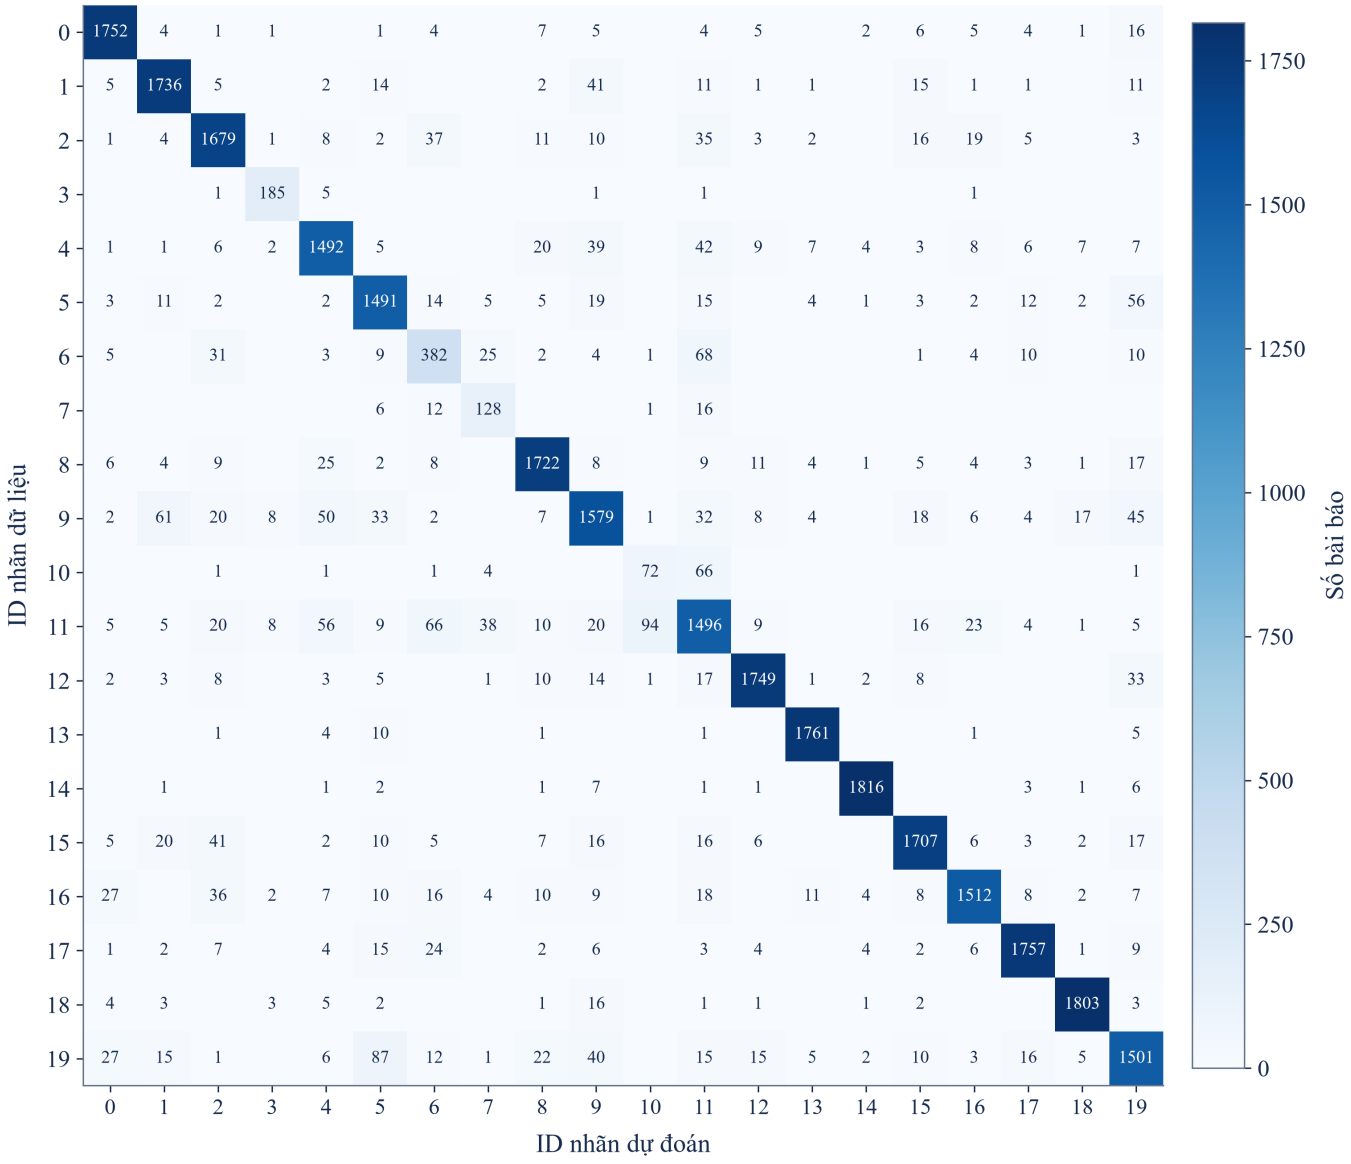
ID	Chuyên mục	τ_c
0	Bạn đọc	0,6055
1	Bất động sản	0,6377
2	Chính trị	0,9915
3	Công nghiệp hỗ trợ	0,9915
4	Công nghệ	0,9432
5	Du lịch	1,0879
6	Dân tộc - Tôn giáo	1,8759
7	Dân tộc thiểu số và miền núi	0,5734
8	Giáo dục	0,9754
9	Kinh doanh	0,7985
10	Nông thôn mới	0,8467
11	Nội dung chuyên đề	1,0000
12	Sức khỏe	2,0367
13	Thế giới	1,2487
14	Thể thao	1,0000
15	Thời sự	1,3452
16	Tuần Việt Nam	0,3322
17	Văn hóa - Giải trí	0,9432
18	Ô tô - Xe máy	0,5734
19	Đời sống	1,0558



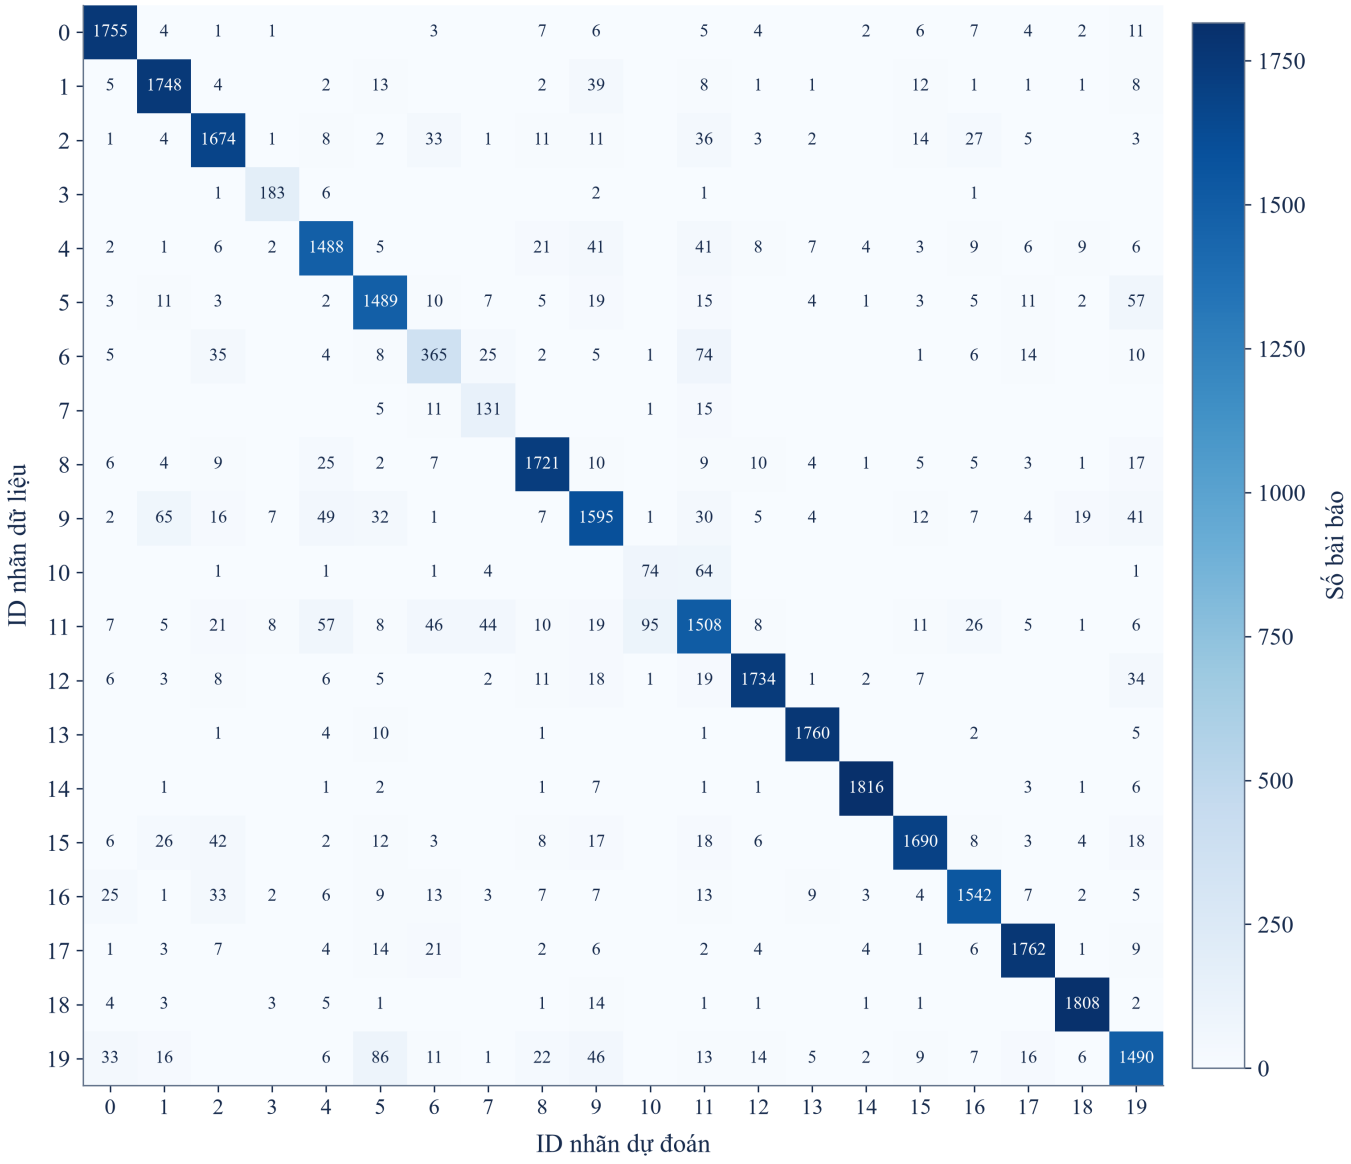
Hình 5.7: Hệ số lớp; đường 1 là mức không điều chỉnh ưu tiên tương đối.

5.5 Ma trận nhầm lẫn và hướng lỗi

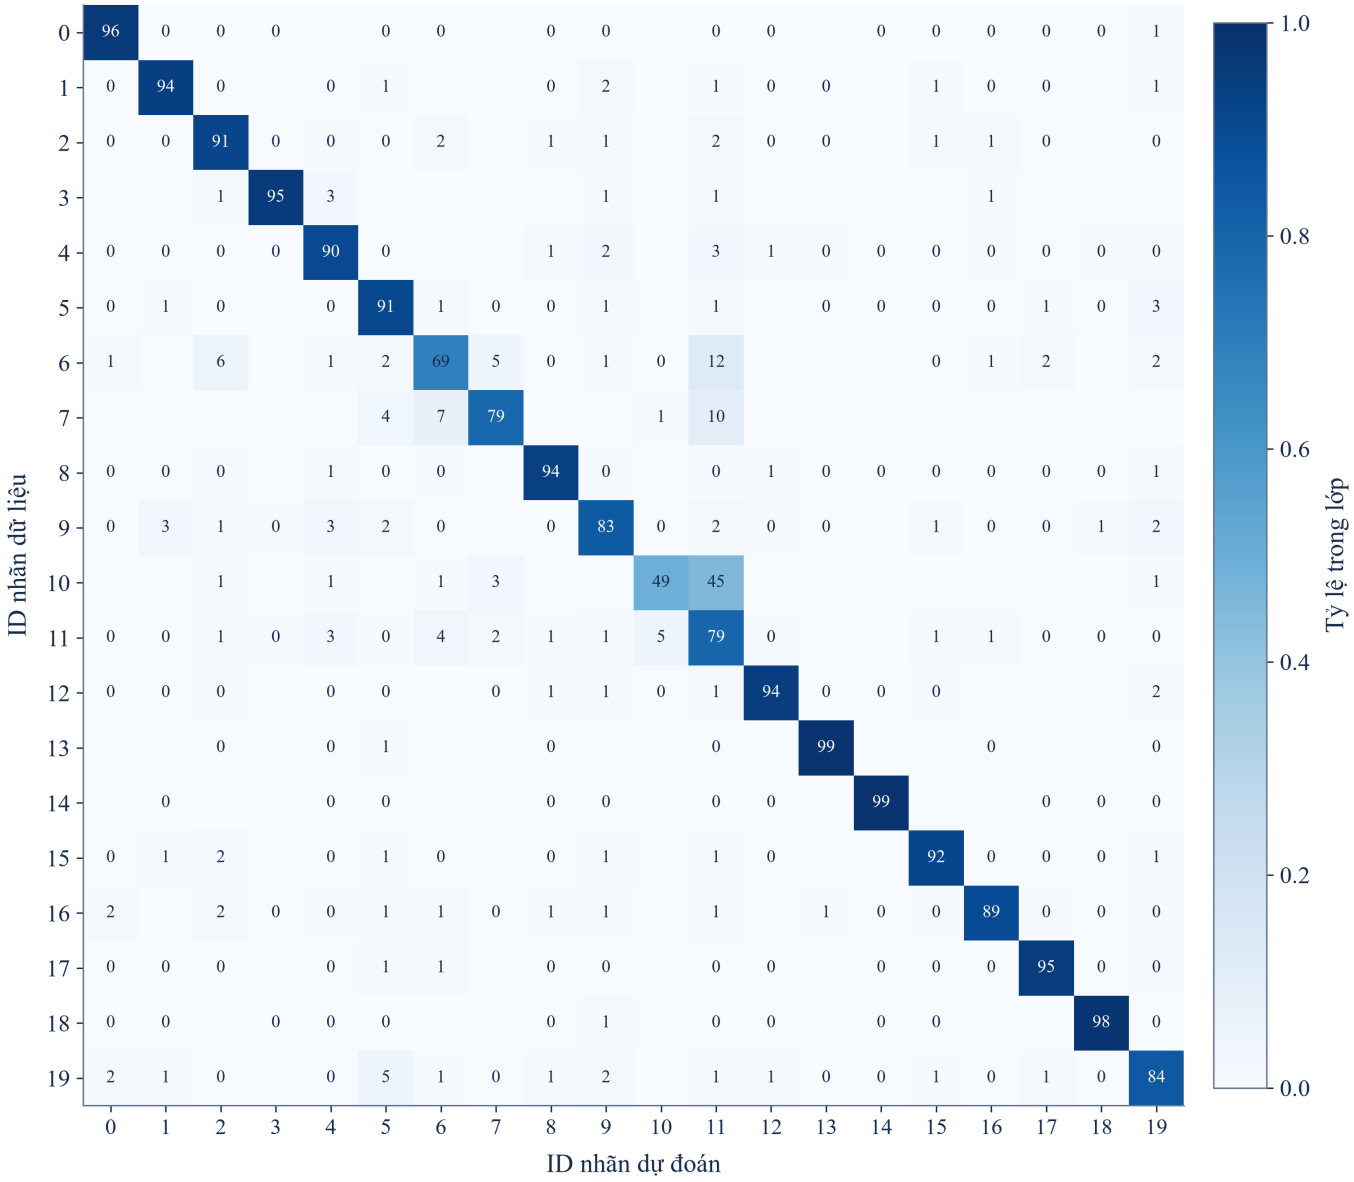
ID 0–19 đối chiếu bảng taxonomy. Ô đường chéo là số đúng; ô ngoài đường chéo là hướng nhầm. Ma trận chuẩn hóa theo hàng cho biết tỷ lệ dự đoán của bài thuộc class tham chiếu, không phải precision của nhãn dự đoán.



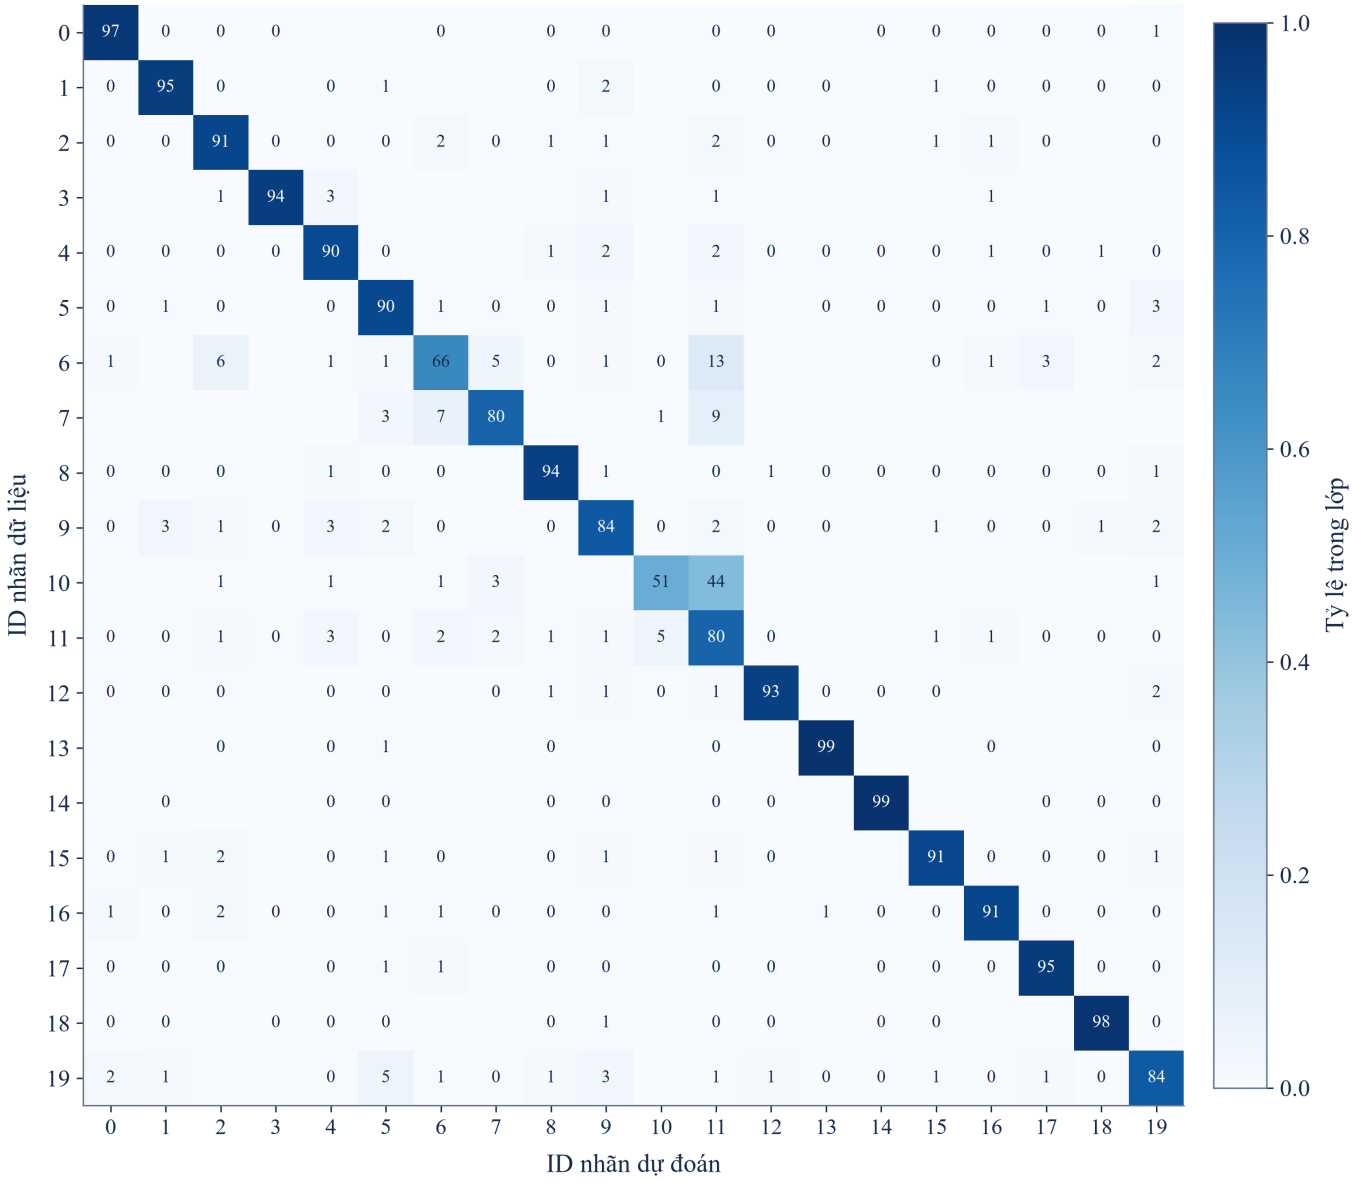
Hình 5.8: Ma trận số lượng trước hiệu chỉnh, tổng 29.995 bài.



Hình 5.9: Ma trận số lượng sau hiệu chỉnh trên cùng test độc lập.



Hình 5.10: Ma trận trước hiệu chỉnh chuẩn hóa theo hàng.



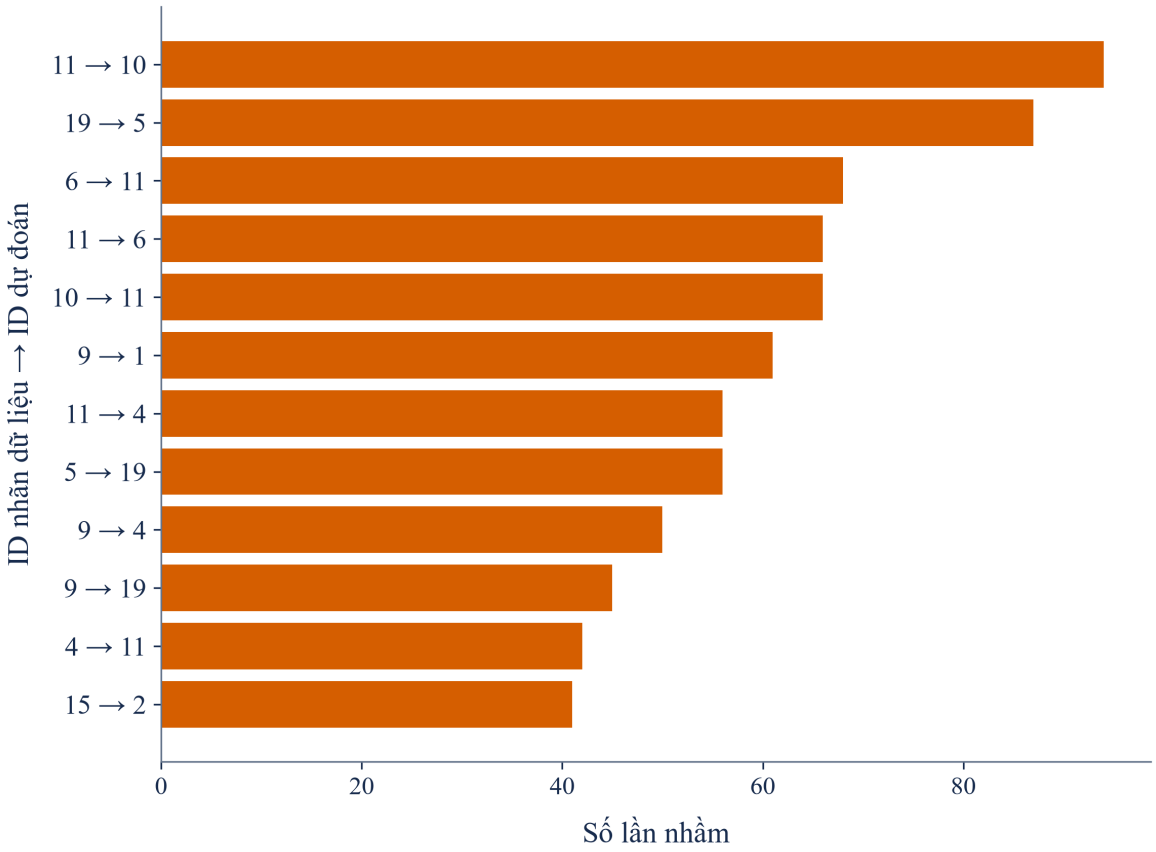
Hình 5.11: Ma trận sau hiệu chỉnh chuẩn hóa theo hàng.

Bảng 5.7: Mười lăm hướng nhầm nhiều nhất trước hiệu chỉnh.

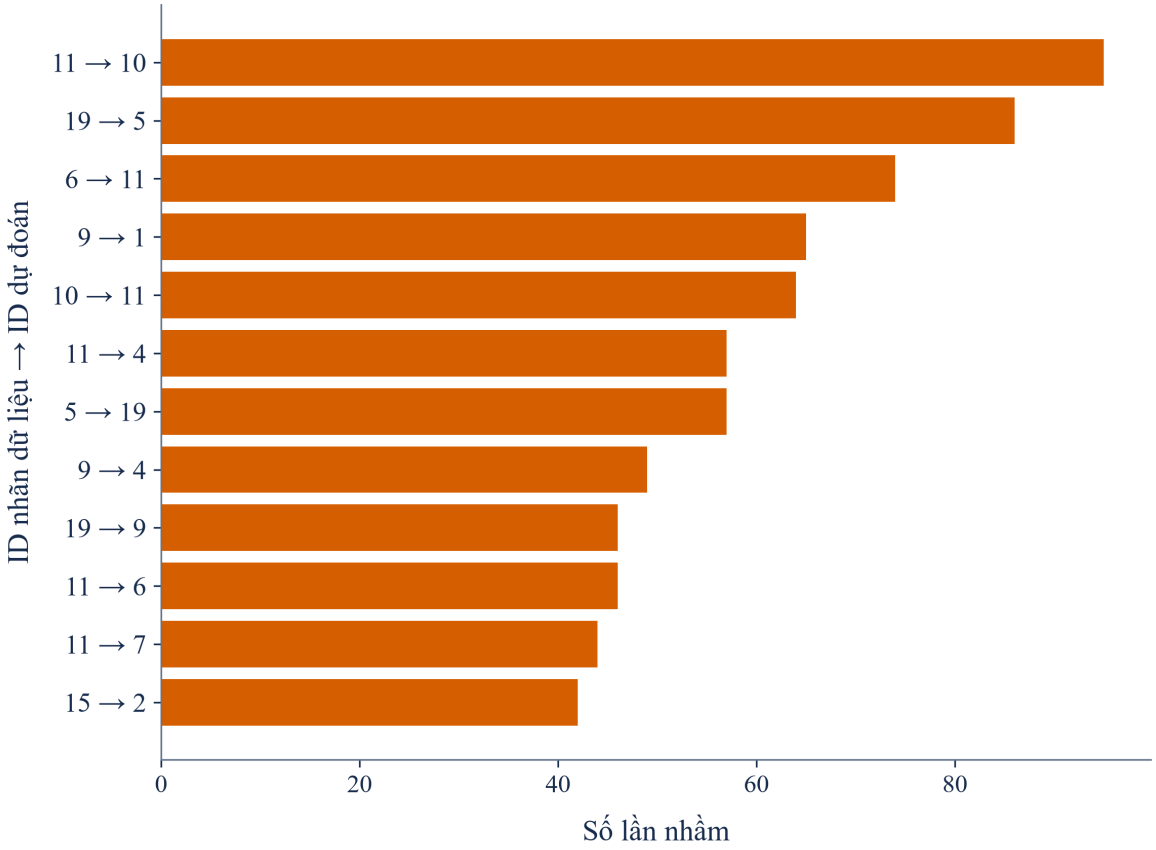
Nhãn tham chiếu	Nhãn dự đoán	Số bài	Tỷ lệ hàng
Nội dung chuyên đề	Nông thôn mới	94	4,99%
Đời sống	Du lịch	87	4,88%
Dân tộc - Tôn giáo	Nội dung chuyên đề	68	12,25%
Nội dung chuyên đề	Dân tộc - Tôn giáo	66	3,50%
Nông thôn mới	Nội dung chuyên đề	66	45,21%
Kinh doanh	Bất động sản	61	3,22%
Nội dung chuyên đề	Công nghệ	56	2,97%
Du lịch	Đời sống	56	3,40%
Kinh doanh	Công nghệ	50	2,64%
Kinh doanh	Đời sống	45	2,37%
Công nghệ	Nội dung chuyên đề	42	2,53%
Thời sự	Chính trị	41	2,20%
Bất động sản	Kinh doanh	41	2,22%
Đời sống	Kinh doanh	40	2,24%
Công nghệ	Kinh doanh	39	2,35%

Bảng 5.8: Mười lăm hướng nhầm nhiều nhất sau hiệu chỉnh; tỷ lệ dùng support hàng.

Nhãn tham chiếu	Nhãn dự đoán	Số bài	Tỷ lệ hàng
Nội dung chuyên đề	Nông thôn mới	95	5,04%
Đời sống	Du lịch	86	4,82%
Dân tộc - Tôn giáo	Nội dung chuyên đề	74	13,33%
Kinh doanh	Bất động sản	65	3,43%
Nông thôn mới	Nội dung chuyên đề	64	43,84%
Nội dung chuyên đề	Công nghệ	57	3,02%
Du lịch	Đời sống	57	3,46%
Kinh doanh	Công nghệ	49	2,58%
Đời sống	Kinh doanh	46	2,58%
Nội dung chuyên đề	Dân tộc - Tôn giáo	46	2,44%
Nội dung chuyên đề	Dân tộc thiểu số và miền núi	44	2,33%
Thời sự	Chính trị	42	2,25%
Kinh doanh	Đời sống	41	2,16%
Công nghệ	Nội dung chuyên đề	41	2,47%
Công nghệ	Kinh doanh	41	2,47%



Hình 5.12: Các hướng lỗi nổi bật trước hiệu chỉnh.



Hình 5.13: Các hướng lỗi nổi bật sau hiệu chỉnh.

Ngoài Nông thôn mới và Nội dung chuyên đề, Đời sống tới Du lịch có 86 bài; Dân tộc – Tôn giáo tới Nội dung chuyên đề có 74; Kinh doanh tới Bất động sản có 65. Hai chiều nhầm không nhất thiết đối xứng. Bài về doanh nghiệp và dự án nhà ở dùng cùng bối cảnh kinh tế; bài về trải nghiệm cá nhân ở điểm đến dùng cả ngôn ngữ đời sống và du lịch. Ma trận gợi ý vùng giao thoa, chưa chứng minh mất phần giữa là nguyên nhân chính.

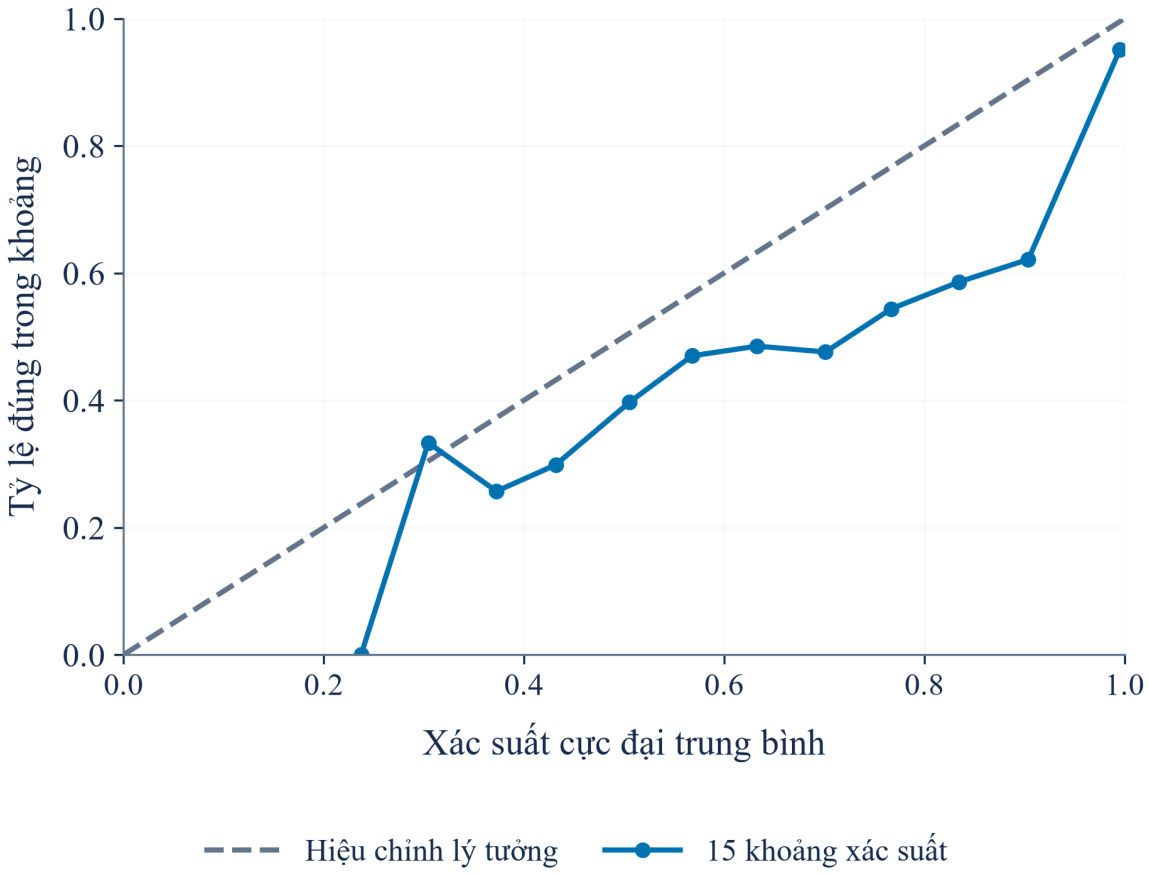
5.6 NLL, ECE và độ tin cậy xác suất

Bảng 5.9: Đo trên test với argmax chuẩn của xác suất; chưa áp dụng hệ số lớp.

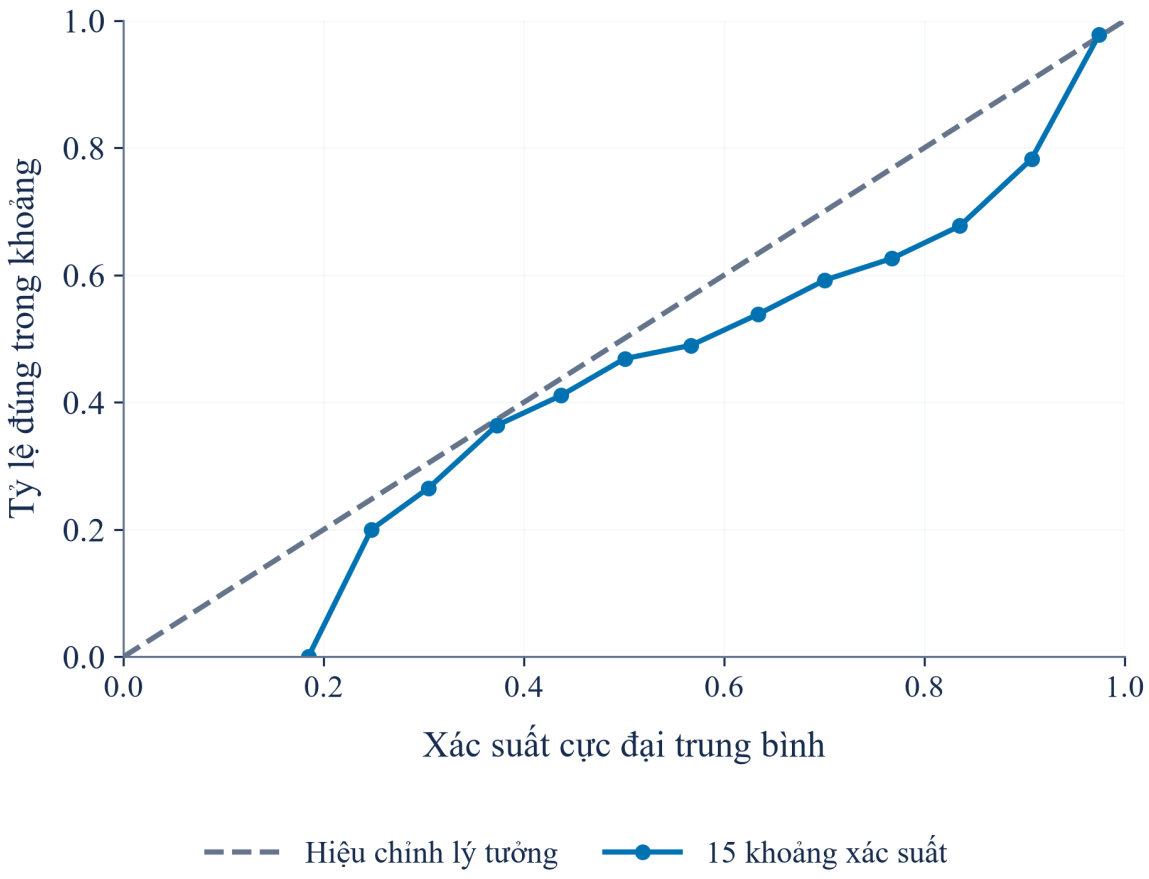
Chỉ số	T = 1	T = 1,4551
NLL	0,383892	0,322030
ECE (15 bins)	0,060291	0,025071

NLL giảm từ 0,383892 xuống 0,322030, tương đối khoảng 16,12%. ECE giảm từ 0,060291 xuống 0,025071, tương đối khoảng 58,41%. Nhãn argmax không đổi khi chỉ thay temperature; mức tăng Accuracy cuối thuộc điều chỉnh τ_c, không thuộc riêng temperature scaling.

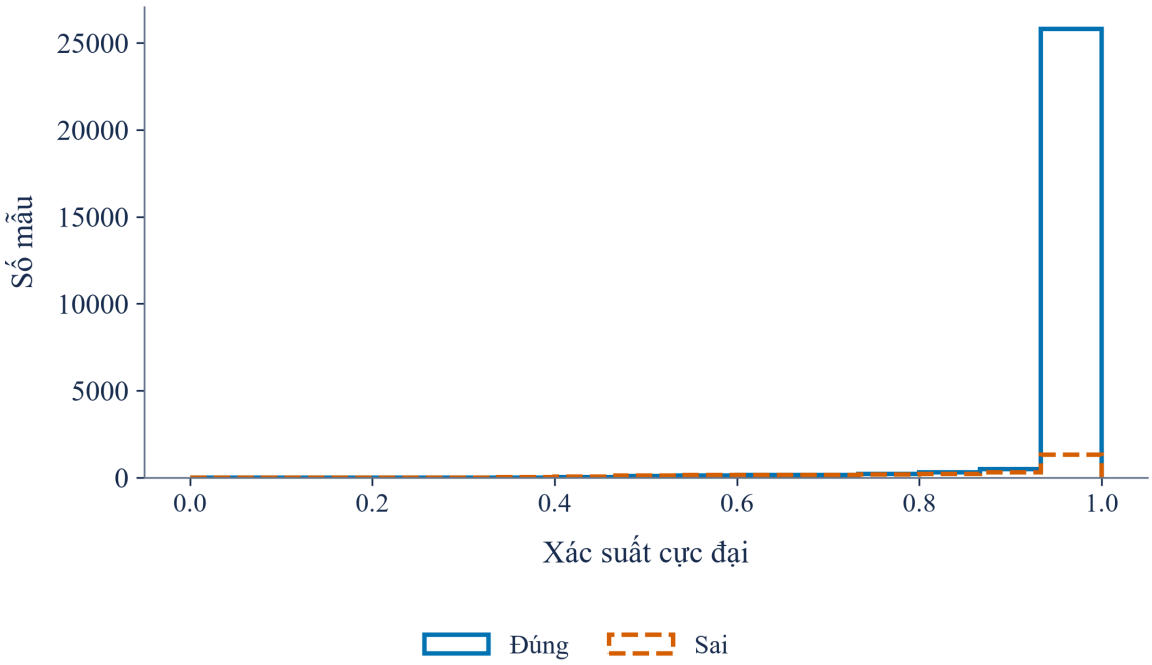
ECE dùng 15 khoảng đều $[b/15, (b+1)/15)$, confidence cực đại và correctness của argmax. Các khoảng không rỗng đóng góp theo số mẫu; xác suất đúng bằng 1 không nằm trong cận trên mở. Định nghĩa này được giữ thống nhất khi đối chiếu. ECE phụ thuộc cách chia bin và không chứng nhận xác suất của từng mẫu.



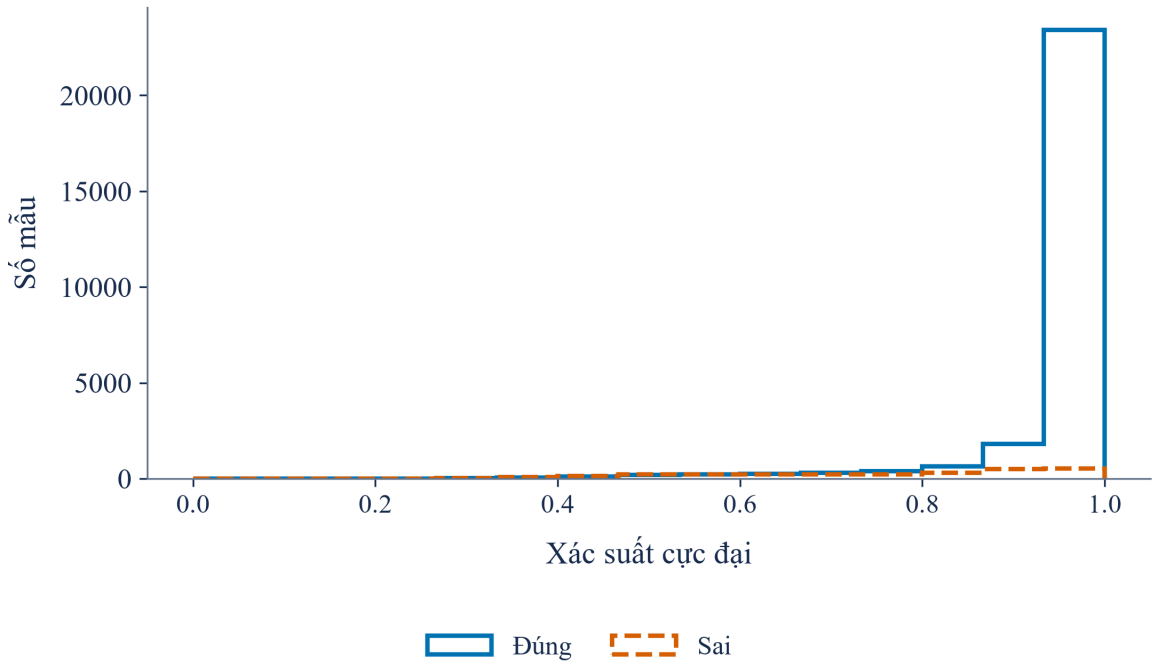
Hình 5.14: Reliability diagram của softmax chưa hiệu chỉnh.



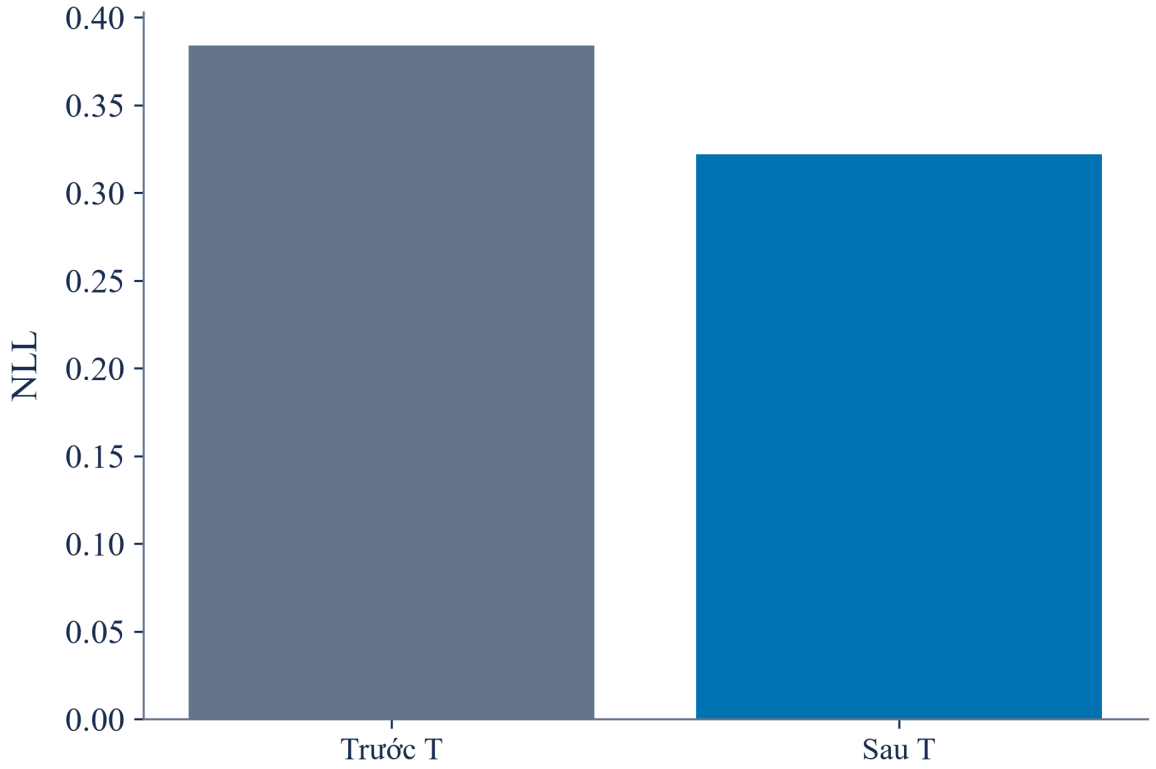
Hình 5.15: Reliability diagram sau temperature fit trên validation.



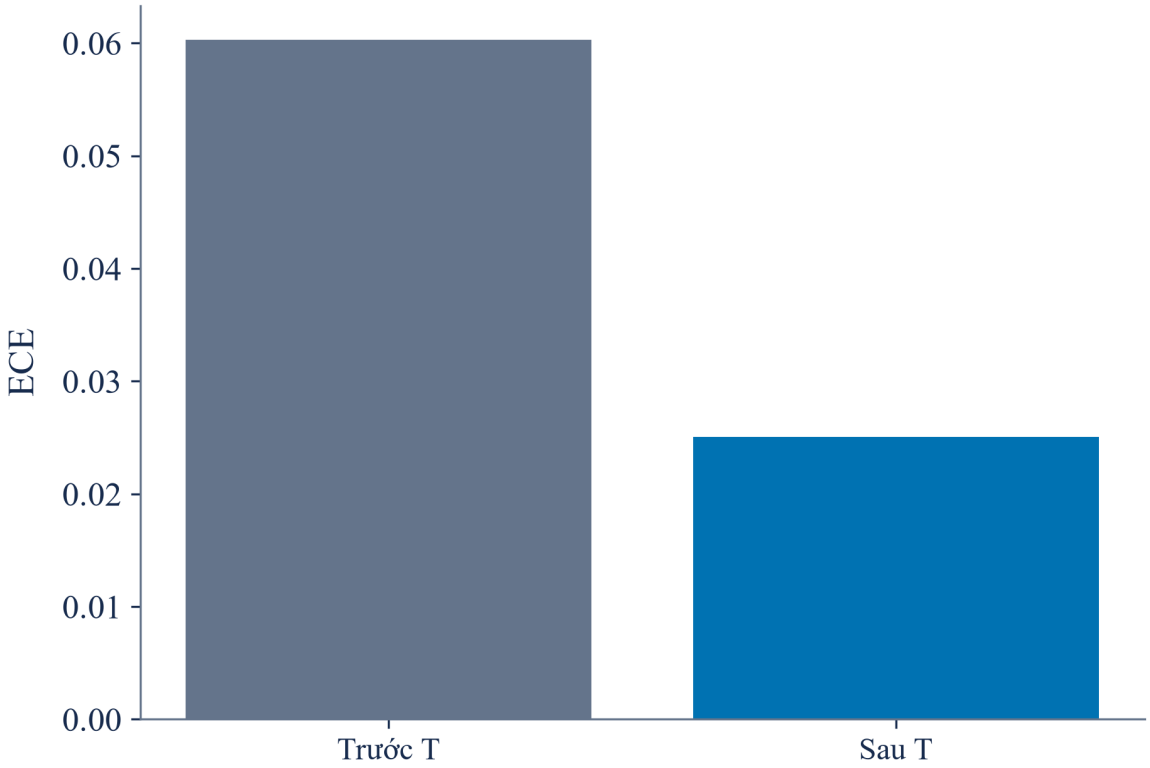
Hình 5.16: Phân bố confidence cực đại theo nhóm đúng/sai trước temperature.



Hình 5.17: Phân bố sau temperature; lỗi vẫn có thể mang confidence cao.



Hình 5.18: So sánh NLL trước/sau temperature trên test.



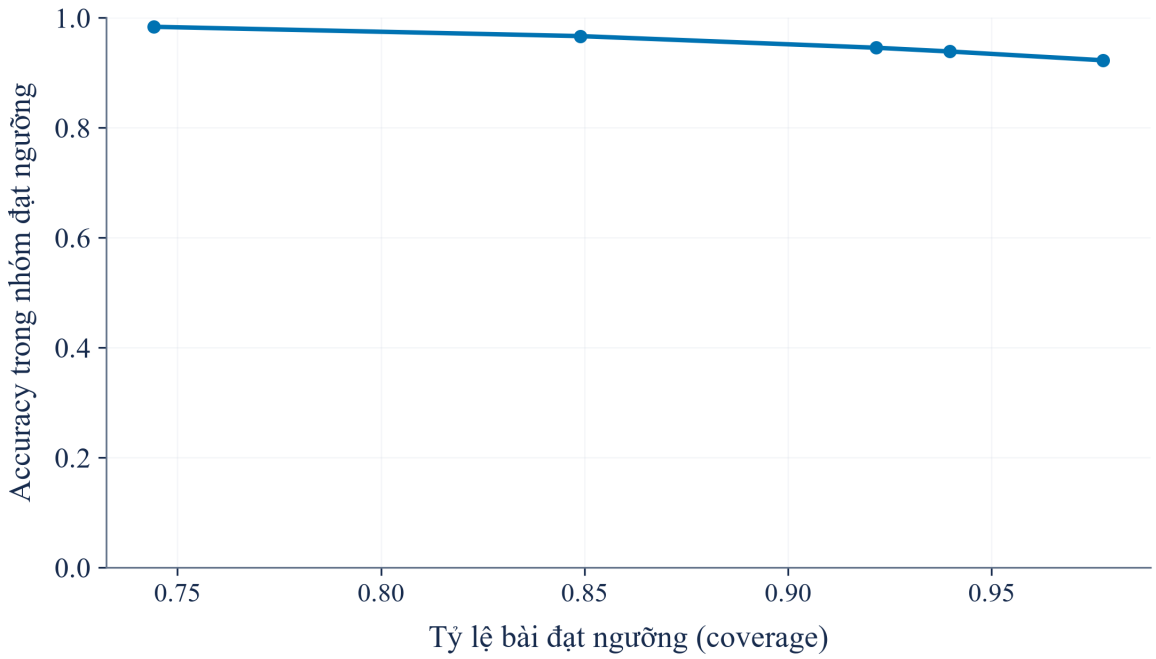
Hình 5.19: So sánh ECE với cùng quy ước 15 bins.

Các biểu đồ reliability áp dụng cho argmax của $p(T)$. App có thể chọn nhãn khác sau chia hệ số; confidence khi đó là xác suất của nhãn được chọn. Muốn chứng nhận hiệu chỉnh cho luồng auto cuối, cần đo calibration trực tiếp theo quyết định cuối, từng lớp và các thời điểm triển khai. ECE của softmax không tự thay thế phép đo này.

5.7 Coverage, ngưỡng định tuyến và margin

Bảng 5.10: Mô phỏng ngưỡng trên test, giữ bài có xác suất nhãn cuối đạt ngưỡng.

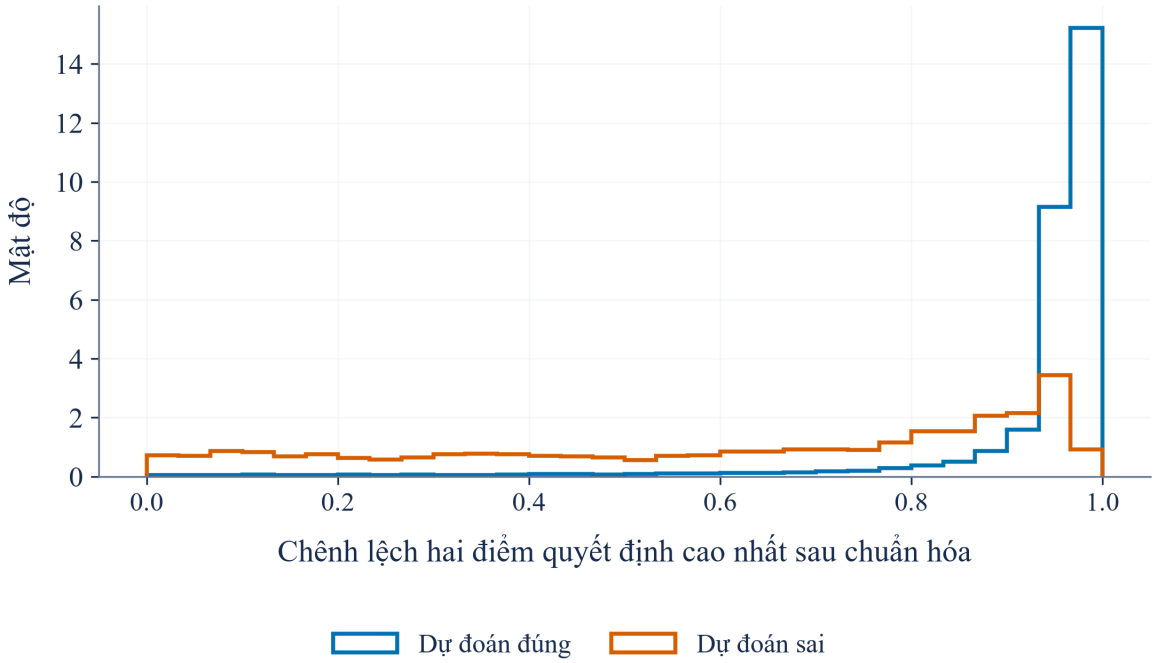
Ngưỡng	Số bài	Coverage	Accuracy nhóm
0,50	29.316	0,9774	0,9227
0,68	28.186	0,9397	0,9387
0,75	27.644	0,9216	0,9455
0,90	25.464	0,8489	0,9667
0,95	22.322	0,7442	0,9836
0,99	0	0,0000	N/A



Hình 5.20: Đánh đổi mức bao phủ và Accuracy của nhóm giữ lại.

Ở ngưỡng 0,75, 27.644 bài được giữ, coverage 92,16% và Accuracy nhóm 94,55%. Vẫn còn khoảng 5,45% lỗi trong nhóm này. Ngưỡng 0,95 giữ 22.322 bài, coverage 74,42%, Accuracy nhóm 98,36%. Ngưỡng 0,99 không có mẫu đạt, Accuracy không xác định; không ghi bằng 0 hoặc 100%.

Các ngưỡng là phân tích mô tả, không là SLA và không được dùng chọn lại model theo test. Định tuyến có thể giảm tải biên tập nhưng tăng chi phí lỗi tự động. Coverage cao không đồng nghĩa chất lượng tốt ở mọi lớp; cần đánh giá chính sách theo tác động nghiệp vụ.



Hình 5.21: Phân bố margin theo nhóm đúng/sai của quyết định cuối.

Margin biểu diễn cạnh tranh tương đối giữa các điểm đã điều chỉnh; vùng nhỏ thường cần xem lại. Nó không đo tính đúng của bài, không phát hiện chắc chắn ngoài miền và không có ngưỡng an toàn tuyệt đối được xác nhận.

5.8 Ví dụ lỗi truy vết được

Bài "Vệ tinh AI Trung Quốc giúp Iran săn lùng căn cứ Mỹ tại Trung Đông?" có nhãn Công nghệ, dự đoán Thế giới. Cả kỹ thuật và địa chính trị đều nổi bật. Bài "Giá thuê nhà tại Los Angeles tăng chóng mặt sau thảm họa cháy rừng" thuộc Bất động sản nhưng bị chọn Thế giới; địa danh và thảm họa có thể cạnh tranh với chủ đề thuê nhà. Đây là diễn giải từ văn bản, không phải attribution đo được của model.

Bài "Một tài xế dùng biển giả bị phạt 17,6 triệu đồng, tước bằng lái 3 tháng" có nhãn Thời sự và dự đoán Ô tô – Xe máy, minh họa ranh giới giữa lĩnh vực phương tiện và bản tin xử lý vi phạm. Bài "Ám ảnh khoa cử, Trung Quốc giảm tải, cấm dạy thêm vì lợi nhuận" thuộc Tuần Việt Nam, dự đoán Giáo dục, cho thấy một chuyên mục bình luận có thể cạnh tranh với lĩnh vực được bàn luận.

Phụ lục giữ title, URL, nhãn, confidence và trích đoạn của ví dụ để đối chiếu. Ví dụ được chọn có chủ đích; tần suất trong danh sách không đại diện tỷ lệ lỗi toàn corpus. Không tự đổi nhãn test chỉ vì dự đoán có vẻ hợp lý rồi báo điểm mới.

5.9 Precision–Recall một-chống-phần-còn-lại

Notebook tạo một đường PR riêng cho mỗi lớp. Các đường dùng xác suất sau temperature, nhãn nhị phân của class và average precision; đường tham chiếu là prevalence. AP đo chất lượng xếp hạng khi thay ngưỡng, khác F1 đa lớp ở một quyết định argmax. Với lớp ít mẫu, đường PR đặc biệt hữu ích để xem recall tăng phải trả giá precision thế nào. Hai mươi hình được đưa riêng vào phụ lục.

5.10 Phản biện và độ vững của kết luận

5.10.1 Hợp lệ nội tại

Test tách khỏi lựa chọn và hiệu chỉnh; exact duplicates được loại trước chia. Tuy vậy, near-duplicates, bài cùng sự kiện và sai nhãn ngữ nghĩa chưa được kiểm toán toàn bộ. Các bước lowercase, bỏ số, PyVi, Head–Tail và balanced weights chưa có đối chứng riêng.

5.10.2 Hợp lệ thống kê

Một seed không cho độ lệch chuẩn do huấn luyện. Chỉ tăng 13 bài đúng ròng sau hiệu chỉnh không đủ chứng minh lợi ích ổn định. Chưa thực hiện kiểm định cặp hay bootstrap cho khoảng tin cậy; không gán mức ý nghĩa thống kê cho sự chênh lệch này.

5.10.3 Hợp lệ bên ngoài

Corpus một tòa soạn, phép chia ngẫu nhiên và taxonomy cố định không đo chất lượng ở nguồn khác, tin tương lai hoặc bài ngoài miền. Không thể cam kết hiệu năng của test áp dụng cho mọi tin đưa vào app. Nhãn chính sách và chuyên đề cần đặc biệt lưu ý khi website đổi cấu trúc.

5.10.4 Baseline và ablation còn thiếu

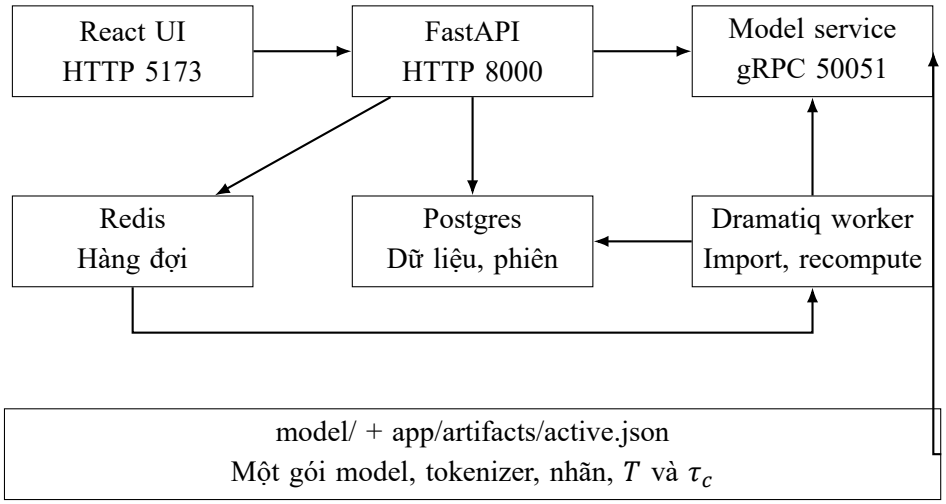
Chưa có TF–IDF + SVM/logistic regression trên cùng split, so sánh model đóng băng encoder, head-only hoặc xử lý nhiều đoạn. Vì vậy, kết quả chứng minh pipeline hoạt động và đạt các chỉ số đã đo, chưa chứng minh PhoBERT hoặc từng thiết kế vượt trội mọi phương án. Những phép đối chứng này là phần ưu tiên khi cần nâng mức thuyết phục học thuật.

6. Ứng dụng hỗ trợ biên tập

6.1 Vai trò của ứng dụng trong bài toán NLP

Ứng dụng đưa bộ phân loại vào một vòng làm việc gồm nhập bài, đề xuất nhãn, rà soát và lưu phản hồi. Kết quả model là tín hiệu hỗ trợ; người dùng có thể giữ, sửa hoặc chuyển bài khó. Ba vai trò là Editor, Admin và Data Scientist, có quyền ở API tương ứng. Phần này trình bày các chức năng cần để hiểu cách model được sử dụng, thay vì liệt kê toàn bộ chi tiết frontend.

6.2 Kiến trúc triển khai và hợp đồng model



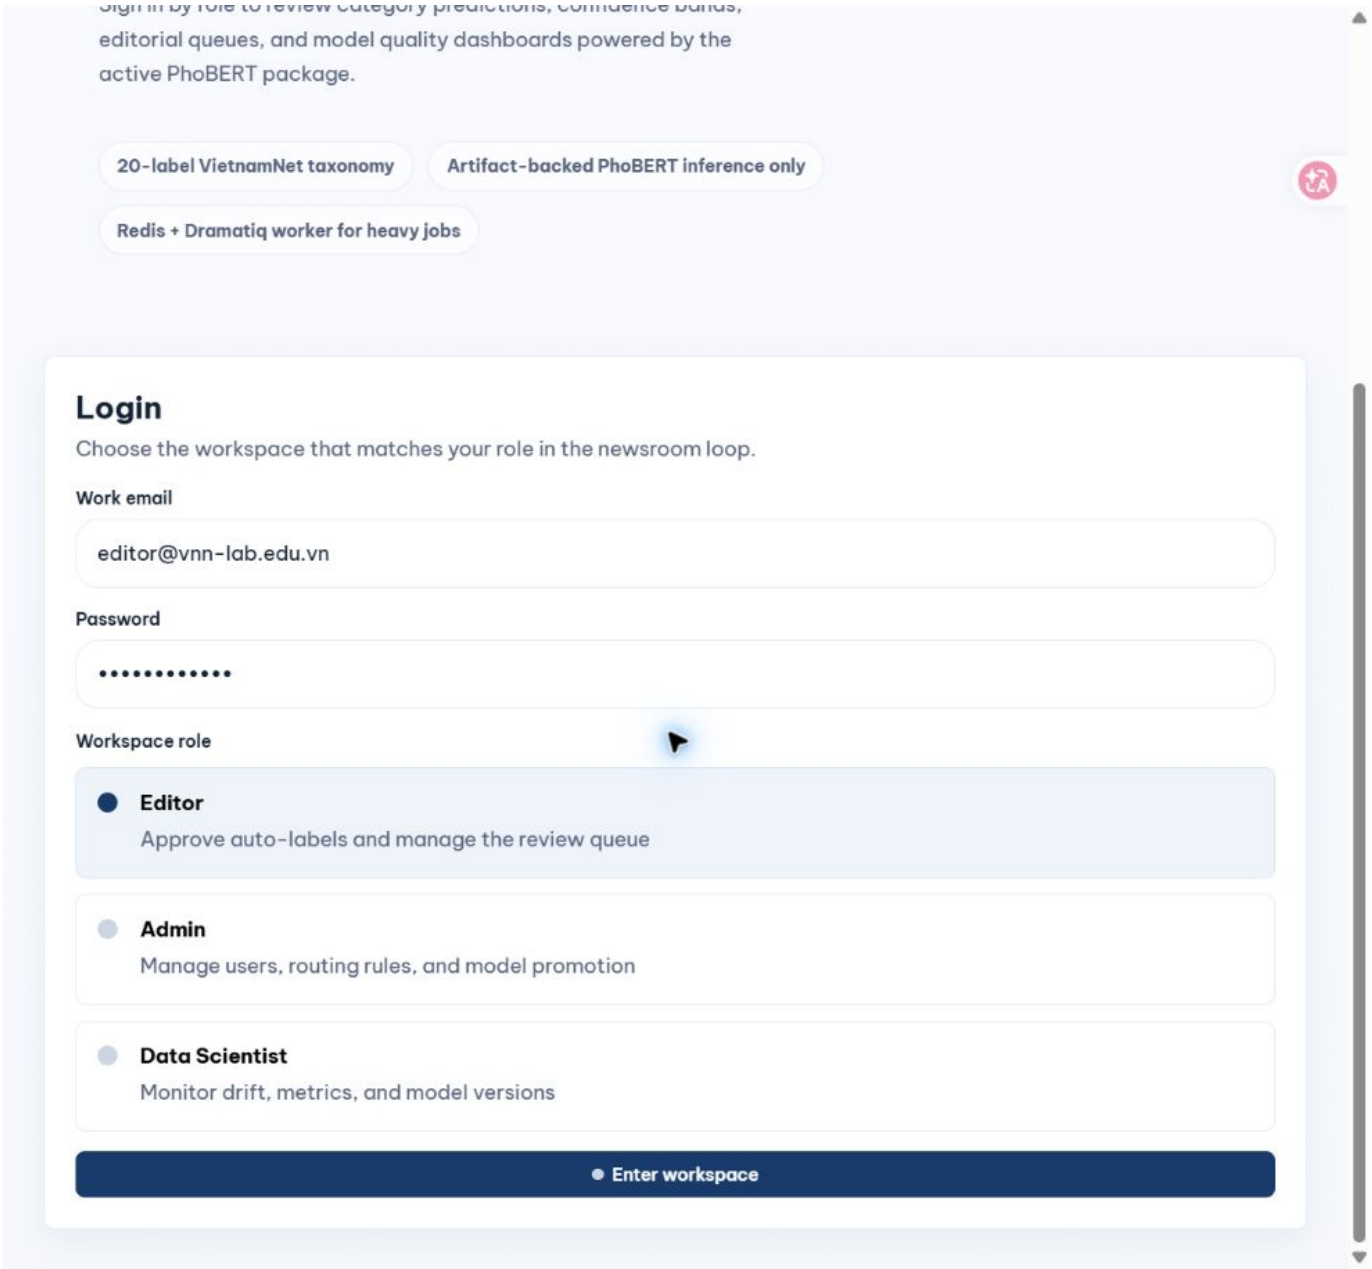
Hình 6.1: Sáu dịch vụ của ứng dụng và gói mô hình dùng cho suy luận.

React/Vite phục vụ UI cổng 5173; FastAPI cổng 8000; model service gRPC 50051. PostgreSQL lưu bài, dự đoán, phản hồi, phiên và registry trong schema vnn. Redis cùng Dramatiq xử lý job nhập bài hoặc tính monitoring. Sáu dịch vụ được khởi động bằng Docker Compose với health check và volume dữ liệu.

Model service nạp model/ qua app/artifacts/active.json. Model SHA-256 bắt đầu 607f3240, taxonomy 20 lớp, Head–Tail 256, PyVi, temperature 1,4551 và toàn bộ hệ số class khớp notebook. Kiểm tra startup từ chối thiếu file, mapping không đồng bộ hoặc hash trọng số sai. Registry kiểm tra cả hash trọng số và calibration, lấy Macro-F1 cùng ma trận 29.995 mẫu từ kết quả hiện tại.

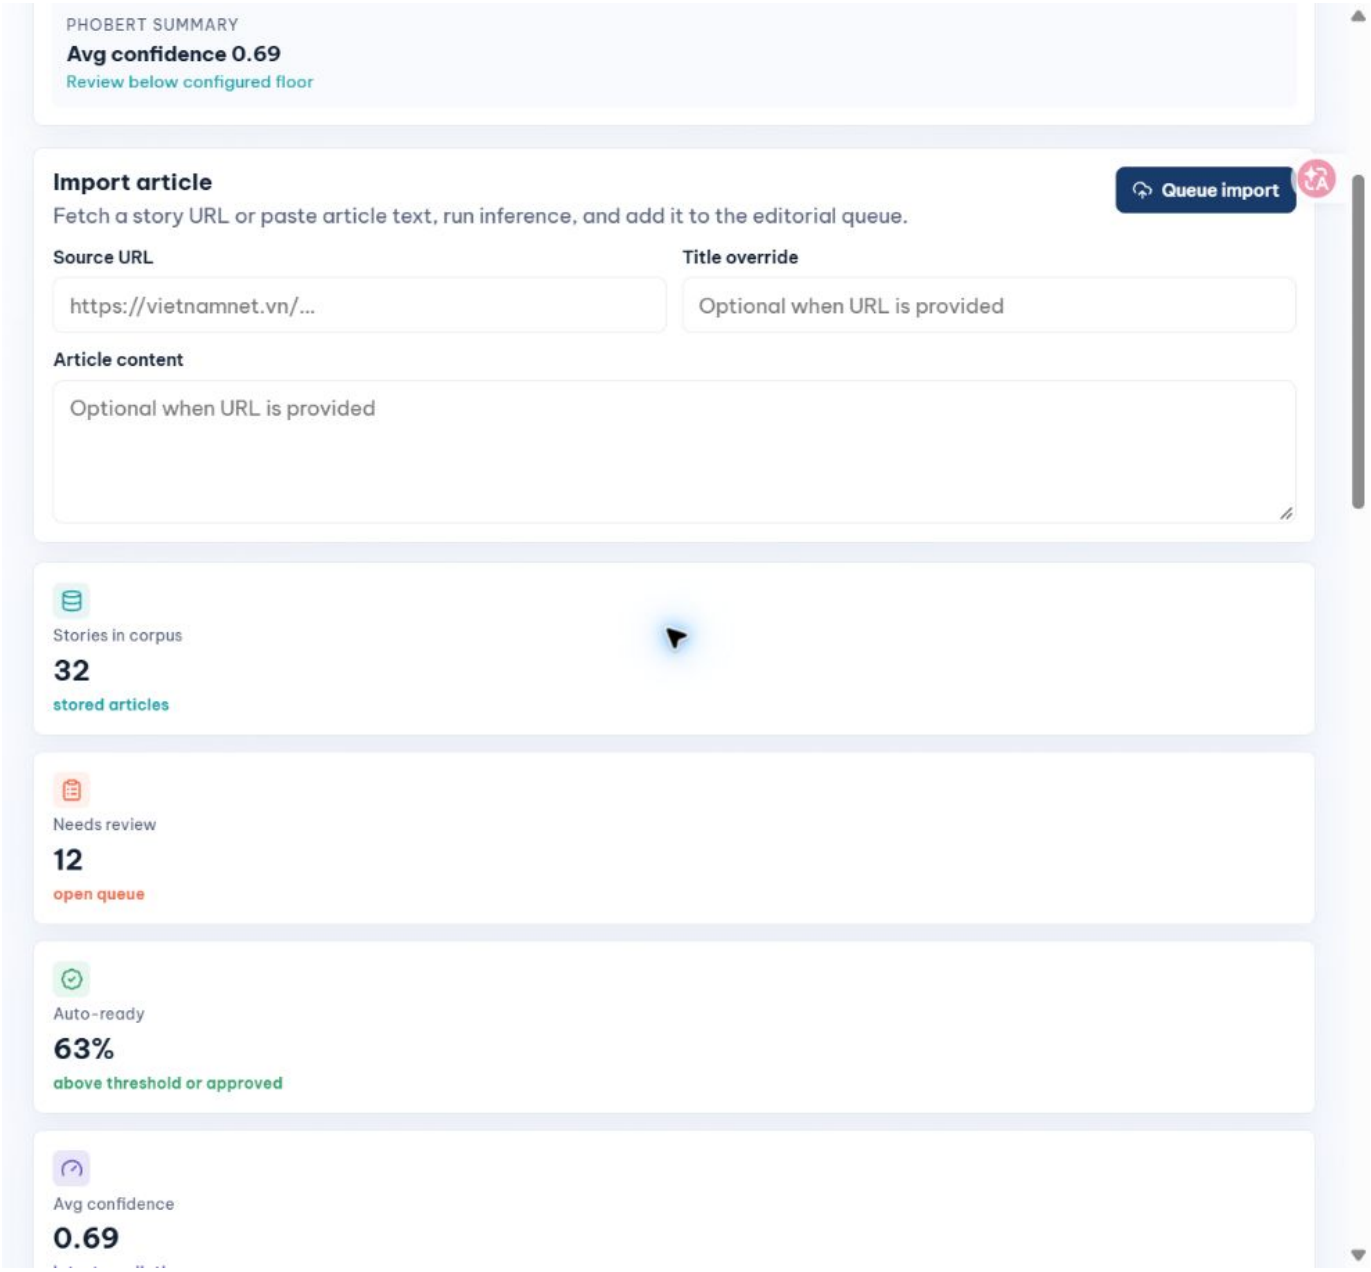
Inference trong container dùng CPU float32; fine-tuning và đánh giá notebook dùng GPU BF16. Nhãn và các bất biến pipeline cần nhất quán, nhưng logits sát ranh giới có thể chênh nhỏ do precision. Dịch vụ dùng tokenizer local và tắt dropout bằng eval; không tải một tokenizer khác khi nhận yêu cầu.

6.3 Đăng nhập và nhập bài

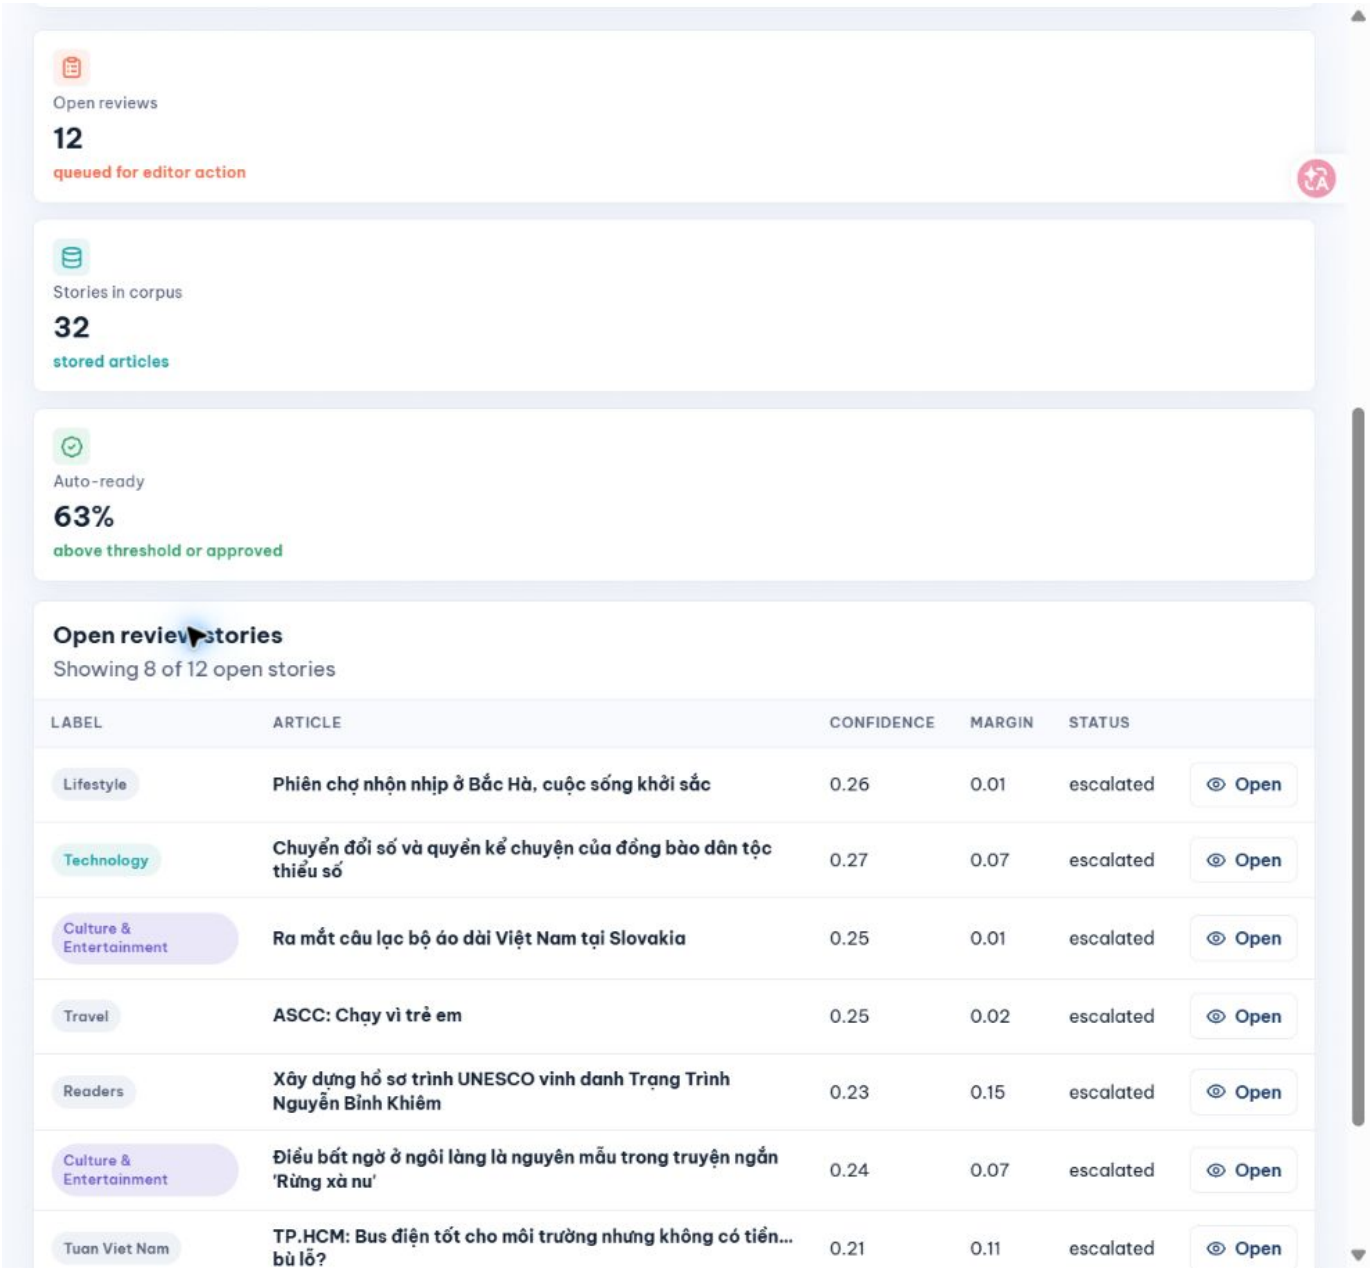


Hình 6.2: Trang đăng nhập phân vai trò, sử dụng taxonomy 20 lớp.

Editor nhập URL VietNamNet hoặc dán title/content. Dịch vụ kiểm tra văn bản hữu ích trước suy luận, lưu full text và kết quả. Job bất đồng bộ trả ID để theo dõi trạng thái; lỗi tải được trả rõ thay vì tạo dự đoán giả. Nội dung người dùng nhập không được tự đưa vào train hoặc thay dataset notebook.

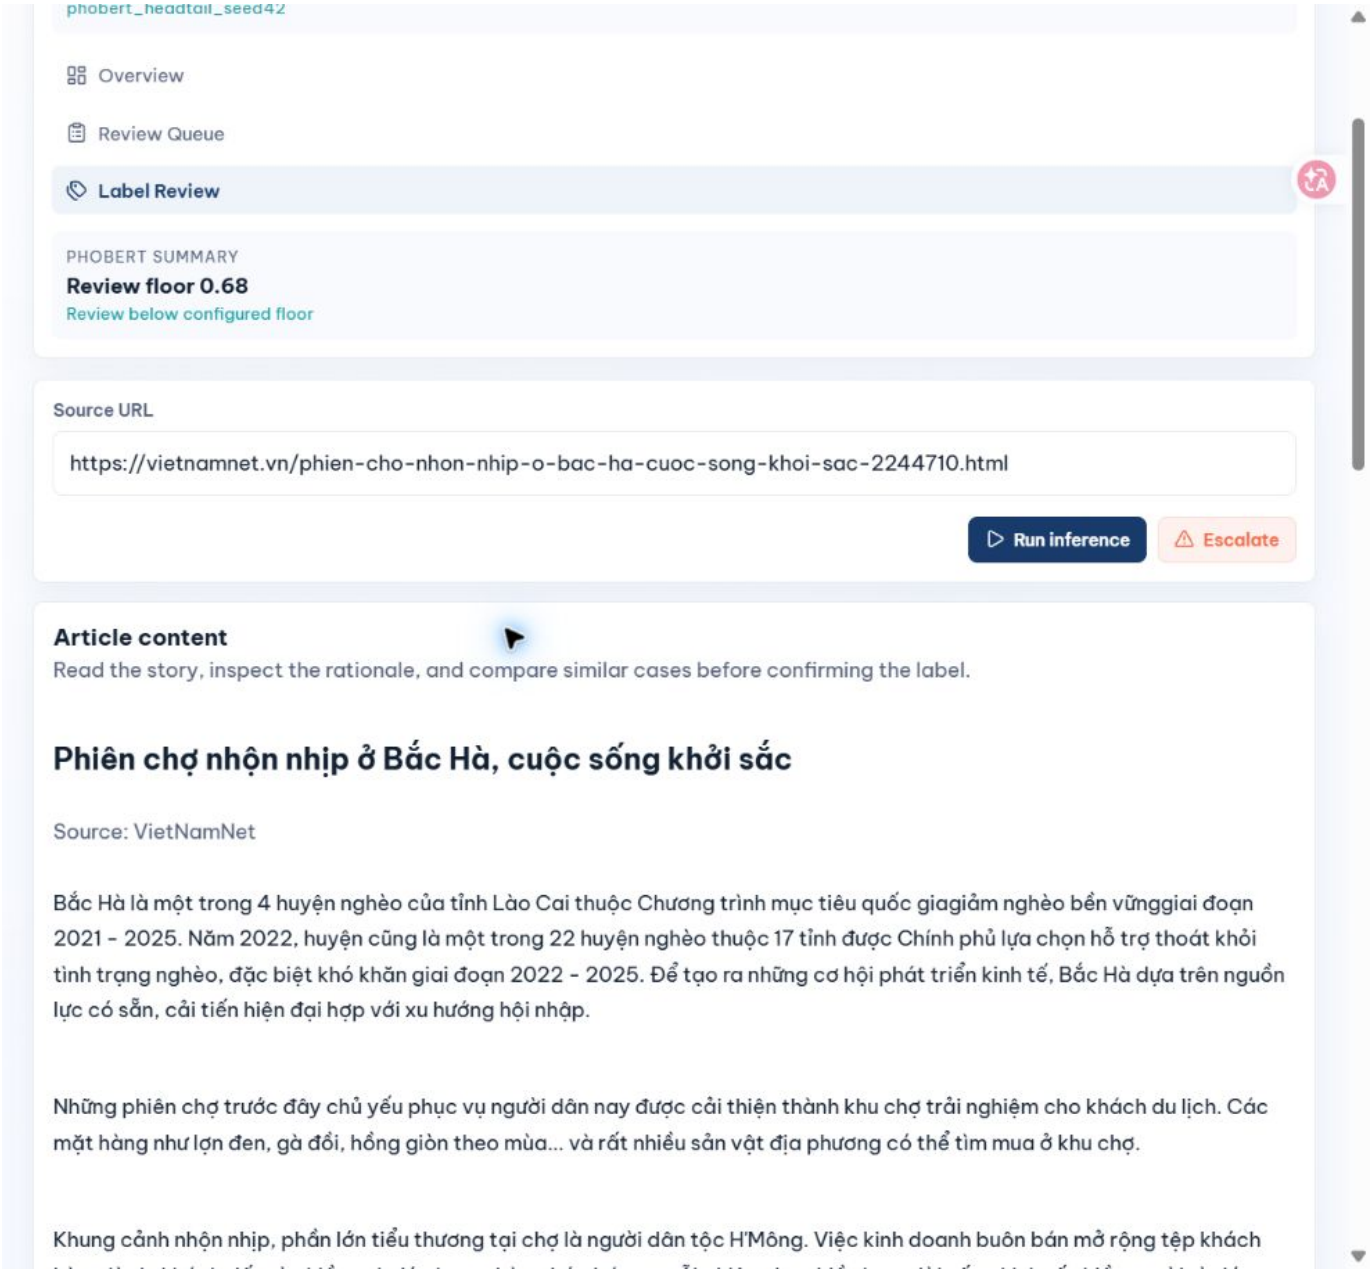


Hình 6.3: Tổng quan Editor với 32 bài minh họa và các số đo từ dự đoán đang lưu.

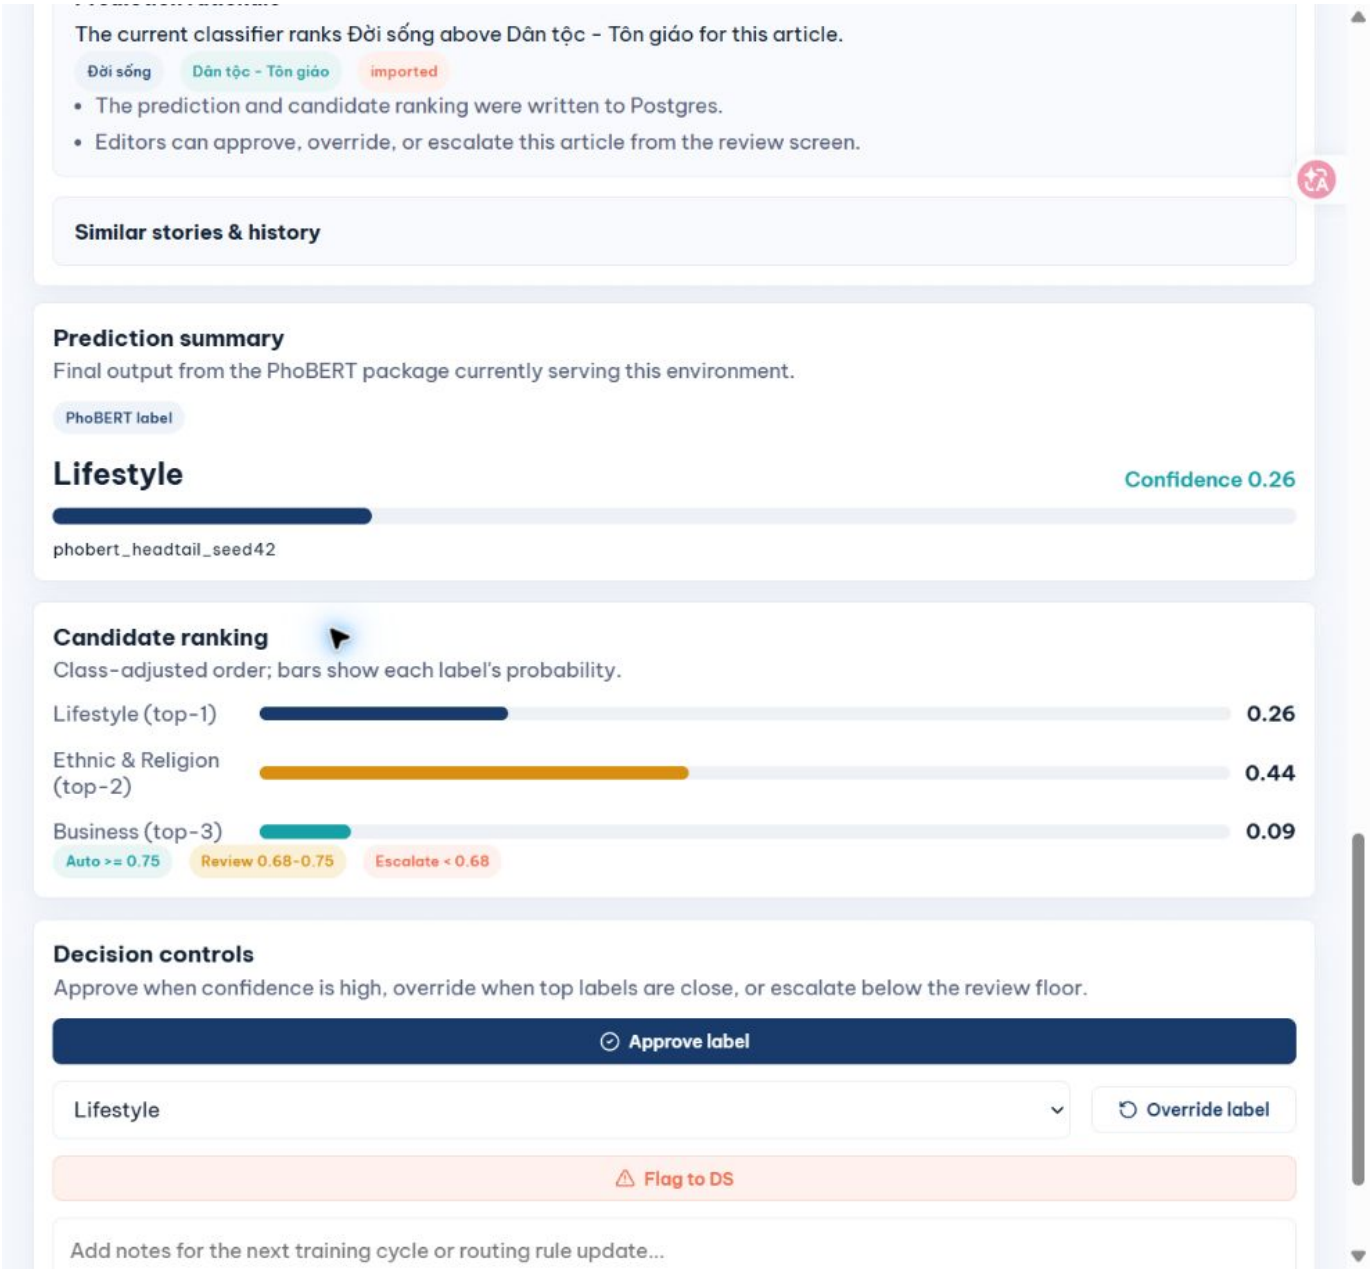


Hình 6.4: Hàng đợi ưu tiên bài confidence thấp và margin nhỏ; đây là dữ liệu minh họa có chọn mẫu.

6.4 Đọc bài và ra quyết định



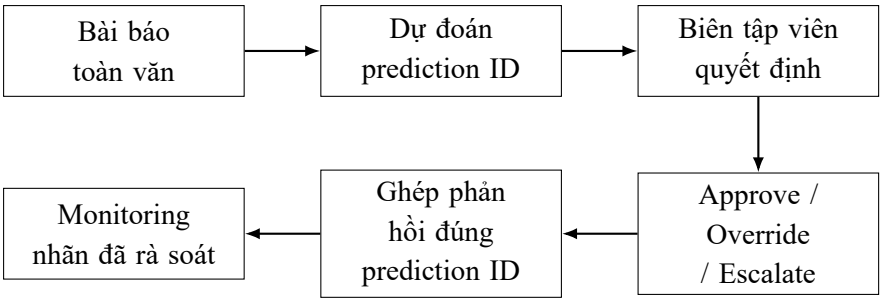
Hình 6.5: Nội dung bài "Phiên chợ nhộn nhịp ở Bắc Hà, cuộc sống khởi sắc" trong màn hình rà soát.



Hình 6.6: Nhãn, confidence, ứng viên và thao tác biên tập được chụp riêng để đọc rõ.

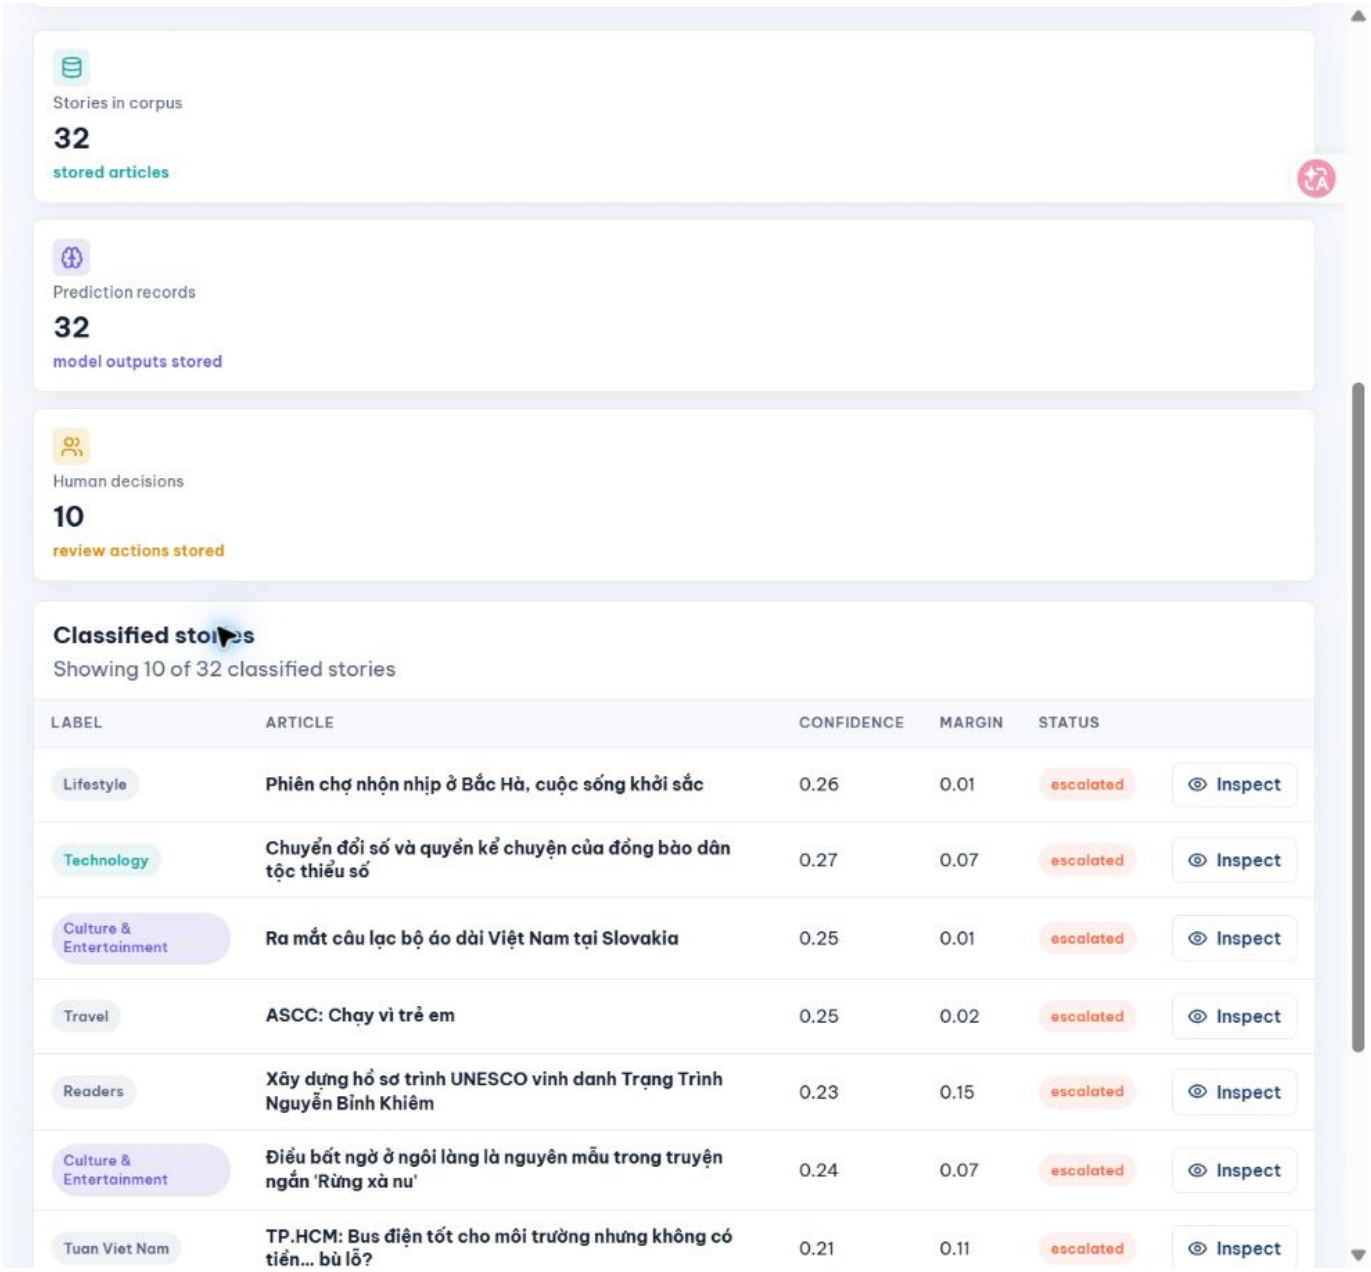
Ví dụ Bắc Hà có nhiều nội dung du lịch, sinh kế và chính sách giảm nghèo. Model chọn Đời sống với confidence khoảng 0,26, trong khi xác suất Dân tộc – Tôn giáo khoảng 0,44. Thứ tự này đúng quy tắc chia hệ số: class Đời sống có hệ số khoảng 1,0558, class Dân tộc – Tôn giáo khoảng 1,8759. Nhãn đứng đầu theo điểm quyết định có thể không có xác suất lớn nhất. Confidence thấp đưa bài vào escalate.

Approve giữ nhãn được đề xuất, Override chọn một nhãn taxonomy khác, Escalate chuyển bài khó. API từ chối approve với nhãn khác top-1, hoặc quyết định khi chưa có suy luận hợp lệ. Prediction ID gắn phản hồi với đúng lần suy luận; chạy lại tạo prediction mới, không coi phản hồi cũ là nhãn đã xác minh của prediction mới.



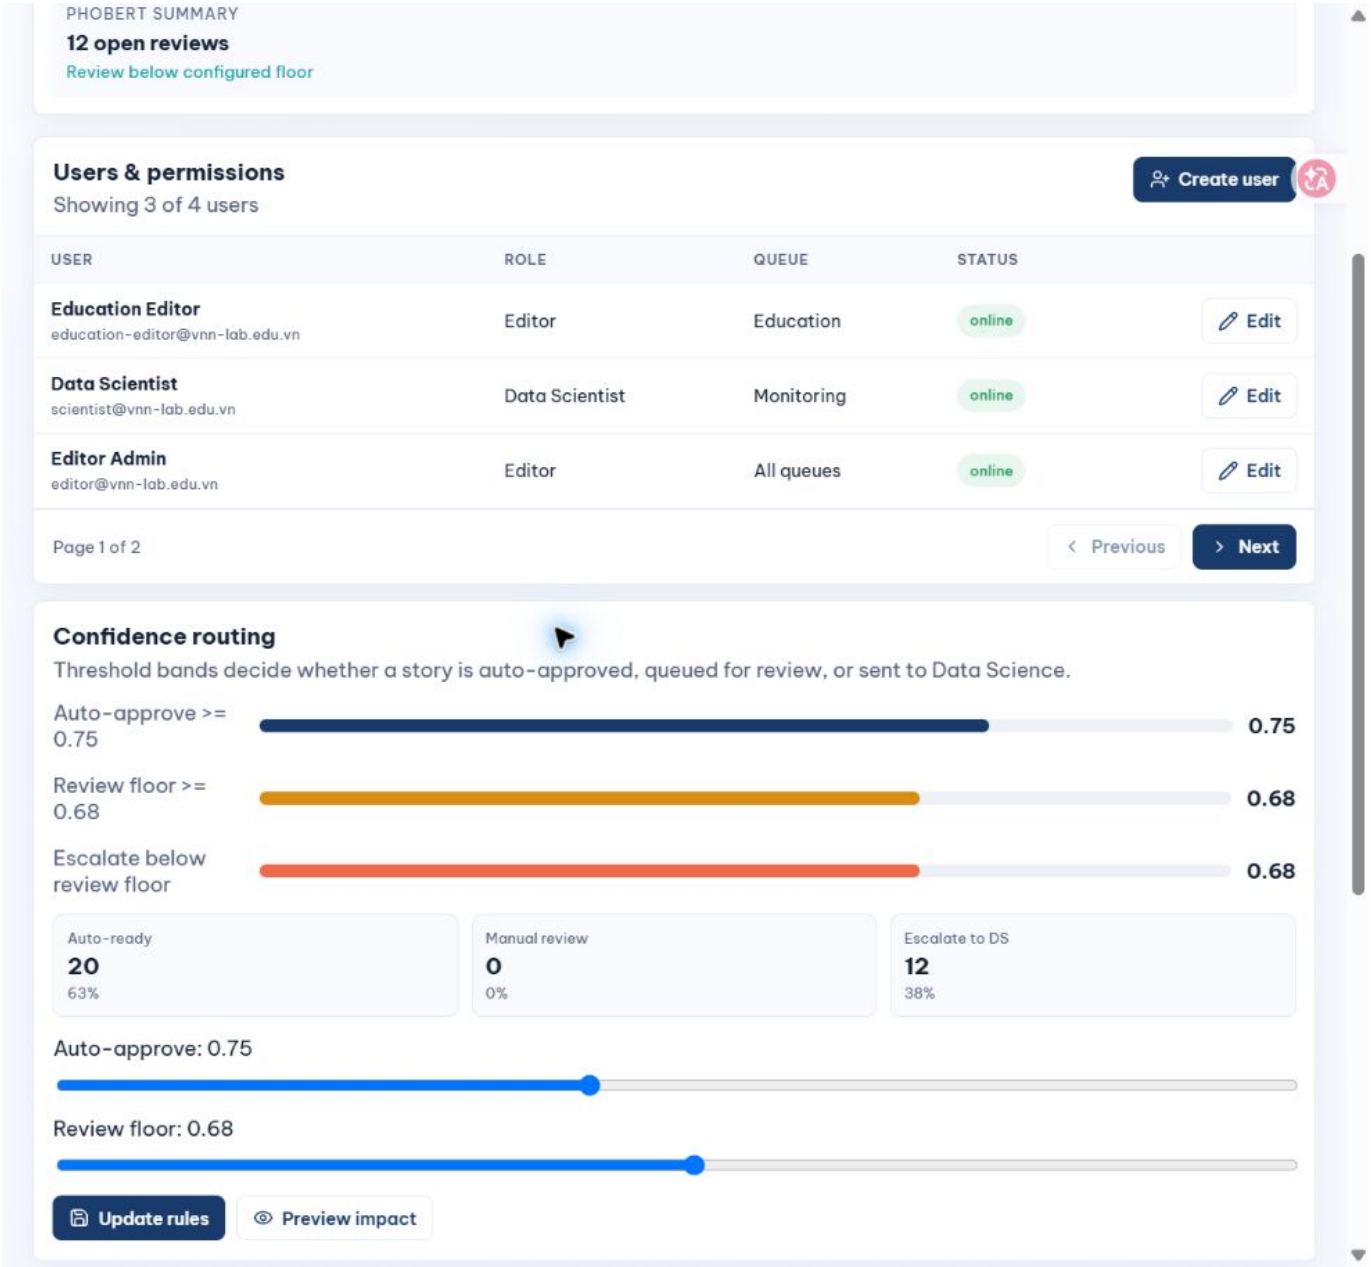
Suy luận lại tạo prediction mới; phản hồi cho prediction cũ không trở thành nhãn tham chiếu cho prediction mới.

Hình 6.7: Vòng phản hồi có truy vết phiên bản mô hình và lần dự đoán.



Hình 6.8: Bảng tất cả bài đã phân loại, gồm confidence, margin, trạng thái và phân trang.

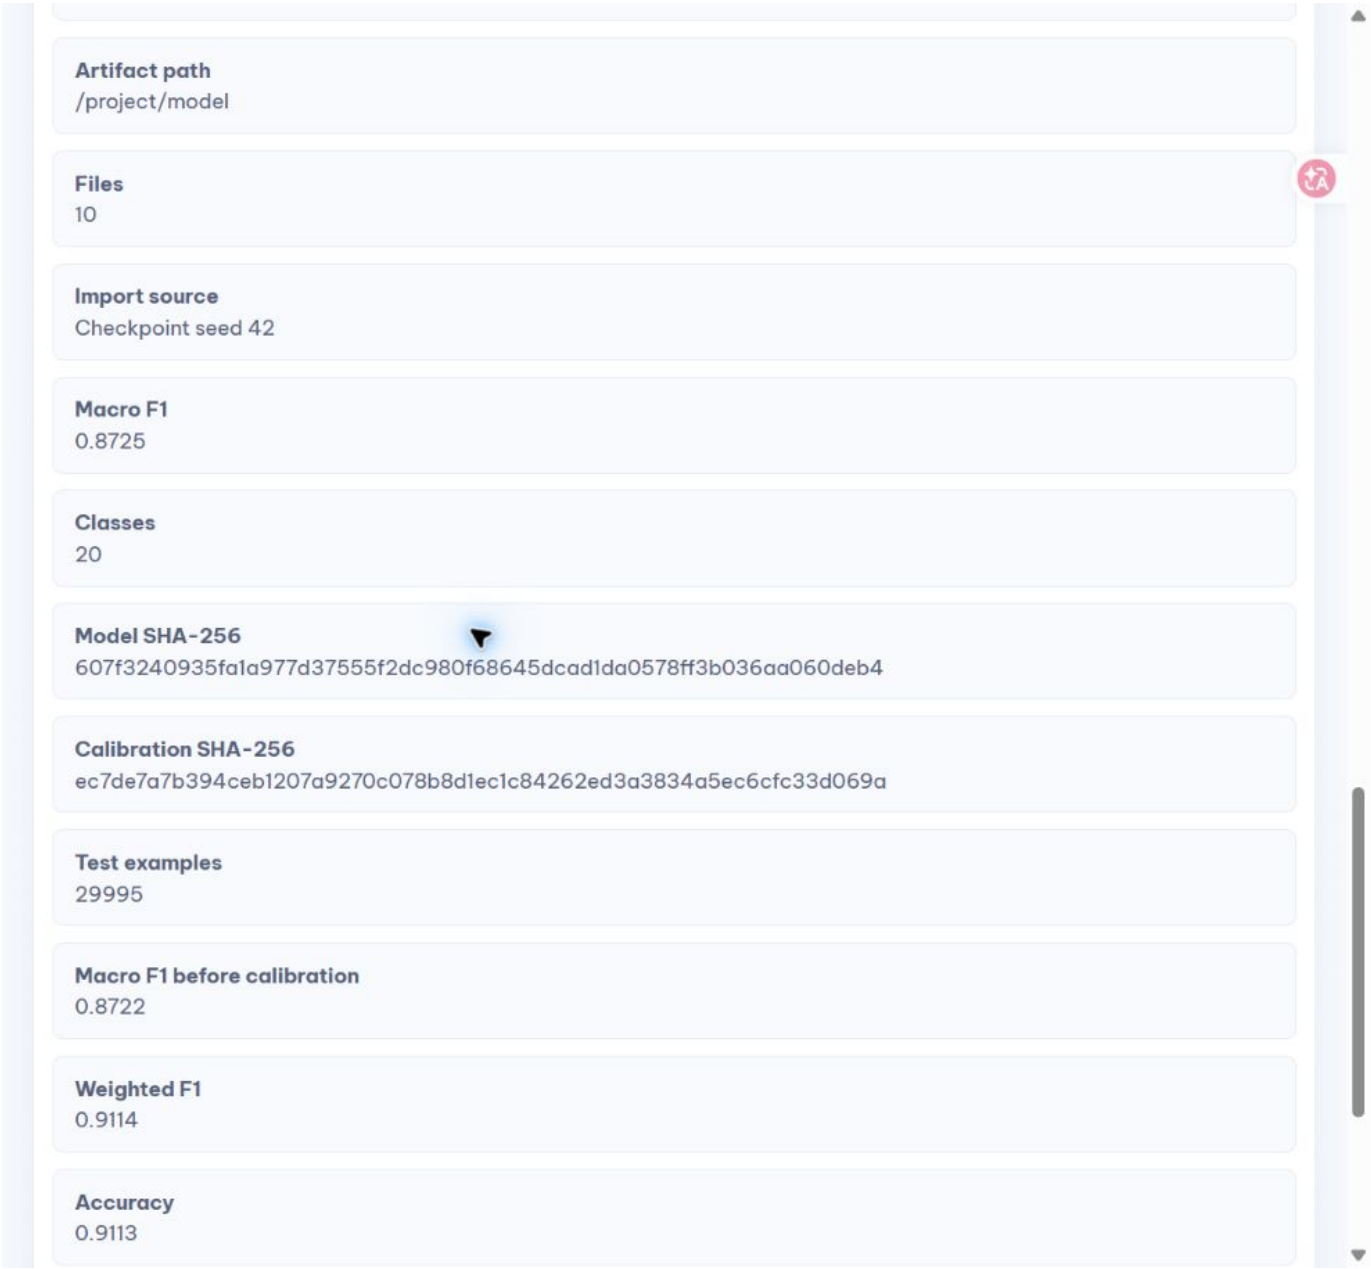
6.5 Chính sách định tuyến và quản trị



Hình 6.9: Admin cấu hình confidence routing, xem preview và thông tin vận hành.

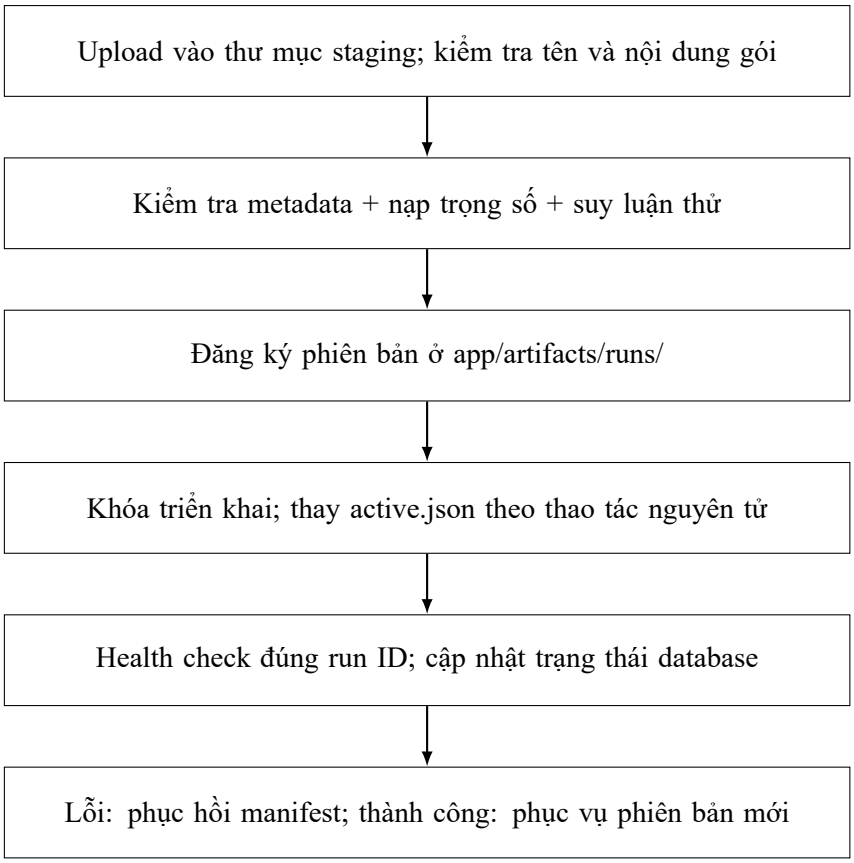
Hai ngưỡng 0,75 và 0,68 nằm trong database; preview cho biết lượng bài ở từng luồng trước khi cập nhật. Thay ngưỡng không train model, không fit lại temperature và không thay 20 hệ số class. Quyền quản lý người dùng và kích hoạt package thuộc vai trò được cấp; UI không phải lớp bảo vệ duy nhất.

6.6 Registry, monitoring và Dataset Lab

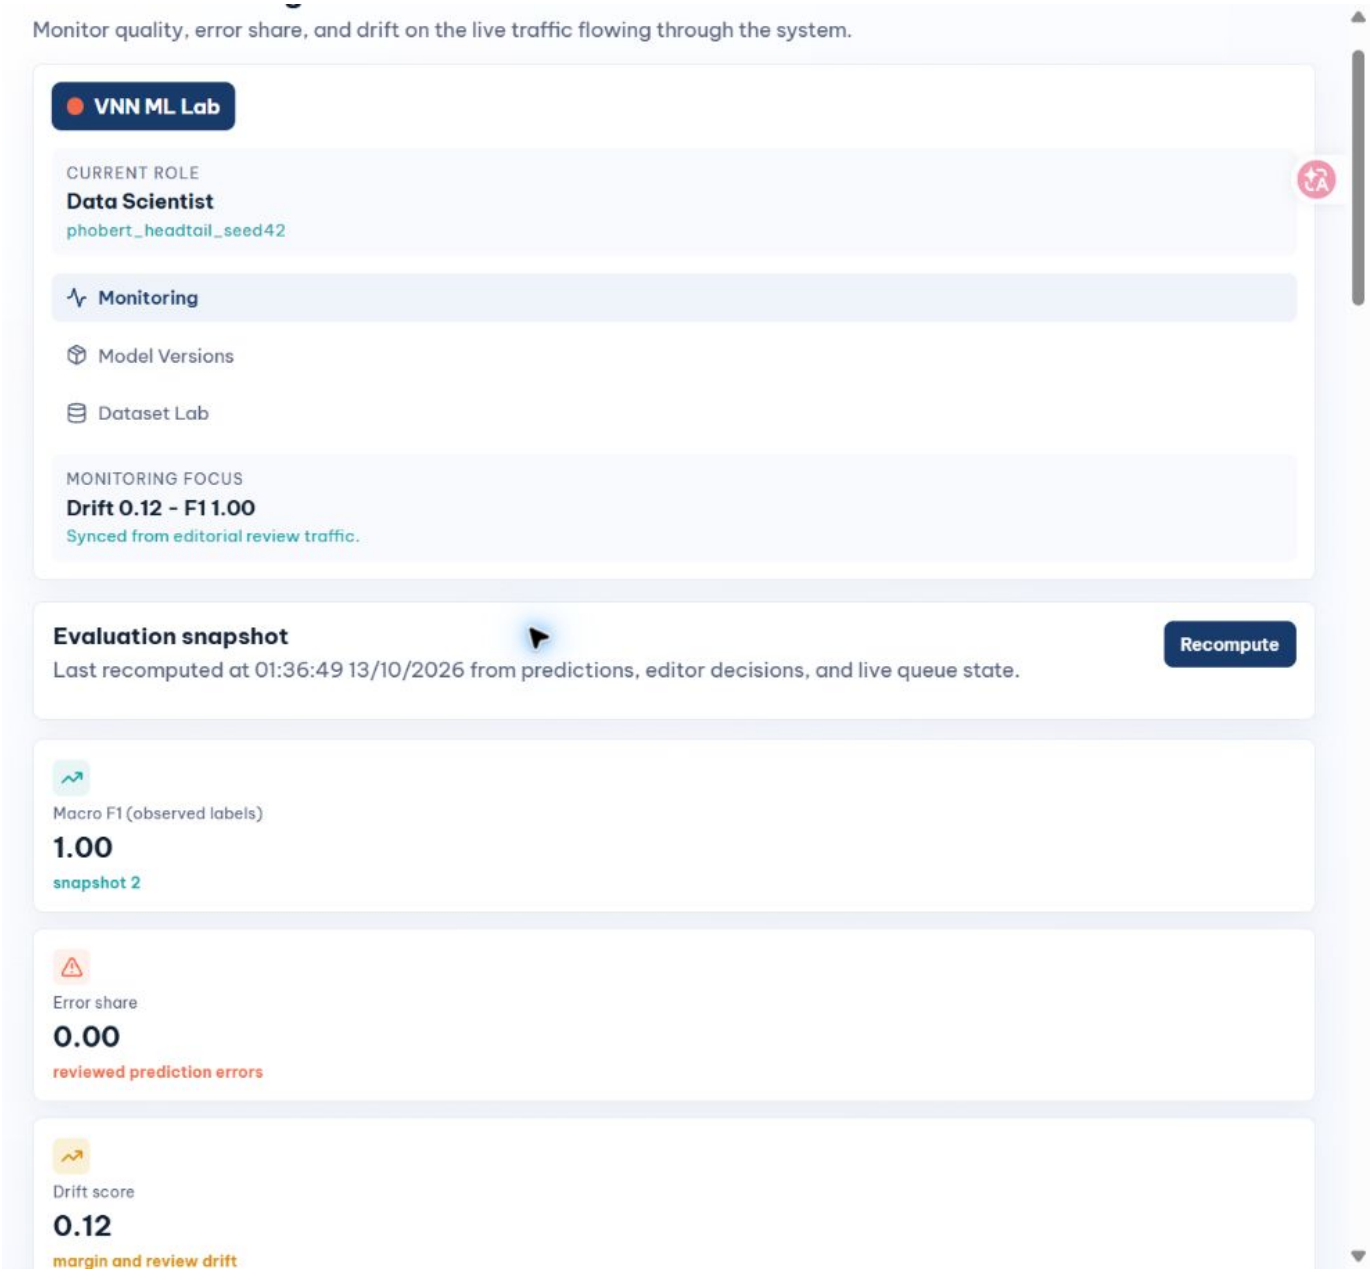


Hình 6.10: Registry của gói PhoBERT 20 lớp; chỉ số offline đọc từ artifact.

Registry hiển thị Macro-F1, ma trận, cấu hình, file xuất và trạng thái active. Upload được kiểm tra tên/path, cấu trúc metadata và khả năng nạp suy luận trước đăng ký. Kích hoạt thay manifest theo thao tác nguyên tử, kiểm tra model service đúng phiên bản và phục hồi manifest nếu thất bại.

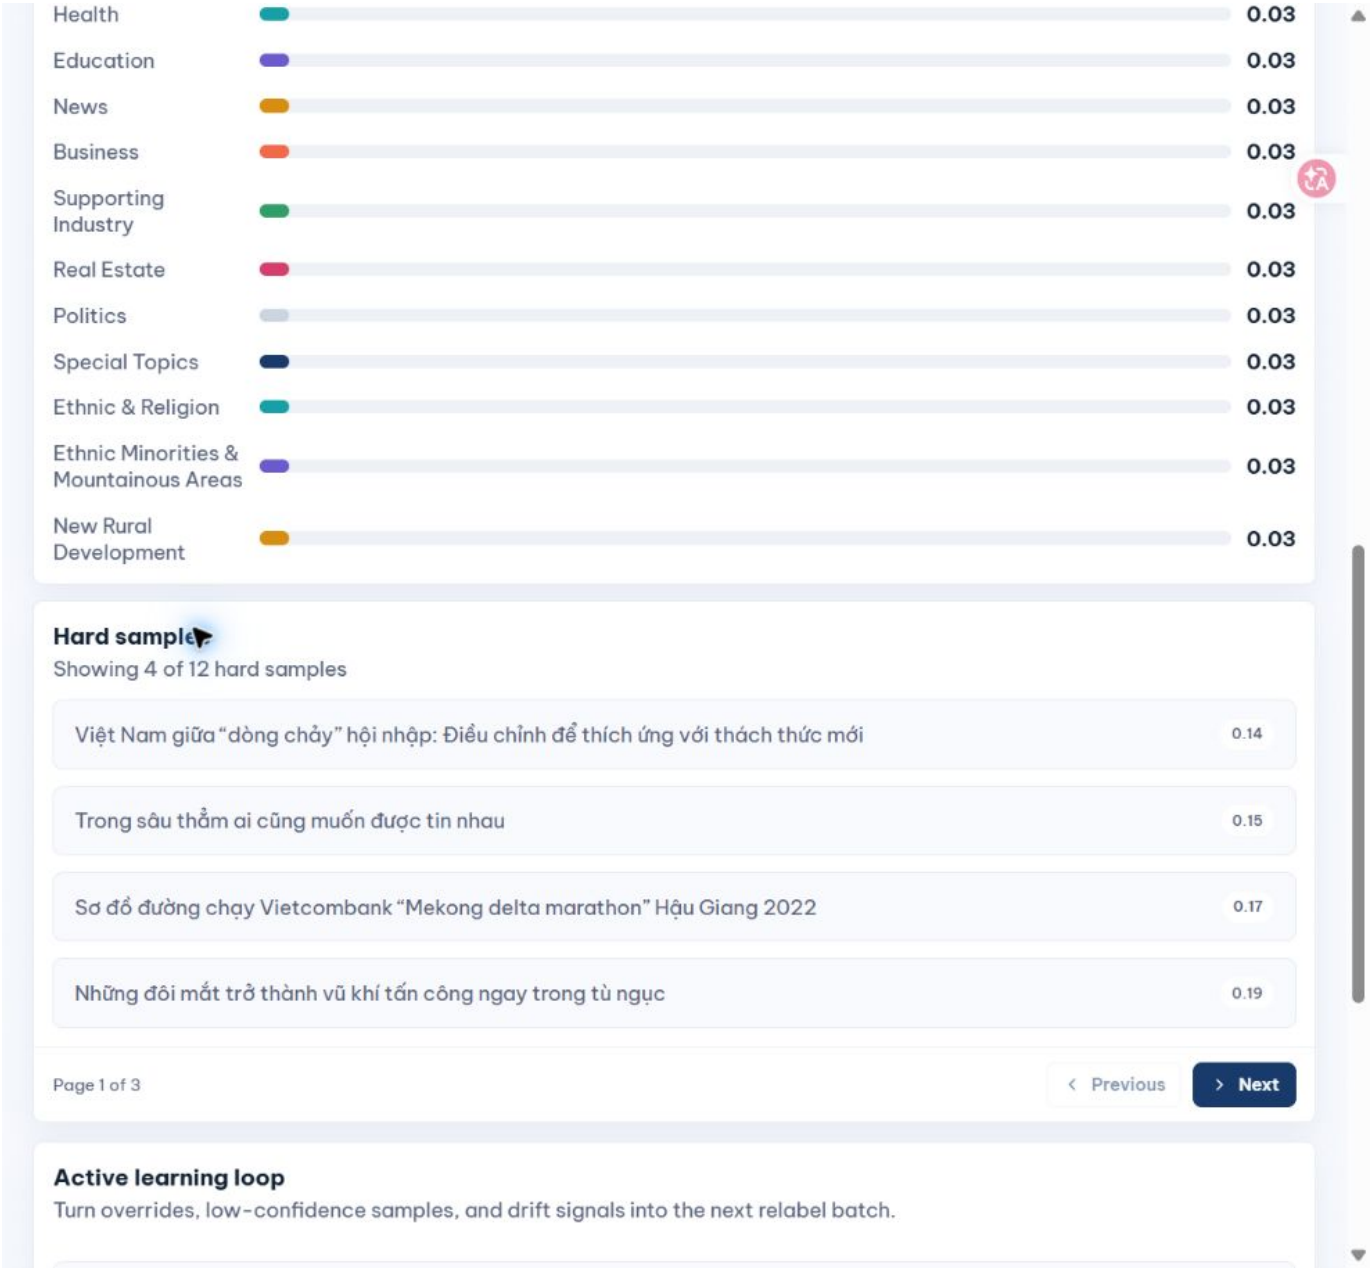


Hình 6.11: Kiểm tra và kích hoạt một gói mô hình có kiểm soát.



Hình 6.12: Monitoring từ nhóm prediction có phản hồi minh họa, không phải chỉ số test offline.

Monitoring ghép phản hồi với prediction tương ứng. Các chỉ số phụ thuộc mẫu đã được rà soát và tập nhãn xuất hiện; không so trực tiếp Macro-F1 này với Macro-F1 offline 20 lớp. Drift score là chỉ báo heuristic từ margin và sai khác phản hồi, chưa là kiểm định phân bố hay bằng chứng model drift. Các phản hồi trong bộ minh họa mô tả thao tác dựa trên nhãn corpus, không phải một đợt đánh giá độc lập bởi biên tập viên. Môi trường production cần secret riêng, TLS, giới hạn request, giám sát tải, retention và quản trị nội dung. Phạm vi triển khai của bài tập lớn là minh họa trên localhost.



Hình 6.13: Dataset Lab theo dõi corpus vận hành và bài khó; không ghi đè dataset huấn luyện.

Dataset Lab hiển thị phân bố bài trong database, confidence thấp và ứng viên relabel. Phân bố 32 bài được chọn để minh họa đầy đủ lớp và tình huống khó, nên không đại diện phân bố 199.965 mẫu training. Hệ thống lưu phản hồi và job, nhưng chưa có vòng tự fine-tuning rồi tự triển khai model.

6.7 Phạm vi minh họa và vận hành

app/demo/postgres.backup chứa schema ứng dụng với 32 bài từ corpus, dự đoán thật của model đang bàn giao và phản hồi minh họa. Backup không chứa dataset hay trọng số. README mô tả chạy, đăng nhập, log, khôi phục và xuất artifact. Các ảnh trong chương là giao diện thực thi của package này, không dùng số liệu hoặc ảnh của một model khác.

7. Kiểm chứng và khả năng tái hiện

7.1 Phân cấp bằng chứng

Output notebook cung cấp bằng chứng thực nghiệm; JSON/Parquet/NPZ cho phép tái tính; app cung cấp bằng chứng phục vụ; ảnh giao diện xác nhận trạng thái người dùng nhìn thấy. Không thay một loại bằng chứng bằng loại khác: app khởi động được không chứng minh nhãn đúng, và ma trận đúng số lượng không chứng minh corpus không có near-duplicates.

Bảng 7.1: Phạm vi kiểm chứng trên sản phẩm.

Phạm vi	Bằng chứng
Notebook dữ liệu	15 cell mã có kết quả; không có output lỗi.
Notebook mô hình	72 cell mã có kết quả; 65 hình; không có output lỗi.
Đánh giá offline	29.995 nhãn sau hiệu chỉnh khớp phép tính của app.
App/API	46 kiểm tra tự động đạt; sáu dịch vụ hoạt động.
Giao diện	Ba vai trò; các trang dùng dữ liệu và dự đoán thật.

Notebook dữ liệu có 15 cell mã đã thực thi và không có output lỗi. Notebook PhoBERT có 72 cell mã, 65 hình và không có output lỗi. Bốn hình dữ liệu cùng 65 hình mô hình tạo 69 PNG riêng 300 dpi. Mỗi hình trong báo cáo lấy từ output tương ứng, trừ sơ đồ TikZ và ảnh app có nguồn được nêu rõ.

7.2 Đối chiếu dữ liệu và kết quả

Số lượt URL, unique URL, Parquet sạch và corpus sau khử trùng được phân biệt. Số mẫu train + validation + test bằng 199.965. Class weights tính từ train; ma trận có 20 hàng/cột và tổng 29.995; tổng hàng khớp support. Tái tính argmax sau temperature và hệ số trên toàn bộ logits test khớp 29.995 nhãn trong predictions và cùng công thức app.

Mapping id2label/label2id của config, label config, calibration và taxonomy phải đồng nhất. Hash trọng số trong active manifest khớp model. Cache được bảo toàn và không dùng làm dữ liệu runtime của app. Thứ tự mẫu được truy vết qua article index, split manifest và hash văn bản, tránh ghép một nhãn dự đoán với bài khác.

7.3 Kiểm tra ứng dụng

Các kiểm tra bao gồm health, ba vai trò đăng nhập, sai mật khẩu, thiếu phiên, truy cập trái vai trò, nội dung rỗng hoặc chỉ ký hiệu, nhãn ngoài taxonomy, ngưỡng đảo thứ tự, bài không

tồn tại, worker Redis–Dramatiq, API của các trang và đăng xuất hủy phiên. Bài minh họa được suy luận thật; không sinh confidence ngẫu nhiên hoặc lấy nhãn tham chiếu thay kết quả model.

Kiểm tra công thức calibration bao gồm nhiệt độ không dương/không hữu hạn và tie theo ID. Frontend được build bằng TypeScript và Vite; giao diện được mở qua trình duyệt để kiểm tra từng vai trò. Chỉ những kiểm tra đã thực thi được ghi là đạt. Không đưa số lượng testcase của một bộ kiểm tra không kèm kết quả vào bằng chứng.

7.4 Trình tự tái hiện

Chạy notebook dữ liệu từ thư mục gốc bằng Python 3.14 để tạo corpus sạch. Chạy notebook PhoBERT với kernel PyTorch CUDA trên GPU NVIDIA. Chế độ fresh bắt đầu fine-tuning từ backbone; các đầu ra được lưu tại dataset, temp, model, result và assets báo cáo. Nội dung HTML có thể thay đổi theo thời điểm, nên crawl lại không cam kết tái tạo đúng số bài của snapshot.

Để xem kết quả mà không train lại, mở output notebook và các file evaluation. Để thực hiện đánh giá lại trong notebook, chọn evaluate với gói tương thích. Để train tiếp, chọn continue và hiểu rằng optimizer/scheduler khởi tạo mới. Những thao tác này khác nhau về mục đích và chi phí; Run All ở chế độ fresh vẫn huấn luyện bảy epoch tối đa.

Ứng dụng khởi động từ gốc bằng Docker Compose; README nêu tài khoản, cổng, backup và log. Báo cáo biên dịch từ source bằng XeLaTeX, BibTeX rồi hai lượt XeLaTeX để giải quyết trích dẫn và tham chiếu. Phông Times New Roman, Cambria Math, khổ A4 và macro trình bày dùng thống nhất theo mẫu.

7.5 Giới hạn tái hiện

Hardware, phiên bản thư viện, precision và kernel có thể thay đổi tốc độ hoặc giá trị số sát ranh giới. Internet ảnh hưởng thu thập và tải backbone. Split seed tái tạo lựa chọn mẫu trong cùng corpus, không thay thế việc khóa snapshot. Metadata môi trường và fingerprint làm rõ phạm vi này; không đưa ra cam kết không có lỗi trong mọi môi trường chưa kiểm tra.

8. Kết luận và hướng phát triển

8.1 Bài toán được giải quyết

Hệ thống phân loại một chuyên mục cho bài tiếng Việt, hỗ trợ rà soát và lưu phản hồi. Thu thập được đặt trong cùng quy trình NLP: mỗi bài được xác minh class, quy mục con về cha, chuyển nhãn trong taxonomy và loại bài ngoài phạm vi. Nhờ đó, dataset không chỉ là danh sách URL gắn nhãn theo nơi phát hiện.

8.2 Phương pháp và kết quả

Corpus 200.337 bài sạch theo URL trở thành 199.965 bài sau khử trùng văn bản. Chia 70/15/15, weighted cross-entropy theo train, fine-tuning toàn bộ PhoBERT, Head–Tail 256 và chọn checkpoint bằng validation tạo một quy trình có thể truy vết. Calibration fit trên validation; test được tách khỏi các bước lựa chọn.

Test 29.995 mẫu đạt Accuracy 91,13% và Macro-F1 87,25% sau hiệu chỉnh. Temperature giảm NLL và ECE đáng kể hơn mức tăng nhãn đúng; hiệu chỉnh class chỉ giảm ròng 13 lỗi. Lớp Nông thôn mới F1 46,39% là hạn chế chính, cùng các ranh giới giữa chuyên đề, dân tộc, du lịch và đời sống. Không diễn giải điểm tổng thể thành chất lượng đồng đều.

Ứng dụng dùng đúng gói model, tiền xử lý và calibration, có phân quyền, worker, registry, lưu prediction và review. Chức năng minh họa thể hiện việc dùng mô hình trong một quy trình có người ra quyết định. Chỉ số monitoring và bộ ví dụ giao diện có phạm vi riêng, không được cộng vào kết quả test.

8.3 Các giới hạn quyết định mức thuyết phục

Một nguồn dữ liệu, một seed, không có baseline cùng giao thức và chưa có ablation làm hạn chế kết luận về ưu thế phương pháp. Exact dedup không giải quyết toàn bộ near-duplicates; nhãn chuyên mục không phải gán nhãn ngữ nghĩa độc lập. Head–Tail bỏ phần giữa, pipeline bỏ chữ số/dấu câu và PyVi khác bộ phân đoạn tiền huấn luyện. Không có phép kiểm tra ngoài miền hoặc theo thời gian.

8.4 Ưu tiên phát triển

Ưu tiên kiểm toán nhãn nhóm Nông thôn mới–Nội dung chuyên đề và phát hiện gần trùng. Đối chứng cần có TF–IDF tuyến tính cùng split, nhiều seed, khoảng tin cậy và ablation Head–Tail, phân đoạn, chữ số. Validation phục vụ lựa chọn; test theo thời gian xác nhận tổng quát hóa.

Tài liệu tham khảo

[1] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*, pages 4171–4186, 2019. doi: 10.18653/v1/N19-1423. URL https://aclanthology.org/N19-1423/.

[2] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning*, volume 70, pages 1321–1330, 2017. URL https://proceedings.mlr.press/v70/guo17a.html.

[3] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. Roberta: A robustly optimized bert pretraining approach, 2019. URL https://arxiv.org/abs/1907.11692.

[4] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations*, 2019. URL https://arxiv.org/abs/1711.05101.

[5] Dat Quoc Nguyen and Anh Tuan Nguyen. Phobert: Pre-trained language models for vietnamese. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 1037–1042, 2020. doi: 10.18653/v1/2020.findings-emnlp.92. URL https://aclanthology.org/2020.findings-emnlp.92/.

[6] Viet Trung Tran. Pyvi: Python vietnamese toolkit, s.d. URL https://github.com/trungtv/pyvi. Mã nguồn toolkit tách từ tiếng Việt; truy cập tháng 10/2026.

[7] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017. URL https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html.

[8] VinAI Research. Phobert-base-v2 model card. Hugging Face, s.d. URL https://huggingface.co/vinai/phobert-base-v2. Truy cập tháng 10/2026.

A. Bằng chứng và chỉ dẫn đối chiếu

A.1 Môi trường thực nghiệm

Python 3.14.7; PyTorch 2.11.0+cu128; CUDA 12.8; Transformers 5.17.0; NumPy 2.5.2; pandas 3.0.6; scikit-learn 1.9.1; PyArrow 26.0.0; PyVi 0.1.1. GPU RTX A3000 Laptop 12 GB; một GPU, BF16/TF32, batch train 32, tích lũy 2 và eval 64. Model checkpoint và tokenizer được giữ cùng cấu hình. Metadata đánh giá ghi thời gian test 106,322 giây không gồm nạp model.

A.2 Chỉ dẫn đọc từng cell notebook PhoBERT

Mã cell dưới đây là vị trí bắt đầu từ 1 trong file, bao gồm markdown. Số thực thi là execution count trong output; số hình là PNG hiển thị của cell đó. Nội dung được đọc theo nhóm chức năng do notebook quy định.

Bảng A.1: Chỉ dẫn cell PhoBERT 1–29.

Cell	Lần chạy	Nội dung	Hình
1	–	Huấn luyện và đánh giá PhoBERT (mô tả)	0
2	–	Môi trường thực thi (mô tả)	0
3	1	Môi trường thực thi	0
4	–	Kiểm tra thư viện (mô tả)	0
5	2	Kiểm tra thư viện	0
6	3	Kiểm tra thư viện	0
7	–	Kiểm tra dataset đầu vào (mô tả)	0
8	4	Kiểm tra dataset đầu vào	0
9	5	Kiểm tra dataset đầu vào	0
10	–	Thiết lập môi trường (mô tả)	0
11	6	Thiết lập môi trường	0
12	7	Thiết lập môi trường	0
13	8	Thiết lập môi trường	0
14	9	Thiết lập môi trường	0
15	–	Đọc dữ liệu thô (mô tả)	0
16	10	Đọc dữ liệu thô	0
17	–	Khám phá dữ liệu (mô tả)	0
18	11	Khám phá dữ liệu	1
19	12	Khám phá dữ liệu	1
20	13	Khám phá dữ liệu	1
21	14	Khám phá dữ liệu	1
22	15	Khám phá dữ liệu	1
23	16	Khám phá dữ liệu	0
24	–	Tiền xử lý văn bản (mô tả)	0
25	17	Tiền xử lý văn bản	0
26	18	Tiền xử lý văn bản	0
27	19	Tiền xử lý văn bản	1
28	–	Tokenize Head-Tail và chia train, validation và test (mô tả)	0
29	20	Tokenize Head-Tail và chia train, validation và test	0

Bảng A.2: Chỉ dẫn cell PhoBERT 30–58.

Cell	Lần chạy	Nội dung	Hình
30	21	Tokenize Head-Tail và chia train, validation và test	0
31	22	Tokenize Head-Tail và chia train, validation và test	1
32	23	Tokenize Head-Tail và chia train, validation và test	1
33	24	Tokenize Head-Tail và chia train, validation và test	1
34	25	Tokenize Head-Tail và chia train, validation và test	1
35	–	Huấn luyện mô hình (mô tả)	0
36	26	Huấn luyện mô hình	0
37	27	Huấn luyện mô hình	0
38	–	Đánh giá mô hình (mô tả)	0
39	28	Đánh giá mô hình	0
40	29	Đánh giá mô hình	1
41	30	Đánh giá mô hình	1
42	31	Đánh giá mô hình	1
43	32	Đánh giá mô hình	1
44	33	Đánh giá mô hình	1
45	34	Đánh giá mô hình	1
46	35	Đánh giá mô hình	1
47	36	Đánh giá mô hình	1
48	37	Đánh giá mô hình	1
49	38	Đánh giá mô hình	1
50	39	Đánh giá mô hình	1
51	40	Đánh giá mô hình	0
52	–	Xuất cấu hình mô hình (mô tả)	0
53	41	Xuất cấu hình mô hình	0
54	–	Đánh giá hiệu chỉnh trên test (mô tả)	0
55	42	Đánh giá hiệu chỉnh trên test	0
56	43	Đánh giá hiệu chỉnh trên test	0
57	44	Đánh giá hiệu chỉnh trên test	1
58	45	Đánh giá hiệu chỉnh trên test	1

Bảng A.3: Chỉ dẫn cell PhoBERT 59–87.

Cell	Lần chạy	Nội dung	Hình
59	46	Đánh giá hiệu chỉnh trên test	0
60	–	Chẩn đoán mô hình (mô tả)	0
61	47	Chẩn đoán mô hình	0
62	–	Xuất kết quả và phân tích trực quan (mô tả)	0
63	48	Xuất kết quả và phân tích trực quan	0
64	49	Xuất kết quả và phân tích trực quan	1
65	50	Xuất kết quả và phân tích trực quan	1
66	51	Xuất kết quả và phân tích trực quan	1
67	52	Xuất kết quả và phân tích trực quan	1
68	53	Xuất kết quả và phân tích trực quan	1
69	54	Xuất kết quả và phân tích trực quan	1
70	55	Xuất kết quả và phân tích trực quan	1
71	56	Xuất kết quả và phân tích trực quan	1
72	57	Xuất kết quả và phân tích trực quan	1
73	58	Xuất kết quả và phân tích trực quan	1
74	59	Xuất kết quả và phân tích trực quan	1
75	60	Xuất kết quả và phân tích trực quan	1
76	61	Xuất kết quả và phân tích trực quan	1
77	62	Xuất kết quả và phân tích trực quan	1
78	63	Xuất kết quả và phân tích trực quan	1
79	64	Xuất kết quả và phân tích trực quan	1
80	65	Xuất kết quả và phân tích trực quan	1
81	66	Xuất kết quả và phân tích trực quan	1
82	67	Xuất kết quả và phân tích trực quan	1
83	68	Xuất kết quả và phân tích trực quan	1
84	69	Xuất kết quả và phân tích trực quan	1
85	70	Xuất kết quả và phân tích trực quan	20
86	71	Xuất kết quả và phân tích trực quan	1
87	72	Xuất kết quả và phân tích trực quan	0

A.3 Các kiểm tra ứng dụng được thực thi

Bảng A.4: Kiểm tra hợp đồng model và ứng dụng 1–23.

ID	Kiểm tra đạt
1	Model SHA-256 và taxonomy 20 lớp
2	Toàn bộ 29.995 quyết định sau hiệu chỉnh khớp app
3	Từ chối nhiệt độ không hợp lệ 0
4	Từ chối nhiệt độ không hợp lệ -1
5	Từ chối nhiệt độ không hợp lệ inf
6	Từ chối nhiệt độ không hợp lệ nan
7	Tie-breaking theo ID
8	Health model
9	Thiếu phiên trả 401
10	Sai mật khẩu trả 401
11	Đăng nhập editor
12	Đăng nhập admin
13	Đăng nhập data-scientist
14	Phân quyền editor /admin/ops
15	Phân quyền editor /scientist/monitoring
16	Phân quyền admin /editor/dashboard
17	Phân quyền data-scientist /admin/ops
18	Bài rỗng trả 422
19	Văn bản chỉ chữ số và ký hiệu trả 422
20	Nhãn ngoài taxonomy trả 422
21	Ngưỡng định tuyến đảo ngược trả 422
22	Worker import Redis–Dramatiq
23	Giao diện/API /editor/dashboard

Bảng A.5: Kiểm tra hợp đồng model và ứng dụng 24–46.

ID	Kiểm tra đạt
24	Giao diện/API /editor/review
25	Giao diện/API /editor/classifier
26	Giao diện/API /admin/ops
27	Giao diện/API /scientist/monitoring
28	Giao diện/API /scientist/model-versions
29	Giao diện/API /scientist/dataset-lab
30	Monitoring được tính lại
31	Article không tồn tại trả 404
32	Đăng xuất hủy phiên editor
33	Đăng xuất hủy phiên admin
34	Đăng xuất hủy phiên data-scientist
35	Head–Tail ranh giới 0
36	Head–Tail ranh giới 1
37	Head–Tail ranh giới 253
38	Head–Tail ranh giới 254
39	Head–Tail ranh giới 255
40	Head–Tail ranh giới 256
41	Head–Tail ranh giới 1000
42	Tiền xử lý ví dụ UNIQLO khớp output notebook
43	Tensor checkpoint có đúng 135.013.652 tham số
44	Registry đọc đúng gói 20 lớp và 29.995 mẫu test
45	32 dự đoán CPU thực tế khớp nhãn offline
46	Khôi phục backup riêng: 32 bài, 32 dự đoán, 10 phản hồi, không phiên đăng nhập

A.4 Ví dụ truy vết của lỗi test

A.4.1 Ví dụ 1

Vệ tinh AI Trung Quốc giúp Iran săn lùng căn cứ Mỹ tại Trung Đông?

Nhãn tham chiếu: Công nghệ; dự đoán: Thế giới; confidence 0,9882; margin 0,9787.

URL: https://vietnamnet.vn/ve-tinh-ai-trung-quoc-giup-iran-san-lung-can-cu-my-tai-trung-dong-2504640.html.

Theo hãng tinABC News,ngày 5/4, các quan chức từ Cơ quan Tình báo Quốc phòng Mỹ (DIA) nhận định Lực lượng Vệ binh Cách mạng Hồi giáo Iran (IRGC) đang sử dụng các bộ dữ liệu do công ty trí tuệ nhân tạo không gian địa lý Trung Quốc MizarVision công bố để hỗ trợ lên kế hoạch tấn công bằng tên lửa và máy bay không người lái. Nhận định cho biết hình ảnh này bao gồm tính năng tự động nhận dạng và gắn thẻ đối tượng, cho phép người điều khiển xác định các tài sản và cơ sở hạ tầng quân sự nhanh hơn nhiều so với phân tích truyền thống. TheoABC News, MizarVision đã công bố hình ảnh vệ tinh độ phân giải c…

A.4.2 Ví dụ 2

Báo chí quốc tế đưa tin Tổng Bí thư Nguyễn Phú Trọng từ trần

Nhãn tham chiếu: Chính trị; dự đoán: Thế giới; confidence 0,9871; margin 0,9752.

URL: https://vietnamnet.vn/bao-chi-quoc-te-dua-tin-tong-bi-thu-nguyen-phu-trong-tu-tran-2304216.html.

Hãng thông tấn Trung Quốc Xinhua đưa tin Tổng Bí thư Đảng Cộng sản Việt Nam Nguyễn Phú Trọng từ trần ở tuổi 80 và đăng chùm ảnh về những hoạt động của Tổng Bí thư tại các sự kiện quan trọng. Báo Granma của Cuba đưa tin, Tổng Bí thư Nguyễn Phú Trọng, một người bạn thuỷ chung của Cuba, từ trần vì tuổi cao, bệnh nặng, dù được bác sĩ tận tình cứu chữa, gia đình hết lòng chăm sóc. Hãng thông tấn Cuba (ACN) ngày 19/7 cho biết, được tin Tổng Bí thư Đảng Cộng sản Việt Nam Nguyễn Phú Trọng từ trần, các đại biểu Quốc hội Cuba đã dành một phút mặc niệm tưởng nhớ đồng chí tại hội trường chính của Trung tâ…

A.4.3 Ví dụ 3

Giá thuê nhà tại Los Angeles tăng chóng mặt sau thảm họa cháy rừng

Nhãn tham chiếu: Bất động sản; dự đoán: Thế giới; confidence 0,9869; margin 0,9772.

URL: https://vietnamnet.vn/gia-thue-nha-tai-los-angeles-tang-chong-mat-sau-tham-hoa-chay-rung-2364710.html.

Theo NBC News, nhiều người dân tại thành phố Los Angeles đã đổ xô đi tìm nhà ở trong khi các vụcháy rừngvẫn đang diễn ra. Điều này dẫn đến một số chủ nhà và người môi giới tăng tiền thuê nhà lên quá cao. Vụ cháy rừng đã khiến ông Joe Thompson phải đi tìm nơi ở mới cho gia đình. Khi đến thành phố Santa Monica, tiểu bang California, ông tìm được căn nhà 5 phòng ngủ với giá chào thuê 28.000 USD/tháng, cao gấp đôi so với năm ngoái. Người môi giới yêu cầu ông phải trả tiền thuê trước 3 tháng và cho biết đã có nhiều người hỏi thuê. Không thể chi trả mức giá thuê quá cao này, ông Joe Thompson nói rằn…

A.4.4 Ví dụ 4

Một tài xế dùng biển giả bị phạt 17,6 triệu đồng, tước bằng lái 3 tháng

Nhãn tham chiếu: Thời sự; dự đoán: Ô tô - Xe máy; confidence 0,9868; margin 0,9908.

URL: https://vietnamnet.vn/mot-tai-xe-dung-bien-gia-bi-phat-17-6-trieu-dong-tuoc-bang-lai-3-thang-2045784.html.

Ngày 29/7, Đội CSGT số 1, Phòng CSGT đường bộ - đường sắt đã ra quyết định xử phạt vi phạm hành chính, phạt tiền 17,6 triệu đồng, tước quyền sử dụng giấy phép lái xe 03 tháng và tịch thu biển số xe 30G-688.68 đối với lái xe N.V.T (SN 1984, trú tại huyện Yên Phong, tỉnh Bắc Ninh). Trước đó, thông qua trao đổi từ Công ty cổ phần giao thông số Việt Nam trong quá trình thu phí theo hình thức điện tử không dừng (ETC) đã phát hiện một số ô tô cố tình gắn biển số của xe khác để lưu thông qua trạm thu phí, Đội CSGT số 1, Phòng CSGT đường bộ - đường sắt đã tăng cường tuần tra kiểm soát. Trong quá trình…

A.4.5 Ví dụ 5

Ấm lòng với hành động nam thanh niên đi xe máy dìu cháu nhỏ qua đường

Nhãn tham chiếu: Bạn đọc; dự đoán: Ô tô - Xe máy; confidence 0,9865; margin 0,9907.

URL: https://vietnamnet.vn/am-long-voi-hanh-dong-nam-thanh-nien-di-xe-may-diu-chau-nho-qua-duong-740420.html.

Hành động đẹp này được camera hành trình của một xe ô tô ghi lại trên tuyến đường Quang Trung (quận Hà Đông, Hà Nội). Theo đoạn video trên, một bé gái khoảng 9 tuổi đang đứng một mình giữa dòng phương tiện qua lại đông đúc để chờ sang đường. Lúc này, nam thanh niên điều khiển chiếcHonda WaveAlpha trong bộ đồng phục công nhân đã không ngại ngần dừng lại và dìu cháu bé sang đường an toàn. Thời điểm trên, đường Quang Trung đang có rất nhiều phương tiện qua lại với tốc độ cao như xe buýt, container, xe tải,... rất nguy hiểm nếu cháu bé sang đường một mình. Nhưng chỉ với một hành động nhỏ, nam than…

A.4.6 Ví dụ 6

Ô tô mới có thể được miễn đăng kiểm lần đầu từ năm 2023

Nhãn tham chiếu: Thời sự; dự đoán: Ô tô - Xe máy; confidence 0,9862; margin 0,9904.

URL: https://vietnamnet.vn/o-to-moi-co-the-duoc-mien-dang-kiem-lan-dau-tu-nam-2023-2094970.html.

Xe mới sẽ được miễn đăng kiểm một năm Thông tin tớiVietNamNetvào sáng 28/12, đại diện Cục Đăng kiểm Việt Nam cho biết, sau 6 tháng đánh giá tác động kết hợp với việc nghiên cứu các yếu tố kỹ thuật và dữ liệu thực tế, Cục Đăng kiểm Việt Nam đã tổng hợp trình Bộ GTVT phương án thực hiện miễnđăng kiểmlần đầu cho xe ô tô sản xuất, lắp ráp, nhập khẩu mới trong thời gian một năm tính từ năm sản xuất. Phương án trên đã được Cục Đăng kiểm Việt Nam đăng ký vào chương trình xây dựng văn bản quy phạm pháp luật năm 2023 của Bộ GTVT và đang thực hiện các bước xây dựng dự thảo bổ sung, sửa đổi 16/2021/TT-BG…

A.4.7 Ví dụ 7

Hạ 2 tiêm kích F-14 Iran chóng vánh: Israel áp đảo công nghệ quân sự?

Nhãn tham chiếu: Công nghệ; dự đoán: Thế giới; confidence 0,9853; margin 0,9695.

URL: https://vietnamnet.vn/ha-2-tiem-kich-f-14-iran-chong-vanh-israel-ap-dao-cong-nghe-quan-su-2412817.html.

Quân đội Israel (IDF) mới đây đã công bố đoạn video ghi lại khoảnh khắc phá hủy haitiêm kích F-14Tomcat đỗ ngoài trời của Iran. Địa điểm không kích là một căn cứ quân sự gần thành phố Isfahan, Iran. Các cuộc không kích, được thực hiện dưới điều kiện mà giới chức Israel mô tả là ”kiểm soát hoàn toàn không phận”, đánh dấu sự leo thang đáng kể trong cuộcxung đột Israel - Iran. Khoảnh khắc Israel phá hủy 2 chiến đấu cơ Iran. Nguồn: Times of Israel Chiến dịch này, được xác nhận qua hình ảnh trên không do Lực lượng Phòng vệ Israel (IDF) công bố, đã nhắm vào một căn cứ không quân trọng yếu ở trung tâ…

A.4.8 Ví dụ 8

Vì sao lần nữa, lại là Pháp?

Nhãn tham chiếu: Tuần Việt Nam; dự đoán: Thế giới; confidence 0,9847; margin 0,9630.

URL: https://vietnamnet.vn/vi-sao-lan-nua-lai-la-phap-273204.html.

- Điều kinh hoàng lại xảy ra ở Paris. Các thi thể nằm trên đường phố, gia đình bạn bè điên cuồng gọi điện thoại, hoảng loạn tìm người thân. Cả một quốc gia trong cơn địa chấn. Một năm bắt đầu với thảm kịch Charlie Hebdo và kết thúc với một làn sóng tấn công mới dữ dội hơn. Tình trạng khẩn cấp quốc gia được ban bố. Lần mới nhất nước Pháp áp dụng nó là năm 2005 khi các cuộc bạo động ở ngoại ô Paris bùng nổ giữa những người trẻ tuổi (chủ yếu là Hồi giáo) hoặc người nhập cư thế hệ hai và lực lượng cảnh sát. Những ngọn nến được thắp lên ở San Francisco, California. Ảnh: Reuters Quá sớm để nói chính…

A.4.9 Ví dụ 9

Tổng thống Nga Putin đi đâu, chơi gì khi rảnh rỗi?

Nhãn tham chiếu: Du lịch; dự đoán: Thế giới; confidence 0,9844; margin 0,9721.

URL: https://vietnamnet.vn/tong-thong-nga-putin-di-dau-choi-gi-khi-ranh-roi-2293553.html.

Mặc dù Tổng thống Putin, cũng giống như tất cả các công chức khác ở Nga, được nghỉ phép 30 ngày/năm nhưng ông hiếm khi nghỉ thời gian dài. Kỳ nghỉ của ông thường ngắn, chỉ vài ngày. Theo trang Russia Beyond, có một vài điểm đến ở Nga mà Tổng thống đặc biệt yêu thích. Cộng hòa Tuva (thuộc Nga) Nhiều người từng thấy bức ảnh ông Putin cưỡi ngựa đầy oai vệ. Theo nhà báo người Áo Armin Wolf, bức ảnh được chụp vào tháng 8/2009 trong kỳ nghỉ của ông Putin ở Cộng hòa Tuva, một trong những điểm đến yêu thích của Tổng thống Nga. Con ngựa được ông Putin cưỡi là của một người chăn cừu địa phương sống gần …

A.4.10 Ví dụ 10

Ô tô đang chạy, cả nhà lịm dần vì ngộ độc khí: Cảnh báo nguy hiểm, đừng xem nhẹ

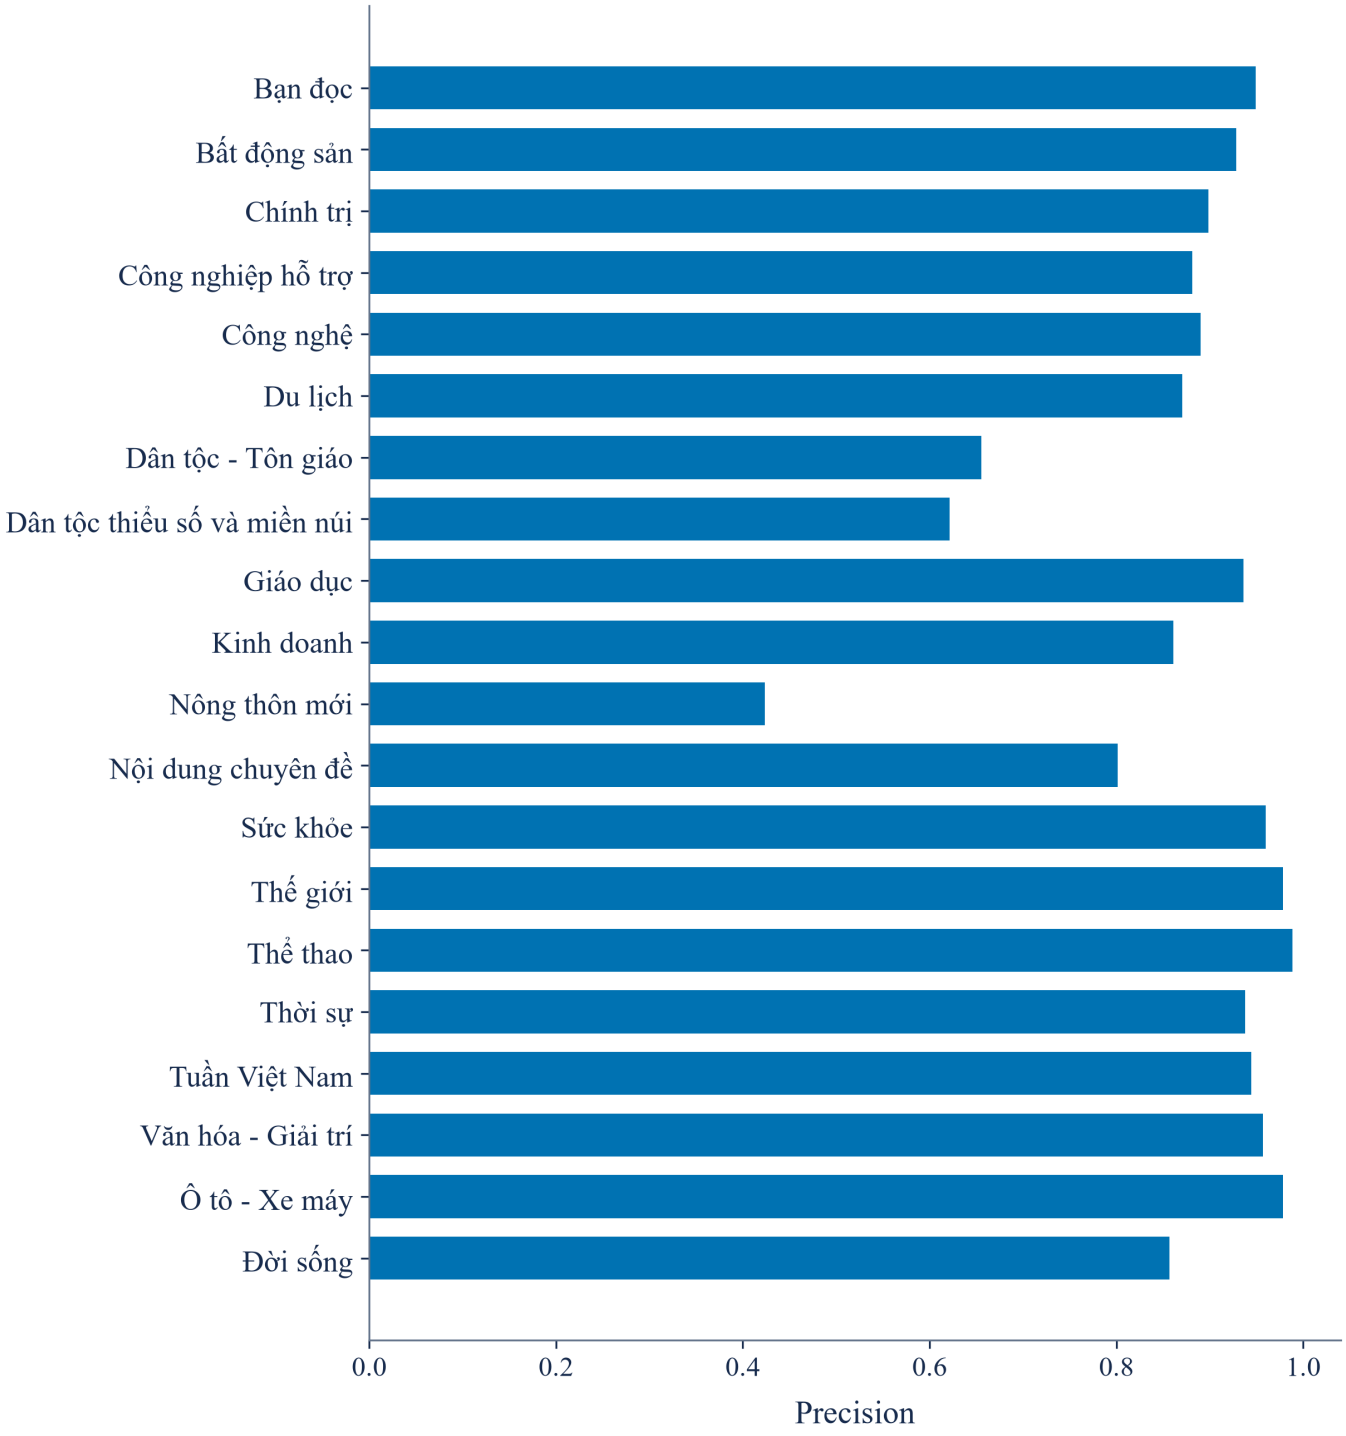
Nhãn tham chiếu: Ô tô - Xe máy; dự đoán: Sức khỏe; confidence 0,9842; margin 0,9589.

URL: https://vietnamnet.vn/o-to-dang-chay-ca-nha-lim-dan-vi-ngo-doc-khi-canh-bao-nguy-hiem-dung-xem-nhe-2422455.html.

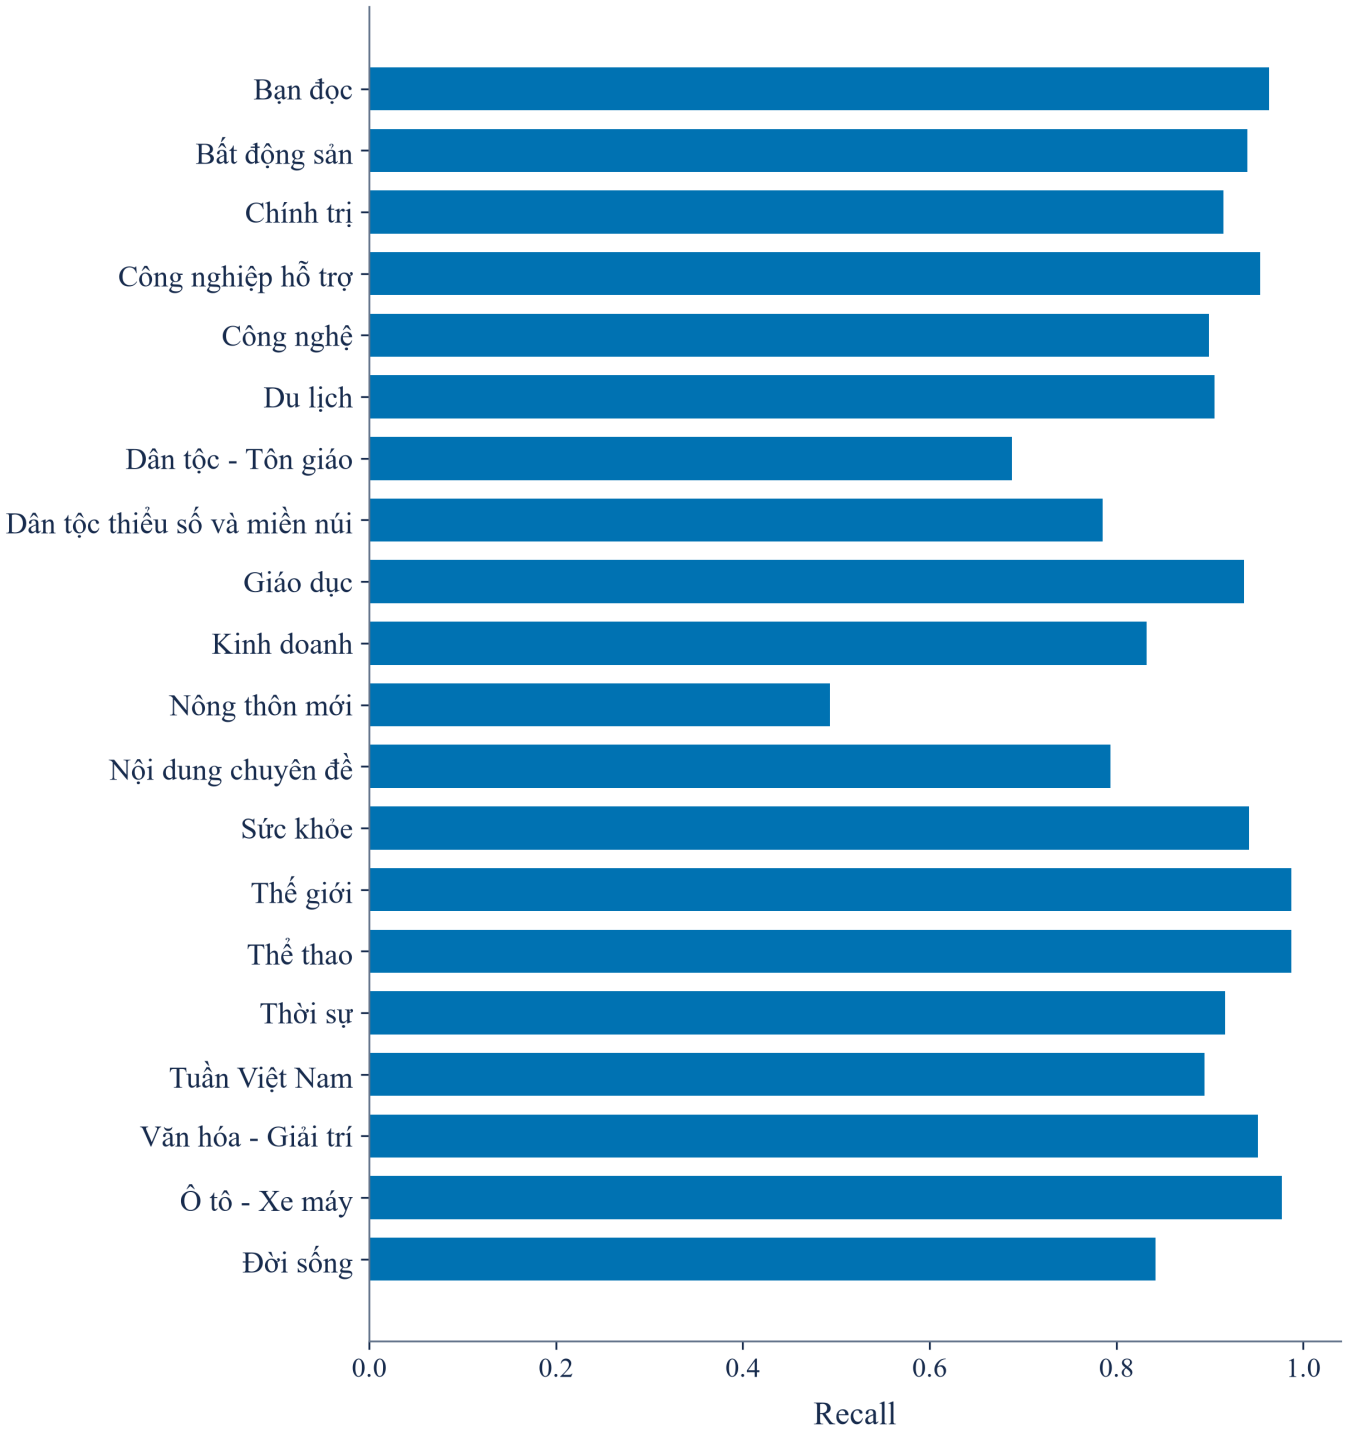
Mới đây, Bệnh viện Sản nhi Ninh Bình cho biết, Khoa Cấp cứu vừa tiếp nhận và điều trị cho hai bệnh nhi là anh em ruột trong tình trạng co giật, mắt trợn, tay chân co cứng, lơ mơ và mất ý thức. Điều đáng chú ý là bố mẹ của hai bé cũng có biểu hiện tương tự, như choáng váng và đau đầu nhẹ. Sự việc xảy ra sau khi cả gia đình di chuyển bằng ô tô hơn một tiếng từ phường Hoa Lư theo hướng tỉnh Hà Nam (cũ). Các bác sĩ chẩn đoán nguyên nhân có thể là do ngộ độckhí thải ô tô. Rất may, hai bé được đưa đến viện và xử lý kịp thời nên đã qua cơn nguy hiểm, sức khỏe ổn định và đã được xuất viện. Anh Trần Vă…

A.5 Các hình chẩn đoán riêng trước hiệu chỉnh

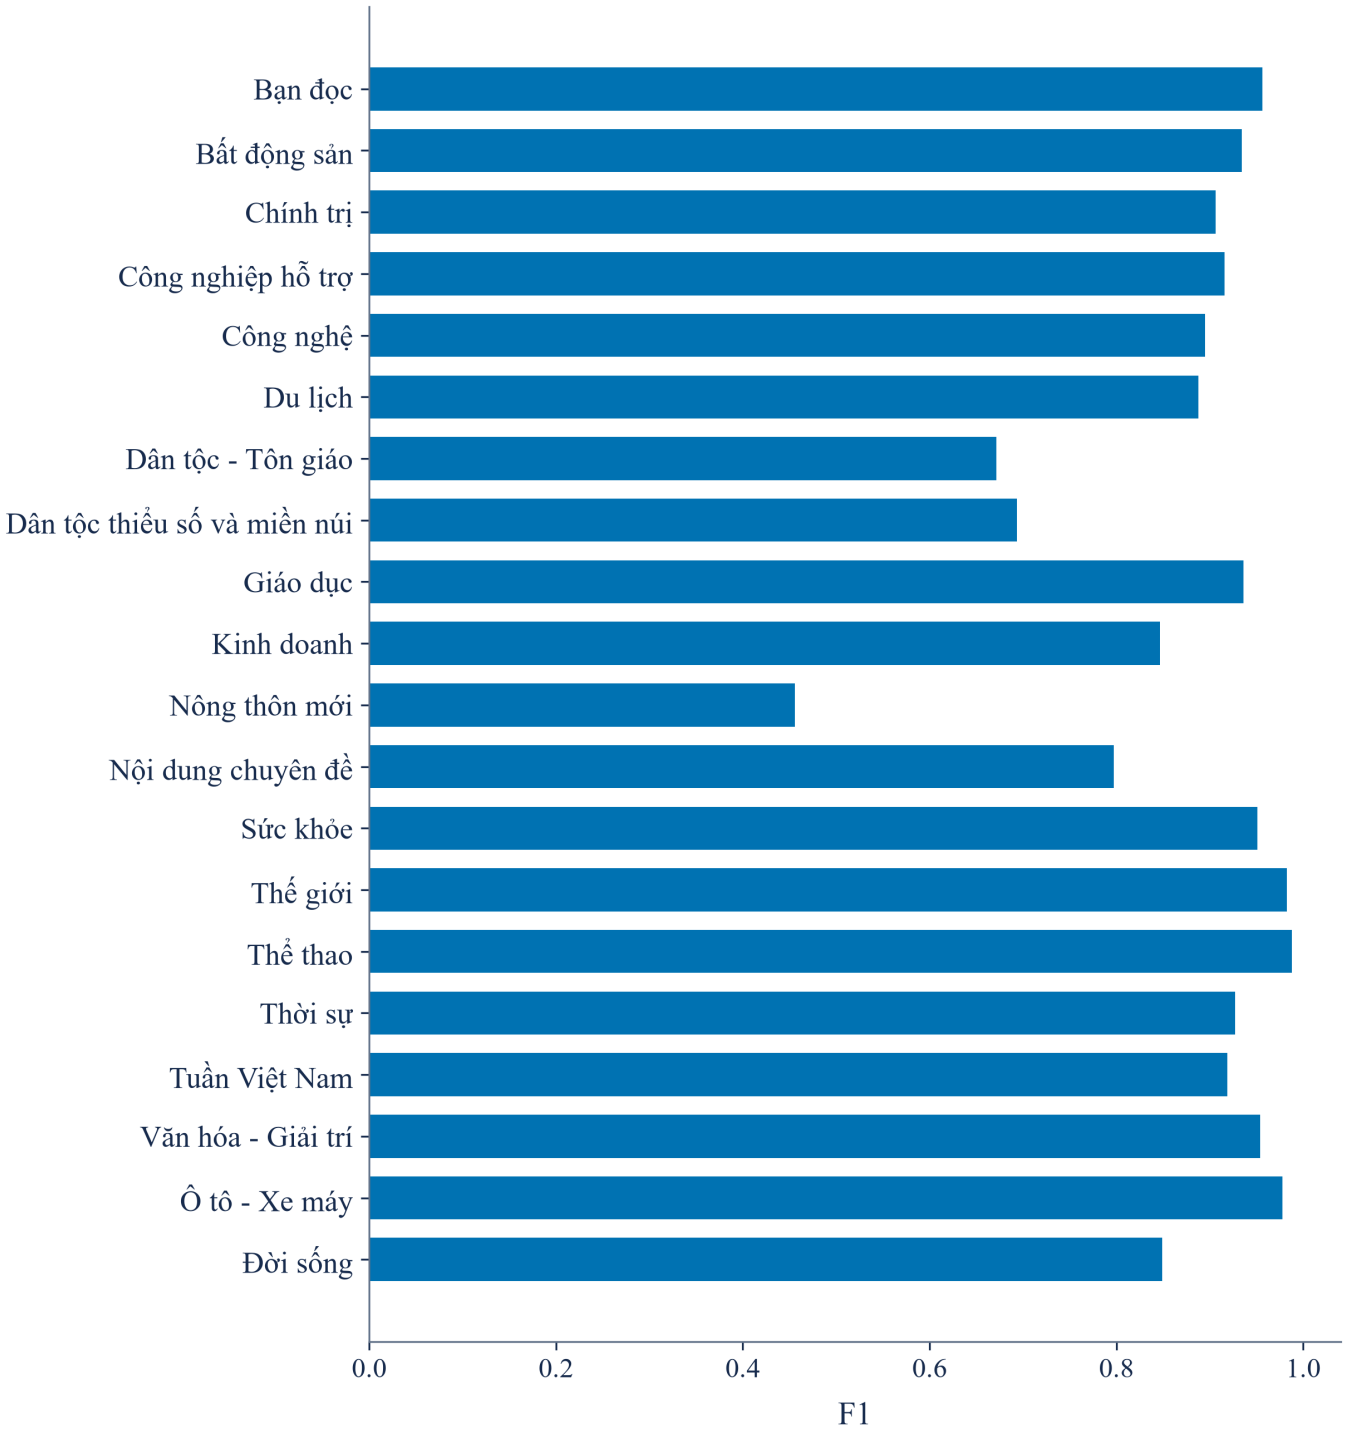
Các biểu đồ sau cung cấp trạng thái trước hiệu chỉnh để đối chiếu với hình so sánh ở chương kết quả. Mỗi biểu đồ là một output riêng của notebook.



Hình A.1: Precision theo 20 lớp trước hiệu chỉnh.



Hình A.2: Recall theo 20 lớp trước hiệu chỉnh.

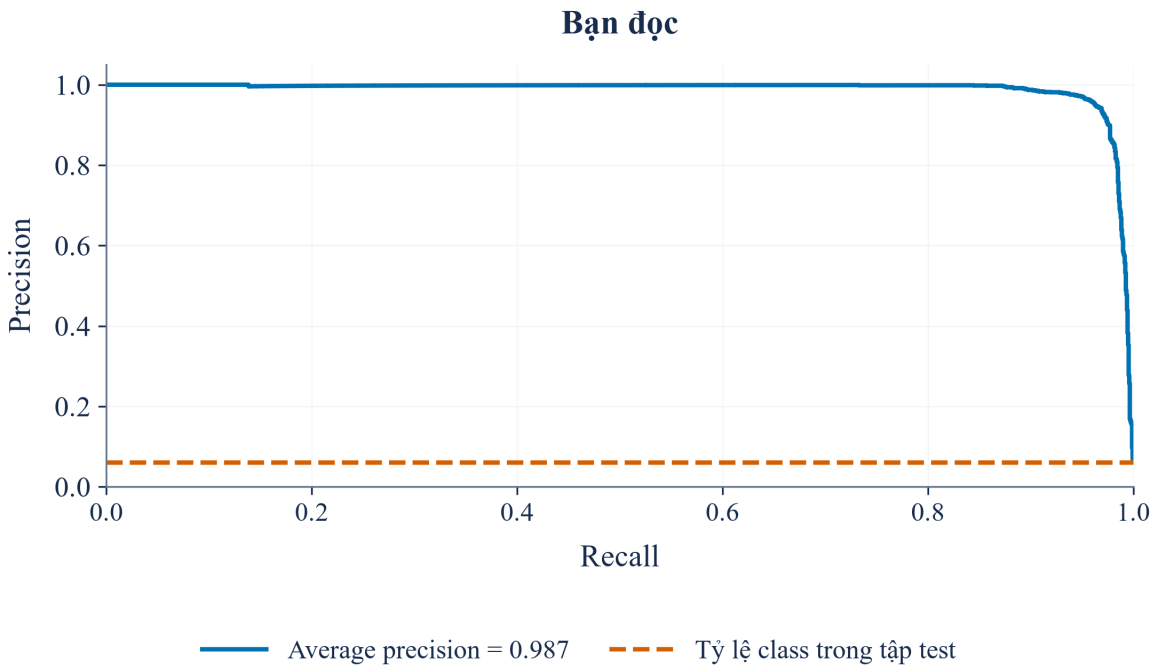


Hình A.3: F1 theo 20 lớp trước hiệu chỉnh.

A.6 Hai mươi đường Precision–Recall

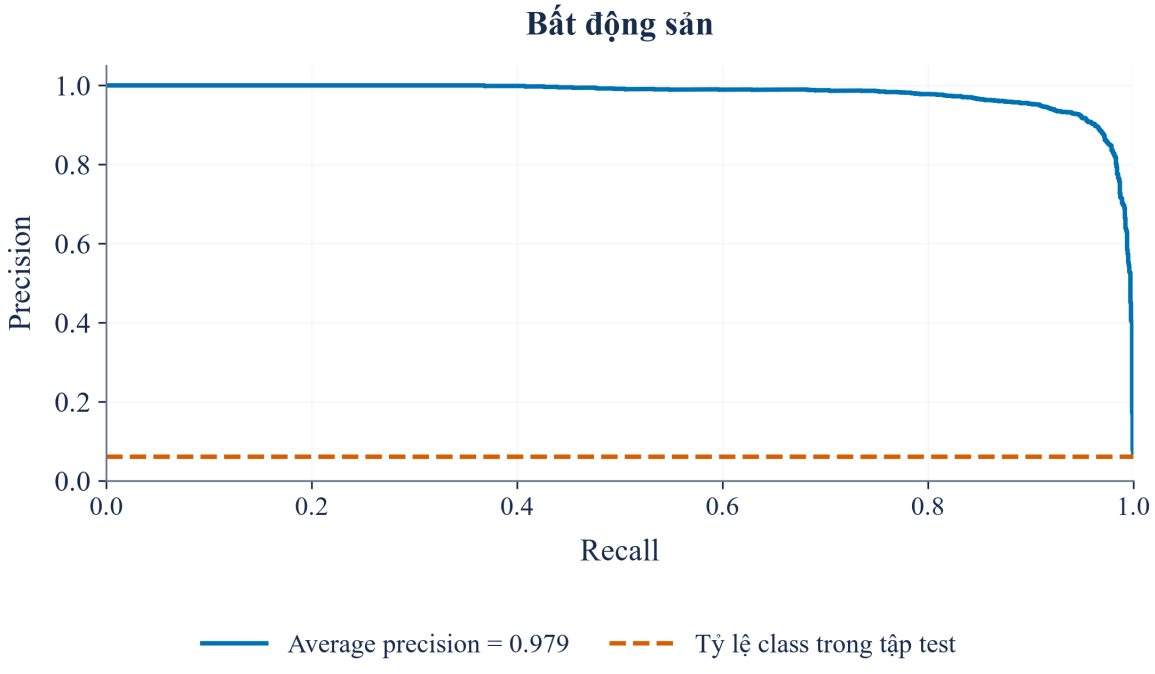
Mỗi class được xét một-chống-phần-còn-lại trên 29.995 mẫu test. Đường tham chiếu là prevalence; AP không phải F1 ở quyết định đa lớp. Các hình giữ nguyên output notebook, không ghép nhiều class thành một ảnh.

A.6.1 ID 0: Bạn đọc



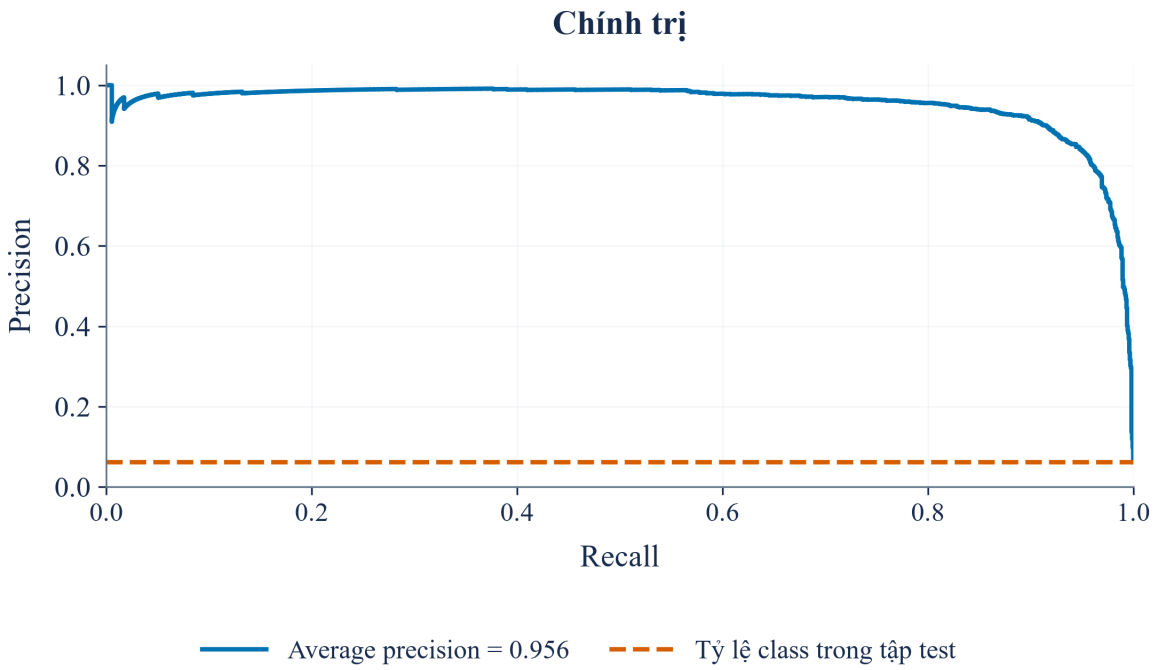
Hình A.4: Precision–Recall của Bạn đọc, trên test độc lập.

A.6.2 ID 1: Bất động sản



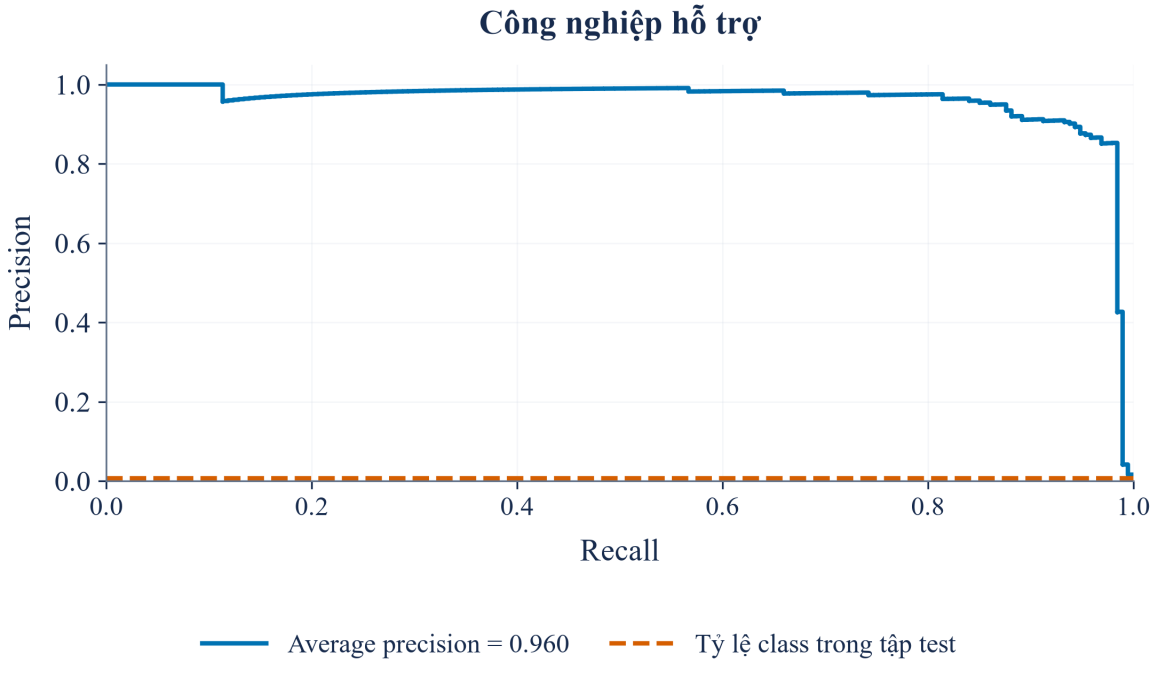
Hình A.5: Precision–Recall của Bất động sản, trên test độc lập.

A.6.3 ID 2: Chính trị



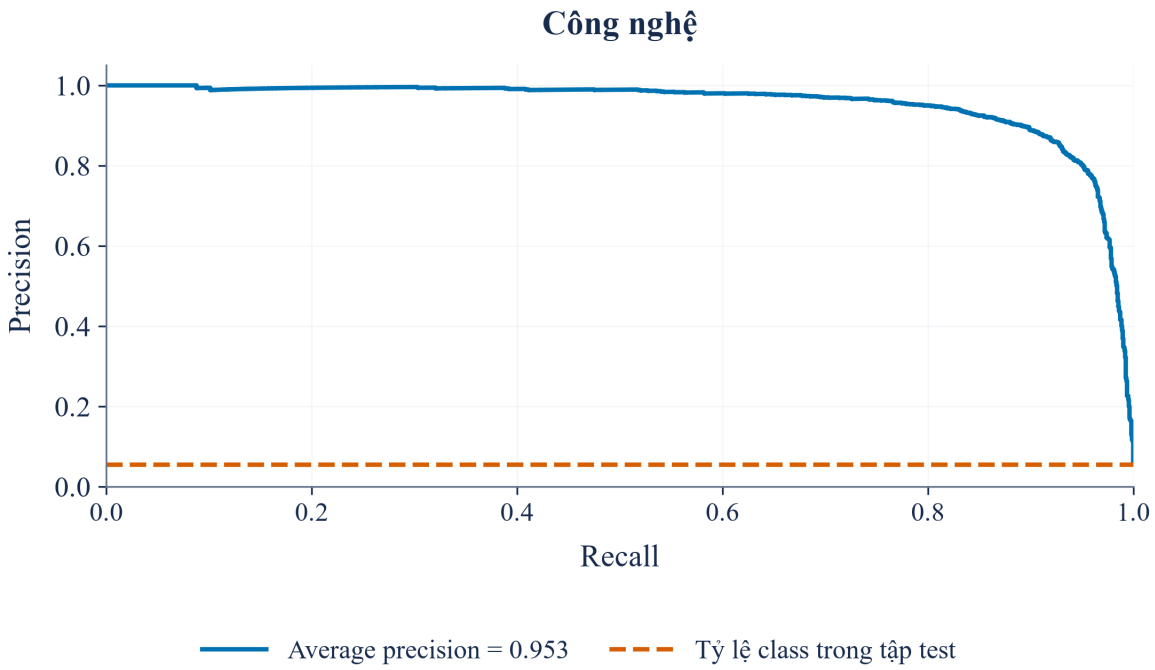
Hình A.6: Precision–Recall của Chính trị, trên test độc lập.

A.6.4 ID 3: Công nghiệp hỗ trợ



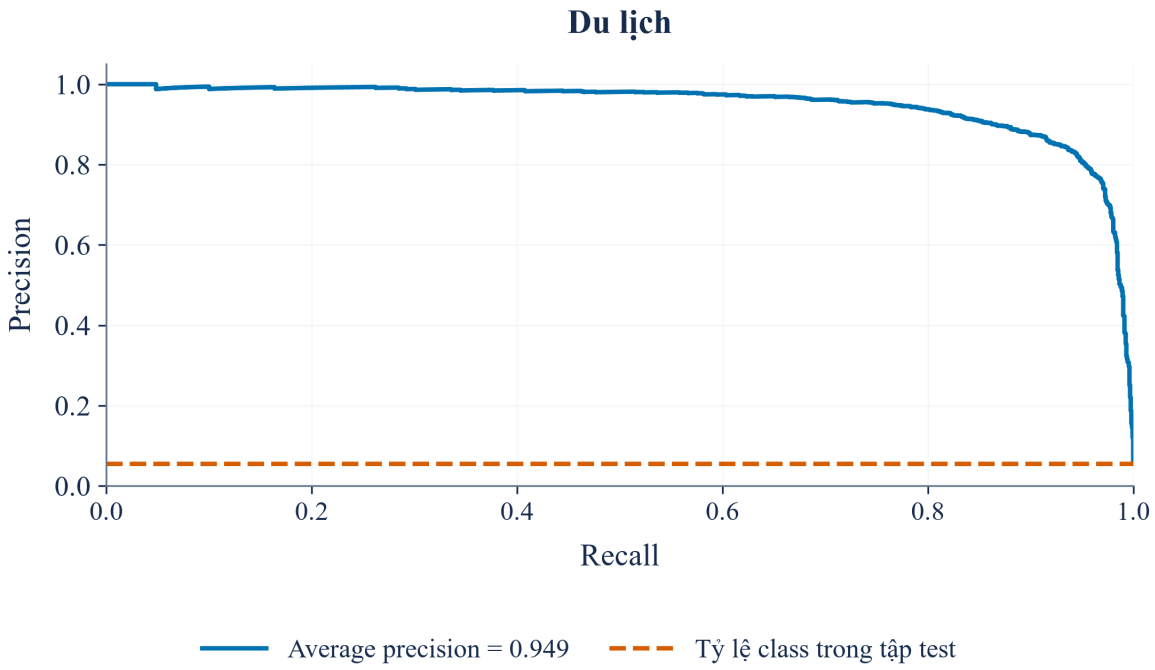
Hình A.7: Precision–Recall của Công nghiệp hỗ trợ, trên test độc lập.

A.6.5 ID 4: Công nghệ



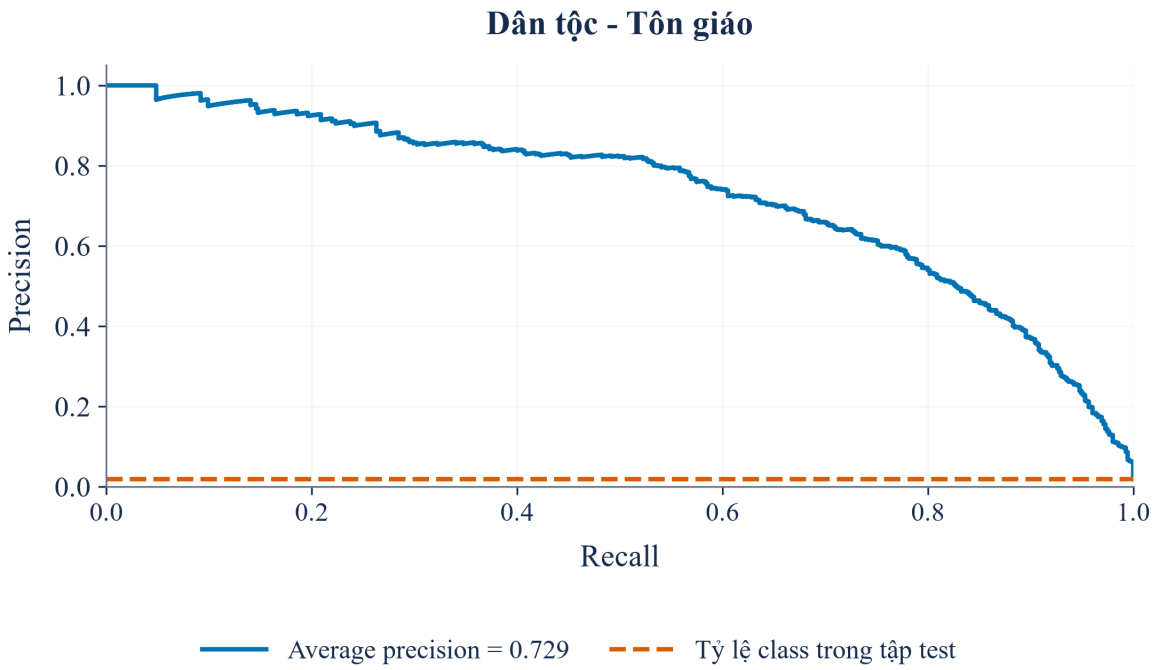
Hình A.8: Precision–Recall của Công nghệ, trên test độc lập.

A.6.6 ID 5: Du lịch



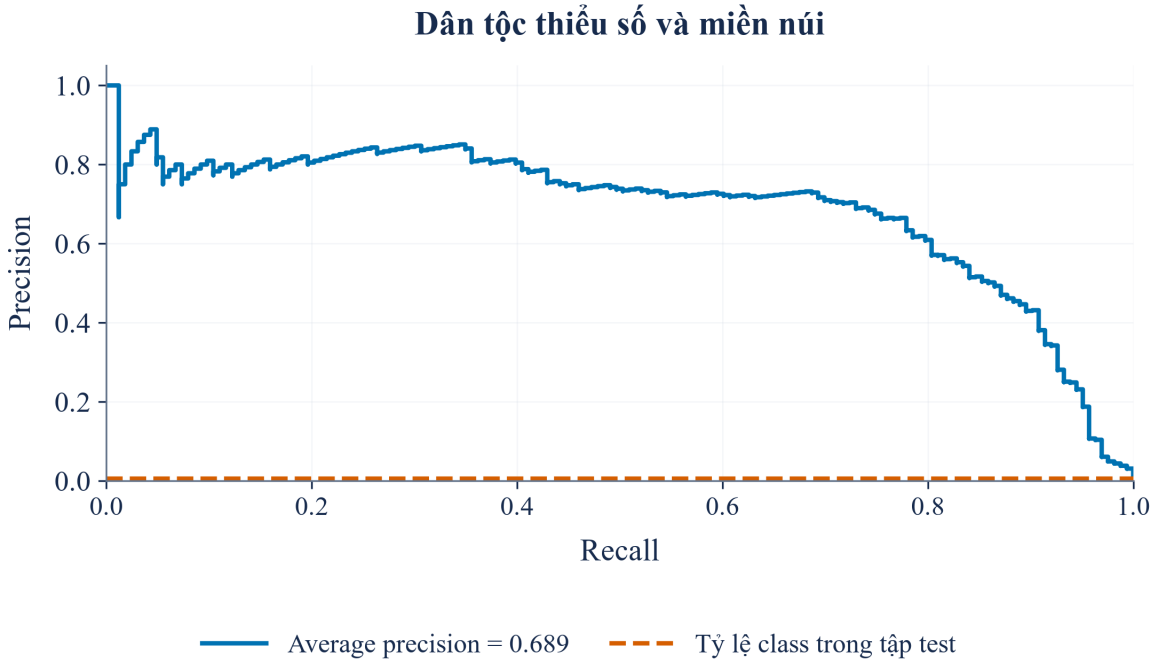
Hình A.9: Precision–Recall của Du lịch, trên test độc lập.

A.6.7 ID 6: Dân tộc - Tôn giáo



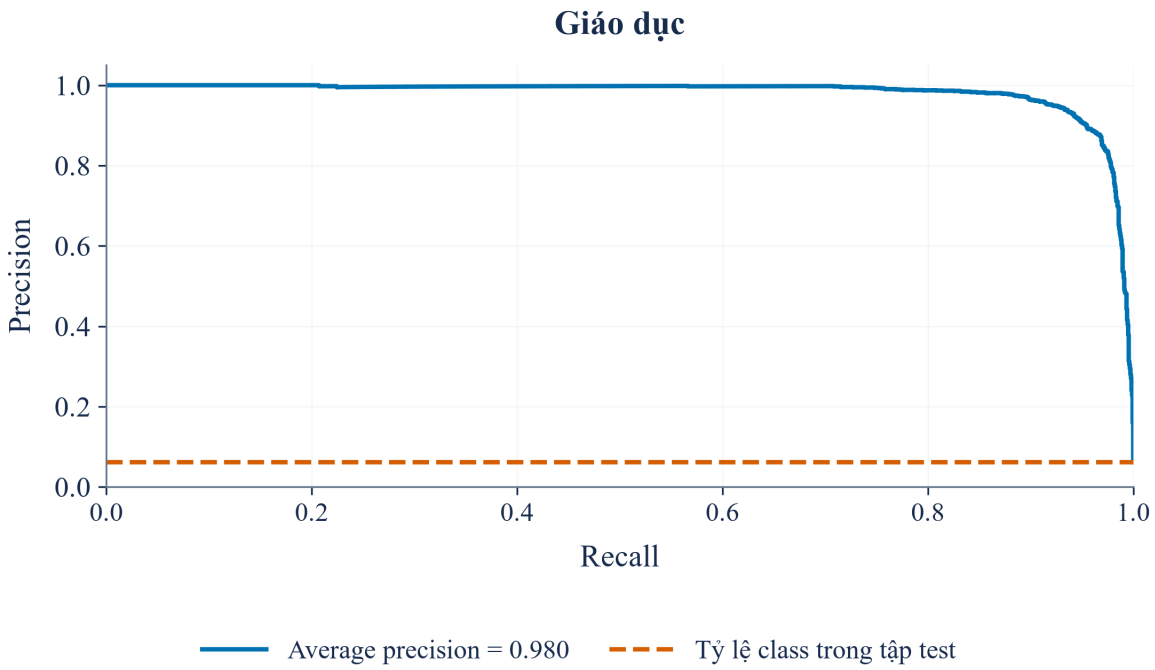
Hình A.10: Precision–Recall của Dân tộc - Tôn giáo, trên test độc lập.

A.6.8 ID 7: Dân tộc thiểu số và miền núi



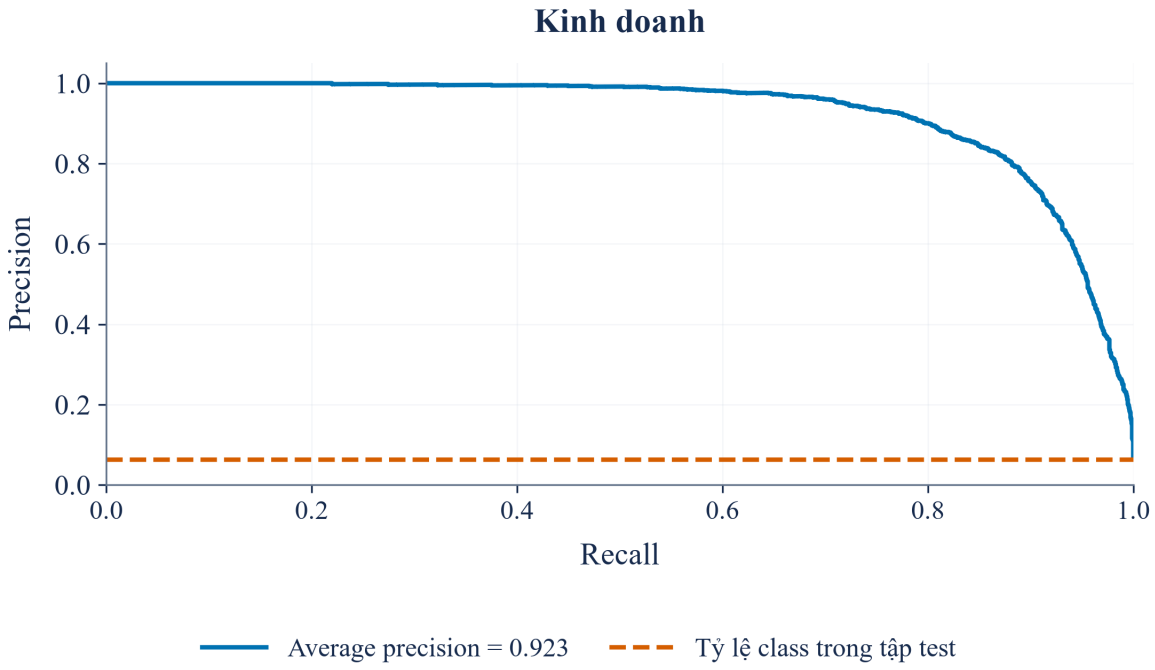
Hình A.11: Precision–Recall của Dân tộc thiểu số và miền núi, trên test độc lập.

A.6.9 ID 8: Giáo dục



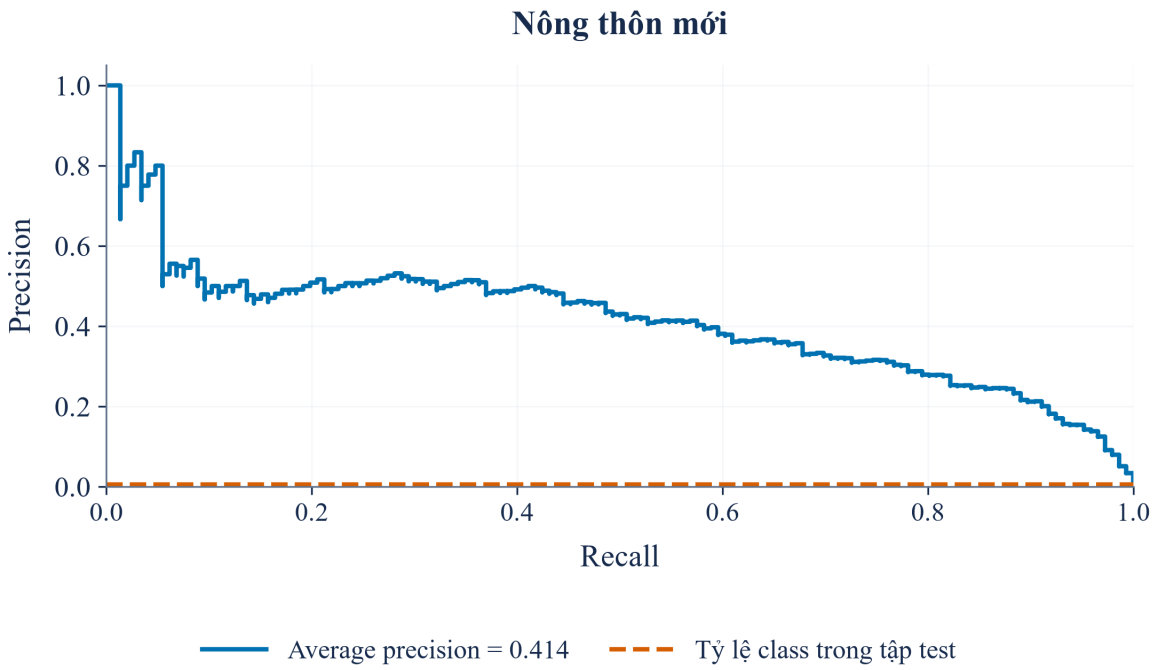
Hình A.12: Precision–Recall của Giáo dục, trên test độc lập.

A.6.10 ID 9: Kinh doanh



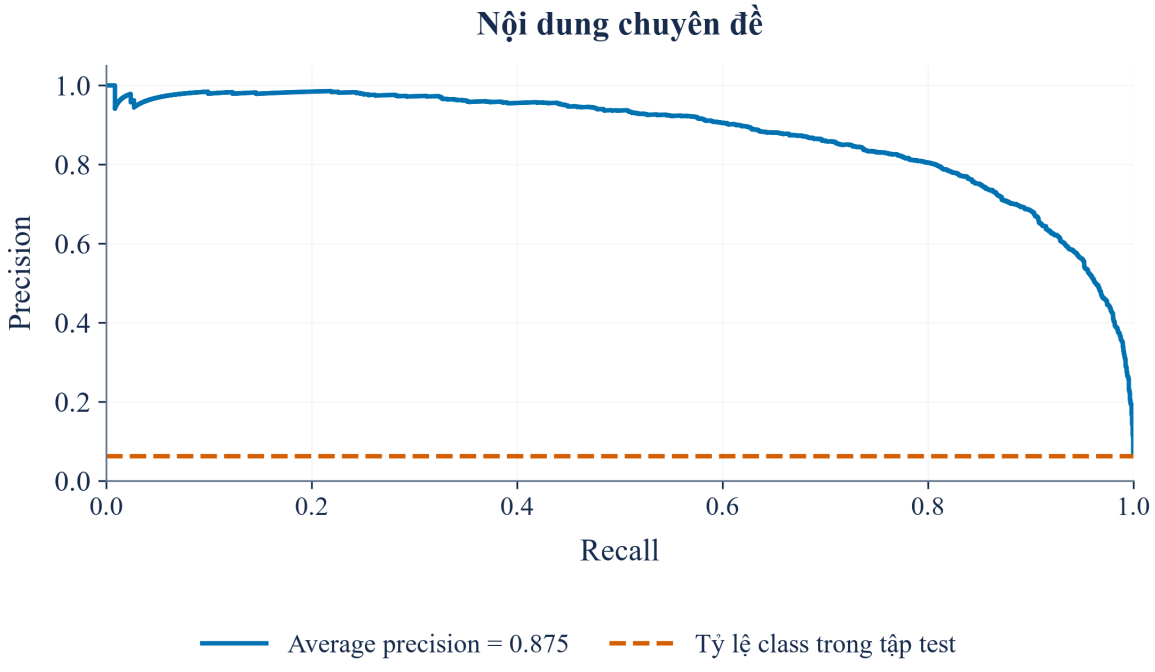
Hình A.13: Precision–Recall của Kinh doanh, trên test độc lập.

A.6.11 ID 10: Nông thôn mới



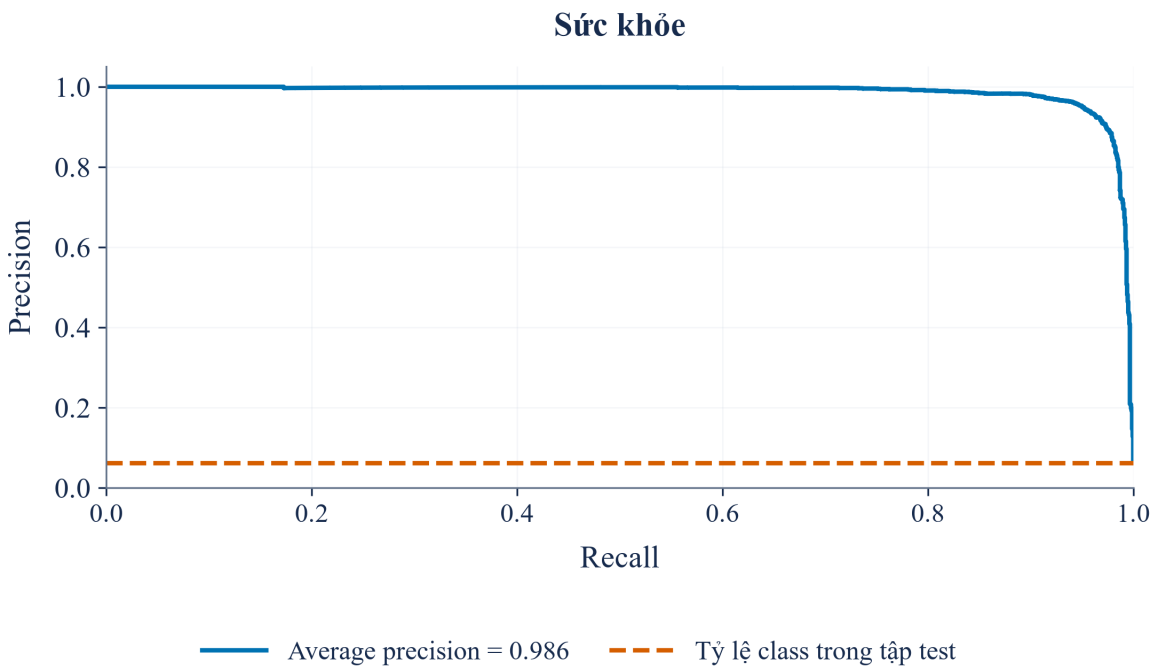
Hình A.14: Precision–Recall của Nông thôn mới, trên test độc lập.

A.6.12 ID 11: Nội dung chuyên đề



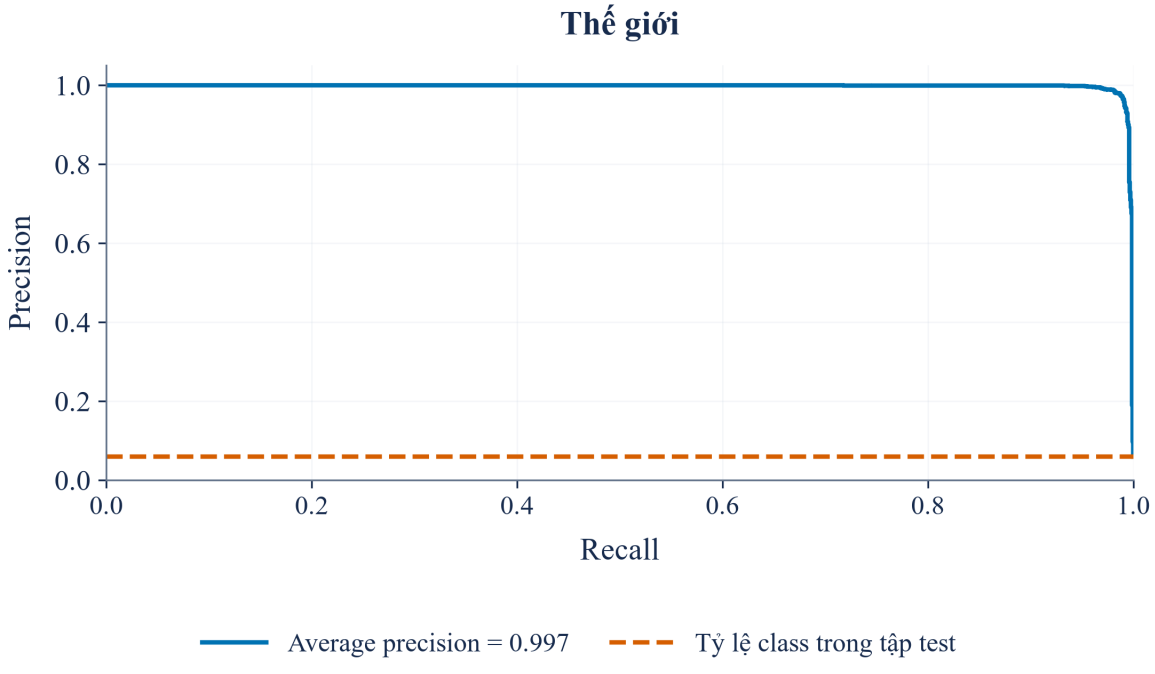
Hình A.15: Precision–Recall của Nội dung chuyên đề, trên test độc lập.

A.6.13 ID 12: Sức khỏe



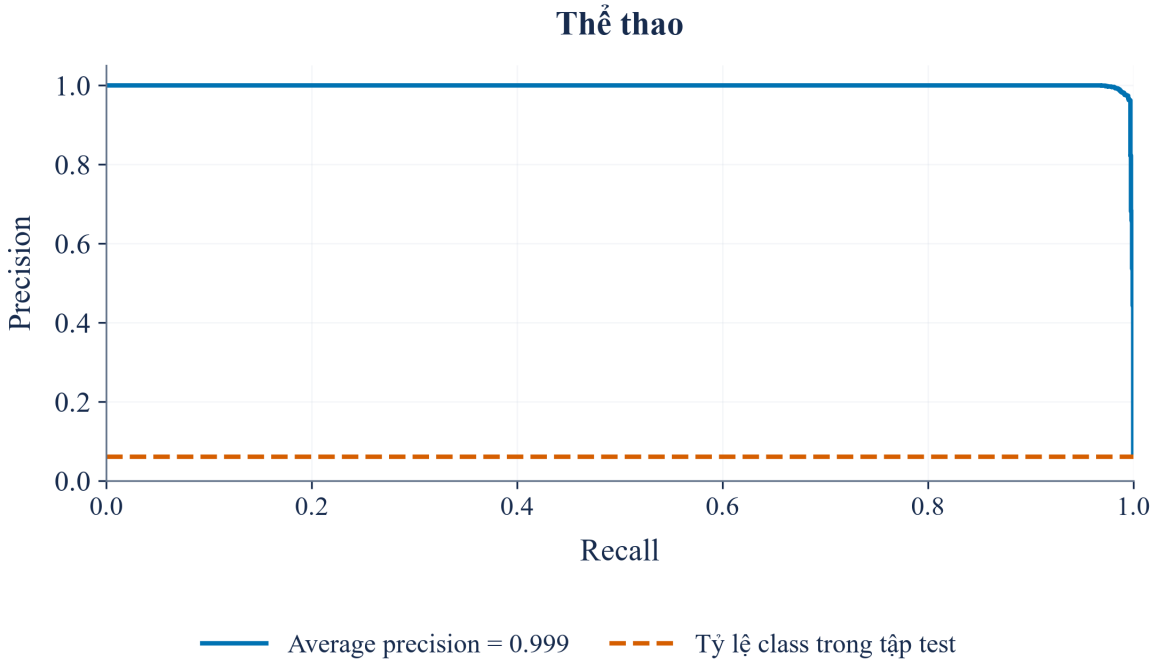
Hình A.16: Precision–Recall của Sức khỏe, trên test độc lập.

A.6.14 ID 13: Thế giới



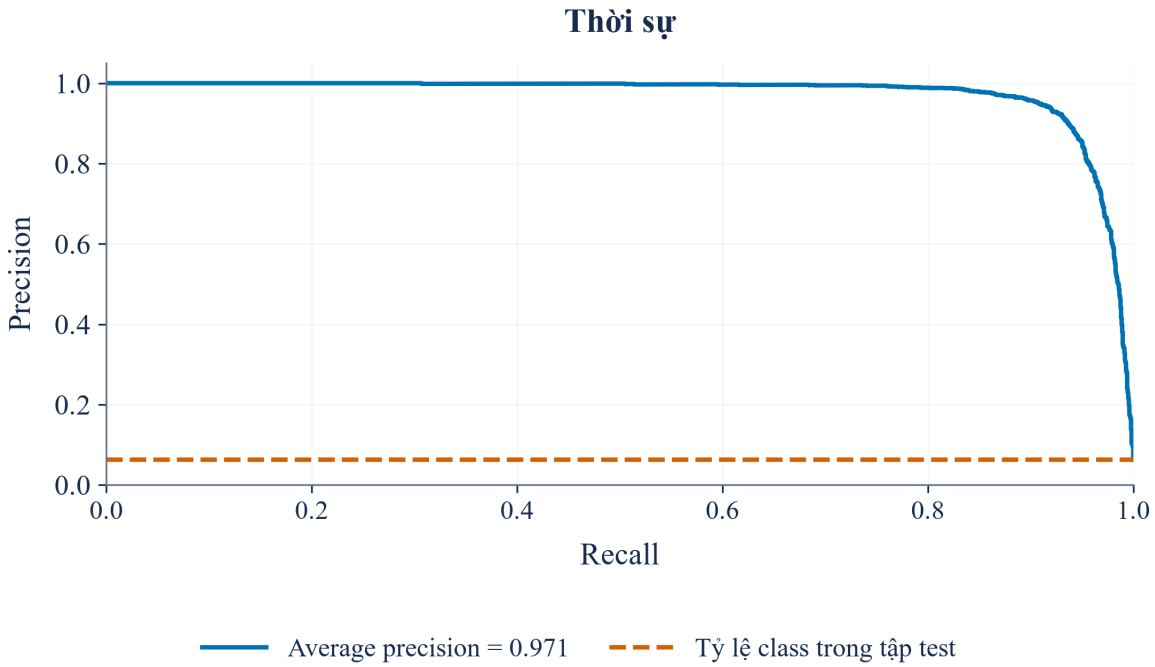
Hình A.17: Precision–Recall của Thế giới, trên test độc lập.

A.6.15 ID 14: Thể thao



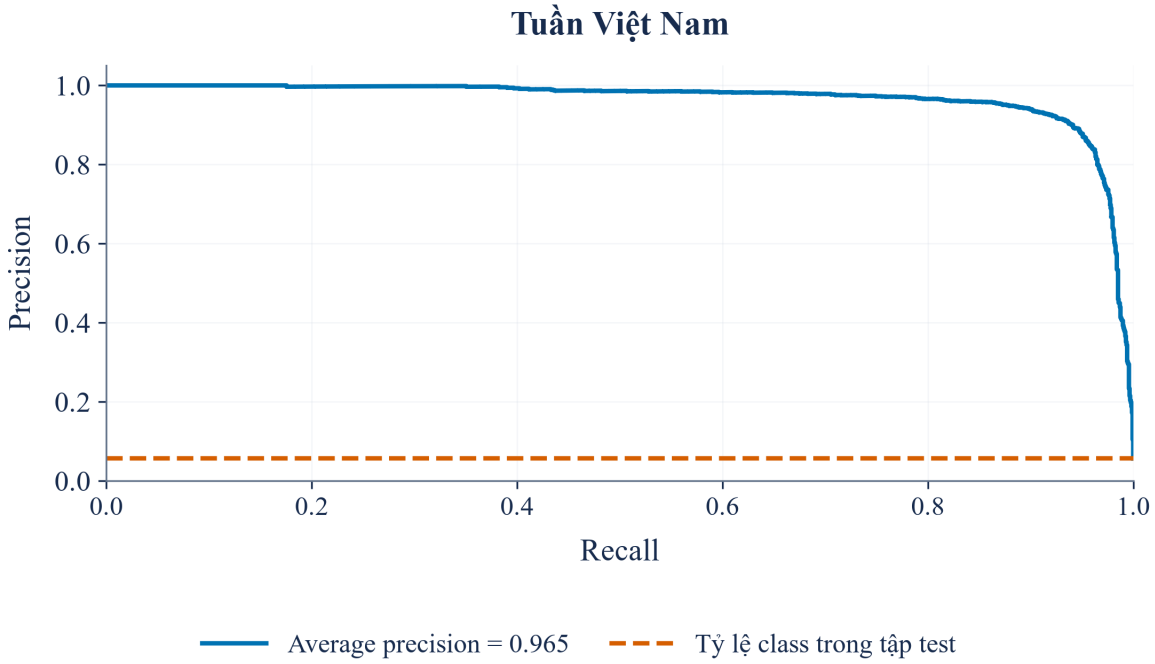
Hình A.18: Precision–Recall của Thể thao, trên test độc lập.

A.6.16 ID 15: Thời sự



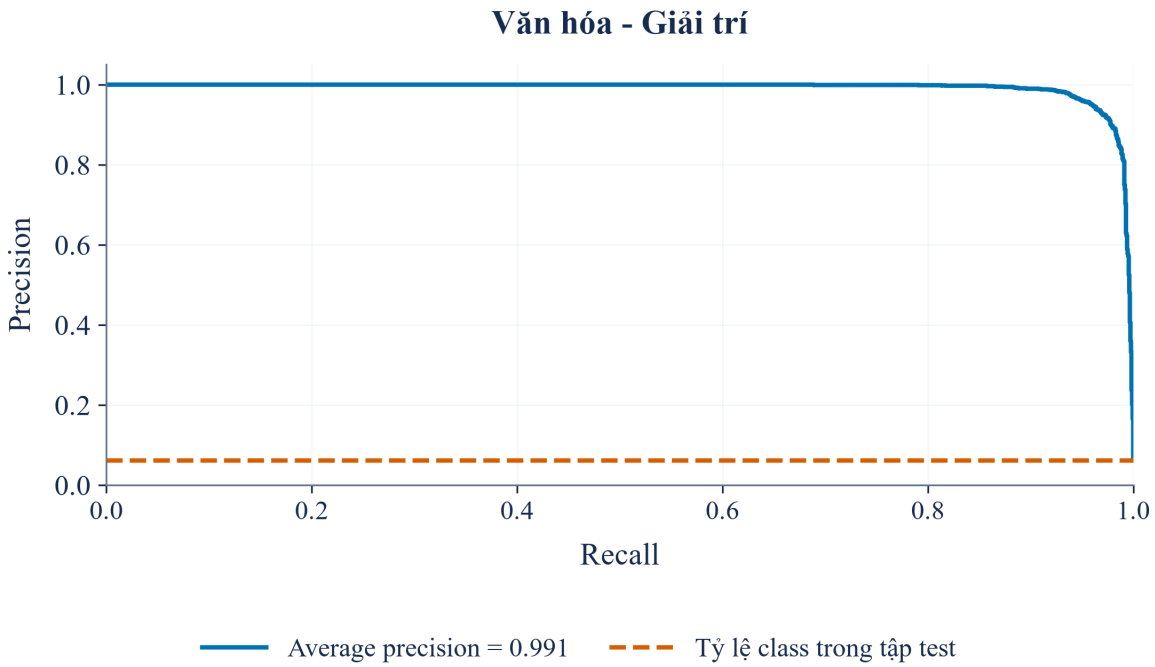
Hình A.19: Precision–Recall của Thời sự, trên test độc lập.

A.6.17 ID 16: Tuần Việt Nam



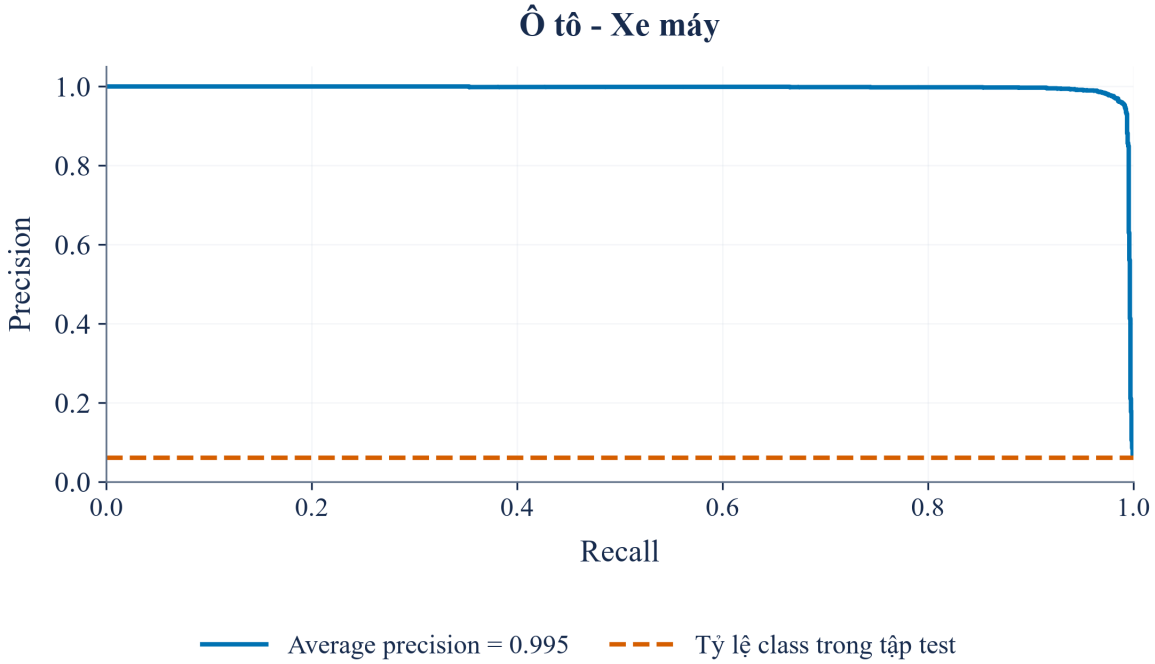
Hình A.20: Precision–Recall của Tuần Việt Nam, trên test độc lập.

A.6.18 ID 17: Văn hóa - Giải trí



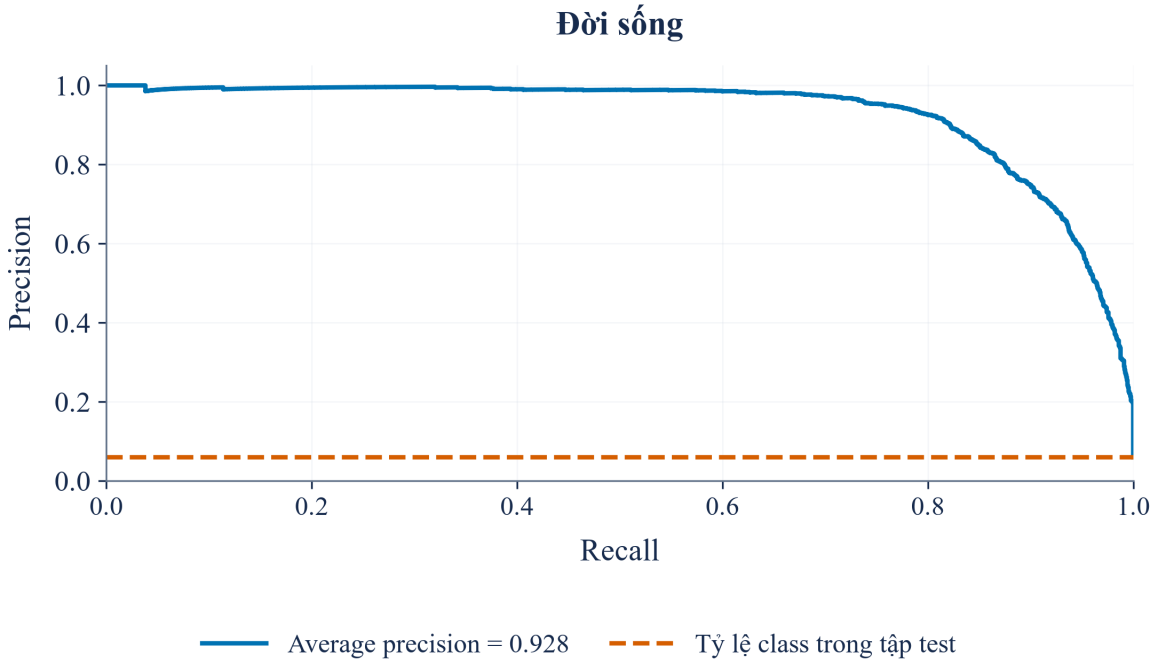
Hình A.21: Precision–Recall của Văn hóa - Giải trí, trên test độc lập.

A.6.19 ID 18: Ô tô - Xe máy



Hình A.22: Precision–Recall của Ô tô - Xe máy, trên test độc lập.

A.6.20 ID 19: Đời sống



Hình A.23: Precision–Recall của Đời sống, trên test độc lập.